

THÈSE PROFESSIONNELLE

**De la Business Intelligence descriptive aux systèmes
décisionnels AI-native : World Models, Ontologies et Decision
Intelligence**

Achir Charafeddine

Tuteur : Mr PIERANGELINI Gustavo

Mastère Spécialisé Big Data

Grenoble École de Management · Grenoble INP Ensimag

Année académique 2025–2026

*À maman,
ma source d'espoir et de motivation.*

*À papa,
dont les sacrifices, sans cesse, m'inspirent.*

*À ma sœur,
ma plus fidèle supportrice, tout en haut des gradins.*

Remerciements

La réalisation de cette thèse professionnelle doit beaucoup à celles et ceux qui l'ont accompagnée, et c'est avec sincérité que je souhaite les remercier.

Je tiens d'abord à exprimer ma gratitude à mon tuteur, Monsieur Gustavo Pierangelini, pour son encadrement, sa disponibilité et la justesse de ses conseils tout au long de ce travail.

Mes remerciements vont également à Madame Céline Roche Roussel, directrice de cette thèse et du programme Mastère Spécialisé Big Data, pour la confiance qu'elle m'a accordée et pour le cadre à la fois exigeant et stimulant qu'elle a su donner à cette formation.

Un mot tout particulier à Madame Virginie Monvoisin, dont l'accompagnement méthodologique a éclairé et guidé nos thèses, et dont les orientations ont nourri ce travail.

Je remercie chaleureusement mes camarades de promotion, pour leur soutien, leurs échanges et l'émulation qui a rendu ce parcours à la fois plus riche et plus léger.

Ma reconnaissance va enfin à toutes les personnes qui ont accepté de m'accorder un entretien, pour leur temps, leur franchise et la richesse de leurs témoignages, ainsi qu'à l'ensemble des répondants au questionnaire, sans qui le volet empirique de cette recherche n'aurait pas été possible.

À toutes et à tous, merci.

Résumé

Malgré des volumes de données sans précédent, la plupart des organisations restent cantonnées à une Business Intelligence descriptive, capable de constater ce qui s'est passé mais non d'en expliquer les causes, d'anticiper ou de recommander une action. Cette thèse professionnelle étudie la transition de ces systèmes vers des systèmes décisionnels dits AI-native, en articulant trois concepts encore rarement pensés ensemble : les world models organisationnels, les ontologies d'entreprise et la Decision Intelligence, sur un socle causal et une couche transversale de gouvernance.

Sur le plan théorique, ce travail propose un cadre intégré qui assemble ces briques en une architecture en couches, de la donnée gouvernée jusqu'à la décision augmentée. Ce cadre est ensuite confronté au terrain selon une approche mixte à triangulation convergente : une enquête par questionnaire (193 répondants) et neuf entretiens semi-directifs couvrant des profils techniques, business et métier.

Les résultats documentent une perception largement partagée des limites de la BI et soutiennent la cohérence ainsi que la pertinence perçue du cadre proposé, sans constituer une validation expérimentale de son architecture. Ils conduisent surtout à en réordonner fortement les priorités. La faisabilité d'un système décisionnel augmenté se joue bien moins dans la sophistication de l'intelligence artificielle que dans le socle organisationnel qui la porte : la donnée gouvernée et sa maintenance, la gouvernance, l'adoption et la confiance. Ce déplacement, que résume la formule emblématique d'un expert interrogé, « le problème est à quatre-vingts pour cent humain et vingt pour cent technique », invite à une transformation incrémentale plutôt qu'à un déploiement descendant : construire par cas d'usage, graduer l'autonomie du copilote au décideur, se prémunir contre le biais d'automatisation et maintenir la responsabilité humaine.

La thèse en tire six recommandations managériales et une feuille de route en trois horizons. Sa contribution est double : proposer une lecture intégrée d'un champ jusqu'ici cloisonné, et montrer, par le terrain, que le futur de la décision augmentée est d'abord un projet organisationnel et humain avant d'être un défi technologique.

Mots-clés : *Business Intelligence ; Decision Intelligence ; world models ; ontologie d'entreprise ; causalité ; systèmes décisionnels AI-native ; gouvernance de l'IA ; automation bias.*

Table des matières

Remerciements	3
Résumé	4
Table des matières	6
Liste des figures	10
Glossaire	10
Acronymes et abréviations	10
Glossaire des concepts clés	11
Introduction générale	14
Contexte et enjeux	14
Problématique	15
Question de recherche et sous-questions	15
Objectifs de la recherche	16
Aperçu méthodologique	16
Plan de la thèse	17
Partie I. Revue de littérature	18
Introduction	18
Chapitre 1. Les limites de la BI descriptive et le plafond de complexité décisionnelle	19
1.1 Genèse et rôle de la BI	20
1.2 L'échelle de maturité analytique	20
1.3 Le paradoxe de la donnée	21
1.4 Le « plafond de complexité décisionnelle »	22
1.5 Ce que la BI n'outille pas	22
Chapitre 2. Decision Intelligence : définition, architecture et reconnaissance institutionnelle	23
2.1 Origines et définition	23
2.2 Du data-centric au decision-centric	24
2.3 Reconnaissance institutionnelle	24
2.4 De la prédiction à l'action	25
Chapitre 3. World models organisationnels : du concept IA à la modélisation d'entreprise	25
3.1 Le world model en IA	26
3.2 État récent de la recherche	27
3.3 Transposition au contexte organisationnel	27
3.4 Le modèle ElixirData / Context OS	28
3.5 Capacités et verrous	29
Chapitre 4. L'Ontologie d'entreprise (modèle Palantir) : substrat industriel d'un world model décisionnel	30
4.1 De l'ontologie formelle à l'ontologie d'entreprise	30
4.2 Les quatre dimensions	31
4.3 L'architecture en trois couches	31
4.4 L'ontologie comme « digital twin » partagé	32
4.5 Le pont conceptuel	33
Chapitre 5. Causal AI, knowledge graphs et couches sémantiques	34

5.1 La hiérarchie causale de Pearl	35
5.2 Le théorème de la hiérarchie causale	36
5.3 Causal AI en entreprise	36
5.4 Knowledge graphs, ontologies formelles et Graph-RAG	37
5.5 Articulation	37
Chapitre 6. Agents IA, copilotes, signaux faibles et digital twins	38
6.1 Agents et copilotes décisionnels	38
6.2 Le digital twin organisationnel	39
6.3 Détection de signaux faibles	40
6.4 Autonomie graduée et confiance	40
6.5 Vers les conditions de possibilité	41
Chapitre 7. Vers un système décisionnel AI-native : le cadre intégré	41
7.1 Le geste d'assemblage	41
7.2 L'architecture en couches	42
7.3 La circulation : un exemple de bout en bout	44
7.4 Pourquoi le tout vaut plus que les parties	45
7.5 La gouvernance, une couche transversale	45
Chapitre 8. Éthique, gouvernance et réglementation	46
8.1 L'automation bias	46
8.2 Biais hérités et boucles de rétroaction	47
8.3 Le cadre réglementaire européen	47
8.4 Standards de gouvernance	48
8.5 Transparence, explicabilité et jugement humain	48
Conclusion de la Partie I	49
Partie II. Étude empirique	51
Chapitre 9. Méthodologie de recherche	51
9.1 Positionnement épistémologique et design mixte	51
9.2 Justification de la triangulation convergente	51
9.3 Volet quantitatif : instrument, population, échantillon et plan d'analyse	52
9.4 Volet qualitatif : guide décliné en deux versions, profils et analyse thématique	53
9.5 Considérations éthiques et conformité RGPD	55
9.6 Limites méthodologiques	55
Chapitre 10. Résultats de l'enquête quantitative	56
10.1 Profil de l'échantillon	56
10.2 La perception des limites de la BI : un plafond largement partagé	57
10.3 Un fort appétit pour les capacités augmentées	59
10.4 Confiance, transparence et automation bias : le paradoxe du décideur	59
10.5 Structure des attitudes et corrélations	60
10.6 Ce qui distingue, et ce qui ne distingue pas, les répondants	62
10.7 Gouvernance et responsabilité perçue	63
10.8 Synthèse et limites	64
Chapitre 11. Résultats des entretiens qualitatifs	65
11.1 Corpus, profils et démarche d'analyse	65
11.2 Le plafond décisionnel, une expérience unanime	66

11.3 « 80 % humain, 20 % technique » : où se joue vraiment la faisabilité	66
11.4 Représenter l'entreprise : world model et ontologie à l'épreuve du terrain	67
11.5 Décider avec l'IA : l'autonomie graduée et le refus de la boîte noire	68
11.6 Le piège du « contrôle humain de façade »	69
11.7 Transparence, responsabilité et conditions organisationnelles	70
11.8 Convergences, divergences et verdict de faisabilité	71
Partie III. Discussion et contributions	75
Chapitre 12. Synthèse croisée et modèle intégré	75
12.1 Le principe de la synthèse croisée	75
12.2 Convergences : ce que les deux volets établissent ensemble	76
12.3 Ce que le qualitatif explique du quantitatif	76
12.4 Réponses aux quatre sous-questions de recherche	77
12.5 Le modèle intégré, révisé par le terrain	78
12.6 Contributions théoriques	79
Chapitre 13. Recommandations managériales et conditions de la transformation	80
13.1 Des principes aux leviers d'action	80
13.2 Six recommandations managériales	81
13.3 Une feuille de route en trois horizons	82
13.4 Facteurs de succès et pièges à éviter	83
13.5 Portée et limites des recommandations	84
Conclusion générale	84
Synthèse des contributions	85
Limites de la recherche	86
Perspectives de recherche	87
Le mot de la fin	87
Bibliographie	88
Annexes	92
Liste des annexes	92
Annexe A. Questionnaire de l'enquête quantitative	92
Profil du répondant	92
Usage des outils de BI	92
Perception des limites de la BI actuelle (items Likert 1 à 5)	92
Valeur perçue des capacités augmentées (items Likert 1 à 5)	93
Confiance, transparence et éthique (items Likert 1 à 5)	93
Perceptions sur la gouvernance (questions fermées)	93
Entretien de suivi	94
Annexe B. Guides d'entretien semi-directifs	94
B.1 Guide d'entretien, version métier (profils décideurs et fonctionnels)	94
B.2 Guide d'entretien, version technique (data scientists, AI engineers)	97
Annexe C. Grille de codage de l'analyse thématique	100
C.1 Codes déductifs (issus du cadre conceptuel)	101
C.2 Codes émergents (issus du terrain)	101
Annexe D. Formulaire de consentement	101
Annexe E. Transcriptions intégrales des entretiens	103

E.1 Entretien T1. Directeur de programme IA, protection sociale (ProBTP)	103
E.2 Entretien T2. Architecte logiciel et IA senior, solutions pour le voyage (Amadeus)	109
E.3 Entretien T3. Fondateur et CEO, société deep-tech (TechnoLynx)	113
E.4 Entretien BA1. Directeur Market Intelligence, équipements de la maison (Somfy)	120
E.5 Entretien BA2. Business Analyst / Solutions Architect, e-commerce (Amazon)	124
E.6 Entretien M1. Directrice crédit et recouvrement, Green IT (Evernex)	128
E.7 Entretien M2. Contrôleuse de gestion senior, distribution automobile (RRG)	132
E.8 Entretien M3. Digital Product Manager, transport aérien (Air France)	137
E.9 Entretien M4. Ingénieur calcul et QSSE, sidérurgie (ArcelorMittal)	142

Liste des figures

Figure 1. L'échelle de maturité analytique et le blocage des organisations aux niveaux inférieurs.	21
Figure 2. L'ontologie d'entreprise de Palantir : quatre dimensions et trois couches.	32
Figure 3. L'échelle de la causalité de Pearl : les trois barreaux du raisonnement causal.	35
Figure 4. Architecture en couches d'un système décisionnel AI-native.	43
Figure 5. Le design de recherche à triangulation convergente.	52
Figure 6. Distribution des réponses aux 18 items, regroupés par thème (n = 193).	58
Figure 7. Matrice des corrélations de Pearson entre les 18 items.	61
Figure 8. Deux différences significatives entre sous-groupes (barres d'erreur : erreur-type).	63
Figure 9. Responsabilité perçue et convictions sur la gouvernance de l'IA décisionnelle.	64
Figure 10. Matrice de convergence thématique selon le profil des personnes interrogées.	72
Figure 11. L'architecture d'un système décisionnel AI-native à l'épreuve du terrain : verdict de faisabilité par couche.	73
Figure 12. Le modèle intégré révisé : le réordonnancement des priorités opéré par le terrain.	79
Figure 13. Feuille de route de la transformation décisionnelle en trois horizons.	83

Glossaire

Acronymes et abréviations

Sigle	Signification
ACP	Analyse en composantes principales (en anglais, PCA)
AGI	Intelligence artificielle générale (Artificial General Intelligence)
AI Act	Règlement (UE) 2024/1689 établissant des règles harmonisées sur l'IA
BFR	Besoin en fonds de roulement
BI	Business Intelligence (informatique décisionnelle)
CDO / CTO	Chief Data Officer / Chief Technology Officer
CNIL	Commission nationale de l'informatique et des libertés
COMEX	Comité exécutif
CRM	Customer Relationship Management (gestion de la relation client)
DAG	Graphe orienté acyclique (Directed Acyclic Graph)

DI	Decision Intelligence (intelligence de la décision)
ERP	Enterprise Resource Planning (progiciel de gestion intégré)
Graph-RAG	Génération augmentée par récupération sur graphe de connaissances
IA	Intelligence artificielle
ISO/IEC 42001	Norme internationale de système de management de l'IA
JEPA	Joint Embedding Predictive Architecture (architecture de world model, LeCun)
KPI	Indicateur clé de performance (Key Performance Indicator)
LIME / SHAP	Méthodes d'explicabilité post-hoc des modèles
LLM	Grand modèle de langage (Large Language Model)
MES	Manufacturing Execution System (système d'exécution de la production)
ML	Apprentissage automatique (Machine Learning)
NIST AI RMF	AI Risk Management Framework du NIST
QSSE	Qualité, Sécurité, Santé, Environnement
RAG	Génération augmentée par récupération (Retrieval-Augmented Generation)
RGPD	Règlement général sur la protection des données
ROI	Retour sur investissement (Return on Investment)
SI	Système d'information
TCO	Coût total de possession (Total Cost of Ownership)
XAI	IA explicable (eXplainable AI)

Glossaire des concepts clés

Abstention (ou calibration) : Capacité d'un système à reconnaître son incertitude, à signaler qu'il ne sait pas et à escalader vers un humain plutôt que de répondre à tort. Érigée dans la thèse en critère central de confiance.

AI-native (système décisionnel) : Système conçu, dès l'origine, autour de l'IA et de la décision, par opposition à une BI descriptive à laquelle on ajoute de l'IA après coup.

Automation bias (biais d'automatisation) : Tendance humaine à suivre les recommandations d'un outil sans les remettre en question, par excès de confiance, fatigue ou surcharge.

Autonomie graduée : Principe consistant à calibrer le degré d'autonomie d'un système selon la réversibilité, l'enjeu et le volume de la décision.

Boucle d'apprentissage : Cycle par lequel le résultat réel d'une décision est mesuré puis réinjecté pour améliorer le système, maillon absent de la BI classique.

Business Intelligence (BI) : Ensemble des outils de reporting et de visualisation servant à décrire ce qui s'est passé (tableaux de bord, analyses dimensionnelles).

Causal AI / inférence causale : Méthodes visant à distinguer corrélation et causalité et à estimer l'effet d'une action (do-calculus, contrefactuels, uplift).

Contrefactuel : Raisonement sur ce qui se serait produit si les conditions avaient été différentes ; troisième barreau de la hiérarchie de Pearl.

Contrôle humain de façade : Anti-pattern où un humain est censé valider les décisions mais, submergé par le volume, se contente de les tamponner.

Copilote décisionnel : Assistant IA qui propose des analyses et des recommandations sans prendre la décision à la place de l'humain.

Decision Intelligence (DI) : Discipline plaçant la décision (et non la donnée) au centre, couvrant tout son cycle, du cadrage à l'apprentissage (Kozyrkov).

Digital twin (jumeau numérique) : Réplique virtuelle et vivante d'un actif ou d'une organisation, permettant d'en simuler le comportement.

Do-calculus : Formalisme de Judea Pearl permettant de raisonner sur les interventions à partir d'un modèle causal explicite.

Drift (dérive) : Évolution progressive de la distribution des données qui dégrade silencieusement la pertinence d'un modèle.

Échelle de maturité analytique : Progression descriptif → diagnostique → prédictif → prescriptif, à valeur et difficulté croissantes.

Hiérarchie causale de Pearl : Trois niveaux de questions : association (voir), intervention (faire), contrefactuel (imaginer).

Knowledge graph (graphe de connaissances) : Représentation d'entités et de relations typées, substrat de la couche sémantique et de l'ontologie.

Ontologie d'entreprise : Carte partagée reliant les données de l'entreprise aux concepts métier, aux actions et à la sécurité (modèle Palantir : dimensions Data, Logic, Action, Security ; couches sémantique, cinétique, dynamique).

Plafond de complexité décisionnelle : Concept central de la thèse : point à partir duquel la BI descriptive cesse de soutenir la décision, non par manque de données mais par nature.

Prescriptif : Niveau de maturité le plus élevé, où le système recommande, voire optimise, une action.

Signaux faibles : Indices précoces et ambigus d'un changement, en deçà du seuil des indicateurs classiques (Ansoff).

Triangulation convergente : Design de recherche mixte croisant les résultats quantitatifs et qualitatifs lors de l'interprétation.

Uplift modeling : Estimation de l'effet incrémental réel d'une action (l'action a-t-elle changé le comportement, ou serait-il survenu de toute façon).

World model (modèle du monde) : Représentation interne modélisant la dynamique d'un environnement et les conséquences des actions (LeCun) ; transposé à l'entreprise, il en simule le fonctionnement (world model organisationnel).

Introduction générale

Contexte et enjeux

Les organisations contemporaines vivent un paradoxe. Jamais elles n'ont accumulé autant de données, ni disposé d'autant d'outils pour les stocker, les nettoyer et les visualiser ; et pourtant, au moment de décider, elles restent largement tributaires de l'intuition, de l'expérience et de quelques experts surchargés. Ce décalage se lit dans les modèles de maturité analytique, qui étagent les usages de la donnée du descriptif au prescriptif (Davenport & Harris, 2007) : la grande majorité des entreprises demeurent bloquées aux niveaux inférieurs, et selon Gartner (2018), à peine 13 % atteignent le stade prescriptif. La Business Intelligence classique, conçue pour produire une lecture fiable du passé, excelle à dire ce qui s'est passé, mais peine à expliquer pourquoi, à anticiper ce qui va suivre et, plus encore, à recommander ce qu'il convient de faire.

Dans le même temps, l'intelligence artificielle connaît une accélération spectaculaire. Au-delà des grands modèles de langage et des agents désormais familiers, une transformation plus profonde se dessine, portée par trois courants convergents : les world models, ces représentations internes du fonctionnement d'un environnement issues de la recherche fondamentale (LeCun, 2022) ; les ontologies d'entreprise, dont l'industrialisation par des plateformes comme Palantir offre une carte partagée entre humains et machines ; et la Decision Intelligence, qui propose de replacer la décision, et non la donnée, au centre du dispositif (Kozyrkov, 2019). La reconnaissance institutionnelle de ce marché, avec le premier Magic Quadrant dédié à la Decision Intelligence publié en janvier 2026, et la structuration d'un cadre réglementaire exigeant, avec l'AI Act européen, confirment que le sujet n'est ni marginal ni prématuré. Il faut toutefois rappeler ce qu'un tel classement établit : l'existence d'une catégorie commerciale et la position relative de ses fournisseurs, non la validité scientifique d'une architecture décisionnelle.

L'enjeu est double. Sur le plan académique, ces champs sont traités de manière cloisonnée : le concept de world model n'a que très peu été transposé au contexte organisationnel, et l'ontologie d'entreprise, largement documentée dans la littérature technique, n'a guère fait l'objet d'analyses académiques approfondies. Sur le plan managérial, le coût du plafond décisionnel est considérable, en décisions

sous-optimales, en temps d'analyse et en dépendance aux experts, tandis que les organisations doivent simultanément décider mieux et garantir transparence, responsabilité et conformité.

Problématique

Le point de départ de cette recherche est donc un constat précis : la Business Intelligence descriptive bute sur ce que Pratt et Zangari (2008) ont nommé le plafond de complexité décisionnelle (decision complexity ceiling), un point à partir duquel elle cesse de soutenir la décision, non par manque de données, mais par la nature même de son outillage. Ce concept n'est donc pas une création de ce travail : il est emprunté aux fondateurs de la Decision Intelligence, et la contribution proposée ici consiste à l'articuler avec les ontologies d'entreprise, les world models et le raisonnement causal, puis à en éprouver la portée empirique. La question devient alors de savoir si, et à quelles conditions, la convergence de ces briques peut franchir ce plafond et faire évoluer les systèmes décisionnels vers une intelligence explicative, anticipative et stratégiquement exploitable.

Cette problématique comporte deux versants indissociables. Un versant *conceptuel* d'abord : ces briques, jusqu'ici pensées séparément, forment-elles une architecture cohérente, et laquelle ? Un versant *empirique* ensuite, tout aussi décisif dans un domaine saturé de promesses : cette architecture est-elle réellement faisable, et qu'en disent celles et ceux qui, sur le terrain, la construisent, la financent ou la subiraient ? C'est la tension entre l'élégance d'un cadre théorique et l'épreuve de sa faisabilité qui structure l'ensemble de ce travail.

Question de recherche et sous-questions

Question principale. Comment les systèmes décisionnels d'entreprise peuvent-ils évoluer d'un rôle de visualisation descriptive vers une intelligence explicative, anticipative et stratégiquement exploitable, en s'appuyant sur les world models organisationnels, les ontologies d'entreprise et la Decision Intelligence ?

SQ1 (Diagnostic) : limites structurelles de la BI descriptive et « plafond de complexité décisionnelle ».

SQ2 (Architecture) : intégration des world models, ontologies et raisonnement causal en un système décisionnel AI-native.

SQ3 (Conditions de possibilité) : conditions organisationnelles, culturelles et techniques de la transformation.

SQ4 (Éthique et gouvernance) : transparence, responsabilité et jugement humain dans un cadre réglementaire en structuration.

Objectifs de la recherche

À ces questions répondent quatre objectifs. Le premier est de *caractériser* le plafond de complexité décisionnelle, en articulant la littérature et le retour d'expérience des praticiens, afin d'établir l'écart entre les capacités des systèmes actuels et les besoins réels de la décision. Le deuxième, cœur de la contribution théorique, est de *formaliser* le lien entre world model, ontologie, raisonnement causal et Decision Intelligence, et de le proposer comme architecture d'un système décisionnel AI-native. Le troisième est d'*éprouver* ce cadre sur le terrain, pour en évaluer la faisabilité et identifier les conditions organisationnelles, culturelles et techniques de sa mise en œuvre. Le quatrième, enfin, est d'en *tirer les implications* éthiques, de gouvernance et managériales, sous la forme de recommandations opérationnelles. La thèse vise ainsi à la fois une contribution conceptuelle, un cadre intégré, et une contribution pratique, un guide d'action fondé sur les preuves rassemblées.

Aperçu méthodologique

L'approche retenue est mixte, à triangulation convergente : les résultats d'une enquête quantitative et d'entretiens qualitatifs, analysés séparément, sont mis en dialogue au moment de l'interprétation. Le volet quantitatif repose sur un questionnaire structuré (voir Annexe A), qui a recueilli 193 réponses de professionnels impliqués dans la décision fondée sur les données. Le volet qualitatif s'appuie sur neuf entretiens semi-directifs conduits à partir de guides déclinés en deux versions, métier et technique (voir Annexe B), couvrant des profils techniques, business et métier. L'analyse qualitative suit une grille de codage thématique (voir Annexe C), selon la méthode de Braun et Clarke (2006), et le recueil des données respecte un protocole de consentement conforme au RGPD (voir Annexe D). Ce dispositif, détaillé au chapitre 9, permet de mesurer la prévalence des phénomènes tout en éclairant les mécanismes et les conditions qui les sous-tendent.

Plan de la thèse

Le travail se déploie en trois parties. La *Partie I* établit le cadre conceptuel : elle diagnostique les limites de la BI descriptive (chapitre 1), introduit la Decision Intelligence (chapitre 2), puis les deux piliers de la contribution que sont les world models (chapitre 3) et l'ontologie d'entreprise (chapitre 4), avant d'exposer le socle causal et sémantique (chapitre 5) et les systèmes qui l'incarnent, agents, copilotes et jumeaux numériques (chapitre 6). Le chapitre 7 assemble ces briques en une architecture intégrée en couches, et le chapitre 8 pose l'éthique et la gouvernance comme sa condition de possibilité.

La *Partie II* est empirique. Elle précise la méthodologie mixte (chapitre 9), puis présente les résultats de l'enquête quantitative (chapitre 10) et ceux des entretiens qualitatifs (chapitre 11), ce dernier confrontant directement le cadre théorique à la question de sa faisabilité. La *Partie III* opère la synthèse : le chapitre 12 croise les deux volets, répond aux sous-questions et propose un modèle intégré révisé par le terrain, tandis que le chapitre 13 en tire des recommandations managériales et une feuille de route. La conclusion générale récapitule les contributions, reconnaît les limites du travail et ouvre des perspectives de recherche.

Partie I. Revue de littérature

Introduction

Toute cette thèse tient dans un écart. D'un côté, des organisations submergées de données et d'outils ; de l'autre, des décisions qui continuent de reposer sur l'intuition, l'expérience et quelques experts surchargés. Comprendre cet écart oblige à convoquer des littératures qui se parlent rarement. Cette revue en réunit six.

La première interroge les limites de la Business Intelligence classique et la maturité analytique des organisations (chapitre 1). La deuxième introduit la *Decision Intelligence*, qui propose de remettre la décision, et non la donnée, au centre du jeu (chapitre 2). Les deux suivantes forment le cœur de la contribution : les *world models* organisationnels (chapitre 3) et leur substrat industriel, l'ontologie d'entreprise à la Palantir (chapitre 4). La cinquième apporte ce qui distingue *expliquer* de *constater* : la causalité et les graphes de connaissances (chapitre 5). La sixième relie ces briques aux systèmes vivants que sont les agents et copilotes décisionnels (chapitre 6). La septième, enfin, pose la condition sans laquelle rien de tout cela n'est acceptable : l'éthique et la gouvernance (chapitre 8).

Un fil rouge traverse l'ensemble : la montée en maturité décisionnelle. Les systèmes d'aujourd'hui savent dire ce qui s'est passé ; nous nous intéressons à ceux qui sauront dire *pourquoi*, *ce qui va suivre*, et surtout *quoi faire*. Ce déplacement, du constat à la prescription, n'est pas qu'une affaire de technologie : il engage la façon dont une organisation se représente son propre fonctionnement.

Une précaution de positionnement s'impose avant d'entrer dans le détail. Les questions abordées ici ne surgissent pas d'un vide : elles prolongent des traditions établies que ce travail ne prétend pas remplacer. Les systèmes d'aide à la décision, et en particulier les model-driven DSS, posent depuis les années 1970 la question de l'assistance à la décision par modèle (Shim et al., 2002 ; Power & Sharda, 2007). La recherche opérationnelle et la théorie de la décision formalisent depuis plus longtemps encore le choix sous contrainte et sous incertitude (Keeney & Raiffa, 1976), tandis que les processus de décision markoviens fournissent un cadre canonique à la décision séquentielle (Puterman, 1994). La dynamique des systèmes modélise les boucles de rétroaction et les effets en cascade dans les organisations (Sterman, 2000) ; le process mining reconstruit les processus réels à partir des

traces d'exécution (van der Aalst, 2016) ; la gestion des règles métier et l'architecture d'entreprise structurent depuis longtemps la logique décisionnelle et la cartographie des systèmes (Zachman, 1987). L'apport revendiqué dans les pages qui suivent n'est donc pas de découvrir l'aide à la décision, mais d'examiner comment des développements récents de l'IA, world models, ontologies opérationnelles et raisonnement causal, se combinent avec ces héritages et déplacent, ou non, le plafond que ceux-ci n'ont pas levé.

D'où l'hypothèse qui structure cette revue : les concepts que nous venons d'énumérer ne prennent leur sens qu'*ensemble*. Le world model dit quoi représenter ; l'ontologie, comment le rendre opérationnel ; la causalité, comment l'expliquer ; la Decision Intelligence, à quelle fin ; la gouvernance, à quelles conditions. Chaque chapitre éclaire une pièce ; la conclusion de la partie les assemble en un cadre intégré, qui servira ensuite de grille de lecture à l'étude empirique.

Un mot, pour finir, sur les sources. La littérature mobilisée est volontairement hétérogène : travaux académiques (Pearl, Simon, Davenport), analyses de cabinets (Gartner), documentation industrielle (Palantir), recherche en IA fondamentale (LeCun). Le sujet est trop récent et trop transversal pour se contenter d'une seule source de légitimité. Nous signalerons donc, au fil du texte, la nature de chaque référence pour que le lecteur distingue toujours ce qui est établi, ce qui est émergent, et ce qui relève encore de la promesse. Une vigilance particulière s'impose à l'égard des sources industrielles : les publications de Gartner, la documentation de Palantir et les contenus d'ElixirData sont des matériaux utiles pour décrire l'état du marché et les architectures proposées, mais ils sont produits par des acteurs ayant un intérêt commercial direct dans le domaine décrit. Ils attestent l'existence et la structuration d'une offre, non la validité scientifique des concepts qu'ils promeuvent ; ils sont donc traités ici comme des sources professionnelles à visée descriptive, systématiquement distinguées des travaux académiques évalués par les pairs.

Chapitre 1. Les limites de la BI descriptive et le plafond de complexité décisionnelle

Il existe un paradoxe que tout praticien de la donnée a un jour ressenti, souvent sans le nommer. Les organisations n'ont jamais eu autant de données, autant d'outils pour

les stocker, les nettoyer, les visualiser, et pourtant, au moment de décider, le tableau de bord se tait. Il montre que les ventes ont chuté, mais pas pourquoi. Il affiche le chiffre, mais laisse l'humain seul devant la question qui compte vraiment : « et maintenant, qu'est-ce qu'on fait ? » Ce chapitre part de ce silence. Il cherche à en comprendre l'origine, à montrer qu'il n'est pas un accident mais une conséquence directe de la manière dont la Business Intelligence (BI) a été conçue, et à donner un nom au phénomène qui en résulte : le *plafond de complexité décisionnelle*.

1.1 Genèse et rôle de la BI

Rendons d'abord à la BI ce qui lui revient. Elle n'est pas née d'un effet de mode, mais d'un besoin sérieux : disposer d'une lecture fiable et partagée de ce qui se passe dans l'entreprise. Popularisé à la fin des années 1980, le terme prolonge les systèmes d'aide à la décision des années 1970 et s'impose avec les entrepôts de données de la décennie suivante, dont l'idée était de réconcilier, dans un référentiel unique, des chiffres jusque-là éparpillés et contradictoires (Kimball & Ross, 2013). Le geste fondateur de la BI est donc un geste de **stabilisation** : imposer une version unique et vérifiable de la réalité, là où chaque service avait la sienne (Wixom & Watson, 2010). Reporting, analyse multidimensionnelle, tableaux de bord : ces outils ont installé une culture du fait chiffré et professionnalisé la décision l'un des apports les plus structurants des systèmes d'information (Chen, Chiang & Storey, 2012). Mais cette réussite dessine déjà sa limite. La BI est un rétroviseur d'une netteté remarquable. Or on ne conduit pas les yeux rivés sur le rétroviseur.

1.2 L'échelle de maturité analytique

Pour situer cette limite, la littérature recourt à un cadre devenu classique : l'échelle de maturité analytique (Davenport & Harris, 2007 ; Gartner, *Analytics Ascendancy Model*). Elle distingue quatre niveaux, chacun répondant à une question un peu plus ambitieuse. Le **descriptif** dit *ce qui s'est passé*. Le **diagnostique** cherche *pourquoi*. Le **prédictif** anticipe *ce qui va se passer*. Le **prescriptif**, enfin, recommande *quoi faire* (voir figure 1).




Figure 1. L'échelle de maturité analytique et le blocage des organisations aux niveaux inférieurs.

L'échelle a une propriété essentielle : à chaque marche la valeur pour la décision augmente, et la difficulté aussi. Compter est facile ; expliquer suppose de relier les phénomènes ; anticiper suppose de modéliser ; prescrire suppose d'assumer un jugement sur l'action. La pente se raidit à mesure qu'on monte et c'est précisément dans cette montée que la plupart des organisations s'essoufflent.

1.3 Le paradoxe de la donnée

Car la théorie est limpide, la pratique beaucoup moins. Selon Gartner (2018), à peine **13 % des organisations** atteignent le stade prescriptif : près de neuf sur dix restent bloquées en bas de l'échelle. Et les freins ne sont pas là où on les attend. L'enquête de Wavestone (2024) auprès de dirigeants de grands groupes montre que moins de la moitié des entreprises se considèrent réellement pilotées par la donnée, et que **78 % désignent les facteurs humains** (culture, organisation, processus) comme obstacle principal. Le constat n'est pas neuf : dès 2011, LaValle et ses collègues concluaient, dans le *MIT Sloan Management Review*, que le principal frein à la valeur n'était ni la technologie ni la donnée, mais la capacité à savoir *quelles décisions éclairer* et à faire *agir* l'organisation. Le paradoxe est là, tenace : on accumule des données comme on empilerait des briques sans jamais bâtir la maison. Le volume grandit ; la capacité à décider stagne.

1.4 Le « plafond de complexité décisionnelle »

Ce décalage n'est pas un retard passager, c'est un obstacle de structure que Pratt et Zangari (2008) ont nommé le plafond de complexité décisionnelle. Dans leur formulation d'origine, ce plafond désigne l'écart croissant entre la sophistication des pratiques décisionnelles d'une organisation et la complexité réelle des situations qu'elle doit trancher ; il constitue le problème fondateur auquel la Decision Intelligence entend répondre (Pratt, 2019 ; Pratt & Malcolm, 2023). Nous reprenons ce concept sans en revendiquer la paternité, en le déplaçant vers un terrain qu'il n'avait pas explicitement investi : celui de la représentation organisationnelle et des architectures décisionnelles augmentées. C'est le point à partir duquel la BI descriptive cesse de soutenir la décision : non par manque de données, mais parce que la décision, devenue complexe et interdépendante, dépasse ce que ces systèmes savent traiter. Ce plafond a un visage concret. Dès qu'une question sort du cadre prévu, il faut mobiliser un expert : la donnée est là, mais le décideur ne peut pas l'interroger lui-même. L'information utile est éclatée entre des systèmes qui s'ignorent. Le contexte externe (marché, concurrence, signaux faibles) est souvent absent d'analyses tournées vers le seul intérieur. Et comprendre pourquoi un chiffre a bougé exige un travail d'interprétation humaine que l'outil ne prend pas en charge. Aucune de ces limites ne se corrige par un meilleur logiciel de reporting, car toutes découlent de la vocation première de la BI : stabiliser le passé, non raisonner sur l'action. Demander à la BI descriptive de franchir ce plafond, c'est demander à un rétroviseur de faire office de pare-brise.

1.5 Ce que la BI n'outille pas

Trois angles morts se dégagent, et ils dessinent le programme des chapitres suivants. Le premier est la **causalité**. La BI révèle des corrélations ; elle ne sait pas dire ce qui causerait quoi *si l'on intervenait*. Pearl et Mackenzie (2018) l'ont établi : aucune donnée d'observation, aussi massive soit-elle, ne répond à une question causale sans un modèle explicite du mécanisme sous-jacent.

Le deuxième est l'**interdépendance**. Une entreprise est un système : un prix modifie des volumes, qui modifient une trésorerie, en cascade. Or les tableaux de bord juxtaposent des indicateurs sans modéliser leurs liens. C'est cette absence de représentation du fonctionnement de l'entreprise, ce que nous appellerons un *modèle du monde organisationnel*, qui interdit toute simulation sérieuse.

Le troisième est l'**action**. Décrire, même expliquer, ne dit pas quoi faire ; entre le constat et la décision subsiste un fossé que la BI ne franchit pas. Simon (1977) le rappelait déjà : l'information ne vaut que par la décision qu'elle sert. C'est ce fossé que la *Decision Intelligence* entreprend de combler (Kozyrkov, 2019) et c'est par elle que s'ouvre le chapitre suivant.

Chapitre 2. Decision Intelligence : définition, architecture et reconnaissance institutionnelle

Le chapitre précédent a montré où la Business Intelligence s'arrête. Celui-ci s'intéresse à ce qui commence là où elle s'arrête. La *Decision Intelligence* (DI) n'est pas une couche technologique de plus dans la pile analytique : c'est un renversement de perspective. Là où la BI demandait « que disent les données ? », la DI demande « quelle décision devons-nous prendre, et de quoi avons-nous besoin pour la prendre bien ? ». Le déplacement paraît anodin. Il change tout.

2.1 Origines et définition

Le terme a une paternité identifiée, mais elle est double, et il importe de ne pas la confondre. La Decision Intelligence a été introduite au milieu des années 2000 par Lorien Pratt et Mark Zangari, dont le livre blanc de 2008, *Overcoming the Decision Complexity Ceiling through Design*, pose à la fois le problème fondateur du champ et son vocabulaire ; Pratt en a développé ensuite le cadre méthodologique, notamment la modélisation par chaînes de causalité (Pratt, 2019 ; Pratt & Malcolm, 2023). Cassie Kozyrkov, première Chief Decision Scientist de Google, n'en est donc pas l'inventrice, mais elle en a été la principale vulgarisatrice, et lui a donné sa définition la plus citée : « transformer l'information en actions meilleures, à toute échelle » (Kozyrkov, 2019). L'essentiel tient dans le mot actions et dans ce qu'il déplace : la finalité n'est plus l'analyse, mais la décision qu'elle sert.

Kozyrkov insiste sur un point qui intéresse directement une thèse managériale : la DI n'est pas une sous-discipline technique de la data science, mais un champ plus large qui articule trois savoirs longtemps séparés. La science des données (pour extraire de l'information), les sciences sociales et comportementales (pour comprendre comment les humains décident, avec leurs biais), et les sciences de gestion (pour relier tout cela à des objectifs d'organisation). Ayant formé plus de vingt mille collaborateurs de Google à cette approche, elle en fait moins une technologie qu'une

culture de la décision : savoir cadrer un objectif, choisir les bons indicateurs, poser des garde-fous avant de déléguer quoi que ce soit à un algorithme. C'est une définition exigeante, et c'est ce qui la rend utile : elle remet l'humain, et son jugement, au centre du tableau.

2.2 Du data-centric au decision-centric

Tout le paradigme tient dans ce basculement. Dans un monde *data-centric*, on part des données que l'on possède et l'on regarde ce qu'elles disent ; la décision, quand elle vient, est un sous-produit de l'analyse. Dans un monde *decision-centric*, on inverse le sens de la marche : on part de la décision à prendre et l'on remonte vers l'information nécessaire pour la prendre. La question n'est plus « qu'est-ce que ces données nous apprennent ? » mais « de quoi avons-nous besoin pour trancher, et comment saurons-nous que nous avons bien tranché ? ».

Ce renversement fait de la **décision l'unité d'analyse**. Il n'a rien d'inédit sur le plan intellectuel, Herbert Simon (1977) plaçait déjà la décision au cœur même de l'acte de gestion, mais il a une conséquence pratique radicale sur la manière de mesurer le succès. Une organisation *data-centric* se félicite d'avoir des tableaux de bord ; une organisation *decision-centric* se demande si ses décisions sont meilleures. Le premier critère est un moyen déguisé en fin ; le second remet les priorités à l'endroit. C'est précisément ce recentrage qui permet d'échapper au paradoxe décrit au chapitre 1 : accumuler de la donnée ne rapproche d'aucune décision tant qu'on n'a pas d'abord clarifié la décision elle-même.

2.3 Reconnaissance institutionnelle

Gartner a classé la DI parmi les technologies « transformationnelles » de son Hype Cycle pour l'intelligence artificielle 2025, avant de publier, en janvier 2026, son tout premier *Magic Quadrant for Decision Intelligence Platforms* (Gartner, 2026). L'événement est plus significatif qu'il n'y paraît : un Magic Quadrant consacre l'existence d'une catégorie, avec ses fournisseurs établis évalués non plus sur leur capacité à visualiser des données, mais sur l'ensemble du cycle décisionnel : modélisation, orchestration, supervision et gouvernance des décisions.

La rigueur impose toutefois une nuance. Reconnaissance institutionnelle ne vaut pas maturité, et l'enthousiasme d'analyste s'accompagne toujours d'un revers. Gartner

lui-même prévoit que **plus de 40 % des projets d'IA agentique seront abandonnés d'ici la fin 2027**, victimes de coûts mal maîtrisés et d'attentes irréalistes (Gartner, 2025b). Autrement dit, la DI est un champ en pleine consolidation, pas une solution éprouvée : une promesse crédible, adossée à un marché réel, mais qui reste à tenir. C'est dans cet entre-deux que se situe l'intérêt de l'étudier.

2.4 De la prédiction à l'action

Reste le chiffre qui circule dans toutes les présentations : d'ici 2027, la moitié des décisions d'entreprise seraient *augmentées ou automatisées* par des agents d'IA, et 15 % des décisions courantes deviendraient autonomes dès 2028, contre 0 % en 2024 (Gartner, 2025a). Le chiffre est spectaculaire ; deux mots méritent qu'on s'y arrête. *Augmentée* et *automatisée* ne disent pas la même chose. L'ambition centrale de la DI est l'**augmentation** : étendre le jugement humain, l'outiller, l'accélérer, bien plus que l'automatisation intégrale. Confondre les deux, promettre le remplacement là où l'on ne peut offrir que l'assistance, c'est précisément ce qui nourrit les 40 % d'abandons évoqués plus haut.

La promesse honnête de la Decision Intelligence n'est donc pas de destituer le décideur, mais de lui donner, pour la première fois, un système qui raisonne sur la décision elle-même plutôt que sur les seules données. Cette distinction entre augmenter et remplacer n'est pas un détail rhétorique : elle rouvre la question de la confiance, de la responsabilité et du contrôle humain, que le chapitre 8 traitera de front.

Mais une question demeure, et elle commande tout le reste. Pour raisonner sur une décision, un système a besoin de quelque chose que la BI n'a jamais possédé : une représentation de l'organisation dans laquelle il décide, à savoir ses entités, ses règles, ses dynamiques. Nommer et construire cette représentation, c'est l'objet du chapitre suivant : les *world models*.

Chapitre 3. World models organisationnels : du concept IA à la modélisation d'entreprise

Imaginez un simulateur de vol. Avant de décoller pour de bon, un pilote peut y tenter une manœuvre risquée, provoquer une panne moteur, observer ce qui se passe puis

recommencer, sans le moindre danger. Ce simulateur ne rejoue pas des vidéos d'anciens vols : il possède un *modèle* de la physique de l'appareil, assez fidèle pour anticiper les conséquences de gestes jamais tentés. Transposez maintenant. Et si une organisation disposait d'un tel simulateur non pour piloter un avion, mais pour éprouver une décision avant de la prendre ? « Si je baisse ce prix de 5 %, qu'advient-il de mes marges, de mes stocks, de la réaction de mes concurrents ? » C'est, en une image, la promesse des *world models*. Reste à comprendre d'où vient l'idée, et jusqu'où elle tient.

3.1 Le world model en IA

L'idée ne sort pas du management, mais de la recherche en IA. En 2018, Ha et Schmidhuber publient un article au titre limpide, *World Models*, où des agents apprennent un modèle compressé de leur environnement, au point de pouvoir s'y entraîner « en rêve », sans interagir avec le monde réel (Ha & Schmidhuber, 2018). L'intuition est puissante : un agent vraiment intelligent ne se contente pas de réagir, il possède une représentation interne de son monde qui lui permet d'anticiper.

C'est Yann LeCun qui en fait une architecture complète. Dans son manifeste de 2022, *A Path Towards Autonomous Machine Intelligence*, il décrit un agent autonome comme un assemblage de modules, dont le plus important, il le dit lui-même, est le **world model** : le composant chargé de *prédire les conséquences des actions* pour permettre de planifier (LeCun, 2022). Un détail technique éclaire toute la démarche : ce modèle ne prédit pas le monde pixel par pixel, mais dans un *espace de représentation abstrait*. Autrement dit, pour savoir qu'une voiture va sortir de la route, nul besoin de dessiner chaque brin d'herbe : il suffit de saisir les variables qui comptent. C'est la logique de l'architecture JEPA (*Joint Embedding Predictive Architecture*) que LeCun oppose frontalement aux grands modèles de langage : là où un LLM (un modèle de langage) prédit le mot suivant sans comprendre les conséquences de rien, un world model cherche à *comprendre pour anticiper*. Pour notre sujet, retenons cette définition de travail : un world model est une représentation interne d'un environnement, suffisamment riche pour simuler l'effet d'actions possibles.

3.2 État récent de la recherche

Il serait imprudent de présenter les world models comme une technologie stabilisée. C'est un front de recherche, et il bouge vite. En 2025, Meta dévoile *V-JEPA 2*, un modèle entraîné sur des millions d'heures de vidéo et une pincée de données robotiques, capable de comprendre, prédire et planifier dans des environnements physiques (Meta AI, 2025) ; la même année, l'article *LeJEPA* lui donne un socle théorique plus solide. L'enjeu est jugé si central que LeCun quitte Meta fin 2025 pour fonder une entreprise entièrement dédiée à ce pari (AMI Labs), qui lève plus d'un milliard de dollars dès son amorçage.

Mais la rigueur commande de dire l'autre moitié. En 2026, des travaux consacrés à la robustesse de ces modèles concluent qu'ils restent *fragiles* : brillants sur leurs terrains d'entraînement, ils peinent encore à généraliser un raisonnement fiable. Le world model est donc une idée séduisante et un chantier ouvert, pas une solution éprouvée. Cette précision n'affaiblit pas notre propos ; elle le protège. Nous ne bâtissons pas sur une technologie acquise, mais sur une direction de recherche prometteuse et il faut la traiter comme telle.

3.3 Transposition au contexte organisationnel

Vient alors le pas que fait cette thèse. Les world models de LeCun modélisent un environnement *physique*. Or une entreprise est aussi un environnement, un système dynamique peuplé d'entités (des clients, des produits, des employés), régi par des processus, des règles et des chaînes de cause à effet. Pourquoi n'aurait-elle pas, elle aussi, son modèle du monde ?

L'idée, transposée, consiste à doter l'organisation d'un système qui ne se contente pas d'*agréger* ses données, mais construit une représentation vivante de *son propre fonctionnement*, assez fidèle pour répondre à des questions en « et si... ? ». C'est une transposition conceptuelle authentique, et largement inexplorée sur le plan académique : le concept de world model, né de l'IA, n'a que très peu été porté vers l'entreprise (LeCun, 2024). C'est précisément là que se loge la contribution de ce travail.

Une mise en garde s'impose d'emblée, car elle traversera tout le chapitre : une organisation n'est pas de la physique. Ses « lois » sont molles, mouvantes, en partie humaines ; un client ne tombe pas comme une pomme. Cette différence de nature

rend la transposition plus difficile qu'il n'y paraît, nous y reviendrons avec les verrous. Mais la direction, elle, est nette : pour bien décider, il faut raisonner sur un modèle de l'organisation, et non sur ses seuls tableaux de bord.

3.4 Le modèle ElixirData / Context OS

Comment décompose-t-on un « modèle du monde » d'entreprise ? Une des premières tentatives concrètes vient de l'éditeur ElixirData, dont le *Context OS* propose explicitement de construire un *Organization World Model* (ElixirData, 2025). On peut en lire l'architecture comme cinq sous-modèles interconnectés, chacun répondant à une question simple.

- Le **modèle d'entités** dit *ce qui existe*: clients, produits, contrats.
- Le **modèle de processus** dit *comment le travail s'enchaîne*.
- Le **modèle d'autorité** dit *qui a le droit de décider quoi*.
- Le **modèle de règles** (*policy*) encode les contraintes, seuils et limites réglementaires.
- Le **modèle de terminologie**, enfin, garantit que tout le monde, humains comme agents IA, entende la même chose derrière un mot : qu'un « client » soit bien le même client d'un service à l'autre.

Ces sous-modèles ne flottent pas dans le vide : ils s'incarnent dans un *graphe de contexte* temporel et versionné, qui relie entités, règles, procédures et provenance des données, et qui se veut « la source unique de vérité gouvernée » pour chaque décision assistée par l'IA (ElixirData, 2025). Le système articule trois plans : ce que l'IA *sait*, ce qu'elle est *autorisée à faire*, et *pourquoi* une décision a été prise. Chaque décision laissant une trace auditable.

Un enseignement mérite d'être souligné, car il annonce nos résultats de terrain. Les sous-modèles les plus difficiles à construire ne sont pas les plus visibles. Les entités et la terminologie se laissent extraire de schémas et de catalogues ; ce sont l'autorité et les règles qui résistent, parce que le pouvoir réel et les processus réels d'une entreprise coïncident rarement avec l'organigramme officiel. Modéliser une organisation, c'est se heurter à tout ce qu'elle ne dit pas d'elle-même.

3.5 Capacités et verrous

Supposons le modèle construit. Que permettrait-il ? Trois choses, exactement celles qui manquaient à la BI.

- **Simuler des scénarios** : éprouver une décision en « et si... ? » avant de l'engager.
- **Prédire des effets en cascade** : voir comment une baisse de prix se propage aux volumes, à la trésorerie, à la capacité d'investissement.
- **Repérer des vulnérabilités structurelles** : identifier un point de fragilité avant qu'il ne cède. C'est tout le saut du *décrire* vers l'*anticiper*.

Reste à nommer honnêtement les verrous, car ils sont réels et plusieurs relèvent encore de la recherche.

- **La modélisation** elle-même : définir les bons états, les bonnes actions et le juste niveau d'abstraction pour un objet aussi vaste qu'une entreprise.
- **La donnée de dépendance** : instrumenter dans le temps les décisions, leurs conditions et leurs résultats. Une donnée que la plupart des organisations ne collectent tout simplement pas.
- **La causalité** : sans structure causale explicite, une simulation, aussi sophistiquée soit-elle, produit une *fausse précision*, un point si central qu'il occupera le chapitre 5.
- **La temporalité** : une règle vraie hier ne l'est plus aujourd'hui, et un modèle figé ment aussitôt qu'il est publié.
- **Le facteur humain** : des décisions prises par des personnes n'obéissent pas à des lois nettes.

Aucun de ces verrous n'est anodin. Le world model organisationnel est donc, aujourd'hui, davantage une *direction* qu'un artefact achevé.

Ce qui appelle une objection immédiate : tout cela ne serait-il qu'un concept séduisant, une vision de tableau blanc ? Pas tout à fait. Car une entreprise a passé quinze ans à construire quelque chose qui ressemble étrangement à un modèle du monde organisationnel opérationnel et à le vendre à des gouvernements et à des grands groupes. Elle s'appelle Palantir, et son « Ontologie » est l'objet du chapitre suivant.

Chapitre 4. L'Ontologie d'entreprise (modèle Palantir) : substrat industriel d'un world model décisionnel

Au terme du chapitre précédent, le modèle du monde organisationnel restait une promesse, une direction de recherche prometteuse, mais inachevée. Il est temps de la confronter au réel. Car depuis une quinzaine d'années, une entreprise construit, vend et déploie, chez des gouvernements comme chez de grands groupes, ce qui ressemble à s'y méprendre à un world model décisionnel opérationnel. Elle s'appelle Palantir, et elle a donné à cet objet un nom précis : l'*Ontologie*. Palantir la décrit sans détour comme « un jumeau numérique de l'organisation », une représentation partagée entre les humains et les agents d'IA (Palantir Technologies, 2024-2026). Là où le chapitre 3 posait le concept, celui-ci en examine l'incarnation industrielle la plus aboutie.

4.1 De l'ontologie formelle à l'ontologie d'entreprise

Le mot « ontologie » vient de la philosophie, où il désigne l'étude de ce qui existe. L'informatique l'a emprunté dans les années 1990 pour un usage plus modeste : Gruber (1993) définit une ontologie comme « la spécification explicite d'une conceptualisation », c'est-à-dire un vocabulaire formel et partagé de concepts et de relations, grâce auquel humains et machines s'accordent enfin sur le sens des choses. Dans cette acception classique, une ontologie est un schéma, un dictionnaire structuré : elle *décrit* un domaine (Noy & McGuinness, 2001).

L'ontologie de Palantir est d'une autre nature et c'est tout l'intérêt. Elle ne se contente pas de décrire : elle *agit*. Elle ne pose pas seulement un vocabulaire commun, elle relie chaque donnée à l'entité réelle qu'elle représente: un client, une commande, un moteur d'avion, *et* aux opérations que l'on peut exécuter sur cette entité. On passe ainsi de l'ontologie-vocabulaire à l'ontologie-système d'exploitation de l'entreprise : non plus un dictionnaire posé à côté des données, mais une couche vivante où la connaissance et l'action tiennent ensemble. C'est ce glissement, du descriptif à l'opérationnel, qui fait de l'ontologie de Palantir un candidat sérieux au titre de world model d'entreprise.

4.2 Les quatre dimensions

Le cœur du modèle tient dans une formule que Palantir répète volontiers : l'Ontologie « modélise les décisions, pas seulement les données ». Pour cela, elle intègre quatre dimensions indissociables (Palantir Technologies, 2024-2026).

- **La Data**: l'information sur laquelle on décide, les objets, leurs propriétés, leurs liens.
- **La Logic**: les règles, modèles d'apprentissage, optimiseurs et LLM qui définissent *comment* décider.
- **L'Action**: l'exécution réelle dans les systèmes opérationnels (ERP, MES, gestion d'entrepôt...), pour que la décision ne reste pas sur une diapositive.
- **La Security**: les politiques qui déterminent *qui*, humain ou agent, a le droit de lire, de proposer ou d'exécuter chaque étape.

L'apport est plus profond qu'il n'y paraît. La BI classique s'arrête à la première dimension qui est la donnée et parfois effleure la deuxième. En liant dans un même objet la donnée, la logique, l'action et le contrôle d'accès, l'ontologie referme le fossé entre *savoir* et *faire*, et le referme *sous gouvernance*. C'est exactement le « système d'engagement » évoqué au chapitre 2, mais rendu concret : une architecture où décider et agir cessent d'être deux mondes séparés.

4.3 L'architecture en trois couches

Palantir organise cette intégration en trois couches successives, chacune ajoutant une capacité à la précédente (voir figure 2).



Figure 2. L'ontologie d'entreprise de Palantir : quatre dimensions et trois couches.

- La couche **sémantique** est le modèle de connaissance : des *types d'objets* (Employé, Équipement, Commande, Vol), leurs *propriétés* et des *liens* typés qui les relient. C'est une représentation partagée de ce qui existe et de la manière dont les choses se connectent.
- La couche **cinétique** met cette carte en mouvement : ce sont les *actions* et *fonctions* gouvernées que les personnes et les systèmes exécutent sur les objets. La carte ne se contente plus de représenter ; elle devient capable d'agir.
- La couche **dynamique**, enfin, fait de l'ensemble un jumeau numérique vivant, qui évolue en temps réel avec l'organisation et applique une sécurité elle aussi dynamique.

Techniquement, Palantir décrit ce système comme la combinaison d'un *langage* (pour modéliser objets, actions et logique), d'un *moteur* (pour les exécuter) et d'une *chaîne d'outils* (pour construire par-dessus). La plateforme Foundry intègre données structurées et non structurées, les normalise dans l'ontologie, et laisse les équipes bâtir applications, workflows et agents sur cette fondation commune.

4.4 L'ontologie comme « digital twin » partagé

La propriété décisive de ce dispositif est d'offrir un *substrat commun* aux humains et aux agents d'IA. Un même objet, un « client », une « commande », signifie la même chose pour une personne, pour un tableau de bord et pour un agent. Surtout, les actions deviennent des *primitives explicites* : plutôt que de laisser un agent inventer la manière dont il modifie l'ERP, les opérations autorisées sont déclarées, typées et gouvernées. On ne demande plus à l'IA de deviner ce qu'elle a le droit de faire ; on le lui dit, au niveau de l'objet et de l'action.

À cela s'ajoute une traçabilité de bout en bout : chaque décision est enregistrée avec sa lignée complète : quand elle a été prise, sur quelles données, avec quelle logique, par quelle application ou quel agent, et avec quel résultat en aval (Palantir Technologies, 2024-2026).

Cette auditabilité n'est pas un ornement : c'est précisément ce qui rend une décision augmentée par l'IA *vérifiable*, et elle répond par avance à une bonne part des inquiétudes de gouvernance que traitera le chapitre 8. C'est en ce sens que Palantir

peut parler de « jumeau numérique » : non parce qu'il afficherait une usine en 3D, mais parce qu'il tient dans un même modèle cohérent, interrogeable et évolutif la donnée, la logique, l'action et le contrôle de l'organisation.

4.5 Le pont conceptuel

Revenons au chapitre 3. Une précaution s'impose avant toute correspondance : l'ontologie d'entreprise ne constitue pas, à elle seule, un world model au sens fort du terme. Elle représente des entités, des relations, des règles et des actions autorisées ; un world model, tel que l'entend la recherche en IA, doit en outre modéliser les dynamiques de transition, l'incertitude et les conséquences futures d'une action. Autrement dit, l'ontologie fournit le substrat de représentation sur lequel un world model peut être construit, sans être elle-même un modèle prédictif ou causal. La description de l'Ontologie comme « digital twin » de l'organisation relève d'ailleurs d'une auto-description industrielle (Palantir Technologies, 2024a, 2024b), et non d'une équivalence scientifiquement établie avec les architectures de LeCun. Le tableau 1 explicite ce que chaque objet représente et ce qu'il ne représente pas.

Objet	État	Actions	Dynamiques	Intervention causale	Simulation du futur
Ontologie d'entreprise	Oui	Parfois (actions déclarées)	Pas nécessairement	Non	Non
Modèle causal	Partiellement	Oui	Oui	Oui	Ciblée
Jumeau numérique (digital twin)	Oui	Oui	Oui	Variable	Oui
World model	Oui	Oui	Oui	Selon l'architecture	Oui

Tableau 1. *Ce que représentent (et ne représentent pas) l'ontologie, le modèle causal, le jumeau numérique et le world model.*

- La couche sémantique recouvre les sous-modèles d'entités et de terminologie, *ce qui existe* et le langage partagé.
- La couche cinétique et la dimension Action recouvrent le sous-modèle de processus, *comment le travail s'exécute*.
- Les dimensions Security et Logic recouvrent les sous-modèles d'autorité et de règles, *qui décide, sous quelles contraintes*.

Sous cette réserve, la correspondance structurelle reste éclairante : Palantir a industrialisé quatre des cinq sous-modèles décrits plus haut, y compris les plus difficiles, ceux de l'autorité et des règles que le chapitre précédent désignait comme les vrais points durs. Ce que l'ontologie apporte est donc un substrat de

représentation gouverné et actionnable ; ce qui lui manque pour mériter le nom de world model, c'est la couche de dynamique et de causalité qu'examine le chapitre 5.

La rigueur impose toutefois d'énoncer les réserves, et elles sont sérieuses.

- La première est la **dépendance propriétaire** : cette ontologie constitue un formidable avantage compétitif, un « fossé » défensif, disent les analystes, ce qui signifie aussi un enfermement chez un fournisseur unique et une concentration du pouvoir décisionnel que la critique et la presse ne manquent pas de pointer.
- La deuxième est le **coût** : construire, et surtout *maintenir*, une ontologie vivante synchronisée avec une organisation qui change en permanence est un effort considérable, une ontologie figée est facile, une ontologie vivante ne l'est pas.
- La troisième est le **risque de monolithe** : une couche sémantique centrale peut devenir un goulot d'étranglement si chaque évolution doit passer par une équipe unique.
- La quatrième tient à la **temporalité et à la gouvernance** : une relation vraie aujourd'hui ne l'était pas forcément hier, et une relation affirmée par un LLM n'a pas le même degré de confiance qu'une relation issue d'un système source. Ces réserves ne disqualifient pas le modèle ; elles en définissent les *conditions de réussite*, c'est-à-dire exactement, l'objet de notre sous-question 3.

Ce pont conceptuel appelle cependant une dernière précision, et elle est décisive. L'ontologie donne à l'organisation une carte partagée, gouvernée et actionnable. Mais une carte, aussi riche soit-elle, dit *ce qui est* et *ce qui est relié à quoi*, elle ne dit pas, à elle seule, *ce qui cause quoi*. Savoir que deux objets sont liés n'est pas savoir qu'agir sur l'un déplacera l'autre. Pour transformer cette représentation structurelle en une véritable capacité d'expliquer et de simuler, il manque une couche : la causalité. C'est l'objet du chapitre 5.

Chapitre 5. Causal AI, knowledge graphs et couches sémantiques

Une entreprise observe que ses clients les plus fidèles utilisent tous son application mobile. Faut-il en conclure qu'installer l'application *rend* les clients fidèles ?

Peut-être. Ou peut-être que les clients déjà fidèles sont simplement ceux qui prennent la peine de l'installer. Investir des millions dans l'application sur la foi de cette corrélation pourrait être une décision brillante ou un gâchis complet.

Toute la BI, et une large part de l'analytique moderne, vit dans ce doute : elle voit des corrélations, pas des causes. Ce chapitre montre pourquoi cette différence n'est pas une subtilité académique, mais le verrou central de tout système décisionnel, et comment la *Causal AI* et les graphes de connaissances proposent de le lever.

5.1 La hiérarchie causale de Pearl

Notre guide sera Judea Pearl, prix Turing, dont les travaux ont refondé la pensée causale. Sa contribution la plus célèbre est une « échelle de la causalité » à trois barreaux, chacun correspondant à un type de question de plus en plus profond (Pearl & Mackenzie, 2018) (voir figure 3).



Figure 3. L'échelle de la causalité de Pearl : les trois barreaux du raisonnement causal.

- Le premier barreau est l'**association**: *voir*. Il répond à la question « qu'est-ce que l'observation m'apprend ? », formellement $P(y | x)$: la probabilité de y sachant qu'on a *observé* x . C'est le territoire de la statistique, du machine learning prédictif et de la BI.
- Le deuxième barreau est l'**intervention**: *faire*. Il répond à « que se passe-t-il si j'agis ? », noté $P(y | do(x))$: non plus observer x , mais le *provoquer*. La nuance est capitale, car agir sur un système le modifie d'une manière que la simple observation ne capture pas.

- Le troisième barreau est le **contrefactuel**: *imaginer*. Il répond à « qu'aurait-il fallu faire ? », en raisonnant sur des mondes alternatifs : *qu'en aurait-il été si nous avions décidé autrement ?*

Chaque barreau répond à des questions que le précédent ne peut pas atteindre. Et pour passer de l'observation à l'intervention, Pearl fournit un outillage formel, le *do-calculus*, qui précise à quelles conditions on peut légitimement inférer l'effet d'une action à partir de données à condition, justement, de disposer d'un modèle du mécanisme (Pearl, 2009).

5.2 Le théorème de la hiérarchie causale

Vient alors le résultat qui devrait figurer au fronton de tout projet décisionnel. Formalisé par Bareinboim et ses collègues (2022), le *théorème de la hiérarchie causale* établit que les trois barreaux sont formellement distincts : **aucune quantité de données d'observation, aussi massive soit-elle, ne permet à elle seule de répondre à une question d'intervention ou de contrefactuel**. On ne gravit pas l'échelle avec des données ; il faut y ajouter un modèle causal explicite, c'est-à-dire des hypothèses sur le fonctionnement du système.

Ce n'est pas une limite passagère de l'IA actuelle que la puissance de calcul finira par lever : c'est une impossibilité mathématique. La conséquence pour notre sujet est directe et sévère. Un système qui se contente d'ingérer *toujours plus* de données ne franchira jamais, par ce seul moyen, le pas qui sépare *décrire* de *prescrire*. C'est le socle théorique qui gît sous tout le « plafond de complexité » du chapitre 1 : la BI reste en bas de l'échelle non par manque d'ambition, mais parce que l'observation seule ne mène nulle part au-delà du premier barreau.

5.3 Causal AI en entreprise

Que fait-on de ce constat en pratique ? La plupart des dispositifs estampillés « IA » en entreprise vivent au premier barreau : corrélations et importances de variables, parfois interprétées causalement ce qui est précisément l'erreur à éviter. La *Causal AI* désigne l'effort pour porter le raisonnement des barreaux supérieurs dans les organisations : construire des graphes causaux (des *DAG*, graphes orientés acycliques) qui explicitent les hypothèses de mécanisme, estimer l'effet incrémental d'une action par *uplift modeling*, exploiter des expériences naturelles ou quasi-expériences quand les tests A/B parfaits sont impossibles.

Cette direction n'est pas marginale. Schölkopf et ses collègues (2021) plaident pour que la prochaine étape de l'apprentissage automatique soit l'*apprentissage de représentations causales*: apprendre des variables qui supportent l'intervention, et pas seulement la prédiction.

Le monde professionnel emboîte le pas : le Forum économique mondial présente la Causal AI comme « la révolution qui dévoile le pourquoi de la décision » (World Economic Forum, 2024), et des travaux industriels explorent son passage à l'échelle dans la BI (Salesforces Research, 2025). La rigueur oblige néanmoins à rappeler le prix à payer : l'inférence causale exige des hypothèses, des données de qualité et souvent de l'expérimentation. Elle est plus exigeante, moins « clé en main » que le machine learning prédictif. Ce n'est pas une baguette magique, c'est une discipline.

5.4 Knowledge graphs, ontologies formelles et Graph-RAG

Où la structure entre-t-elle en jeu ? Un *knowledge graph* représente des entités et des relations typées entre elles (Hogan et al., 2021), exactement la couche sémantique de l'ontologie du chapitre 4. Il fournit l'échafaudage sur lequel opèrent le raisonnement causal et les agents d'IA : navigation à travers des relations métier, questions à sauts multiples (*multi-hop*), traçabilité, vocabulaire partagé. Le *Graph-RAG* est la génération augmentée par récupération, mais sur un graphe plutôt que sur des documents permet ainsi à un LLM de répondre en s'appuyant sur les relations réelles de l'entreprise, avec une bien meilleure provenance.

Une nuance, toutefois, mérite d'être martelée, car elle sépare l'outil sérieux du gadget. **Un graphe ne rend pas la donnée vraie.** Si les entités sont mal résolues, si le graphe est périmé, si une relation est dépourvue de provenance, le LLM produira une réponse magnifiquement structurée et potentiellement fausse. Le graphe rend les conflits *visibles* ; il ne les résout pas. Il doit s'accompagner de fraîcheur, de prévalence, de droits d'accès et d'une stratégie d'abstention. En somme, il offre une meilleure *infrastructure de contexte*, pas un *certificat de vérité*. C'est une distinction qui sera, on le verra, au cœur des préoccupations éthiques du chapitre 8.

5.5 Articulation

Assemblons à présent les trois derniers chapitres, car c'est leur convergence qui répond à notre sous-question d'architecture.

- Le knowledge graph et l'ontologie fournissent la **structure** : ce qui existe et ce qui est relié à quoi, la carte.
- La causalité fournit l'**explication et la simulation** : ce qui déplace quoi lorsqu'on agit, les barreaux supérieurs de l'échelle.
- Le world model est l'**ambition** qui les relie : une représentation assez riche pour anticiper.

Ces trois pièces sont interdépendantes. Sans causalité, l'ontologie est une carte précise mais inerte, qui sait tout des liens et rien des effets. Sans ontologie, la causalité n'a aucun substrat partagé sur lequel raisonner. Et sans l'une ni l'autre, le world model n'est qu'un slogan. Ensemble, en revanche, elles composent le **noyau de raisonnement** d'un système décisionnel AI-native : une structure pour représenter, une causalité pour expliquer, une capacité de simulation pour anticiper. C'est la réponse architecturale que cherchait la sous-question 2.

Mais un noyau de raisonnement, aussi élégant soit-il, ne décide pas tout seul. Il faut le mettre au travail : l'incarner dans des systèmes qui observent en continu, alertent sur les signaux faibles, proposent des actions et collaborent avec les humains. Ce sont les agents, les copilotes et les jumeaux numériques du chapitre 6.

Chapitre 6. Agents IA, copilotes, signaux faibles et digital twins

Jusqu'ici, nos systèmes savaient *représenter* (l'ontologie) et *raisonner* (la causalité). Il leur manque encore de *vivre* : observer en continu, alerter, proposer, agir.

C'est le rôle des agents et des copilotes, la couche qui met le noyau de raisonnement au travail. Signe des temps : même les outils de BI les plus classiques s'y convertissent. En 2025, Microsoft a rendu Power BI capable d'écrire directement dans les systèmes sources depuis un rapport, les *translytical task flows*, mot-valise de « transactionnel » et « analytique » qui dit tout du basculement en cours (Microsoft, 2025). Le tableau de bord qu'on *regardait* devient un tableau de bord qui *agit*.

6.1 Agents et copilotes décisionnels

Deux objets, souvent confondus, méritent d'être distingués. Le **copilote** est un assistant conversationnel branché sur les données de l'entreprise : par des techniques de *text-to-SQL* ou de *RAG* (génération augmentée par récupération,

éventuellement sur graphe), il permet d'interroger l'organisation en langage naturel. Son mérite immédiat est de desserrer la dépendance aux experts data pointée au chapitre 1 : un décideur peut enfin poser sa question sans passer par un intermédiaire. L'**agent** va plus loin : il décompose une tâche, appelle des outils, propose voire exécute des actions.

Mais c'est ici qu'intervient l'enseignement architectural le plus important, convergent entre la recherche et le terrain : **le LLM ne doit pas être le simulateur de la vérité**. Le modèle de langage excelle à comprendre une intention, à planifier, à formuler, pas à garantir la cohérence d'un état ou l'exactitude d'un calcul de conséquences. L'architecture robuste est donc *hybride* : le LLM sert d'interface et de planificateur *au-dessus* d'un moteur explicite, l'ontologie, la couche causale, les règles métier qui, lui, calcule et vérifie. L'agent orchestre ; la couche déterministe autorise, contraint et exécute. On retrouve exactement les « actions comme primitives explicites » du chapitre 4 : on ne laisse pas l'agent inventer comment il modifie l'ERP, on lui déclare ce qu'il a le droit de faire.

6.2 Le digital twin organisationnel

Le terme de *jumeau numérique* vient de l'industrie manufacturière, où Grieves l'a introduit pour désigner la réplique virtuelle et vivante d'un actif physique que l'on peut observer et simuler à distance (Grieves & Vickers, 2017). L'ontologie du chapitre 4 en propose la transposition : un jumeau numérique non plus d'une machine, mais de l'*organisation* entière.

Une propriété conditionne toutes les autres : la **temporalité**. Pour bien décider, et surtout pour *apprendre* de ses décisions, un système doit pouvoir reconstruire ce qu'il savait à l'instant t , quelles options étaient alors disponibles, quelle décision fut prise, quel résultat s'ensuivit. Sans cette mémoire du temps, pas de *backtesting*, pas de causalité, pas d'audit possible. Un jumeau organisationnel crédible n'est donc pas une photographie de l'entreprise, mais un film versionné de son évolution. C'est une exigence lourde, la plupart des organisations n'instrumentent pas ainsi leurs décisions et elle sépare le jumeau décisionnel véritable du simple catalogue de données bien rangé.

6.3 Détection de signaux faibles

Il est une capacité que ce type de système ouvre et que la BI, par construction, étouffe : la détection des *signaux faibles*. Le concept remonte à Ansoff (1975), qui invitait les stratèges à « gérer la surprise stratégique » en réagissant à des indices précoces et ambigus, bien avant qu'ils ne franchissent le seuil des indicateurs conventionnels. Or la BI agrège et lisse : elle est faite pour consolider des tendances établies, pas pour repérer le frémissement qui les précède.

Un système adossé à un modèle du monde, connecté au contexte interne *et* externe, pourrait au contraire faire remonter ces signaux avant qu'ils n'apparaissent dans les KPI. Ce n'est pas un hasard si, dans notre enquête, la détection de signaux faibles figure parmi les capacités les plus désirées par les répondants : c'est aussi, paradoxalement, l'une des plus difficiles à outiller. C'est la frontière où la valeur est la plus haute et la maturité la plus basse, autrement dit, exactement là où se joue la promesse des systèmes décisionnels de nouvelle génération.

6.4 Autonomie graduée et confiance

Reste la question qui décidera de tout : jusqu'où laisser le système décider seul ? La bonne manière de la poser n'est pas binaire. Ce n'est pas « fait-on confiance à l'IA, oui ou non ? », mais « *quel niveau d'autonomie accorde-t-on, à quel type de décision ?* ». Le principe directeur, convergent entre les bonnes pratiques et le retour des praticiens, tient en une formule : **le système doit gagner le droit d'agir**.

Concrètement, l'autonomie se gradue selon quelques critères: l'impact, la réversibilité, l'observabilité de l'état, la maturité du modèle. Une décision à faible enjeu, réversible et mesurable, peut être automatisée rapidement. Une décision à enjeu moyen, sous bonne observabilité, peut l'être sous seuil, avec revue humaine. Une décision à fort enjeu, irréversible ou peu observable, reste du ressort de la recommandation assortie d'une validation humaine jamais de l'autonomie complète, et surtout pas au seul motif qu'un *benchmark* est bon. « L'autonomie est la dernière chose, pas la première. » Ce recentrage sur le contrôle humain gradué n'est pas qu'une prudence d'ingénieur : il prépare directement le traitement de l'automation bias et de la responsabilité que développera le chapitre sur l'éthique.

6.5 Vers les conditions de possibilité

Tout ce qui précède présuppose des conditions qui sont organisationnelles autant que techniques. Une **maturité data** suffisante, d'abord sans la donnée de dépendance qui instrumente décisions et résultats, le reste s'effondre. Une **culture décisionnelle**, ensuite, prête à se laisser challenger par un système plutôt qu'à défendre son intuition. Une **gouvernance** claire, qui désigne un responsable. Et une véritable **conduite du changement**, car l'introduction de tels outils réveille des peurs légitimes de perte de contrôle, de perte d'emploi que la technique seule n'apaise pas.

Ces conditions sont l'objet même de notre sous-question 3, et l'étude empirique les mettra à l'épreuve. Retenons pour l'instant que les briques sont désormais toutes sur la table : de quoi *représenter* (world model, ontologie), *expliquer* (causalité), *agir* (agents, copilotes), *anticiper* (signaux faibles, jumeau numérique) et *garder la main* (autonomie graduée). Il est temps de les assembler. Le chapitre suivant réunit ces éléments épars en une seule architecture cohérente : celle du système décisionnel AI-native.

Chapitre 7. Vers un système décisionnel AI-native : le cadre intégré

Nous avons, au fil des cinq derniers chapitres, sorti les pièces une à une de leur boîte.

- Un paradigme: la Decision Intelligence.
- Une représentation: le world model et son incarnation, l'ontologie.
- Un moteur d'explication: la causalité.
- Des organes d'action et d'anticipation: agents, copilotes, jumeaux numériques, signaux faibles.

Prises séparément, chacune a ses mérites et ses limites, que nous avons énoncés sans complaisance. Mais cette thèse ne porte pas sur ces pièces : elle porte sur ce qu'elles forment ensemble. Ce chapitre les assemble en une seule architecture, celle d'un système décisionnel AI-native, et en propose une lecture en couches (figure 4).

7.1 Le geste d'assemblage

La littérature, on l'a vu, traite ces domaines en silos : la BI d'un côté, la causalité de l'autre, les plateformes d'entreprise ailleurs, la gouvernance à part. Cet éclatement

n'est pas qu'un défaut bibliographique : il explique pourquoi tant d'organisations possèdent des morceaux de solution sans jamais obtenir de système. Car la valeur ne réside dans aucune brique isolée, elle naît de leur convergence.

L'hypothèse d'architecture de cette thèse peut alors s'énoncer simplement : un système décisionnel AI-native n'est pas une technologie, mais un empilement où chaque couche fournit précisément ce dont la couche supérieure a besoin. La donnée nourrit la représentation ; la représentation donne prise au raisonnement ; le raisonnement rend la simulation possible ; la simulation alimente l'action ; l'action produit un résultat qui, mesuré, réapprend au système. Et le tout n'a de sens que gouverné. C'est cette chaîne, et non l'un de ses maillons, qui franchit le plafond de complexité décisionnelle du chapitre 1.

7.2 L'architecture en couches

La figure 4 présente cette architecture comme une pile, de la donnée brute (en bas) à la décision augmentée (en haut), traversée verticalement par la gouvernance et animée par une boucle d'apprentissage.




Figure 4. Architecture en couches d'un système décisionnel AI-native.

Couche 1: Données et systèmes sources. Le socle : ERP, CRM, journaux d'événements, capteurs, et surtout données externes (marché, concurrence). C'est le réel opérationnel, brut et fragmenté, le point de départ que la BI, seule, ne dépassait pas.

Couche 2: Ontologie et couche sémantique. Le world model opérationnel : entités, relations, processus, règles, autorité et terminologie partagée. Cette couche transforme des données éparses en une carte cohérente, commune aux humains et aux agents. C'est le chapitre 4 rendu à sa fonction : donner un substrat de sens.

Couche 3: Raisonnement causal. Le moteur qui distingue expliquer de constater : graphes causaux, do-calculus, contrefactuels. Il répond aux questions d'intervention « que se passe-t-il si j'agis ? » que la structure seule ne peut trancher.

Couche 4: Simulation et anticipation. La capacité proprement dite du world model : rejouer des scénarios, projeter des effets en cascade, faire remonter des signaux faibles. C'est le passage du présent au futur possible.

Couche 5: Agents et copilotes. L'orchestration et l'interface : interroger en langage naturel, proposer, et exécuter des actions gouvernées, sous autonomie graduée. La couche qui met le noyau au travail sans jamais le laisser inventer ce qu'il n'a pas le droit de faire.

Finalité: Decision Intelligence. Au sommet, la décision augmentée, et la boucle d'apprentissage qui relie le résultat obtenu à la décision prise refermant le cycle que la BI laissait ouvert.

Transversal: Gouvernance, éthique et contrôle humain. Non pas une couche parmi d'autres, mais une colonne qui traverse toutes les autres. Nous y revenons en 7.5.

7.3 La circulation : un exemple de bout en bout

Rien ne vaut un cas concret. Une enseigne envisage de baisser de 5 % le prix d'une gamme. Dans un système AI-native, la décision circule à travers la pile. Les données internes (ventes, stocks, marges) et externes (prix concurrents) sont d'abord rapportées à l'ontologie, qui sait que ce « produit » est lié à ce fournisseur, à cette marge, à ce segment de clientèle. Le moteur causal n'estime pas une simple corrélation, mais l'effet d'une intervention sur les volumes et la trésorerie. La couche de simulation projette la cascade : volumes en hausse, tension sur les stocks, réaction probable d'un concurrent. Un agent met le résultat en forme et propose une recommandation ; parce que la décision engage la marge, l'autonomie graduée impose une validation humaine. Une fois validée, l'action est écrite dans les systèmes opérationnels le tableau de bord qui agit du chapitre 6. Enfin, le résultat réel est mesuré et réinjecté : la boucle d'apprentissage corrige le modèle pour la

prochaine décision. À chaque étape, la gouvernance enregistre qui a décidé, sur quelles données, avec quelle logique.

7.4 Pourquoi le tout vaut plus que les parties

L'intérêt de cette lecture en couches n'est pas esthétique ; il est démonstratif. Retirez une couche, et le système régresse. Sans ontologie, le moteur causal n'a aucun substrat partagé sur lequel raisonner. Sans causalité, la simulation produit une fausse précision. Sans agents, rien n'agit. Sans Decision Intelligence, l'empilement n'a ni finalité ni boucle d'apprentissage. Sans gouvernance, il n'est pas acceptable. La contribution théorique de cette thèse n'est donc pas d'inventer l'une de ces briques, chacune existe et a ses auteurs, mais de montrer que leur articulation dessine un objet cohérent, encore rarement pensé comme tel.

Une précision de méthode s'impose ici, pour éviter toute confusion avec la suite. Ce cadre est un modèle théorique, reconstruit à partir de la littérature : il propose. Le chapitre 11, en Partie II, le confrontera aux résultats de l'enquête et des entretiens : il éprouvera. L'un est une hypothèse d'architecture ; l'autre, sa mise à l'épreuve empirique. Les tenir distincts est la condition de leur crédibilité respective.

7.5 La gouvernance, une couche transversale

Reste à justifier la place singulière de la gouvernance dans la figure 4, verticale, et non horizontale. Si nous ne l'avons pas posée comme une couche au sommet ou à la base, c'est qu'elle n'y appartient pas : elle traverse toutes les couches. La traçabilité s'ancre dès la donnée ; l'autorité est inscrite dans l'ontologie ; l'abstention se décide dans la couche causale ; l'autonomie se gradue au niveau des agents ; le contrôle humain s'exerce au moment de la décision. La gouvernance n'est pas un vernis appliqué à la fin, mais la colonne vertébrale éthique de l'ensemble.

C'est pourquoi le dernier chapitre de cette revue ne traite pas l'éthique en appendice, mais comme la condition même de possibilité du cadre que nous venons d'assembler. Sans transparence, sans responsabilité et sans jugement humain préservé, l'architecture la plus élégante ne serait qu'une boîte noire de plus. C'est l'objet du chapitre 8.

Chapitre 8. Éthique, gouvernance et réglementation

On pourrait croire l'éthique reléguée au dernier chapitre parce qu'elle viendrait après l'essentiel. C'est l'inverse. Un système décisionnel augmenté qui serait opaque, irresponsable ou biaisé ne serait pas un *mauvais* système : il ne serait pas un système *acceptable* donc pas déployable. La figure 4 l'a déjà dit à sa manière : la gouvernance ne coiffe pas la pile, elle la traverse. Ce chapitre en développe les quatre enjeux : un risque humain (l'automation bias), un risque technique (les biais et boucles de rétroaction), les cadres qui tentent de les contenir (réglementation et standards), et le principe qui doit tous les gouverner (transparence et jugement humain).

8.1 L'automation bias

Le premier danger n'est pas que la machine se rebelle : c'est que l'humain abdique. L'*automation bias* désigne notre tendance à sur-faire confiance aux sorties d'un système automatisé à moins vérifier, voire à ignorer une information contradictoire dès lors qu'un outil affiche une réponse (Parasuraman & Manzey, 2010). La revue systématique de Goddard et ses collègues (2012), menée sur les systèmes d'aide à la décision médicale, montre que le phénomène est fréquent, mesurable et lourd de conséquences : des professionnels compétents suivent une recommandation erronée précisément parce qu'elle est *présentée* par le système.

Le paradoxe est cruel, et il vise droit au cœur de notre sujet : plus un système est précis et fluide, plus il désarme la vigilance. Une recommandation bien formulée inspire une confiance visuelle supérieure à la solidité réelle de ce qui la fonde. C'est ce que traduit, dans notre enquête, l'idée qu'un système très performant pourrait « réduire progressivement la capacité des décideurs à remettre en question ses conclusions » une inquiétude que les répondants reconnaissent volontiers. Le risque n'est donc pas spectaculaire ; il est silencieux. Et il ne se corrige pas en améliorant le modèle, au contraire, un meilleur modèle l'aggrave, mais en rendant *la preuve aussi visible que la réponse* : citer la source, afficher la fraîcheur de la donnée, signaler l'incertitude, surveiller les cas où l'utilisateur valide sans jamais ouvrir les justifications (Cummings, 2004).

8.2 Biais hérités et boucles de rétroaction

Le deuxième danger est technique, et il tient en une formule : bias in, bias out. Un modèle entraîné sur des données historiques hérite des discriminations de cette histoire ; un système qui apprend des décisions passées en reproduit les préjugés, avec l'autorité trompeuse du chiffre. Le problème s'aggrave quand s'installe une boucle de rétroaction : les recommandations du système façonnent les données futures, qui confirment ensuite le système. L'exemple canonique est la police prédictive, envoyer des patrouilles là où l'outil a prédit des délits y fait constater davantage de délits, ce qui « valide » la prédiction. Le système devient une prophétie auto-réalisatrice.

Ce n'est pas un bug que l'on corrige d'un correctif, mais un risque structurel qui appelle une surveillance active : audits d'équité, contrôle de la dérive, et ce n'est pas un hasard, le raisonnement causal du chapitre 5. Car distinguer « les données disent X » de « nos choix passés ont fait dire X aux données » est, littéralement, une question causale. La gouvernance et la causalité se rejoignent ici : sans modèle de ce qui cause quoi, on ne sait même pas nommer le biais que l'on reproduit.

8.3 Le cadre réglementaire européen

Face à ces risques, l'Europe a légiféré. L'AI Act (Règlement UE 2024/1689) est la première réglementation générale de l'intelligence artificielle, bâtie sur une logique de risque : plus l'usage est sensible, plus les obligations sont lourdes. Son calendrier est échelonné : interdiction des usages prohibés en février 2025, obligations de transparence pour les modèles à usage général en août 2025, puis exigences pour les systèmes à haut risque (Annexe III) prévues au 2 août 2026, un volet toutefois partiellement reporté à décembre 2027 par le paquet de simplification dit « AI Omnibus », les systèmes intégrés à des produits réglementés bénéficiant d'un délai jusqu'en 2028.

Pour les systèmes à haut risque parmi lesquels tombent souvent les outils d'aide à la décision en matière de crédit, d'emploi ou de santé, les obligations sont concrètes : gestion des risques, gouvernance des données, journalisation, supervision humaine, évaluation de conformité, enregistrement. Les sanctions atteignent 35 millions d'euros ou 7 % du chiffre d'affaires mondial davantage que le RGPD. En France, les

recommandations de la CNIL complètent ce cadre. La conséquence, pour notre architecture, est limpide : la conformité n'est plus une formalité a posteriori, mais une contrainte de conception. La traçabilité de bout en bout de l'ontologie (chapitre 4) et la supervision humaine graduée des agents (chapitre 6) cessent d'être des raffinements pour devenir des obligations.

8.4 Standards de gouvernance

Au-delà de la loi, des cadres volontaires mais structurants traduisent les principes en routines. La norme ISO/IEC 42001:2023 est le premier standard de système de management de l'IA, en quelque sorte l'« ISO 9001 de l'intelligence artificielle », qui exige de documenter, mesurer et améliorer en continu la gestion des risques liés à l'IA. Le NIST AI Risk Management Framework (NIST, 2023) propose, côté américain, quatre fonctions (gouverner, cartographier, mesurer, gérer) et une boîte à outils pour les appliquer. À l'échelle des pratiques, ces cadres s'incarnent dans des model cards, des audits de modèles, une lignée documentée.

Un constat tempère l'optimisme. Jobin, Ienca et Vayena (2019), dans une cartographie mondiale des principes éthiques de l'IA, montrent une convergence remarquable des chartes autour de quelques valeurs (transparence, justice, non-malfaisance, responsabilité, respect de la vie privée), mais soulignent le fossé persistant entre principes et pratiques. C'est précisément la valeur de normes comme ISO 42001 ou le NIST RMF : non pas énoncer de nouveaux principes, mais fournir le chaînon opérationnel qui manquait pour les tenir.

8.5 Transparence, explicabilité et jugement humain

Reste le principe qui gouverne tous les autres. L'exigence de transparence doit porter sur le système de décision, et non sur le seul modèle. Un composant peut rester opaque, un modèle très performant l'est souvent, pourvu que la décision, elle, demeure explicable : encadrée de règles, de seuils, d'une stratégie d'abstention et d'une revue humaine. C'est la réponse mûre au dilemme que notre enquête a fait remonter avec force : la transparence y est l'exigence numéro un, mais l'acceptation d'une IA « si elle améliore la performance » n'est guère moins forte. Ces deux attentes tirent en sens opposés ; une gouvernance sérieuse ne tranche pas en

sacrifiant l'une, elle rend la décision explicable même lorsqu'un de ses composants ne l'est pas.

Au bout de la chaîne se tient une exigence non négociable : préserver le jugement et la redevabilité humaine. L'autonomie graduée du chapitre 6 en est l'expression opérationnelle ; le principe, lui, est simple, une décision doit toujours avoir un responsable humain identifiable, jamais un « c'est l'algorithme qui a décidé ». C'est la ligne qui sépare l'augmentation de l'abdication, et c'est elle qui rend l'ensemble de notre architecture non seulement puissante, mais légitime.

Ainsi se referme la revue de littérature en revenant, par l'éthique, à l'humain que la Decision Intelligence promettait d'augmenter plutôt que de remplacer. Mais ces tensions: confiance, automation, bias, transparence contre performance, responsabilité, ne se tranchent pas dans les livres. Elles se vivent, différemment, par ceux qui construisent et utilisent ces systèmes. Ce qu'ils en pensent vraiment est la question que l'étude empirique reprend à présent.

Conclusion de la Partie I

Au terme de ce parcours, la revue de littérature a rempli sa promesse : réunir des courants qui s'ignoraient et montrer qu'ils dessinent, ensemble, un même objet. Le chemin fut linéaire par nécessité, mais son sens est cumulatif. Nous sommes partis d'un constat que la Business Intelligence descriptive bute sur un plafond de complexité décisionnelle qu'aucun surcroît de données ne peut, à lui seul, franchir (chapitre 1). Nous y avons opposé un renversement de perspective, la Decision Intelligence, qui remet la décision au centre (chapitre 2). Puis nous avons rassemblé les briques d'une réponse : une représentation vivante de l'organisation, le world model et son incarnation industrielle, l'ontologie (chapitres 3 et 4) ; un moteur qui explique au lieu de constater, la causalité (chapitre 5) ; des organes qui agissent et anticipent, agents, copilotes et jumeaux numériques (chapitre 6). Le chapitre 7 les a assemblés en une architecture unique, et le chapitre 8 a rappelé que rien de tout cela n'est légitime sans une gouvernance qui traverse chaque couche.

La contribution théorique de cette partie tient dans cet assemblage. Prises isolément, aucune de ces idées n'est neuve, et chacune a ses auteurs. Ce qui l'est davantage, c'est de les lire comme les couches d'un même système décisionnel AI-native, où la structure rend possible le raisonnement, le raisonnement la simulation, la simulation l'action, et où la boucle d'apprentissage referme enfin le cycle que la BI laissait ouvert. C'est le cadre intégré que la figure 4 résume, et qui servira de grille de lecture à toute la suite.

Mais une revue de littérature ne prouve rien ; elle problématise. Et celle-ci laisse ouvertes des questions qu'elle ne peut trancher seule. La transposition des world models à l'entreprise est-elle réaliste, ou reste-t-elle un idéal d'ingénieur ? À quelles conditions organisationnelles et culturelles une telle architecture peut-elle réellement s'implanter ? Comment se vit, sur le terrain, la tension entre l'exigence de transparence et l'attrait de la performance ? Et les praticiens qui construisent ces systèmes en ont-ils la même lecture que ceux qui les subissent ou les pilotent ?

Ces questions ne se résolvent pas dans les livres. Elles appellent le terrain. C'est l'objet de la Partie II, qui confronte ce cadre conceptuel à la parole de celles et ceux qui décident, analysent et conçoivent pour vérifier ce qu'il éclaire, corriger ce qu'il simplifie, et faire apparaître ce qu'il n'avait pas prévu.

Partie II. Étude empirique

Chapitre 9. Méthodologie de recherche

Ce chapitre expose la démarche de recherche mise en œuvre pour éprouver le cadre conceptuel développé en première partie. Il précise le positionnement épistémologique et le choix d'un design mixte, justifie la logique de triangulation convergente, détaille les deux volets empiriques et leurs instruments, puis expose les garanties éthiques et les limites de la méthode.

9.1 Positionnement épistémologique et design mixte

Le sujet de cette recherche, la transformation des systèmes décisionnels d'entreprise, se prête mal à un paradigme méthodologique unique. Il appelle à la fois une mesure de la perception à large échelle et une compréhension fine des mécanismes, des contraintes et des conditions de cette transformation. Un tel objet relève naturellement d'une posture pragmatique, dans laquelle le choix des méthodes est dicté par la question de recherche plutôt que par une allégeance théorique a priori (Creswell & Plano Clark, 2018).

La démarche retenue est donc une approche mixte, combinant un volet quantitatif par questionnaire et un volet qualitatif par entretiens semi-directifs. Plus précisément, elle relève d'un design convergent : les deux volets sont recueillis et analysés de manière parallèle et indépendante, puis mis en dialogue au moment de l'interprétation. Le volet quantitatif mesure la prévalence des phénomènes identifiés dans la littérature (plafond de complexité décisionnelle, automation bias, exigence de transparence) ; le volet qualitatif en éclaire les ressorts et fait émerger des dimensions que le questionnaire ne pouvait anticiper.

9.2 Justification de la triangulation convergente

Le recours à la triangulation convergente répond à un objectif de validité. En abordant le même phénomène sous deux angles complémentaires, la recherche renforce la robustesse de ses conclusions : les résultats d'un volet peuvent confirmer, nuancer ou enrichir ceux de l'autre (Fetters, Curry & Creswell, 2013). Là où le questionnaire établit qu'un phénomène est répandu, les entretiens expliquent pourquoi et comment il se manifeste ; là où les chiffres laissent apparaître une tension, la parole des praticiens en révèle la logique. L'intégration ne se fait pas au

moment du recueil, mais lors de la synthèse interprétative, présentée au chapitre 12. La figure 5 schématise cette architecture.




Figure 5. Le design de recherche à triangulation convergente.

9.3 Volet quantitatif : instrument, population, échantillon et plan d'analyse

L'instrument est un questionnaire structuré, diffusé en ligne et bilingue (français et anglais), d'une durée d'environ trois minutes (voir Annexe A). Il mobilise des échelles de Likert à cinq points (Likert, 1932) et des questions de type Vrai/Faux, et couvre les thématiques suivantes : perception des limites de la BI actuelle, niveau de maturité analytique perçu, familiarité avec les concepts de Decision Intelligence, degré de confiance dans les recommandations algorithmiques, perception de l'automation bias et attentes en matière de gouvernance de l'IA décisionnelle.

La population cible réunit les professionnels impliqués dans la prise de décision fondée sur les données : décideurs, data analysts, data scientists, data engineers, architectes data, responsables CDO ou CTO, consultants et chefs de projet SI, ainsi que tout répondant averti pour les questions éthiques. L'échantillonnage, de type volontaire et raisonné, s'est appuyé sur des réseaux professionnels.

193 réponses exploitables ont été collectées. Il convient de préciser d'emblée qu'aucun calcul de puissance a priori n'a été conduit : la taille de l'échantillon résulte de la diffusion effective du questionnaire, non d'un dimensionnement statistique préalable, ce qui limite la portée des analyses par sous-groupes. L'échantillonnage

est volontaire et non probabiliste, et la composition présente un déséquilibre notable : près de la moitié des répondants ont entre 18 et 24 ans, et le questionnaire ne mesure ni l'ancienneté professionnelle réelle, ni le pouvoir décisionnel effectif, ni le pays d'exercice, ni la maturité data de l'organisation. La composition reste néanmoins diversifiée en fonctions, avec une part sensiblement équilibrée de profils techniques (data scientists, ingénieurs, développeurs) et de profils métier ou décisionnels, répartis sur plusieurs secteurs (conseil, banque et assurance, technologie, industrie, distribution, secteur public). À la fin du questionnaire, une demande de participation à l'enquête qualitative est proposée aux répondants.

Deux limites de conception de l'instrument doivent également être signalées. D'une part, les items mesurant la valeur perçue des capacités augmentées sont tous formulés positivement (« améliorerait », « apporterait une valeur significative ») et ne comportent aucun item inversé : l'adhésion élevée qu'ils recueillent est donc en partie prévisible et probablement surestimée par un effet d'acquiescement. D'autre part, le questionnaire n'a fait l'objet ni d'un prétest documenté, ni d'une procédure de validation d'échelles au sens psychométrique. Les résultats qui suivent doivent être lus comme des indications de perception, et non comme des mesures validées de construits latents.

Le plan d'analyse se déploie en quatre temps : nettoyage des données et vérification de la fiabilité des échelles multi-items (alpha de Cronbach ; Cronbach, 1951) ; statistiques descriptives (moyennes et taux d'accord) ; analyses bivariées par corrélations ; enfin, si la taille de l'échantillon le permet, analyse en composantes principales et modélisation par régression pour identifier les facteurs explicatifs de la perception du plafond décisionnel et de la confiance dans les systèmes augmentés.

9.4 Volet qualitatif : guide décliné en deux versions, profils et analyse thématique

L'instrument est un guide d'entretien semi-directif structuré autour des dimensions centrales de la thèse : plafond de complexité, Decision Intelligence, modèle du monde et ontologie, raisonnement causal, confiance et automation bias, gouvernance. Ce guide a été décliné en deux versions (voir Annexe B). La version destinée aux profils métier procède en deux temps, une phase généraliste non orientée puis une vulgarisation suivie de questions ciblées, afin de ne pas biaiser des répondants peu familiers du sujet. La version destinée aux profils techniques aborde

frontalement les mêmes dimensions, avec un vocabulaire spécialisé et une profondeur d'implémentation supérieure. Les deux versions partagent les mêmes dimensions, la comparabilité inter-profils est préservée.

Les profils ciblés couvrent, d'un côté, des décideurs, contrôleurs de gestion et fonctions métier, de l'autre, des data scientists, ingénieurs en IA et architectes, ainsi que des experts du domaine (Decision Intelligence, ontologie, causal AI, gouvernance de l'IA). Les entretiens ont été recrutés parmi les volontaires du questionnaire, complétés par une prospection ciblée grâce à mon réseau personnel et professionnel. Les entretiens, d'une durée de 30 à 40 minutes, sont conduits en visioconférence, enregistrés puis transcrits.

L'analyse suit la méthode d'analyse thématique de Braun et Clarke (2006), en six phases, avec un codage ouvert puis axial. Une grille de codage de départ (voir Annexe C) combine des codes déductifs, issus du cadre conceptuel, et des codes émergents relevés au fil des entretiens. Une variable de profil (technique, métier, décideur) est systématiquement codée, de sorte que l'analyse des divergences entre profils constitue un objectif de recherche à part entière, et non un simple artefact (Miles, Huberman & Saldaña, 2014).

Plusieurs limites propres à ce volet doivent être explicitées. Les guides, en particulier la version technique, énoncent eux-mêmes une partie des catégories de réponse possibles (donnée, causalité, maintenance, abstention, dérive, contrôle humain) et invitent les interlocuteurs à se positionner par rapport à elles : la démarche relève donc davantage d'une élicitation d'experts sur un cadre préconstruit que d'une exploration pleinement inductive. La phase B du guide métier présente en outre la vision de manière favorable avant d'interroger l'évolution du ressenti ; l'élévation de confiance observée peut ainsi refléter un effet pédagogique, un effet de cadrage ou un biais de désirabilité envers l'intervieweur, et elle n'est mesurée par aucune échelle standardisée avant-après. Enfin, le même chercheur a construit le cadre théorique, conduit les entretiens, codé le corpus et interprété les résultats, sans double codage ni vérification inter-codeurs, et sans journal d'audit documentant les décisions de codage. Les convergences rapportées doivent être lues à la lumière de ces contraintes.

	Volet quantitatif	Volet qualitatif
--	--------------------------	-------------------------

Objectif	Mesurer la prévalence des phénomènes à large échelle	Comprendre les mécanismes, perceptions et logiques d'action
Instrument	Questionnaire structuré, échelles de Likert à 5 points (Annexe A)	Guide semi-directif en deux versions, métier et technique (Annexe B)
Population	Professionnels de la décision data-driven, BI, analytics, data science	Décideurs et fonctions métier, profils techniques, experts du domaine
Échantillon	193	9 entretiens (3 techniques, 2 business analysts, 4 métier)
Recueil	En ligne, bilingue, environ 3 minutes	Visioconférence, 30 à 40 minutes, enregistrés et transcrits
Analyse	Statistiques descriptives, corrélations, ACP et régression (selon l'échantillon)	Analyse thématique (Braun & Clarke, 2006), codage ouvert puis axial (Annexe C)

Tableau 2. Synthèse du design mixte.

9.5 Considérations éthiques et conformité RGPD

La dimension éthique de la méthode revêt ici une importance particulière : une thèse consacrée à la gouvernance et à la transparence de l'IA se doit d'appliquer à sa propre démarche les principes qu'elle défend. Le questionnaire est anonyme et son remplissage volontaire ; les adresses électroniques ne sont collectées que pour les répondants acceptant un entretien de suivi, et conservées séparément des réponses.

Chaque entretien est précédé d'un consentement éclairé (voir Annexe D), rappelant la finalité de la recherche, l'enregistrement et son anonymisation, le droit de se retirer à tout moment, ainsi que les modalités de conservation et de suppression des données. L'ensemble du dispositif respecte les principes du Règlement général sur la protection des données : finalité déterminée, minimisation des données collectées et limitation de leur durée de conservation.

Une précision de transparence : le questionnaire proposait initialement un entretien de suivi de dix à quinze minutes. Les entretiens effectivement conduits ont duré de trente à quarante minutes, cette durée ayant été annoncée et acceptée par chaque participant lors de la prise de rendez-vous.

9.6 Limites méthodologiques

Plusieurs limites doivent être reconnues. La première tient à l'échantillon quantitatif : avec 193, les résultats sont exploratoires et la puissance des analyses par

sous-groupes reste limitée. L'échantillonnage volontaire n'assure pas la représentativité, et le recours à des mesures déclaratives expose aux biais de perception et de désirabilité sociale.

La deuxième limite concerne le volet qualitatif. La déclinaison du guide en deux versions enrichit la collecte mais complique une comparaison stricte entre profils, un risque atténué par le partage des mêmes dimensions et par le codage d'une variable de profil. Le codage réalisé par un chercheur unique comporte une part de subjectivité, que la grille de codage et une posture réflexive visent à contenir, sans remplacer un contrôle inter-codeurs.

Enfin, le caractère bilingue de l'instrument peut introduire de légères variations de sens entre les deux versions, et le design convergent suppose une commensurabilité des deux volets qu'il convient de manier avec prudence. L'explicitation de ces limites participe elle-même de la rigueur de la démarche et éclaire la portée exacte des résultats présentés dans les chapitres suivants.

Chapitre 10. Résultats de l'enquête quantitative

Ce chapitre présente les résultats de l'enquête par questionnaire, fondée sur 193 réponses exploitables (voir Annexe A pour l'instrument). L'exposé suit une logique cumulative : après la description de l'échantillon, il établit d'abord les résultats descriptifs, thème par thème, puis explore la structure des attitudes et les relations entre variables, avant d'examiner les différences entre sous-groupes et les questions de gouvernance. Conformément à la nature de l'échantillon, volontaire et transversal, les analyses relationnelles conservent un statut exploratoire : elles sont rapportées avec leur taille d'effet (Cohen, 1988) et leur niveau de signification, sans prétention de causalité.

10.1 Profil de l'échantillon

L'échantillon réunit 193 répondants ayant complété le questionnaire, soit en français (141 répondants, 73 %), soit en anglais (52 répondants, 27 %). Sur le plan des fonctions, il se répartit en profils techniques (data scientists, ingénieurs, analystes, architectes : 96 répondants, 50 %), profils métier ou décisionnels (managers, contrôleurs de gestion, consultants, fonctions financières : 79 répondants, 41 %) et autres profils (18 répondants). L'échantillon est jeune : près de la moitié des répondants ont entre 18 et 24 ans, ce qui reflète une population de professionnels en

début de carrière et constitue une limite discutée en fin de chapitre. Les organisations représentées couvrent tout le spectre de taille, des très petites structures aux groupes de plus de 10 000 salariés, et la fréquence d'usage des outils de BI est élevée : une majorité s'en sert plusieurs fois par semaine ou quotidiennement. Enfin, 58 répondants (30 %) déclarent travailler exclusivement avec Excel, sans outil de BI moderne.

10.2 La perception des limites de la BI : un plafond largement partagé

Le premier constat de la thèse trouve ici un écho empirique net, au niveau des perceptions. Une majorité nette de répondants estime que la BI actuelle produit avant tout des analyses descriptives plutôt qu'explicatives (moyenne = 3,82 sur 5 ; 66 % d'accord), et que toute variation d'indicateur exige une analyse exploratoire supplémentaire au-delà des tableaux de bord standards (3,83 ; 67 %). Les trois mécanismes du plafond décrits dans la revue de littérature ressortent tous au-dessus du point neutre : la dépendance aux experts et à l'analyse manuelle (3,62 ; 52 %), la fragmentation des données entre systèmes (3,69 ; 59 %) et l'absence de contexte externe dans les analyses (3,65 ; 56 %). La figure 6 donne la distribution complète des réponses, et le tableau 3 en récapitule les statistiques.

Ces proportions mesurent une perception partagée, non l'existence objective d'un plafond structurel : elles indiquent que deux tiers des répondants décrivent leur outillage comme descriptif, ce qui rend le diagnostic plausible et répandu, sans en établir l'universalité.

Un résultat mérite toutefois d'être souligné pour sa nuance. Interrogés sur le fait que la BI leur *permet de comprendre clairement les causes profondes* des variations, les répondants sont franchement partagés (3,08 ; 36 % d'accord contre 30 % en désaccord). Autrement dit, le caractère descriptif de la BI fait consensus, mais l'incapacité à comprendre les causes ne fait pas l'unanimité : le plafond est ressenti comme une limite d'outillage plus que comme une cécité totale. Ce partage constitue en soi une donnée intéressante pour la discussion.




Figure 6. Distribution des réponses aux 18 items, regroupés par thème (n = 193).

Item (résumé)	M	ÉT	% d'accord
BI descriptive plutôt qu'explicative	3,82	1,00	66 %
Analyse exploratoire supplémentaire requise	3,83	0,86	67 %
Données réparties entre systèmes	3,69	0,94	59 %
Contexte externe souvent absent	3,65	1,06	56 %
Dépendance aux experts / analyse manuelle	3,62	1,00	52 %
BI détecte les variations de KPI	3,53	0,90	56 %
Intégration interne / externe difficile	3,35	1,05	41 %
BI fait comprendre les causes profondes	3,08	1,11	36 %
Valeur : détection de signaux faibles	4,01	0,97	72 %
Valeur : requête en langage naturel	3,90	0,99	67 %
Valeur : systèmes prédictifs	3,84	1,05	61 %

Valeur : identification automatique des drivers	3,77	1,17	62 %
Importance de la transparence	4,22	0,91	79 %
Acceptable si améliore la performance	3,85	0,79	65 %
Se sentirait responsable en cas d'erreur IA	3,77	1,04	66 %
Confort : décisions partiellement guidées	3,38	1,11	44 %
Préoccupation vis-à-vis des biais	3,47	1,06	51 %
Confort à s'appuyer sur l'IA	3,27	1,10	41 %

Tableau 3. Statistiques descriptives des 18 items (moyenne, écart-type, part de réponses 4-5).

10.3 Un fort appétit pour les capacités augmentées

À l'inverse des limites, les capacités « au-delà du descriptif » suscitent une adhésion large et homogène. Les quatre items concernés se situent tous nettement au-dessus du point neutre : la *détection de signaux faibles* arrive en tête (4,01 ; 72 % d'accord), suivie de la *requête en langage naturel* (3,90), des *systèmes prédictifs* (3,84) et de l'*identification automatique des drivers* (3,77). Le fait que la capacité la plus désirée soit aussi la plus difficile à outiller, la détection de signaux faibles, dessine précisément l'espace où se joue la promesse des systèmes décisionnels de nouvelle génération.

10.4 Confiance, transparence et automation bias : le paradoxe du décideur

Le contraste avec la section précédente est frappant. Alors que les répondants désirent ces capacités, leur *confort à s'appuyer sur une IA* pour des décisions importantes reste modéré (3,27 ; 41 % seulement à l'aise, contre 22 % mal à l'aise et un tiers de neutres). Cet écart entre un désir élevé et une confiance mesurée est l'un des résultats les plus nets de l'enquête, et le socle empirique du « paradoxe du décideur » que la partie qualitative viendra éclairer.

Deux exigences dominent le versant éthique. L'*importance de la transparence et de l'explicabilité* est le score le plus élevé de toute l'enquête (4,22 ; 79 % d'accord), tandis que l'acceptation de l'IA *si elle améliore la performance* est également forte (3,85 ; 65 %). La préoccupation vis-à-vis des biais est plus modérée et partagée

(3,47 ; 51 %). Ce paysage prépare l'analyse relationnelle : ces exigences se contredisent-elles, ou coexistent-elles ?

10.5 Structure des attitudes et corrélations

Une analyse en composantes principales sur les 18 items révèle une structure attitudinale modeste mais interprétable (six valeurs propres supérieures à 1 selon le critère de Kaiser, 1960 ; les quatre premières composantes expliquent 42,5 % de la variance). Deux dimensions se détachent : une première composante d'appétit pour l'augmentation (saturée par les items de valeur des capacités et l'acceptation liée à la performance) et une seconde de confort et confiance (saturée positivement par les items de confort, négativement par la préoccupation des biais). Les coefficients de cohérence interne restant faibles à modérés (alpha de Cronbach de 0,48 à 0,63), ces dimensions ont été analysées au niveau des items plutôt qu'agrégées en scores composites, choix plus prudent statistiquement (Field, 2018). Cette analyse doit toutefois être fortement relativisée : les indices de factorabilité usuels (mesure KMO, test de sphéricité de Bartlett) n'ont pas été calculés, aucune rotation ni analyse parallèle n'a été conduite, et les charges factorielles détaillées ne sont pas reportées. Compte tenu par ailleurs de la faiblesse des cohérences internes, cette exploration est présentée à titre purement indicatif et ne fonde aucune des conclusions du chapitre.

Les corrélations entre items (figure 7) livrent trois résultats contre-intuitifs, essentiels pour la discussion.

Un avertissement statistique s'impose sur l'ensemble de cette section : le nombre de tests conduits (corrélations entre dix-huit items, comparaisons de sous-groupes multiples) accroît mécaniquement le risque de faux positifs, et aucune correction pour comparaisons multiples n'a été appliquée. Les relations rapportées doivent donc être considérées comme exploratoires ; seules les plus fortes et les plus cohérentes avec le volet qualitatif sont discutées.

- *Premièrement*, l'exigence de transparence est totalement indépendante du confort à s'appuyer sur l'IA ($r = -0,01$; non significatif) : vouloir de la transparence n'est pas un frein à la confiance, mais une condition posée en parallèle.

- *Deuxièmement*, le fameux paradoxe transparence contre performance n'oppose pas deux camps : l'importance de la transparence et l'acceptation liée à la performance sont *positivement* corrélées ($r = +0,23$; $p = 0,003$). Ce sont les mêmes personnes qui veulent les deux.
- *Troisièmement*, contrairement à l'intuition d'un rejet par ceux qui désirent le plus, le désir de capacités augmentées et le confort à s'y appuyer varient dans le même sens ($r = +0,29$; $p < 0,001$; confort moyen de 3,54 chez les plus demandeurs contre 2,95 chez les moins demandeurs). L'écart désir-confiance est donc un phénomène *agrégé*, à l'échelle de la population, et non un conflit intérieur au niveau de l'individu. Le tableau 4 synthétise ces relations.




Figure 7. Matrice des corrélations de Pearson entre les 18 items.

Relation	Coefficient	p	Lecture
Transparence × Confort IA	$r = -0,01$	n.s.	Transparence : condition, pas frein
Transparence × Acceptable si perf.	$r = +0,23$	0,003	Les deux exigences coexistent
Désir de capacités × Confort IA	$r = +0,29$	$< 0,001$	Désir et confiance vont de pair
Confort × Acceptable si perf.	$r = +0,33$	$< 0,001$	Cohérence de l'ouverture à l'IA

Contexte absent × Acceptable si perf.	$r = +0,34$	$< 0,001$	Le point de douleur nourrit l'acceptation
Français vs English (Confort)	$d = 0,71$	$< 0,001$	Anglophones nettement plus réservés
Technique vs Métier (BI descriptive)	$d = 0,47$	$0,003$	Les techniques plus critiques de la BI
Taille d'organisation × BI descriptive	$\rho = +0,19$	$0,009$	Plus l'organisation est grande, plus la BI paraît descriptive

Tableau 4. Corrélations et effets de sous-groupes notables ($n = 168$ à 193 selon les items).

10.6 Ce qui distingue, et ce qui ne distingue pas, les répondants

L'analyse par sous-groupes réserve la surprise la plus marquée de l'enquête (figure 8). La différence la plus forte n'oppose pas les métiers aux techniciens, mais les *langues* : les répondants anglophones se déclarent nettement moins à l'aise à l'idée de s'appuyer sur l'IA que les francophones (2,73 contre 3,48 ; $d = 0,71$; $p < 0,001$), soit un effet de taille importante. Ce résultat doit être interprété avec prudence, car la langue est ici confondue avec la composition de l'échantillon (rôles, régions, canaux de diffusion).

Entre profils techniques et métier, une seule différence est significative, mais elle est parlante : les techniciens jugent la BI *plus fortement descriptive* que les décideurs (4,06 contre 3,61 ; $d = 0,47$; $p = 0,003$). Ceux qui connaissent le mieux les outils en perçoivent le plus nettement les limites. En revanche, le confort à s'appuyer sur l'IA ne diffère pas significativement entre les deux groupes. Enfin, plus l'organisation est grande, plus la BI est perçue comme descriptive ($\rho = +0,19$; $p = 0,009$).

Les résultats non significatifs méritent également d'être signalés, à condition d'être interprétés correctement. Ni le fait de travailler uniquement sur Excel, ni l'intensité d'usage des outils de BI, ni l'âge ne produisent de différence statistiquement significative sur la perception du plafond décisionnel. Il serait toutefois erroné d'en conclure à une équivalence entre ces groupes : l'absence de preuve d'une différence n'est pas la preuve d'une absence de différence, et seule une procédure d'équivalence, ou l'examen d'intervalles de confiance, permettrait de l'établir. Ces résultats sont donc simplement compatibles avec l'hypothèse d'un plafond perçu de façon transversale, sans la démontrer.




Figure 8. Deux différences significatives entre sous-groupes (barres d'erreur : erreur-type).

10.7 Gouvernance et responsabilité perçue

Le volet catégoriel de l'enquête éclaire les attentes de gouvernance (figure 9). Interrogés sur la responsabilité en cas de décision gravement erronée d'une IA, les répondants désignent en majorité le *décideur humain qui utilise le système* (51 %), loin devant les concepteurs de l'IA (22 %), une responsabilité partagée (17 %) ou l'entreprise déployant l'outil (10 %). La responsabilité est donc imputée à l'usage plus qu'à la conception, un résultat cohérent entre profils techniques et métier.

Sur l'explicabilité, une majorité de 68 % estime qu'une décision doit pouvoir s'expliquer pour être légitime, tandis que 32 % acceptent une décision opaque si elle est fiable. Fait notable, cette position est *indépendante* du confort à s'appuyer sur l'IA (3,24 contre 3,22 ; $p = 0,92$) : l'exigence d'explicabilité relève d'un principe, non d'une méfiance.

Trois convictions, enfin, dessinent une forme de lucidité déclarée sur les risques. 81 % des répondants se disent d'accord avec l'idée qu'un système très précis réduit progressivement la propension à remettre en question ses conclusions ; 72 % anticipent que les organisations délègueront des décisions à des systèmes qu'elles ne comprennent pas pleinement ; et 87 % estiment que l'IA influencera à terme la définition même d'une « bonne décision ». Ces chiffres mesurent un accord avec des formulations relativement suggestives, et non un comportement observé : ils indiquent que les répondants savent nommer le mécanisme de l'automation bias, non qu'ils y résistent effectivement. Sous cette réserve, ils suggèrent que les

répondants ne sont pas naïfs : ils désirent l'augmentation tout en nommant précisément ses dangers.




Figure 9. Responsabilité perçue et convictions sur la gouvernance de l'IA décisionnelle.

10.8 Synthèse et limites

En synthèse, l'enquête documente une perception convergente qui soutient le diagnostic de la thèse : la BI est perçue comme descriptive et bute sur un plafond largement partagé ; les capacités augmentées sont fortement désirées, la détection de signaux faibles en tête ; et la transparence s'impose comme l'exigence numéro un. Elle apporte surtout trois enseignements moins attendus : le désir de capacités et le confort à s'y fier progressent ensemble, si bien que l'écart désir-confiance est un phénomène de population et non un conflit individuel ; l'exigence de transparence est une condition posée en parallèle du confort, non un frein ; et les répondants savent nommer le mécanisme de l'automation bias, auquel 81 % déclarent adhérer. Ces résultats portent sur des perceptions déclarées : ils rendent le diagnostic plausible et répandu, sans en établir la portée structurelle.

Ces résultats appellent la prudence. L'échantillon, volontaire et jeune, n'est pas représentatif, et le déséquilibre entre répondants francophones et anglophones interdit de tirer des conclusions culturelles fermes. Les données sont transversales et déclaratives, exposées aux biais de perception et de désirabilité. Enfin, le grand nombre de tests exploratoires invite à ne retenir que les effets robustes et à traiter les corrélations faibles comme des pistes, non comme des preuves. C'est précisément le rôle du volet qualitatif, présenté au chapitre 11, que d'éclairer les mécanismes derrière ces tendances.

Chapitre 11. Résultats des entretiens qualitatifs

Si l'enquête quantitative mesure la prévalence des phénomènes, les entretiens en éclairent les mécanismes et, surtout, permettent de répondre à la question que la Partie I laissait ouverte : le cadre conceptuel assemblé au chapitre 7 est-il *faissable* ? Ce chapitre confronte l'architecture d'un système décisionnel AI-native à la parole de praticiens qui, chacun à sa place, la construisent, la financent, la subissent ou la piloteraient. Il en ressort un verdict nuancé, mais remarquablement convergent : le cadre est désirable et directionnellement juste, mais sa faisabilité se joue bien moins dans la technologie que dans le socle organisationnel qui la porte.

11.1 Corpus, profils et démarche d'analyse

Neuf entretiens semi-directifs ont été conduits, transcrits puis analysés selon la méthode d'analyse thématique de Braun et Clarke (2006), avec un codage combinant des thèmes déductifs, issus du cadre conceptuel, et des thèmes émergents. Les personnes interrogées se répartissent en trois profils, conformément au design de la recherche : trois profils techniques très seniors, deux business analysts et quatre profils métier (tableau 5). Les verbatims sont cités de façon anonymisée, par le seul poste, et légèrement édités pour la lisibilité ; les transcriptions intégrales figurent en Annexe E. Les codes (T pour technique, BA pour business analyst, M pour métier) permettent de suivre les convergences et divergences entre profils, qui constituent un objectif d'analyse à part entière.

Code	Poste	Secteur	Séniorité
T1	Directeur de programme IA	Protection sociale	Très senior
T2	Architecte logiciel & IA senior	Édition de solutions pour le voyage	Très senior
T3	Fondateur & CEO d'une société deep-tech	Vision par ordinateur & IA générative	Très senior
BA1	Directeur Market Intelligence	Équipements de la maison	Senior
BA2	Business Analyst / Solutions Architect	E-commerce international	Junior
M1	Directrice crédit & recouvrement	Maintenance IT durable (Green IT)	Senior
M2	Contrôleuse de gestion senior	Distribution automobile	Senior
M3	Digital Product Manager	Transport aérien	Junior
M4	Ingénieur calcul & QSSE / gestion des risques	Sidérurgie / automobile	Junior

Tableau 5. Profil des neuf personnes interrogées.

11.2 Le plafond décisionnel, une expérience unanime

Le diagnostic de départ de la thèse, le *plafond de complexité décisionnelle*, ressort des neuf entretiens avec une force inattendue, et souvent de manière spontanée, avant même toute introduction des concepts. La formule qui revient, presque mot pour mot, oppose le *quoi* au *pourquoi*. Les outils signalent qu'un indicateur a bougé ; ils n'en disent jamais la cause.

« Les chiffres sont excellents pour le « quoi » et le « où ». Ils sont à peu près inutiles pour le « pourquoi ». Chaque fois qu'il s'agit de la cause, je dois quitter le tableau de bord et aller parler à un humain qui a le contexte que la donnée ne capture pas. » (BA2, Business Analyst)

« Les chiffres vont suffire pour identifier qu'il y a un problème. Ils ne vont pas suffire pour comprendre la cause derrière, et ça, c'est mon métier, ma responsabilité de creuser. » (M3, Product Manager)

Le constat traverse tous les profils, du contrôle de gestion (« côté interprétation, c'est à nous de le faire, c'est notre métier », M1) au market intelligence (« on ne sait pas pourquoi ça bouge », BA1) jusqu'aux profils techniques, pour qui le *root-cause* automatisé reste un mirage : « dans quatre-vingt-quinze pour cent des cas, c'est un humain qui ouvre son tableau, descend niveau par niveau et appelle deux collègues » (T1). Le plafond n'est donc pas une hypothèse de chercheur : c'est le quotidien vécu, et l'enquête qualitative le documente de façon convergente dans le corpus.

11.3 « 80 % humain, 20 % technique » : où se joue vraiment la faisabilité

Le résultat le plus structurant de tout le corpus tient dans une phrase, prononcée par le profil le plus senior, et confirmée en substance par presque tous les autres.

« Le problème est à quatre-vingts pour cent humain et organisationnel, et à vingt pour cent technique. Et tout le monde passe quatre-vingts pour cent de son énergie sur les vingt pour cent techniques. » (T1, Directeur de programme IA)

Cette formule doit être reçue pour ce qu'elle est : une citation emblématique, frappante parce qu'elle condense une intuition partagée, et non une proportion établie empiriquement. Aucune mesure de ce partage n'a été conduite ; sa valeur est rhétorique et heuristique, non statistique.

Ce déplacement du regard, de la technologie vers son socle, est la clé de voûte du chapitre. Interrogés sur ce qui bloque le passage du descriptif au prescriptif, aucun des profils techniques ne cite en premier le modèle ou la puissance de calcul. Tous citent la *donnée gouvernée*. Le fondateur deep-tech est catégorique : « le compute, c'est le moindre de nos soucis, on en a à revendre ; le mur, c'est la donnée propre et gouvernée » (T3). La même idée se retrouve, formulée en termes de métier, chez le business analyst : « tout ce système ne vaut que ce que valent la donnée et les définitions qui le nourrissent, et j'ai vu à quel point cette couche est sale, même dans une entreprise très pilotée par la donnée » (BA2).

La conséquence sur la faisabilité est directe : le facteur limitant n'est pas la maturité des algorithmes, mais la capacité de l'organisation à produire et surtout à *entretenir* des fondations propres. Or cette maintenance est précisément ce que personne ne finance, un angle mort que la littérature sur la dette technique des systèmes d'apprentissage documente depuis longtemps (Sculley et al., 2015) et que T1 résume d'une image : « construire, c'est facile ; maintenir dix ans, c'est ce qui tue, et personne ne budgète la maintenance ».

11.4 Représenter l'entreprise : world model et ontologie à l'épreuve du terrain

Le cœur théorique de la thèse, le world model organisationnel et son incarnation, l'ontologie, est aussi l'endroit où le terrain se montre le plus lucide. Le concept est jugé juste, mais sa faisabilité à l'échelle de l'entreprise entière est fermement relativisée.

Deux limites de principe reviennent chez les profils techniques. La première tient à la nature même de l'organisation. « Un système physique a des dynamiques stables ; la gravité ne change pas d'avis le mardi. Une organisation est non-stationnaire et réflexive : au moment où vous déployez un modèle qui prédit ce que l'organisation va faire, les gens le contournent, et vos dynamiques se dérobent sous vos pieds » (T3). Cette *non-stationnarité* trouve un écho frappant, en langage métier, chez la Product Manager : « il y a un aspect de fausse précision, parce que la capacité de mes équipes n'est pas stable, la décision de dernière minute d'un partenaire non plus » (M3). La seconde limite concerne les sous-modèles les plus difficiles. Interrogés sur la décomposition d'ElixirData (entités, processus, autorité, règles, terminologie), les deux profils techniques désignent spontanément les mêmes points durs :

« Les deux qui tuent, c'est l'autorité et les règles. Qui a le droit de décider quoi, dans une vraie boîte, ce n'est jamais écrit proprement : il y a l'organigramme officiel, et il y a comment ça marche vraiment. Et les règles se contredisent, changent avec le dernier mail du directeur. » (T1, Directeur de programme IA)

La raison est technique autant qu'organisationnelle : ces sous-modèles sont *non observés*, donc impossibles à apprendre proprement, faute de signal d'entraînement. À quoi s'ajoute la temporalité, « une relation vraie aujourd'hui ne l'était pas hier » (T2), et la maintenance, qui condamne les référentiels figés. Quant au « digital twin » vendu par les plateformes, il déclenche la même réaction ironique chez les deux profils techniques : « quand j'entends digital twin de l'organisation, ma main se pose sur mon portefeuille » (T1) ; « c'est du marketing, Palantir sont d'excellents marketeurs » (T3). Le concept est noté « dix sur dix », la facilité de mise en œuvre promise « deux sur dix » (T1).

De cette lucidité émerge pourtant une voie de faisabilité claire, et convergente : l'ontologie est nécessaire à terme, mais elle ne doit jamais être construite en une fois.

« Ne passez pas trois ans à bâtir l'ontologie parfaite de toute l'entreprise avant de livrer quoi que ce soit. Vous mourrez avant. Construisez par petits bouts, cas d'usage par cas d'usage, là où vous en avez besoin. » (T3, Fondateur & CEO deep-tech)

Fait notable, la représentation partagée n'est pas un fantasme de chercheur pour les métiers : plusieurs la vivent déjà. L'ingénieur en simulation observe que « le jumeau numérique, on travaille déjà dessus, mais sur un élément physique ; c'est la première fois que je vois l'idée à l'échelle macro de l'entreprise » (M4). Et le problème de terminologie que l'ontologie prétend résoudre est décrit spontanément par presque tous, du business analyst (« deux équipes utilisaient le même mot pour deux définitions différentes ; on a perdu du temps et un peu de confiance dans toutes les données ») au market intelligence, qui note toutefois l'avoir *dompté* par un processus discipliné : « on a des appellations différentes, mais on est intransigeants sur la collecte, donc ça ne nous coûte rien » (BA1). Preuve que le point dur de l'ontologie est moins de la modéliser que de la *gouverner* dans la durée.

11.5 Décider avec l'IA : l'autonomie graduée et le refus de la boîte noire

Sur la confiance à accorder à un système décisionnel, le corpus fait apparaître un principe partagé, énoncé indépendamment par les neuf personnes, quel que soit leur

profil : la confiance n'est jamais binaire, elle se *gradue*. Le critère n'est pas la performance du modèle, mais les conséquences d'une erreur.

« Le critère, ce n'est pas « est-ce que le modèle est bon ». C'est « qu'est-ce qui se passe le jour où il se trompe, et qui paie ». Parce qu'il se trompera. La question, ce n'est jamais si, c'est quand. » (T1, Directeur de programme IA)

De ce principe découle une règle d'automatisation que les deux profils techniques formulent à l'identique, et qui inverse l'intuition commune : « automatisez le volume ennuyeux, répétitif et réversible, et gardez vos humains pour les cas rares et lourds ; c'est exactement l'inverse de ce que les gens ont envie de faire » (T3, en écho à T1). Les métiers arrivent au même partage par un autre chemin, celui du refus de déléguer la décision qui les engage : « un outil qui m'aide, oui ; un outil de décision, non ; en tant que PM responsable, je garde le rôle de validation » (M3) ; « je ne suis pas preneuse pour reposer toute une décision d'entreprise là-dessus » (M1). Le mot qui revient est celui de *copilote*, jamais celui de décideur.

Les profils techniques ajoutent un critère de confiance plus original, et convergent : la capacité du système à *s'abstenir*. « Je fais dix fois plus confiance à un système qui, sur les vingt pour cent de cas incertains, lève la main et dit “celui-là, humain, occupe-t'en”, qu'à un système qui a toujours une réponse » (T1). Le fondateur deep-tech en fait sa signature : « un modèle bien calibré qui sait dire “je ne suis pas sûr, escaladez” vaut dix points de précision brute, parce que le modèle simplement plus précis vous tue exactement sur le cas rare, silencieusement, l'air sûr de lui » (T3). Cette exigence de calibration trouve son pendant, côté métier, dans une méfiance instinctive envers l'assurance uniforme : « un outil toujours sûr à cent pour cent me paraît moins fiable, pas plus » (BA2).

11.6 Le piège du « contrôle humain de façade »

Sur l'automation bias, les entretiens apportent la contribution la plus opérationnelle du corpus. Les profils techniques ne se contentent pas de reconnaître le risque, ils en identifient l'anti-pattern précis, celui qui ruine la garantie que l'on croit apporter en plaçant un humain « dans la boucle ».

« Le pire, c'est le human-in-the-loop de façade : vous mettez un humain censé valider, mais vous lui donnez trois secondes, deux cents cas par heure, et un système qui a raison quatre-vingt-quinze pour cent du temps. Au bout d'une semaine, il tamponne. Vous avez l'illusion d'un contrôle, et zéro contrôle réel. » (T1, Directeur de programme IA)

Ce diagnostic, formulé presque à l'identique par T3, prolonge et précise la littérature sur la complaisance face à l'automatisation (Parasuraman et Manzey, 2010) : le danger n'est pas la machine qui se rebelle, mais l'humain qui abdique par surcharge et par fatigue. Sa portée pour la faisabilité est considérable, car il retourne l'argument habituel : ajouter un humain ne suffit pas, encore faut-il ne pas le noyer. Le garde-fou proposé rejoint d'ailleurs le critère d'abstention de la section précédente : « si vous voulez un vrai contrôle humain, donnez-lui peu de cas, du temps, et les bons cas ; dix cas difficiles par jour gardent un humain vigilant, deux cents tampons non » (T1). Les métiers, eux, vivent la version ordinaire du biais : le collègue qui « ne pense plus, prend ce que l'outil lui donne et l'applique, c'est sa Bible » (M1), ou le tableau de bord alarmant qui n'était qu'un défaut de chargement, où le business analyst a eu raison *contre* l'outil (BA2). L'enquête quantitative confirmait déjà cette lucidité collective : 81 % des répondants reconnaissaient le mécanisme.

11.7 Transparence, responsabilité et conditions organisationnelles

L'exigence de transparence et d'explicabilité, première du volet quantitatif, est unanime dans les entretiens, mais les praticiens en précisent la fonction et les limites. Pour le business analyst, l'explicabilité n'est pas qu'une case éthique : « si vous ne pouvez pas expliquer pourquoi le système a dit X, alors quand X se révèle faux, vous n'avez rien appris » (BA2). Autrement dit, elle conditionne la boucle d'apprentissage elle-même. L'ingénieur QSSE la relativise selon la criticité, exemple du scandale des airbags défectueux à l'appui : « ça dépend de l'exigence ; dans l'automobile de sécurité, je ne ferai jamais confiance aveuglément à une décision générée par l'IA » (M4). Et les profils techniques pointent le piège de l'explication *a posteriori* : « une explication fabriquée après coup pour justifier une décision déjà prise, c'est exactement ce que fait un humain de mauvaise foi ; plausible n'est pas vrai » (T3), un dilemme dont seul un modèle causal, explicable par construction, sortirait vraiment, mais « le construire, on sait très mal le faire » (T1).

Sur la responsabilité, le corpus révèle une divergence instructive entre profils. Les techniques sont catégoriques et unanimes : la responsabilité est *humaine*, toujours. « “C'est l'IA qui a décidé” n'est pas une défense et ne doit jamais en devenir une, sinon plus personne n'est responsable de rien » (T1, T3 à l'identique) ; mieux, une responsabilité claire est vue comme « le meilleur garde-fou de tous ». Les métiers partagent le principe, mais le *distribuent* en niveaux : le décideur qui valide, l'équipe

qui a conçu le système, l'entreprise qui en assure la gouvernance (M3), voire « toute partie, y compris le système lui-même » (M1). L'ingénieur QSSE ouvre même la question, non résolue, du statut juridique de l'IA (M4). Là où le technicien cherche à verrouiller la responsabilité sur une personne, le métier tend à la répartir, ce qui dessine un vrai enjeu pour la gouvernance à construire.

Cette gouvernance, justement, est au cœur des *conditions organisationnelles* que les métiers mettent en avant, et qui prolongent la sous-question 3. Trois reviennent avec insistance. La conduite du changement d'abord : « il y aura des gens qui n'auront pas confiance, et une partie qui aura peur pour son poste » (M4), écho au « on aime rester dans notre zone de confort » de la contrôleuse de gestion (M2). La confidentialité ensuite, sous une forme paradoxale : le système a besoin de données sensibles pour être utile, mais « il y a des données clients que je ne peux pas lui donner, donc ses recommandations seront faussées » (M3), et il doit être « sécurisé, parce qu'on parle d'un jumeau de l'entreprise réelle » (M1). Le coût enfin, que l'ingénieur industriel chiffre en termes crus : « ça coûte quoi pour le maintenir ? Est-ce qu'avoir cinq ingénieurs qui simulent dix pour cent du système ne serait pas plus économique ? » (M4), lequel ajoute une dimension que nul autre ne soulève, l'empreinte énergétique et carbone du dispositif au regard des engagements environnementaux de l'entreprise, préoccupation que la littérature commence à documenter (Strubell, Ganesh et McCallum, 2019). Enfin, la vulgarisation opérée en cours d'entretien semble s'accompagner, chez plusieurs profils métier, d'une évolution favorable de leur perception du cadre : la confiance dans la *vision* s'élève à mesure qu'ils la comprennent, sans que la prudence sur les *conditions* ne faiblisse ; comme le formule le business analyst, « je suis passé de “je ne fais pas confiance à l'IA” à “je fais confiance à l'idée, mais pas au fait qu'on ait fait le travail ennuyeux pour la rendre réelle” » (BA2).

11.8 Convergences, divergences et verdict de faisabilité

La mise en regard des trois profils (figure 10) fait apparaître un noyau de convergence remarquable et quelques divergences éclairantes. Convergent, à travers tous les profils : le plafond vécu, l'autonomie graduée et le refus de la boîte noire, l'exigence de transparence et le principe d'une responsabilité humaine. Propres aux profils techniques : la lucidité sur les sous-modèles impossibles à apprendre (autorité, règles), l'abstention et la calibration érigées en critères de

confiance, et la robustesse. Propres aux métiers : l'adoption et la conduite du changement, la confidentialité, le coût et l'empreinte énergétique, ainsi qu'une responsabilité distribuée plutôt que verrouillée. Cette complémentarité valide, en creux, le choix méthodologique des deux guides : chaque profil éclaire une face que l'autre ne voit pas.

La lecture de cette matrice appelle deux précautions. Les mentions « fort » et « partiel » traduisent une appréciation qualitative du chercheur, fondée sur la récurrence et l'explicitation du thème dans les entretiens d'un même groupe, et non un décompte codé selon une règle formalisée ; elles indiquent une tendance, non une mesure. Par ailleurs, plusieurs résultats saillants, notamment le rapport entre facteurs humains et techniques, l'abstention calibrée et le contrôle humain de façade, proviennent principalement de deux interlocuteurs (T1 et T3), les plus seniors du corpus : leur poids dans l'analyse est donc supérieur à celui des autres profils, ce qui invite à les considérer comme des hypothèses fortes plutôt que comme des constats partagés par l'ensemble des personnes interrogées.

Convergence des thèmes selon le profil des personnes interrogées

	Technique (n=3)	Business Analyst (n=2)	Métier (n=4)
Plafond vécu : « le quoi, jamais le pourquoi »	fort	fort	fort
Donnée gouvernée = mur fondateur	fort	fort	partiel
Ontologie par morceaux (big-bang à proscrire)	fort	partiel	
Autorité, règles, temporalité = points durs	fort		
Non-stationnarité / « fausse précision »	fort	partiel	partiel
Autonomie graduée (« copilote, pas décideur »)	fort	fort	fort
Abstention / calibration (« savoir dire je ne sais pas »)	fort	partiel	partiel
Automation bias / contrôle humain de façade	fort	fort	partiel
Transparence & explicabilité = condition	fort	fort	fort
Responsabilité humaine	fort	fort	fort
Adoption, conduite du changement, confidentialité	partiel	partiel	fort
Coût, maintenance (TCO), empreinte énergétique	fort		fort

Figure 10. Matrice de convergence thématique selon le profil des personnes interrogées.

Que conclure sur la faisabilité du cadre assemblé au chapitre 7 ? La figure 11 en propose une lecture, couche par couche, à la lumière du terrain. Le *paradigme* de la Decision Intelligence, remettre la décision au centre plutôt que la donnée, fait consensus et ne coûte rien à adopter : il est mûr. La couche des *agents et copilotes* est jugée mûre en assistance, mais pas en décision autonome : « copilote, pas décideur ». La couche *ontologique* est faisable, mais seulement construite par morceaux et à condition d'en financer la maintenance. Les couches les plus ambitieuses, le *raisonnement causal* et la *simulation* à l'échelle de l'entreprise, restent de l'ordre de la recherche ou du cap : réalistes sur des sous-domaines bornés, prématurées sur « la boîte » entière. Et sous tout l'édifice, la couche des *données gouvernées* apparaît comme le mur réel, le point de convergence numéro un, celui dont dépend tout le reste. La gouvernance et la responsabilité humaine, enfin, ne sont pas une couche parmi d'autres mais la condition transversale de l'ensemble.




Figure 11. L'architecture d'un système décisionnel AI-native à l'épreuve du terrain : verdict de faisabilité par couche.

Le verdict d'ensemble est donc ni un rejet, ni une adhésion naïve, mais une *faisabilité conditionnelle et incrémentale*. Le cadre théorique de la Partie I n'est pas démenti par le terrain : il est validé dans sa direction et dans sa valeur, mais

réordonné dans ses priorités. Ce que la littérature présentait comme le sommet, le world model qui simule tout, le terrain le renvoie à la recherche ; ce que la littérature traitait comme un préalable technique, la donnée gouvernée et la maintenance, le terrain l'érige en facteur décisif de réussite ou d'échec. La contribution de ce chapitre est là : montrer que la faisabilité d'un système décisionnel AI-native ne se décrète pas au sommet de la pile, par la sophistication de l'IA, mais se gagne à la base, par un travail patient et peu spectaculaire sur les données, la gouvernance et la confiance. C'est ce réordonnement des priorités que le chapitre 12 traduira en recommandations managériales.

Partie III. Discussion et contributions

Chapitre 12. Synthèse croisée et modèle intégré

Ce chapitre accomplit la promesse du design mixte : les deux volets empiriques, analysés séparément aux chapitres 10 et 11, sont ici mis en dialogue. Il ne s'agit plus de mesurer ni de raconter, mais de *croiser*, pour répondre aux quatre sous-questions de recherche et pour réviser, à la lumière du terrain, le cadre intégré proposé au chapitre 7. Rappelons la distinction, essentielle à la crédibilité de l'ensemble : le chapitre 7 *proposait* un modèle reconstruit de la littérature ; ce chapitre le *confronte* aux données et en dégage une version consolidée.

Une précision liminaire encadre tout ce qui suit. Le questionnaire mesure des perceptions : limites ressenties de la BI, désir de capacités augmentées, confiance, exigences de transparence et convictions éthiques. Il n'évalue pratiquement pas les world models, l'ontologie, la causalité ou l'architecture en couches en tant que dispositifs techniques. Les résultats quantitatifs sont donc compatibles avec le diagnostic posé en Partie I et soutiennent la pertinence perçue du cadre, mais ils ne constituent en aucun cas une validation expérimentale de son architecture. Cette distinction vaut pour l'ensemble des réponses aux sous-questions présentées ci-après.

12.1 Le principe de la synthèse croisée

La démarche relève de la triangulation convergente (Creswell & Plano Clark, 2018). Les deux volets abordent les mêmes phénomènes sous des angles complémentaires : le quantitatif établit la *prévalence* d'une perception à large échelle, le qualitatif en révèle les *mécanismes* et les logiques d'action. Leur intégration ne consiste pas à additionner deux rapports, mais à les faire se répondre, selon trois modes : la *confirmation* (les deux volets pointent dans le même sens), l'*explication* (le qualitatif donne le pourquoi d'un résultat chiffré) et la *nuance* (un volet corrige ou précise l'autre). Le tableau 6 en propose une lecture synthétique sous la forme d'un affichage conjoint (Fetters, Curry & Creswell, 2013), qui met en regard, thème par thème, ce qu'établit chaque volet et l'enseignement intégré qui en résulte.

12.2 Convergences : ce que les deux volets établissent ensemble

Quatre résultats ressortent de manière concordante des deux volets ; leur convergence méthodologique en fait les constats les plus solides de ce travail, étant entendu qu'ils portent sur des perceptions et non sur des performances mesurées. D'abord, le plafond de complexité décisionnelle : confirmé par 66 % des répondants au questionnaire jugeant la BI descriptive plutôt qu'explicative, il est vécu à l'unanimité dans les entretiens, sous la forme récurrente du « quoi sans le pourquoi ». Ensuite, l'exigence de transparence : première du volet quantitatif (4,22 sur 5 ; 79 % d'accord), elle est unanime dans les entretiens. Troisièmement, le maintien de la responsabilité humaine : plébiscité dans l'enquête (51 % l'imputent au décideur humain) et posé comme un principe dans les entretiens. Enfin, la confiance graduée : le confort modéré mesuré par l'enquête (3,27 ; 41 % seulement à l'aise) trouve son explication directe dans le principe, martelé en entretien, du « copilote, pas décideur ». Ces convergences ne sont pas triviales : elles montrent que, par-delà la diversité des profils et des méthodes, un socle de perceptions partagées existe bel et bien.

12.3 Ce que le qualitatif explique du quantitatif

La valeur propre de la synthèse tient toutefois moins aux convergences qu'à la capacité du qualitatif à *expliquer* les résultats chiffrés, y compris les plus contre-intuitifs. Le tableau 6 en rassemble les principaux.

Résultat quantitatif	Éclairage qualitatif	Enseignement intégré
BI descriptive à 66 % ; causes profondes non comprises (partagé)	« Le quoi, jamais le pourquoi » ; le root-cause reste humain à 95 %	Le plafond est une limite d'outillage structurelle, pas une cécité : réel et vécu
Confort modéré (3,27) mais désir et confort corrélés positivement ($r = +0,29$)	« Copilote, pas décideur » ; autonomie graduée selon réversibilité et enjeu	L'écart désir-confiance n'est pas un rejet mais une demande d'augmentation contrôlée
Transparence indépendante du confort ($r = -0,01$)	La transparence est une condition posée en parallèle, non un frein ; elle nourrit l'apprentissage	La transparence est une précondition de légitimité, pas un obstacle à l'adoption
Paradoxe transparence × performance ($r = +0,23$, positif)	Les mêmes personnes veulent les deux ; expliquer la décision même si un composant est opaque	Non un arbitrage entre deux camps, mais une double exigence à satisfaire au niveau du système
81 % reconnaissent le mécanisme de l'automation bias	Anti-pattern du « contrôle humain de façade » (surcharge → tamponnage)	La lucidité est élevée, mais le garde-fou naïf échoue : il faut l'abstention et ne pas noyer l'humain
Techniques plus critiques de la BI ($d = 0,47$) ; nuls pour outils, âge	Complémentarité technique ↔ métier ; plafond partagé par tous	Les divergences portent sur la profondeur du diagnostic et les conditions, pas sur le noyau

Tableau 6. Affichage conjoint (joint display) : mise en dialogue des volets quantitatif et qualitatif.

Trois de ces croisements méritent d'être soulignés. Le premier lève une ambiguïté : l'écart entre un fort désir de capacités et un confort mesuré, que l'on pourrait lire comme une méfiance, se révèle être une demande d'*augmentation sous contrôle*, le désir et le confort progressant même de pair au niveau individuel. Le deuxième dissout un faux paradoxe : transparence et performance ne s'opposent pas dans deux camps, ce sont les mêmes acteurs qui exigent les deux, ce que le qualitatif traduit par l'idée d'une décision explicable même lorsqu'un composant ne l'est pas. Le troisième est le plus opérationnel : la lucidité massive sur l'automation bias (81 %) ne protège de rien si le garde-fou reste naïf, car ajouter un humain surchargé produit un tamponnage. La combinaison des deux volets transforme ainsi des chiffres isolés en enseignements actionnables.

12.4 Réponses aux quatre sous-questions de recherche

Sous-question 1 (diagnostic). Les limites de la BI descriptive et le plafond de complexité décisionnelle sont documentés de façon convergente par les deux volets. Le plafond n'apparaît pas comme un simple artefact théorique : il se manifeste, dans les perceptions recueillies, par un outillage qui décrit sans expliquer, une interprétation causale laissée à l'humain et une donnée fragmentée. La réponse est donc que le plafond est largement perçu, de manière transversale aux secteurs, aux outils et aux âges de l'échantillon ; son caractère structurel et universel, lui, resterait à établir par des mesures objectives de performance décisionnelle.

Sous-question 2 (architecture). L'intégration des world models, des ontologies et du raisonnement causal constitue une architecture cohérente, et sa direction est validée. Mais sa faisabilité est *inégaie selon les couches* : le paradigme decision-centric et les copilotes en assistance sont mûrs ; l'ontologie est faisable à condition d'être construite par morceaux ; le raisonnement causal reste un cap ; et le world model simulant l'entreprise entière demeure de l'ordre de la recherche, buté sur la non-stationnarité et la rareté des données de cascades. L'architecture tient, mais pas au rythme ni dans l'ordre que la littérature suggérerait.

Cette réponse reste toutefois de nature perceptuelle et experte : elle s'appuie sur le jugement de praticiens et sur la cohérence interne du cadre, non sur la mise en

œuvre et la mesure d'un système réel. La validité technique de l'architecture demeure, à ce stade, une hypothèse argumentée.

Sous-question 3 (conditions de possibilité). C'est ici que le terrain apporte le plus. Les conditions décisives ne sont pas technologiques : donnée gouvernée et maintenue dans la durée, gouvernance claire, conduite du changement, confidentialité, maîtrise du coût complet et de l'empreinte énergétique, et confiance gagnée par l'usage. L'effet de la vulgarisation observé en entretien le confirme : mieux comprendre le cadre en élève l'acceptabilité tout en aiguisant la conscience de ces conditions.

Sous-question 4 (éthique et gouvernance). La transparence s'impose comme condition première de légitimité ; l'automation bias est reconnu mais résiste aux garde-fous naïfs ; la responsabilité doit rester humaine, avec une tension féconde entre une vision technique qui la *verrouille* sur une personne et une vision métier qui la *distribue* entre décideur, concepteur et entreprise. La gouvernance n'est pas une option ajoutée, mais la colonne transversale de tout l'édifice.

12.5 Le modèle intégré, révisé par le terrain

Que devient, au terme de cette confrontation, le cadre du chapitre 7 ? Il n'est ni renversé ni simplement confirmé : il est *réordonné*. La littérature, et le discours ambiant, concentrent l'attention sur le sommet de la pile, le world model, l'IA générative, les agents, ce que l'un des experts appelait « les mots qui brillent ». Or le terrain déplace le centre de gravité vers la base. Ce que la théorie traitait comme un préalable technique presque trivial, la donnée gouvernée et sa maintenance, devient le facteur décisif de réussite ou d'échec ; ce qu'elle plaçait au sommet devient un horizon directionnel plutôt qu'un livrable immédiat. La figure 12 illustre ce réordonnement : l'attention et l'investissement perçu se portent vers le haut, tandis que le levier réel de faisabilité se situe en bas.




Figure 12. Le modèle intégré révisé : le réordonnancement des priorités opéré par le terrain.

Le modèle intégré consolidé conserve donc l'architecture en couches, mais l'assortit de cinq principes que le terrain a fait émerger. Premièrement, une *construction ascendante et incrémentale* : on part de la donnée gouvernée et l'on modélise l'ontologie cas d'usage par cas d'usage, jamais en big-bang. Deuxièmement, une *gouvernance transversale* portée par une responsabilité humaine clairement établie. Troisièmement, une *autonomie graduée*, calée sur la réversibilité, l'enjeu et le volume, avec le principe du copilote plutôt que du décideur. Quatrièmement, *l'abstention et la calibration* érigées en primitives de confiance : un système qui sait dire « je ne sais pas » vaut mieux qu'un système plus précis mais aveugle sur ses limites. Cinquièmement, le *world model comme cap* et non comme promesse immédiate, réaliste sur des sous-domaines bornés. Le cadre passe ainsi d'une ambition descendante à une *faisabilité conditionnelle et incrémentale*.

12.6 Contributions théoriques

Au regard de la littérature, ce travail apporte plusieurs contributions. La première est le cadre intégré lui-même : penser le world model, l'ontologie, la causalité, la Decision Intelligence et la gouvernance non comme des champs séparés, mais comme les couches d'un même système décisionnel, articulées par une chaîne allant de la donnée à la décision. La deuxième, plus originale, est le réordonnancement

des priorités que suggère le terrain : l'argument, convergent dans le corpus, selon lequel la faisabilité d'un tel système se joue d'abord à la base (donnée, gouvernance, confiance) plutôt qu'au sommet (sophistication de l'IA), ce que résume la formule emblématique d'un expert, « quatre-vingts pour cent humain, vingt pour cent technique ». La troisième est la mise au jour d'une complémentarité structurée entre profils : là où le technique diagnostique les limites profondes et le métier porte les conditions d'adoption, aucun des deux ne suffit seul, ce qui justifie a posteriori le double guide d'entretien.

À ces contributions s'ajoutent plusieurs concepts émergents, utiles au-delà de cette thèse : l'*abstention calibrée* comme dimension de la confiance à part entière ; le *contrôle humain de façade* comme anti-pattern de gouvernance, prolongeant la littérature sur l'automation bias ; la distinction entre un écart désir-confiance *agrégé* et une corrélation *individuelle* positive, qui invite à ne pas confondre prudence collective et méfiance personnelle ; et la lecture de la transparence comme *condition parallèle* plutôt que comme frein à l'adoption. Ce sont ces enseignements qui fondent les recommandations managériales du chapitre 13, dernier volet de cette partie.

Chapitre 13. Recommandations managériales et conditions de la transformation

Le chapitre précédent a montré que la faisabilité d'un système décisionnel AI-native ne se gagne pas au sommet de la pile, par la sophistication de l'IA, mais à sa base, par un travail patient sur la donnée, la gouvernance et la confiance. Ce dernier chapitre de la Partie III en tire les conséquences pratiques. Il s'adresse aux dirigeants et aux responsables qui voudraient engager cette transformation, et traduit le réordonnancement des priorités en six recommandations, une feuille de route et une lecture des facteurs de succès et d'échec. Toutes découlent directement des résultats empiriques : elles ne sont pas des prescriptions générales sur l'IA, mais les conditions que le terrain a désignées comme décisives.

13.1 Des principes aux leviers d'action

Quatre principes directeurs structurent l'ensemble. *Commencer par la base* : la donnée gouvernée est le préalable de tout, non un détail d'intendance. *Avancer par petits pas* : la valeur se livre cas d'usage par cas d'usage, jamais par un grand projet total. *Garder l'humain aux commandes* : l'IA augmente la décision, elle ne s'y

substitue pas sur ce qui engage. *Faire de la confiance un objectif, pas un présumé* : elle se construit dans la durée, par la transparence et par la preuve. Les six recommandations qui suivent opérationnalisent ces principes.

13.2 Six recommandations managériales

Recommandation 1 : traiter la donnée gouvernée comme un produit, pas comme un projet. Le résultat le plus constant de l'étude est que la donnée, et non la technologie, constitue le mur. Il convient donc d'y investir en premier : définitions partagées, qualité mesurée, propriété claire. Surtout, il faut en financer la *maintenance dans la durée*, ce que les organisations budgètent rarement et que la littérature nomme la dette technique des systèmes d'apprentissage (Sculley et al., 2015). Un référentiel construit puis abandonné diverge du réel en quelques mois et perd toute confiance. La donnée doit avoir un propriétaire, un budget récurrent et une feuille de route, comme un produit.

Recommandation 2 : construire l'ontologie par cas d'usage, jamais en big-bang. Vouloir modéliser toute l'entreprise avant d'agir est le plus sûr moyen d'épuiser un budget sans livrer de valeur, un piège que les experts techniques ont unanimement pointé. La bonne démarche part d'une décision précise, modélise juste ce qu'il faut pour l'éclairer, livre un résultat utile, puis élargit. On accepte d'emblée que les sous-modèles les plus durs, l'autorité réelle et les règles mouvantes, ne seront jamais parfaitement formalisés, et l'on concentre l'effort là où il produit de la décision.

Recommandation 3 : graduer l'autonomie, du copilote au décideur. La confiance mesurée par l'enquête est modérée (3,27 sur 5), et les entretiens en donnent la clé : les praticiens veulent un « copilote, pas un décideur ». L'autonomie doit donc se calibrer sur trois critères, la réversibilité, l'enjeu et le volume. On automatise le flux répétitif, réversible et à faible impact unitaire, où l'humain n'apporte rien ; on réserve la validation humaine aux décisions rares, lourdes ou irréversibles. C'est l'inverse de la tentation courante, qui vise à automatiser d'abord les décisions les plus intéressantes, c'est-à-dire les plus risquées.

Recommandation 4 : concevoir explicitement contre le biais d'automatisation. La lucidité ne suffit pas : 81 % des répondants reconnaissent le mécanisme, et pourtant le garde-fou le plus répandu, « mettre un humain dans la boucle », échoue lorsqu'on le noie sous les cas et qu'il finit par tamponner. Quatre parades concrètes ressortent

: faire de l'*abstention* une sortie à part entière du système, qui n'escalade vers l'humain que les cas incertains ; ne donner à l'humain que *peu de cas, mais les bons* ; afficher des *contrefactuels* qui forcent à réfléchir plutôt qu'à valider ; et *contrôler le contrôleur* en glissant des cas-tests dont on connaît la réponse.

Recommandation 5 : faire de la gouvernance et de la responsabilité une colonne vertébrale. La gouvernance n'est pas un vernis final mais une exigence transversale. Concrètement : tracer chaque décision (quelles données, quelle logique, quel acteur) dès la couche donnée ; établir sans ambiguïté une responsabilité *humaine*, car « c'est l'IA qui a décidé » ne saurait être une défense ; formaliser cette responsabilité, par exemple par une matrice qui distingue qui propose, qui valide et qui répond ; et vivre les cadres AI Act et ISO/IEC 42001 comme une discipline utile, non comme une paperasse de conformité. L'étude a révélé une tension à arbitrer explicitement : les profils techniques veulent verrouiller la responsabilité sur une personne, les métiers la répartissent entre décideur, concepteur et entreprise ; une gouvernance saine tranche cette question avant l'incident, pas après.

Recommandation 6 : piloter l'adoption, la confiance et le coût comme des conditions de réussite. Une technologie que personne n'adopte est un échec, quelle que soit sa performance. Il faut donc conduire le changement (Kotter, 1996) : déployer le système *aux côtés* des humains avant de le leur confier, traiter ouvertement la peur pour l'emploi, et se souvenir qu'expliquer le dispositif en élève l'acceptabilité, comme l'a montré l'évolution du ressenti des personnes interrogées une fois le cadre compris. Deux conditions matérielles complètent le tableau : la confidentialité, car un système privé des données sensibles produit des recommandations faussées, et le coût complet, run et maintenance, auquel s'ajoute une dimension trop souvent oubliée, l'empreinte énergétique et carbone du dispositif au regard des engagements environnementaux (Strubell, Ganesh & McCallum, 2019).

13.3 Une feuille de route en trois horizons

Ces recommandations se déploient dans le temps. La figure 13 propose une trajectoire en trois horizons, du plus fondamental au plus ambitieux, adossée à un socle permanent de donnée gouvernée, de gouvernance et de confiance.



La faisabilité se construit de gauche à droite, mais repose en permanence sur le socle du bas.

Figure 13. Feuille de route de la transformation décisionnelle en trois horizons.

L'horizon 1 (jusqu'à un an) *fonde* : il fiabilise la donnée, livre un ou deux cas d'usage à retour sur investissement clair, déploie des copilotes en simple assistance et pose d'emblée la gouvernance. L'horizon 2 (un à trois ans) *étend* : il construit l'ontologie cas d'usage par cas d'usage, gradue l'autonomie sur le réversible, instrumente la boucle d'apprentissage et investit la conduite du changement. L'horizon 3 (au-delà de trois ans) *viser* l'ambition initiale, le raisonnement causal ciblé et la simulation sur des sous-domaines bornés, en gardant le world model comme cap directionnel plutôt que comme promesse. La règle d'or, illustrée par le socle de la figure, est que chaque horizon repose en permanence sur les fondations du précédent : on n'atteint jamais l'horizon 3 en sautant l'horizon 1.

Ces horizons sont indicatifs. Ils ne résultent pas d'une mesure conduite dans cette recherche, mais d'une mise en ordre logique des dépendances entre couches ; ils doivent être adaptés à la maturité data, à la taille, aux ressources et aux contraintes sectorielles de chaque organisation.

13.4 Facteurs de succès et pièges à éviter

Le tableau 7 récapitule, pour chaque levier, ce qui distingue une démarche qui réussit d'une démarche qui échoue. Cette lecture en miroir est directement issue des entretiens, où les praticiens décrivaient souvent le succès en creux, par le récit d'un échec.

Facteur de succès	Piège symétrique à éviter
Donnée traitée comme un produit, maintenance financée	Projet ponctuel, référentiel laissé à l'abandon
Ontologie construite par cas d'usage	Big-bang ontologique, « aspirateur à budget »
Autonomie graduée, logique de copilote	Automatiser d'emblée le rare et l'irréversible
Abstention et peu de cas, bien choisis, pour l'humain	Contrôle humain de façade (surcharge, tamponnage)
Responsabilité humaine explicite et formalisée	« C'est l'IA qui a décidé » ; responsabilité floue
Transparence, adoption et confiance construites	Déploiement descendant, peurs et confidentialité ignorées
Coût complet et empreinte énergétique anticipés	Coût de run et de maintenance découverts trop tard

Tableau 7. Facteurs de succès et pièges symétriques de la transformation décisionnelle.

13.5 Portée et limites des recommandations

Ces recommandations sont des *conditions*, non des garanties, et leur portée doit être bornée honnêtement. Elles reposent sur un échantillon exploratoire (193 réponses et neuf entretiens) et sur des perceptions déclaratives ; elles gagneraient à être éprouvées par des études de cas longitudinales suivant une organisation qui les applique réellement. Elles sont aussi sensibles au contexte : la maturité data, la taille, le secteur et la criticité des décisions en modulent l'application, comme l'a rappelé l'ingénieur pour qui, dans un métier de sécurité, aucune décision générée par l'IA ne saurait être suivie aveuglément. Enfin, elles ne dispensent pas du jugement : la meilleure feuille de route ne remplace pas la décision, proprement humaine, de savoir quand faire confiance à la machine et quand s'en défier. C'est précisément l'objet que la conclusion générale reprendra pour clore ce travail.

Conclusion générale

Cette thèse est partie d'un paradoxe familier à toute organisation contemporaine : jamais les entreprises n'ont disposé d'autant de données, et pourtant leurs décisions continuent trop souvent de reposer sur l'intuition, l'expérience et quelques experts surchargés. La question de recherche qui a guidé ce travail en découlait directement : comment les systèmes décisionnels d'entreprise peuvent-ils évoluer d'un rôle de visualisation descriptive vers une intelligence explicative, anticipative et stratégiquement exploitable, en s'appuyant sur les world models organisationnels, les

ontologies d'entreprise et la Decision Intelligence ? Au terme d'un parcours qui a mené de la revue de littérature à la construction d'un cadre intégré, puis à sa confrontation au terrain, une réponse se dégage, nuancée mais claire.

Cette évolution est possible, et sa direction est juste : les briques existent, elles se répondent, et leur articulation dessine une architecture cohérente de système décisionnel AI-native. Mais cette évolution n'est ni un grand soir technologique, ni le déploiement descendant d'un world model qui simulerait l'entreprise entière. Elle est une transformation *conditionnelle et incrémentale*, dont la réussite dépend bien moins de la sophistication de l'intelligence artificielle que de la solidité du socle organisationnel qui la porte : la donnée gouvernée, la gouvernance, la confiance et le maintien du jugement humain aux commandes. Le principal enseignement de ce travail tient dans ce déplacement du regard, du sommet vers la base.

Synthèse des contributions

Sur le plan théorique, la première contribution de cette thèse est le cadre intégré lui-même. Là où la littérature traitait séparément la Business Intelligence, la causalité, les plateformes d'entreprise, la Decision Intelligence et la gouvernance de l'IA, ce travail les a pensées comme les couches d'un même système, articulées par une chaîne allant de la donnée à la décision. Il a en particulier transposé le concept de world model, issu de la recherche fondamentale en IA, au contexte organisationnel, et proposé de lire l'ontologie d'entreprise comme son substrat industriel, c'est-à-dire la couche de représentation gouvernée sur laquelle un tel modèle peut être construit sans s'y réduire, un pont conceptuel jusqu'ici peu exploré.

La deuxième contribution, plus originale encore, est le réordonnancement empirique des priorités que la confrontation au terrain a imposé. La formule emblématique qui la résume, empruntée à l'un des experts interrogés, « le problème est à quatre-vingts pour cent humain et organisationnel, et à vingt pour cent technique », inverse la hiérarchie spontanée des projets d'IA : la faisabilité d'un système décisionnel augmenté est d'abord un problème de base, la donnée et sa maintenance, la gouvernance, l'adoption, et non un problème de sommet, la puissance des modèles. La troisième contribution est la mise au jour d'une complémentarité structurée entre profils : le regard technique diagnostique les limites profondes du cadre, le regard métier en porte les conditions d'adoption, et aucun ne suffit seul, ce qui a justifié le

choix méthodologique d'un double guide d'entretien. S'y ajoutent enfin plusieurs concepts émergents utiles au-delà de ce travail : l'abstention calibrée comme dimension de la confiance, le « contrôle humain de façade » comme anti-pattern de gouvernance, et la distinction entre un écart désir-confiance agrégé et une corrélation individuelle positive.

Sur le plan managérial, la thèse offre un cadre d'action concret : six recommandations et une feuille de route en trois horizons, qui traduisent le réordonnancement en leviers opérationnels. Le message adressé aux décideurs est simple : investir d'abord dans les fondations, avancer par cas d'usage plutôt que par grands projets, graduer l'autonomie du copilote au décideur, et faire de la gouvernance et de la responsabilité humaine une colonne vertébrale, non un vernis final.

Limites de la recherche

La portée de ces résultats doit être bornée avec honnêteté. La première limite est celle de l'échantillon. Le volet quantitatif repose sur 193 réponses, en deçà de la cible de 300 fixée pour une modélisation inférentielle complète, avec un échantillon volontaire, plutôt jeune, et un déséquilibre entre répondants francophones et anglophones qui interdit toute conclusion culturelle ferme. Le volet qualitatif, riche de neuf entretiens couvrant trois profils, n'atteint pas la saturation pour chacun d'eux, et une partie du recrutement s'est opérée par réseau professionnel. Les données sont en outre déclaratives et transversales, exposées aux biais de perception et de désirabilité.

La deuxième limite est plus fondamentale. Les couches les plus ambitieuses du cadre, le raisonnement causal et la simulation à l'échelle de l'entreprise, n'ont pu être éprouvées *en déploiement réel*, pour une raison simple : aucune organisation, à notre connaissance, n'a construit la pile complète. Le verdict de faisabilité repose donc sur le jugement d'experts et sur des perceptions, non sur l'observation longitudinale d'une mise en œuvre. Ce travail est, en définitive, une contribution conceptuelle et perceptuelle, et non une validation expérimentale de l'architecture elle-même. Enfin, le sujet évolue à un rythme rapide : ses résultats sont datés de 2025-2026 et devront être relus à l'aune des évolutions technologiques et réglementaires à venir.

Perspectives de recherche

Ces limites dessinent en creux un programme de recherche. La perspective la plus naturelle est l'*étude de cas longitudinale* : suivre une organisation qui applique réellement la feuille de route proposée, pour éprouver en pratique le verdict de faisabilité et la séquence des trois horizons, là où cette thèse s'est arrêtée à la perception. Sur le plan quantitatif, atteindre puis dépasser la cible de 300 réponses permettrait de tester rigoureusement, par analyse en composantes et par régression, les effets seulement esquissés ici, notamment la différence francophones-anglophones et le contraste technique-métier, en segmentant par secteur et par maturité data.

Trois chantiers thématiques mériteraient enfin d'être ouverts. Le premier est celui de la *causalité opérationnelle* : comment une organisation peut concrètement construire les modèles causaux qui font aujourd'hui défaut, alors même que tous les praticiens en reconnaissent la nécessité et l'extrême difficulté. Le deuxième est celui de la *gouvernance de la responsabilité* : formaliser et tester des dispositifs, tels qu'une matrice de responsabilité des décisions augmentées, capables de trancher la tension entre une responsabilité verrouillée et une responsabilité distribuée. Le troisième, plus émergent, est celui du *coût énergétique et environnemental* des systèmes décisionnels augmentés, soulevé sur le terrain et encore largement absent du débat managérial.

Le mot de la fin

Au fond, ce travail conduit à un renversement de perspective sur ce que signifie « moderniser » la décision d'entreprise. On imagine volontiers que l'avenir des systèmes décisionnels réside dans des machines toujours plus intelligentes. Le terrain suggère l'inverse : il réside surtout dans des organisations mieux gouvernées, des données mieux tenues, et un jugement humain préservé plutôt que dissous. La Decision Intelligence promettait d'augmenter le décideur, non de le remplacer ; c'est cette promesse, et la discipline qu'elle exige, qui devraient guider la transformation. Le système décisionnel de nouvelle génération ne sera pas celui qui décidera à la place des humains, mais celui qui les rendra capables de décider mieux, plus vite et de manière plus responsable. Bâtir un tel système est moins un défi technologique qu'un projet organisationnel et humain, et c'est peut-être là, en définitive, le véritable sujet de cette thèse.

Bibliographie

- Ansoff, H. I. (1975). Managing strategic surprise by response to weak signals. *California Management Review*, 18(2), 21–33.
- Bareinboim, E., Correa, J. D., Ibeling, D., & Icard, T. (2022). On Pearl's hierarchy and the foundations of causal inference. In *Probabilistic and causal inference: The works of Judea Pearl* (p. 507–556). ACM.
- Braun, V., & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77–101.
- Chen, H., Chiang, R. H. L., & Storey, V. C. (2012). Business intelligence and analytics: From big data to big impact. *MIS Quarterly*, 36(4), 1165–1188.
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2e éd.). Lawrence Erlbaum.
- Commission européenne. (2024). Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act) [et « AI Omnibus », 2026]. *Journal officiel de l'Union européenne*.
- Creswell, J. W., & Plano Clark, V. L. (2018). *Designing and conducting mixed methods research* (3e éd.). Sage.
- Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. *Psychometrika*, 16(3), 297–334.
- Cummings, M. L. (2004). Automation bias in intelligent time critical decision support systems. *AIAA 1st Intelligent Systems Technical Conference*.
- Davenport, T. H., & Harris, J. G. (2007). *Competing on analytics: The new science of winning*. Harvard Business School Press.
- ElixirData. (2025). Context OS: The governed context graph for enterprise AI, Organization World Model [documentation de plateforme]. ElixirData.
- Fetters, M. D., Curry, L. A., & Creswell, J. W. (2013). Achieving integration in mixed methods designs. *Health Services Research*, 48(6 Pt 2), 2134–2156.
- Field, A. (2018). *Discovering statistics using IBM SPSS statistics* (5e éd.). Sage.
- Gartner. (2018). Analytics Ascendancy Model [modèle de maturité analytique ; environ 13 % des organisations au stade prescriptif]. Gartner, Inc.
- Gartner. (2025a, 17 juin). Gartner announces the top data & analytics predictions [50 % des décisions augmentées ou automatisées par des agents d'IA d'ici 2027]. Gartner, Inc.
- Gartner. (2025b, 25 juin). Gartner predicts over 40 % of agentic AI projects will be canceled by end of 2027. Gartner, Inc.
- Gartner. (2026, 26 janvier). Magic Quadrant for decision intelligence platforms [1re édition ; leaders : FICO, SAS Viya, Quantexa]. Gartner, Inc.
- Goddard, K., Roudsari, A., & Wyatt, J. C. (2012). Automation bias: A systematic review of frequency, effect mediators, and mitigators. *Journal of the American Medical Informatics Association*, 19(1), 121–127.

- Grieves, M., & Vickers, J. (2017). Digital twin: Mitigating unpredictable, undesirable emergent behavior in complex systems. In *Transdisciplinary perspectives on complex systems* (p. 85–113). Springer.
- Gruber, T. R. (1993). A translation approach to portable ontology specifications. *Knowledge Acquisition*, 5(2), 199–220.
- Ha, D., & Schmidhuber, J. (2018). World models. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://doi.org/10.48550/arXiv.1803.10122>
- Hogan, A., Blomqvist, E., Cochez, M., d'Amato, C., de Melo, G., Gutiérrez, C., ... Zimmermann, A. (2021). Knowledge graphs. *ACM Computing Surveys*, 54(4), 1–37.
- ISO/IEC. (2023). ISO/IEC 42001:2023. Information technology, artificial intelligence, management system. International Organization for Standardization.
- Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines. *Nature Machine Intelligence*, 1(9), 389–399.
- Kaiser, H. F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1), 141–151.
- Keeney, R. L., & Raiffa, H. (1976). *Decisions with multiple objectives: Preferences and value tradeoffs*. Wiley.
- Kimball, R., & Ross, M. (2013). *The data warehouse toolkit* (3e éd.). Wiley.
- Kotter, J. P. (1996). *Leading change*. Harvard Business School Press.
- Kozyrkov, C. (2019). *Introduction to Decision Intelligence*. Google Cloud.
- LaValle, S., Lesser, E., Shockley, R., Hopkins, M. S., & Kruschwitz, N. (2011). Big data, analytics and the path from insights to value. *MIT Sloan Management Review*, 52(2), 21–32.
- LeCun, Y. (2022). A path towards autonomous machine intelligence (version 0.9.2). OpenReview.
- LeCun, Y. (2024). Objective-Driven AI [conférences, Collège de France et CMSA, Harvard University].
- Likert, R. (1932). A technique for the measurement of attitudes. *Archives of Psychology*, 140, 1–55.
- Meta AI. (2025). V-JEPA 2: Self-supervised video world models for understanding, prediction and planning [et R. Balestriero & Y. LeCun, LeJEPA].
- Microsoft. (2025). Translytical task flows in Power BI [+ Copilot Studio]. Microsoft Corporation.
- Miles, M. B., Huberman, A. M., & Saldaña, J. (2014). *Qualitative data analysis: A methods sourcebook* (3e éd.). Sage.
- NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology.
- Noy, N. F., & McGuinness, D. L. (2001). *Ontology development 101: A guide to creating your first ontology*. Stanford Knowledge Systems Laboratory.

- Palantir Technologies. (2024a). The Ontology system [documentation technique]. Palantir Technologies.
- Palantir Technologies. (2024b). Ontology architecture [documentation technique]. Palantir Technologies.
- Palantir Technologies. (2026). Connecting agents to decisions with the Palantir Ontology [billet de blog]. Palantir Technologies.
- Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors*, 52(3), 381–410.
- Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2e éd.). Cambridge University Press.
- Pearl, J., & Mackenzie, D. (2018). *The book of why: The new science of cause and effect*. Basic Books.
- Power, D. J., & Sharda, R. (2007). Model-driven decision support systems: Concepts and research directions. *Decision Support Systems*, 43(3), 1044–1061.
- Pratt, L. (2019). *Link: How decision intelligence connects data, actions, and outcomes for a better world*. Emerald Publishing.
- Pratt, L., & Malcolm, N. (2023). *The decision intelligence handbook: Practical steps for evidence-based decisions in a complex world*. O'Reilly Media.
- Pratt, L., & Zangari, M. (2008). *Overcoming the decision complexity ceiling through design* [livre blanc]. Quantellia.
- Puterman, M. L. (1994). *Markov decision processes: Discrete stochastic dynamic programming*. Wiley.
- Salesforce Research. (2025). AI-driven causal analysis for business intelligence: A scalable approach [communication de conférence]. IEEE. <https://ieeexplore.ieee.org/document/11380110>
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612–634.
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., ... Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems (NeurIPS)*, 28, 2503–2511.
- Shim, J. P., Warkentin, M., Courtney, J. F., Power, D. J., Sharda, R., & Carlsson, C. (2002). Past, present, and future of decision support technology. *Decision Support Systems*, 33(2), 111–126.
- Simon, H. A. (1977). *The new science of management decision* (éd. rév.). Prentice Hall.
- Sterman, J. D. (2000). *Business dynamics: Systems thinking and modeling for a complex world*. Irwin/McGraw-Hill.
- Strubell, E., Ganesh, A., & McCallum, A. (2019). Energy and policy considerations for deep learning in NLP. *Proceedings of the 57th Annual Meeting of the ACL*, 3645–3650.
- van der Aalst, W. M. P. (2016). *Process mining: Data science in action* (2e éd.). Springer.

- Wavestone. (2024). Data and AI Leadership Executive Survey 2024. Wavestone (anc. NewVantage Partners).
- Wixom, B. H., & Watson, H. J. (2010). The BI-based organization. *International Journal of Business Intelligence Research*, 1(1), 13–28.
- World Economic Forum. (2024). Causal AI: The revolution uncovering the 'why' of decision-making.
- Zachman, J. A. (1987). A framework for information systems architecture. *IBM Systems Journal*, 26(3), 276–292.

Annexes

Liste des annexes

Annexe A. Questionnaire de l'enquête quantitative

Annexe B. Guides d'entretien semi-directifs (version métier et version technique)

Annexe C. Grille de codage de l'analyse thématique

Annexe D. Formulaire d'information et de consentement (RGPD)

Annexe E. Transcriptions intégrales des neuf entretiens (E.1 à E.9)

Annexe A. Questionnaire de l'enquête quantitative

Questionnaire bilingue (français / anglais) diffusé en ligne sous le titre « 3 minutes Survey – Business Intelligence to AI-driven Decision Systems / De la Business Intelligence aux systèmes décisionnels basés sur l'IA ». Version française reproduite ci-dessous ; les items d'accord utilisent une échelle de Likert en cinq points (1 = pas du tout d'accord ; 5 = tout à fait d'accord). 193 réponses exploitables ont été recueillies.

Profil du répondant

Q1. Quelle est votre fonction principale ?

Q2. À quelle tranche d'âge appartenez-vous ?

Q3. Dans quel secteur travaillez-vous ?

Q4. Taille de votre organisation

Usage des outils de BI

Q5. À quelle fréquence utilisez-vous des tableaux de bord ou des outils de reporting (BI) ?

Q6. Quels outils utilisez-vous principalement ?

Perception des limites de la BI actuelle (items Likert 1 à 5)

Q7. Les systèmes de BI actuels fournissent principalement des analyses descriptives plutôt qu'explicatives.

Q8. Les outils de BI actuels me permettent d'identifier facilement lorsqu'un KPI évolue de manière significative.

Q9. Les outils de BI actuels me permettent de comprendre clairement les causes profondes des variations de KPI.

Q10. Lorsqu'un KPI évolue, des analyses exploratoires supplémentaires sont généralement nécessaires au-delà des tableaux de bord standards.

Q11. Identifier les facteurs expliquant la performance nécessite généralement des analyses manuelles ou l'intervention de spécialistes de la data.

Q12. Les données pertinentes pour analyser la performance organisationnelle sont réparties entre plusieurs systèmes ou sources de données.

Q13. L'intégration de données internes et externes reste difficile dans les systèmes actuels d'aide à la décision.

Q14. Des informations contextuelles importantes (conditions de marché, concurrence, signaux externes) sont souvent absentes des analyses BI.

Valeur perçue des capacités augmentées (items Likert 1 à 5)

Q15. Des systèmes capables d'identifier automatiquement les facteurs expliquant les variations de KPI amélioreraient la prise de décision.

Q16. Des systèmes prédictifs capables d'anticiper les évolutions de performance apporteraient une valeur significative à mon organisation.

Q17. Des systèmes capables de détecter des signaux faibles ou des risques émergents amélioreraient la capacité d'anticipation stratégique.

Q18. La possibilité d'interroger les données organisationnelles en langage naturel améliorerait l'accessibilité des analyses.

Confiance, transparence et éthique (items Likert 1 à 5)

Q19. Comment vous sentiriez-vous personnellement à l'idée de vous appuyer sur un système d'intelligence artificielle pour soutenir des décisions importantes dans votre activité professionnelle ?

Q20. Dans quelle mesure vous sentiriez-vous à l'aise à l'idée que certaines décisions dans votre organisation soient partiellement guidées par des analyses produites par une IA ?

Q21. Si une décision assistée par l'IA entraînait des conséquences négatives dans votre travail, dans quelle mesure vous sentiriez-vous personnellement responsable de ce résultat ?

Q22. Dans quelle mesure est-il important pour vous que les systèmes d'IA utilisés dans la prise de décision soient transparents et explicables ?

Q23. Dans quelle mesure êtes-vous personnellement préoccupé(e) par les biais potentiels dans les systèmes d'IA utilisés pour la prise de décision dans les organisations ?

Q24. Dans quelle mesure considérez-vous que l'utilisation de l'IA dans la prise de décision organisationnelle est acceptable si elle améliore les performances de l'entreprise ?

Perceptions sur la gouvernance (questions fermées)

Q25. Un système décisionnel capable de produire des recommandations très précises pourrait progressivement réduire la capacité des décideurs à remettre en question ses conclusions.

Q26. À long terme, pensez-vous que les systèmes d'IA pourraient influencer la manière dont les organisations définissent ce qui constitue une "bonne décision" ?

Q27. Une bonne décision est-elle toujours une décision expliquée, ou peut-elle être considérée comme acceptable même si son raisonnement reste opaque ?

Q28. À mesure que les systèmes d'IA deviennent plus performants, les organisations pourraient progressivement déléguer des décisions importantes à des systèmes qu'elles ne comprennent pas pleinement.

Q29. Selon vous, qui devrait être tenu responsable si un système d'intelligence artificielle conduit à une décision gravement erronée ou trompeuse dans une organisation ?

Entretien de suivi

Q30. Seriez-vous disposé(e) à participer à un court entretien de suivi (10 à 15 minutes) ? Si oui, merci de laisser votre adresse e-mail.

Annexe B. Guides d'entretien semi-directifs

Deux versions d'un même guide, partageant les mêmes dimensions d'analyse pour garantir la comparabilité inter-profils. La version métier procède en deux phases (regard spontané, puis vulgarisation standardisée et réactions informées) ; la version technique aborde frontalement les concepts. Texte à dire entre guillemets ; consignes de l'intervieweur entre crochets.

B.1 Guide d'entretien, version métier (profils décideurs et fonctionnels)

Guide d'entretien — profil BUSINESS / non-technique (30 min)

Thèse : De la Business Intelligence descriptive aux systèmes décisionnels AI-native — World Models, Ontologies et Decision Intelligence

Achir Charafeddine · MS Big Data · GEM / Grenoble INP–Ensimag

Cible : business analysts, managers, décideurs, contrôleurs de gestion, consultants — non spécialistes de l'IA.

Logique de ce guide — à lire avant

Ce guide est en deux temps, et c'est volontaire :

- Phase A — Généraliste (non biaisée). On explore d'abord l'expérience vécue de la personne sans jamais mentionner les concepts de la thèse (world models, ontologie, Decision Intelligence). But : recueillir un regard spontané, non influencé par le cadre théorique.

- Phase B — Vulgarisation + questions ciblées. On explique alors le sujet en mots simples, puis on recueille des réactions informées sur les concepts au cœur de la thèse. On peut même mesurer si l'avis de la personne évolue une fois le sujet clarifié — c'est un matériau d'analyse précieux.

Format. Texte à dire entre guillemets ; instructions pour toi [entre crochets] ; relances optionnelles. Lis les questions telles quelles, laisse le silence, demande toujours un exemple concret, ne suggère jamais la réponse.

Minutage (≈ 30 min)

| | Bloc | Durée |

|---|---|---|

| 0 | Accueil + consentement | 2 min |

| A1 | Mise en route | 3 min |

| A2 | Décider avec des données aujourd'hui | 4 min |

| A3 | Confiance spontanée dans l'IA | 3 min |

| A4 | Suivre un outil sans le questionner | 3 min |

| — | Transition : vulgarisation du sujet | 3 min |

| B1 | Le « modèle du monde » de l'entreprise | 4 min |

| B2 | Decision Intelligence & scénarios | 3 min |

| B3 | Conditions, confiance revisitée & éthique | 3 min |

| 7 | Clôture | 2 min |

0. Accueil et consentement — *2 min*

> « Bonjour, et merci beaucoup d'avoir accepté cet entretien. Deux mots sur le cadre : je fais une recherche de thèse sur la façon dont les entreprises prennent leurs décisions à partir de leurs données, et sur la place que l'IA pourrait y prendre. Ça dure environ 30 minutes.

>

> Il n'y a aucune bonne ou mauvaise réponse, et surtout pas besoin d'être spécialiste : c'est vraiment votre expérience qui m'intéresse. Tout restera anonyme. Avec votre accord, j'aimerais enregistrer, uniquement pour la retranscription — rien n'est partagé. Vous pouvez passer une question ou arrêter quand vous voulez. C'est bon pour vous, et d'accord pour que j'enregistre ? »

[Attendre le « oui » explicite, lancer l'enregistrement, reconfirmer sur la bande.]

PHASE A — Regard spontané *(ne pas introduire les concepts de la thèse)*

A1. Mise en route — *3 min*

> « Pour commencer, vous pouvez me décrire votre poste et en quoi consiste votre travail au quotidien ? »

[Relances :]

> « Est-ce que vous prenez, ou contribuez à, des décisions importantes ? Lesquelles, par exemple ? »

>

> « Vous vous appuyez sur quels chiffres, tableaux de bord ou outils pour ça ? »

A2. Décider avec des données aujourd'hui — *4 min*

> « Pensez à une décision importante et récente que vous avez prise en vous appuyant sur des données. Racontez-moi comment ça s'est passé, du début à la fin. »

[Laisse dérouler, puis :]

> « À quel moment les chiffres vous ont suffi, et à quel moment il a fallu creuser, réfléchir ou demander à quelqu'un ? »

>

> « Quand un indicateur important bouge, est-ce que vos outils vous disent pourquoi, ou seulement que ça a bougé ? »

A3. Confiance spontanée dans l'IA — *3 min*

> « Imaginez un outil d'IA qui, au lieu d'afficher des chiffres, vous proposerait directement une recommandation : "voici ce que je vous conseille de décider, et voici pourquoi". Comment vous sentiriez-vous à l'idée de vous appuyer là-dessus pour une décision qui compte ? »

[Relances :]

> « Qu'est-ce qui vous mettrait en confiance ? Qu'est-ce qui vous ferait douter ? »

[IMPORTANT : note bien le niveau de confiance exprimé ici — tu y reviendras en B3 après la vulgarisation.]

A4. Suivre un outil sans le questionner — *3 min*

> « Avez-vous déjà vu quelqu'un — vous ou un collègue — suivre ce que disait un outil ou un chiffre sans vraiment le remettre en question ? »

[Relances :]

> « Comment ça s'est passé, avec quel résultat ? »

>

> « Vous est-il déjà arrivé d'avoir raison contre ce que disait un outil ? »

TRANSITION — Vulgarisation du sujet — *3 min*

[À lire calmement, en marquant des pauses. Adaptez les analogies si besoin, mais gardez les 3 idées : modèle du monde, ontologie, Decision Intelligence. Vérifiez que la personne suit : « c'est clair jusque-là ? »]

> « Merci, c'est très clair. Je vais maintenant vous expliquer en deux minutes le cœur de ma recherche, puis j'aimerais recueillir vos réactions.

>

> Aujourd'hui, la plupart des outils décisionnels — la "business intelligence" — servent surtout à décrire le passé : des tableaux de bord qui montrent ce qui s'est passé. Ma thèse s'intéresse à la génération suivante, capable non seulement de décrire, mais d'expliquer les causes, d'anticiper, et de recommander des décisions. Trois idées reviennent au centre.

>

> La première, c'est ce qu'on appelle un "modèle du monde" de l'entreprise : une sorte de maquette vivante, un peu comme un simulateur de vol, mais pour l'organisation. Elle représenterait comment l'entreprise fonctionne vraiment — ses clients, ses processus, ses règles — et permettrait de tester "si je fais ça, qu'est-ce qui se passe ?".

>

> La deuxième, c'est l'ontologie, qu'on peut voir comme une carte partagée : elle relie toutes les données de l'entreprise à ce qu'elles représentent réellement, pour que tout le monde — humains comme systèmes d'IA — parle exactement le même langage. Certains la décrivent comme un "jumeau numérique" de l'organisation.

>

> La troisième, la "Decision Intelligence", c'est l'idée de remettre la décision au centre, plutôt que la donnée : un système qui vous accompagne sur tout le cycle d'une décision, de la question de départ jusqu'à l'apprentissage tiré du résultat.

>

> Voilà le décor. J'aimerais maintenant votre réaction, très librement. »

PHASE B — Réactions informées sur le sujet de la thèse

B1. Le « modèle du monde » de l'entreprise — *4 min*

> « Cette idée d'une maquette vivante de l'entreprise, un modèle qui simule les conséquences d'une décision avant de la prendre — qu'est-ce que ça vous évoque ? »

[Relances :]

> « Est-ce que, dans votre organisation, tout le monde parle le même langage sur les données ? Quand deux services parlent d'un "client" ou d'un "produit", désignent-ils vraiment la même chose ? »

>

> « Et quand ce n'est pas le cas, qu'est-ce que ça coûte concrètement — en temps, en erreurs, en désaccords ? »

>

> « Une capacité à tester des scénarios "et si... ?" avant de décider, ça changerait quoi pour vous ? »

B2. Decision Intelligence & scénarios — *3 min*

> « Imaginez un système qui ne vous donne pas juste des chiffres, mais qui vous accompagne sur toute la décision : cadrer la question, simuler des options, recommander, puis apprendre du résultat. Ça vous semble utile, ou plutôt inquiétant ? Pourquoi ? »

[Relances :]

> « Qu'est-ce qui vous emballe le plus dans cette idée ? Qu'est-ce qui vous freine le plus ? »

>

> « Sur quelles décisions de votre métier ça aurait le plus de valeur ? »

B3. Conditions, confiance revisitée & éthique — *3 min*

> « Pour que ce genre de système marche vraiment dans votre organisation, qu'est-ce qu'il faudrait réunir — côté données, côté culture, côté organisation ? »

[Puis, revenir sur la confiance — clé de l'analyse :]

> « Tout à l'heure, avant que je vous explique tout ça, vous me disiez [rappeler son niveau de confiance de A3]. Maintenant que vous voyez mieux de quoi il s'agit, est-ce que votre ressenti a changé ? »

[Puis l'éthique :]

> « Si un tel système menait à une décision gravement erronée, qui devrait en être tenu responsable, selon vous ? Et une décision doit-elle toujours pouvoir s'expliquer pour être acceptable ? »

7. Clôture — *2 min*

> « On arrive à la fin. Y a-t-il quelque chose d'important qu'on n'a pas abordé et que vous aimeriez ajouter ? »

>

> « Verriez-vous une ou deux personnes que ça pourrait intéresser et à qui je pourrais parler ? »

>

> « Un grand merci pour votre temps. Je peux vous envoyer une synthèse anonyme des résultats si vous le souhaitez. »

[Couper l'enregistrement. Noter à chaud : niveau de confiance avant/après vulgarisation, réactions marquantes, incompréhensions éventuelles.]

Note méthodologique (chapitre 9)

Le design en deux phases répond à un risque de biais d'amorçage : introduire d'emblée « world model » ou « ontologie » orienterait les réponses. La phase A capte donc un regard spontané comparable à celui des profils techniques ; la phase B mesure des réactions informées après une vulgarisation standardisée (lue à l'identique pour tous, pour rester comparable). La comparaison confiance A3 → confiance B3 documente un éventuel effet de la compréhension sur l'acceptabilité — un résultat exploitable pour la sous-question 3 (conditions de possibilité).

B.2 Guide d'entretien, version technique (data scientists, AI engineers)

Guide d'entretien — profil AI ENGINEER / technique (30 min)

Thèse : De la Business Intelligence descriptive aux systèmes décisionnels AI-native — World Models, Ontologies et Decision Intelligence

Achir Charafeddine · MS Big Data · GEM / Grenoble INP–Ensimag

Cible : AI/ML engineers, data scientists, data/ML architects, praticiens Decision Intelligence, ontologie, knowledge graphs, Causal AI.

À lire avant

Cette version attaque directement les trois piliers de la thèse — world models, ontologies/knowledge graphs, Decision Intelligence — plus le socle causal et la gouvernance. Pas de vulgarisation : on

suppose la maîtrise des concepts et on cherche la profondeur d'implémentation (architecture, métriques, limites réelles).

Comparabilité. Chaque bloc porte un repère `↔ Bx` renvoyant au bloc équivalent du guide business, pour croiser les regards technique ↔ métier sur une même dimension.

Format. Texte à dire entre guillemets ; instructions [entre crochets] ; relances optionnelles. Demande des détails d'implémentation (« quelle stack ? quelle métrique ? ça scalait ? »), reste neutre, ne valide pas leurs réponses.

Minutage (≈ 30 min)

| Bloc | Durée |

|---|---|

| 0. Cadre + consentement | 2 min |

| 1. Profil & stack | 2 min |

| 2. Maturité : du descriptif au causal | 4 min |

| 3. World models organisationnels | 5 min |

| 4. Ontologie, knowledge graph & couche sémantique | 5 min |

| 5. Decision Intelligence, agents & confiance | 4 min |

| 6. Explicabilité, automation bias & gouvernance | 5 min |

| 7. Architecture cible & clôture | 3 min |

0. Cadre et consentement — *2 min*

> « Merci d'avoir accepté. En deux mots : thèse sur le passage d'une BI descriptive vers des systèmes décisionnels AI-native — l'angle, c'est la convergence world models / ontologies / Decision Intelligence, avec le socle causal en dessous. Ton profil m'intéresse pour dépasser les perceptions et parler archi et limites réelles. 30 min, anonyme, j'enregistre juste pour la retranscription, tu peux t'arrêter quand tu veux. OK pour toi et pour l'enregistrement ? »

[Attendre le « oui », lancer l'enregistrement, reconfirmer sur la bande.]

1. Profil & stack — *2 min* · `↔ B-A1`

> « Décris-moi ton rôle et la stack data/ML sur laquelle tu bosses, et à quel niveau de la chaîne tu intervies — ingestion, modélisation, déploiement, decision support. »

2. Maturité : du descriptif au causal — *4 min* · `↔ B-A2`

> « Sur l'échelle descriptif → diagnostique → prédictif → prescriptif, où situes-tu honnêtement les systèmes que tu opères, et qu'est-ce qui bloque le passage au niveau supérieur ? »

[Relances :]

> « Quand un KPI décroche, qui fait le root-cause : un humain, du drill-down, ou de l'automatique ? »

>

> « Vous faites de l'inférence causale au sens propre — do-calculus, uplift, quasi-expériences, DAGs — ou de la corrélation et du feature importance interprétés causalement ? Où est la limite ? »

3. World models organisationnels — *5 min* · `↔ B-B1`

> « Le concept de world model — au sens de LeCun, une représentation interne qui modélise la dynamique d'un environnement et les conséquences des actions — transposé à l'entreprise : ça te paraît réaliste ou fumeux, pour une organisation ? »

[Relances :]

> « Une formalisation (ElixirData / Context OS) décompose ce "modèle du monde organisationnel" en cinq sous-modèles : entités, processus, autorité, règles/policies, et terminologie. Ça te parle ? Lesquels sont les plus durs à construire en vrai ? »

>

> « Est-ce qu'on sait aujourd'hui construire un modèle qui simule des effets en cascade et des vulnérabilités structurelles à l'échelle d'une boîte, ou c'est encore de la recherche ? Qu'est-ce qui manque — données, causalité, compute, modélisation ? »

>

> « La distinction entre simuler avec un modèle explicite vs un LLM qui "raisonne" sur le contexte, tu la poses comment ? »

4. Ontologie, knowledge graph & couche sémantique — *5 min* · ↔ B-B1`

> « L'ontologie d'entreprise façon Palantir — quatre dimensions Data / Logic / Action / Security, et une architecture en couches sémantique / cinétique / dynamique, présentée comme un "digital twin" de l'organisation partagé entre humains et agents. Sur le fond, qu'est-ce que tu en penses techniquement ? »

[Relances :]

> « Dans ton expérience, la vraie difficulté d'une couche sémantique / d'un knowledge graph d'entreprise, elle est où : modélisation, résolution d'entités, gouvernance, maintenance, adoption ? »

>

> « Le Graph-RAG et les couches sémantiques pour brancher des LLM sur la donnée métier — ça tient la route pour de la décision, ou ça déplace juste le problème de fiabilité ? »

>

> « Une ontologie partagée comme substrat commun humains ↔ agents IA : condition nécessaire pour des systèmes décisionnels fiables, ou over-engineering ? »

5. Decision Intelligence, agents & confiance — *4 min* · ↔ B-A3 / B-B2`

> « La Decision Intelligence pose un paradigme decision-centric plutôt que data-centric, avec un cycle complet : données → paramètres de décision → modèles → outputs → boucle d'apprentissage. Sur les systèmes que tu connais, à quel point ferais-tu confiance à un système prescriptif — voire à un agent — en prod pour une décision à fort enjeu ? »

[Relances :]

> « Qu'est-ce qu'il te faudrait techniquement pour la confiance : backtesting, validation online/offline, intervalles de confiance, human-in-the-loop, monitoring de drift, feedback loop instrumentée ? »

>

> « Où tu places la frontière décision automatisable / décision sous contrôle humain, et sur quels critères ? »

6. Explicabilité, automation bias & gouvernance — *5 min* · ↔ B-A4 / B-B3`

> « Arbitrage classique : un système black-box nettement plus performant vs un modèle interprétable un peu moins bon, sur une décision qui engage l'organisation. Tu prends lequel, et sous quelles conditions tu changes d'avis ? »

[Relances :]

> « L'explicabilité post-hoc (SHAP, LIME, importances) te suffit pour justifier une décision, ou c'est de la rationalisation a posteriori ? Un modèle causal résout-il une partie du dilemme ? »

>

> « As-tu vu de l'automation bias concret — des sorties suivies sans être challengées ? Cause racine, impact, et quels garde-fous tu mets (seuils, abstention, revue humaine, contrefactuels affichés, alerting drift) ? »

>

> « AI Act, ISO 42001, model cards, audit de modèles : contrainte réelle dans ton taf ou paperasse ? Et si un système mène à une erreur grave, où doit être la responsabilité ? »

7. Architecture cible & clôture — *3 min* · ↔ B-B2 / B-7`

> « Projection : le système décisionnel AI-native idéal pour ton organisation, il ressemble à quoi — archi, place de la couche sémantique/ontologie, du causal, des agents, degré d'autonomie ? Et qu'est-ce qui manque aujourd'hui pour y arriver ? »

> « Dernier point : quelque chose d'important qu'on n'a pas creusé ? Une ou deux personnes à qui tu me conseillerais de parler ? Merci beaucoup — je t'envoie une synthèse anonymisée si tu veux. »

[Couper l'enregistrement. Noter à chaud : positions techniques tranchées, désaccords avec les profils métier, concepts émergents à ajouter à la grille de codage.]

Aide-mémoire — une page

Cadre : thèse · 30 min · anonyme · OK enregistrement ?

1. Profil & stack — rôle, stack, niveau dans la chaîne.

2. Maturité — desc/diag/préd/presc : où ? bloquant ? root-cause manuel/auto ? causal vrai (do-calculus, uplift, DAG) ou corrélation ?

3. World models — transposable à l'entreprise ? les 5 sous-modèles (entités/processus/autorité/policies/terminologie), lesquels durs ? simulation d'effets en cascade : réaliste ou recherche ? modèle explicite vs LLM ?

4. Ontologie / KG — Palantir (Data/Logic/Action/Security ; sémantique/cinétique/dynamique), digital twin : avis ? vraie difficulté (résolution d'entités, gouvernance...) ? Graph-RAG fiable pour décider ? substrat humain ↔ agent nécessaire ?

5. DI, agents & confiance — decision-centric, cycle complet : confiance en prod ? conditions (backtesting, HITL, drift) ? frontière auto/humain ?

6. Explicabilité & gouvernance — black-box vs interprétable : lequel ? SHAP/LIME suffisant ? causal ? automation bias vécu + garde-fous ? AI Act/ISO 42001/model cards réel ou paperasse ? responsabilité ?

7. Archi cible — système AI-native idéal + ce qui manque. À ajouter ? mise en relation ? merci.

Note méthodologique (chapitre 9)

Ce guide et le guide « business » partagent les mêmes 7 dimensions ; seule la profondeur change (les profils techniques abordent frontalement world models, ontologie et DI, là où les profils métier y accèdent après vulgarisation). Coder une variable profil (technique / métier / décideur) permet deux niveaux d'analyse : convergences transversales sur chaque pilier, et divergences systématiques technique ↔ métier (notamment sur la faisabilité des world models organisationnels, l'utilité réelle d'une ontologie, et l'arbitrage explicabilité/performance) — un apport différenciant de la recherche.

Annexe C. Grille de codage de l'analyse thématique

Grille utilisée pour l'analyse thématique des neuf entretiens (Braun & Clarke, 2006), avec codage ouvert puis axial. Les codes déductifs sont issus du cadre conceptuel de la Partie I ; les codes émergents sont apparus au fil du codage. Une variable de profil (technique / business analyst / métier) est codée pour chaque extrait.

C.1 Codes déductifs (issus du cadre conceptuel)

PLAFOND : Manifestations du plafond de complexité décisionnelle : rupture d'outil, recours à l'analyse manuelle, dépendance aux experts, fragmentation des données, contexte externe absent.

VALEUR : Capacités augmentées désirées : explication automatique des variations, prédiction, détection de signaux faibles, requête en langage naturel.

CONFIANCE : Conditions et freins à l'appui sur l'IA pour décider : transparence, track record, contrôle, frontière décisionnelle.

BIAIS : Automation bias : suivi sans remise en question, complaisance, capacité de contestation.

WORLDMODEL : Maturité de la représentation organisationnelle : ontologie, knowledge graph, terminologie partagée, silos sémantiques, faisabilité de la simulation.

AGENTS : Attentes et limites vis-à-vis des copilotes et agents : rôle d'assistance, autonomie, orchestration.

ETHIQUE : Responsabilité, explicabilité contre opacité, arbitrage transparence/performance, réglementation (AI Act, ISO 42001).

C.2 Codes émergents (issus du terrain)

ABSTENTION : Calibration et abstention : capacité du système à dire « je ne sais pas » et à escalader, érigée en critère de confiance.

HITL-FACADE : Contrôle humain de façade : validation humaine vidée de sa substance par la surcharge (tamponnage).

REVERSIBILITE : Réversibilité, enjeu et volume comme critères premiers d'automatisation.

DATA-SOCLE : Donnée gouvernée et maintenance dans la durée comme mur de faisabilité (« 80 % humain, 20 % technique »).

NON-STATIONNARITE : Non-stationnarité et réflexivité de l'organisation comme limite de principe du world model global.

INCREMENTAL : Construction incrémentale de l'ontologie, cas d'usage par cas d'usage, refus du big-bang.

ADOPTION : Conduite du changement, peur pour l'emploi, confiance construite dans la durée.

COUT : Coût complet (TCO), maintenance, empreinte énergétique et carbone, confidentialité et souveraineté des données.

Annexe D. Formulaire de consentement

Formulaire remis et lu à chaque participant avant l'entretien ; accord recueilli par écrit ou oralement, puis reconfirmé sur l'enregistrement.

Objet de la recherche. Cet entretien s'inscrit dans une thèse professionnelle (Mastère Spécialisé Big Data, Grenoble École de Management / Grenoble INP-Ensimag) portant sur l'évolution des systèmes décisionnels d'entreprise, de la Business Intelligence descriptive vers des systèmes augmentés par l'intelligence artificielle.

Nature de la participation. La participation consiste en un entretien semi-directif d'environ 30 à 40 minutes, en visioconférence ou en présentiel. La participation est libre et volontaire : le participant peut refuser de répondre à toute question, interrompre l'entretien ou se retirer de l'étude à tout moment, sans justification.

Enregistrement et transcription. Avec l'accord du participant, l'entretien est enregistré à des seules fins de retranscription. L'enregistrement n'est partagé avec aucun tiers ; il est conservé de manière sécurisée puis supprimé après validation de la transcription et au plus tard à l'issue de l'évaluation de la thèse.

Anonymisation. Les propos sont anonymisés dans la thèse : ni le nom du participant ni tout élément permettant de l'identifier directement ne sont publiés ; seule la fonction occupée et l'entreprise sont mentionnées. Conformément aux règles d'intégrité académique de l'école, l'identité des participants peut toutefois être communiquée, de manière confidentielle, au tuteur ou à l'évaluateur à des fins de vérification de l'authenticité de la collecte.

Traitement des données (RGPD). Les données collectées (enregistrement, transcription, fonction, coordonnées de contact) sont traitées sur la base du consentement (art. 6.1.a du RGPD), pour la seule finalité de cette recherche. Elles ne font l'objet d'aucun transfert à des tiers ni d'aucune décision automatisée. Le participant dispose d'un droit d'accès, de rectification, d'effacement et de retrait du consentement à tout moment, en écrivant à l'auteur (charaf.achir6@gmail.com). Le retrait du consentement n'affecte pas la licéité du traitement antérieur.

Consentement. « Je reconnais avoir été informé(e) de l'objet de la recherche et des modalités ci-dessus. J'accepte librement de participer à cet entretien et j'autorise son enregistrement à des fins de retranscription. »

Nom, date et signature du participant : _____

Annexe E. Transcriptions intégrales des entretiens

Les neuf entretiens sont reproduits ci-dessous dans l'ordre des profils du tableau 5 (chapitre 11) : profils techniques (E.1 à E.3), business analysts (E.4 et E.5), profils métier (E.6 à E.9). Les transcriptions sont issues des enregistrements réalisés avec le consentement des participants (voir Annexe D) ; les échanges sont restitués intégralement, avec une anonymisation par la fonction. Par souci de compacité, ces annexes sont composées en interligne simple et en corps réduit.

E.1 Entretien T1. Directeur de programme IA, protection sociale (ProBTP)

Entreprise : ProBTP

Poste du répondant : Directeur de programme IA (freelance)

Secteur : Protection sociale

Langue : Français

Format : Entretien à distance (~30 min)

ACHIR Charaf — Juste avant de commencer, je te reconfirme sur la bande : t'es OK pour que j'enregistre, juste pour la retranscription ?

Directeur programme IA (ProBTP) — Ouais, ouais, vas-y, pas de souci. Anonyme, c'est mieux, franchement, parce que je vais te dire ce que je pense, hein, pas la version corporate. (rires) Vas-y, enregistre. OK pour l'enregistrement, c'est confirmé.

ACHIR Charaf — Parfait, merci. Donc on y va. Décris-moi ton rôle et la stack data/ML sur laquelle tu bosses en ce moment, et à quel niveau de la chaîne t'interviens — ingestion, modélisation, déploiement, decision support ?

Directeur programme IA (ProBTP) — Alors, euh... faut que je sois honnête avec toi tout de suite, sinon on va se planter pendant trente minutes. Aujourd'hui, moi, je touche plus le clavier, hein. Mon rôle, c'est direction de programme IA. Concrètement, euh, la DSI a sélectionné quatre cas d'usage, et mon boulot c'est de les formaliser, d'objectiver les ROI, de mesurer l'impact sur les systèmes existants, et de coordonner tout ce petit monde — on est sur une vingtaine de projets en parallèle, quoi. Donc je suis très en haut de la chaîne : cadrage, archi cible, adéquation moyens-objectifs, budget, qualification des ressources. Le decision support, quoi, au sens organisationnel.

ACHIR Charaf — Donc pas la modélisation ni le déploiement au sens hands-on.

Directeur programme IA (ProBTP) — Voilà. Mais attention, hein — j'ai un passif. J'ai fait, euh, vingt-cinq ans de technique avant. DBA Oracle-Sybase, architecte, j'ai monté les plateformes de conteneurs chez Orange, Docker Swarm puis Kubernetes, en 2015-2016, full open source, j'étais PO de l'équipe produit. J'ai géré des datacenters, sept mille serveurs, du SDN, du SDS, du stockage distribué. Donc la stack, l'infra, la prod, le run — ça, c'est mon monde, je le sens dans mes tripes. Le ML pur et dur, les modèles, l'entraînement... j'ai frôlé, quoi. À un moment on avait monté une cellule d'innovation qui faisait des études LLM, de l'entraînement de modèles pour automatiser l'analyse de nos appels d'offres. Mais moi j'étais le sponsor, le mec qui débloque le budget et qui pose le cadre, pas le data scientist qui bricole les features. Faut que tu le saches, parce que sur certaines de tes questions, euh, je vais te renvoyer la balle, hein.

ACHIR Charaf — C'est noté, et c'est exactement pour ça que je veux te parler. On y va comme ça vient.

ACHIR Charaf — Sur l'échelle classique descriptif, diagnostique, prédictif, prescriptif, où tu situes honnêtement les systèmes que t'as sous la main, et qu'est-ce qui bloque le passage au niveau au-dessus ?

Directeur programme IA (ProBTP) — Honnêtement ? La grande masse, c'est descriptif. Faut arrêter de se raconter des histoires, hein. Quatre-vingts pour cent de ce qui tourne dans un grand groupe, c'est du reporting. Des Power BI, des tableaux, « voilà les chiffres du mois ». Diagnostique, on y arrive un peu, mais souvent, euh, c'est un humain qui drille dedans à la main. Prédictif, y'a des poches — la fraude, l'actuariat, des trucs de scoring — mais c'est cloisonné, c'est des îlots, quoi. Prescriptif à l'échelle... non. Franchement non. On en parle beaucoup, on en fait très peu.

ACHIR Charaf — Et qu'est-ce qui bloque, concrètement ?

Directeur programme IA (ProBTP) — Alors, plusieurs trucs, et le premier c'est pas celui qu'on croit. C'est pas la techno, hein. C'est la donnée. La donnée est pourrie, elle est en silos, elle est pas gouvernée, personne est d'accord sur ce qu'est un « client » ou un « contrat ». Tu veux faire du prescriptif sur des fondations en sable, ça marche pas, quoi. Le deuxième blocage, euh, c'est la confiance et la responsabilité — le jour où le système dit « fais ça » et que personne veut mettre sa signature en dessous, bah ça avance plus. Et le troisième, plus bête mais réel : l'organisation. Les gens dont le métier c'est de décider, ils ont pas envie qu'une machine décide à leur place. Donc c'est autant un sujet humain qu'un sujet techno.

ACHIR Charaf — Quand un KPI décroche, genre un indicateur qui plonge d'un coup, qui fait le root-cause ? Un humain, du drill-down, ou quelque chose d'automatique ?

Directeur programme IA (ProBTP) — (rires) Un humain. Toujours un humain. Dans, euh, quatre-vingt-quinze pour cent des cas, un mec ouvre son tableau, il descend niveau par niveau, il appelle deux collègues, et il finit par comprendre. De l'automatique sur le root-cause, du vrai, j'en ai très peu vu tourner en prod. C'est un peu le Graal dont tout le monde parle et que personne livre, quoi.

ACHIR Charaf — Est-ce que sur ces systèmes vous faites de l'inférence causale au sens propre — je pense do-calculus, uplift modeling, quasi-expériences, des DAGs — ou plutôt de la corrélation et du feature importance qu'on interprète causalement ? Où est la limite, pour toi ?

Directeur programme IA (ProBTP) — Alors là... (souffle) tu me mets sur un terrain où je vais être moins bon, faut que je te le dise, hein. Do-calculus, franchement, c'est pas mon vocabulaire quotidien, je vais pas te faire semblant. Ce que je peux te dire de ce que j'ai vu, euh, c'est que dans la vraie vie, ce qu'on appelle « causal » c'est souvent de la corrélation habillée. On sort un feature importance d'un modèle, genre « regarde, c'est cette variable qui pèse », et hop, les gens lisent ça comme une cause. Et ça, c'est un piège monumental. Parce que le modèle il te dit « ces deux trucs bougent ensemble », il te dit pas « celui-là fait bouger l'autre ».

ACHIR Charaf — Donc la limite tu la mets où ?

Directeur programme IA (ProBTP) — La limite... écoute, moi je la sens plus que je la théorise, hein. Je la sens le jour où quelqu'un veut agir sur un levier. Tant que t' observes, la corrélation ça suffit à peu près. Le jour où tu dis « je tire sur ce levier et l'effet va être celui-là », là t'es dans du causal, et là ton modèle corrélationnel il te ment potentiellement. L'uplift, j'en ai entendu parler dans le marketing, « est-ce que mon action a vraiment changé le comportement ou le gars allait acheter de toute façon » — ça, le concept, je le comprends, hein. Mais les tests A/B, les quasi-expériences propres, dans un groupe classique, c'est rare, parce que ça demande une rigueur que les gens ont pas. Voilà où je suis : je sais reconnaître le piège, je saurais pas te construire le DAG proprement. C'est pas mon métier, quoi.

ACHIR Charaf — C'est très clair, et c'est utile justement que tu poses la frontière comme ça. On monte un cran en abstraction. Le concept de world model, au sens de LeCun — une représentation interne qui modélise la dynamique d'un environnement et les conséquences des actions — transposé à l'entreprise. Ça te paraît réaliste, ou fumeux, l'idée d'un modèle du monde d'une organisation ?

Directeur programme IA (ProBTP) — Alors le mot « world model » à la LeCun, euh, je vais pas te commenter LeCun, c'est pas mon rayon la recherche fondamentale. Mais l'idée derrière, si je la traduis dans mon langage : est-ce qu'on peut avoir un modèle de comment la boîte fonctionne, qui prédit ce qui se passe si on tire sur tel truc ? Ça, ça me parle énormément. Parce que c'est exactement ce qu'un bon directeur de production fait dans sa tête depuis toujours, hein. Quand j'étais chez Orange et que je gérais les datacenters, j'avais un modèle mental de mon système : je savais que si je touchais au réseau ici, ça allait faire tousser le stockage là-bas. C'était pas formalisé, c'était dans ma tête et dans celle de quinze experts.

ACHIR Charaf — Donc l'objet existe déjà, informellement.

Directeur programme IA (ProBTP) — Exactement. Le modèle du monde, il existe. Il est juste dans les têtes, pas dans une machine. La question c'est : est-ce qu'on peut le sortir des têtes et le mettre dans un système ? Et là je suis... partagé, je t'avoue. Parce qu'un système d'hébergement, c'est déjà hyper complexe, mais c'est déterministe, à peu près. Une organisation humaine, avec des politiques, des egos, des jeux de pouvoir, des règles qui changent — modéliser ça, la dynamique de ça... je suis pas sûr qu'on sache, hein. Réaliste sur des sous-domaines bien bornés, oui. Réaliste sur « la boîte » entière, aujourd'hui, je dis fumeux. Ou en tout cas très prématuré.

ACHIR Charaf — Une des formalisations que je regarde — ça s'appelle ElixirData, ou Context OS — décompose ce modèle du monde en cinq sous-modèles : les entités, les processus, l'autorité, les règles ou politiques, et la terminologie. Ça te parle, ce découpage ? Et lesquels te paraissent les plus durs à construire en vrai ?

Directeur programme IA (ProBTP) — Ah ouais, ça, ça me parle beaucoup plus que le « world model » abstrait. Les entités, les processus, l'autorité, les règles, le vocabulaire — ça, c'est concret, je vois ce que c'est. Et je vais te répondre direct sur les plus durs, parce que là j'ai un avis, hein. Les entités, c'est déjà chaud, mais c'est un problème connu — c'est de la modélisation de données, on sait faire, mal, mais on sait faire. Les processus, pareil, y'a du BPMN, y'a des gens qui font ça depuis trente ans. Les deux qui tuent, pour moi, c'est l'autorité et les règles. L'autorité — qui a le droit de décider quoi — dans une vraie boîte, c'est jamais écrit nulle part proprement. Y'a l'organigramme officiel, et y'a comment ça marche vraiment. Et les deux sont différents, hein. Tu vas modéliser lequel ? Et les règles, les politiques — elles se contredisent, elles ont des exceptions partout, elles changent avec le dernier mail du directeur. Formaliser ça dans un modèle cohérent, euh, moi j'ai jamais vu personne y arriver vraiment. Et la terminologie, on en reparlera

après je pense, mais c'est un cauchemar aussi, parce que le même mot veut dire trois choses selon le service.

ACHIR Charaf — Est-ce qu'on sait aujourd'hui construire un modèle qui simule des effets en cascade, des vulnérabilités structurelles à l'échelle d'une boîte ? Ou c'est encore de la recherche ? Et qu'est-ce qui manque le plus — données, causalité, compute, modélisation ?

Directeur programme IA (ProBTP) — Ça, c'est une super question, et j'ai un avis tranché. Les effets en cascade, on sait les simuler sur des systèmes techniques. Moi je faisais de l'analyse d'impact, du « si ce composant tombe, qu'est-ce qui tombe avec » — sur de l'infra, ça existe, c'est de la modélisation de dépendances, ça marche. À l'échelle d'une organisation entière, avec les effets humains, économiques, les fournisseurs, les clients qui réagissent — non. On sait pas. C'est de la recherche, et même, je dirais, c'est encore un peu du fantasme. Et qu'est-ce qui manque ? Je vais te surprendre : pour moi, dans l'ordre, c'est la donnée d'abord, la causalité ensuite, et le compute en dernier — le compute c'est le moindre de nos soucis, on a de la puissance à revendre, hein. Le vrai problème c'est qu'on a pas les données des enchaînements. Pour apprendre les cascades, il faudrait avoir observé plein de cascades, proprement instrumentées. Or ces événements-là — les crises, les défaillances structurelles — ils sont rares, ils sont mal documentés, chaque boîte en vit deux ou trois par décennie. Tu peux pas entraîner un truc là-dessus. Et derrière, oui, la causalité, parce qu'une cascade c'est causal par définition. Donc données et causalité, c'est ça le mur. Pas le compute.

ACHIR Charaf — Dernière relance sur ce bloc : la distinction entre simuler avec un modèle explicite, du symbolique, et un LLM qui « raisonne » sur le contexte qu'on lui donne — tu la poses comment ?

Directeur programme IA (ProBTP) — Alors ça, c'est le débat du moment, et je vais te donner mon intuition de vieux de la vieille, hein. Un modèle explicite, un truc symbolique, causal, avec des règles — c'est rigoureux, c'est auditable, tu sais pourquoi il a dit ça, mais c'est une horreur à construire et à maintenir, et ça casse dès que la réalité sort du cadre que t'as prévu. Un LLM, c'est l'inverse : c'est bluffant de souplesse, tu lui balances du contexte et il te sort un raisonnement plausible sur n'importe quoi, mais... plausible, c'est le mot dangereux. Il « raisonne » entre guillemets. En vrai il produit du texte qui a la forme d'un raisonnement, quoi. Et pour une décision à enjeu, la forme du raisonnement ça suffit pas, il me faut le fond. Moi ce que je crois, et c'est une conviction pas une certitude, c'est que la vérité est au milieu. Le LLM comme interface, comme moteur de langage, pour discuter avec le système, sortir des hypothèses. Et un modèle explicite, dur, en dessous, pour tout ce qui engage. Le LLM propose, le modèle validé dispose. Lâcher un LLM seul sur une simulation d'organisation et croire ce qu'il raconte, pour moi c'est non. Il hallucine avec un aplomb terrifiant, hein.

ACHIR Charaf — On arrive sur un des cœurs de la thèse. L'ontologie d'entreprise, façon Palantir — ils la présentent avec quatre dimensions, Data, Logic, Action, Security, et une architecture en couches, l'ensemble vendu comme un « digital twin » de l'organisation, partagé entre les humains et les agents. Sur le fond, qu'est-ce que t'en penses, techniquement ?

Directeur programme IA (ProBTP) — Bon. Alors déjà, « digital twin de l'organisation », quand j'entends ça, euh, ma main se pose sur mon portefeuille. (rires) C'est du marketing, ça, hein. Palantir c'est très fort en marketing. Mais derrière le mot, y'a des trucs vrais, faut pas jeter le bébé. L'idée d'avoir une couche unique où la donnée, la logique métier, les actions possibles et la sécurité sont modélisées ensemble et cohérentes — sur le principe, c'est le bon rêve. C'est ce que tout architecte d'entreprise cherche depuis toujours : un référentiel partagé où « client » veut dire la même chose partout, où t'as pas à retraduire d'un système à l'autre. Le fait d'y accrocher les actions, le « Action » là, c'est malin, parce que la plupart des modèles de données classiques ils décrivent le monde mais ils te laissent pas agir dessus. Là tu relies la représentation à ce que tu peux faire. Ça, c'est intéressant.

ACHIR Charaf — Mais ?

Directeur programme IA (ProBTP) — Mais. Le « mais » il est énorme, hein. C'est un chantier de dingue. Palantir te vend un objet fini, propre, brillant. La réalité c'est que pour remplir cette ontologie avec les données pourries de ta vraie boîte, il te faut une armée, des années, et une gouvernance de fer. Le digital twin il est aussi bon que les données que tu mets dedans, et tes données elles sont dégueulasses. Donc le concept, dix sur dix. La facilité de mise en œuvre qu'on te vend, deux sur dix. C'est un aspirateur à budget si t'as pas les fondations.

ACHIR Charaf — Justement, dans ton expérience, la vraie difficulté d'une couche sémantique ou d'un knowledge graph d'entreprise, elle est où ? Modélisation, résolution d'entités, gouvernance, maintenance, adoption ?

Directeur programme IA (ProBTP) — Ah, tu me poses la question à mille points. (réfléchit) Je vais te la classer, parce que j'ai vécu tous ces murs, hein. La modélisation, c'est dur intellectuellement mais c'est faisable, tu prends de bons architectes, ils modélisent. C'est le plus visible mais c'est pas le plus mortel. La résolution d'entités — savoir que le « Dupont » de ce système et le « Dupont J. » de cet autre c'est le même — c'est un enfer technique, mais c'est un enfer connu, y'a des outils, du matching, on s'en sort à peu

près. Le vrai tueur, celui qui fait mourir les projets, c'est la maintenance et l'adoption, et je les mets ensemble parce qu'ils sont liés. Un knowledge graph, une ontologie, tu la construis une fois, super, elle est belle. Six mois après, la boîte a changé, les processus ont bougé, y'a un nouveau produit, et si personne maintient le modèle, il diverge du réel. Et le jour où le modèle correspond plus à la réalité, les gens arrêtent de lui faire confiance, et le jour où ils lui font plus confiance, ils l'utilisent plus, et le truc meurt. J'ai vu ça des dizaines de fois avec les CMDB, les référentiels — c'est le même schéma. La techno c'est jamais ce qui tue. C'est le fait que personne a le budget ni l'envie de tenir le référentiel à jour dans la durée. C'est un problème d'organisation et de volonté, pas de techno.

ACHIR Charaf — Le Graph-RAG, les couches sémantiques pour brancher des LLM sur la donnée métier — ça tient la route pour de la décision, ou ça déplace juste le problème de fiabilité ?

Directeur programme IA (ProBTP) — Franchement ? Un peu des deux, hein. Le Graph-RAG, brancher le LLM sur un graphe de connaissances plutôt que le laisser inventer, c'est un vrai progrès, je crache pas dessus. Ça réduit les hallucinations parce que tu forces le modèle à s'appuyer sur des faits structurés au lieu de piocher dans sa soupe interne. Pour de la recherche d'info, du « retrouve-moi les bons documents, les bonnes relations », c'est bien. Mais pour de la décision — attention, hein. Tu déplaces le problème de fiabilité, tu le supprimes pas. Avant, ta fiabilité elle dépendait des tripes du LLM. Maintenant elle dépend de la qualité de ton graphe. Si ton graphe est faux ou périmé — et vu ce que je viens de te dire sur la maintenance, il le sera — ben le LLM va te sortir une connerie très bien sourcée, très confiante, appuyée sur une donnée fausse. C'est presque pire, parce que ça a l'air rigoureux. Donc oui, ça tient la route pour aider à décider, pour éclairer. Pour décider tout seul à enjeu, non. On tourne un peu en rond mais c'est ça la vérité.

ACHIR Charaf — Et une ontologie partagée comme substrat commun entre les humains et les agents IA — c'est une condition nécessaire pour des systèmes décisionnels fiables, ou c'est de l'over-engineering ?

Directeur programme IA (ProBTP) — Là je vais être plus positif. Je pense que c'est nécessaire, à terme. Pas over-engineering. Pour une raison simple : si l'humain et l'agent parlent pas le même langage, tu peux pas leur faire collaborer sur une décision, et tu peux surtout pas auditer ce que l'agent a fait. Le substrat commun, le vocabulaire partagé, c'est ce qui permet à un humain de comprendre et de contester ce que la machine propose. Sans ça, l'agent c'est une boîte noire dans son coin. Maintenant, « nécessaire » veut pas dire « il faut le construire en entier avant de commencer », hein. Ça, ce serait l'erreur. Le piège c'est de dire « on va passer trois ans à bâtir l'ontologie parfaite de toute la boîte et après on fera de l'IA ». Non. Tu meurs avant. Il faut la construire par petits bouts, cas d'usage par cas d'usage, là où t'en as besoin. L'ontologie partagée comme cible, oui. Comme préalable géant, non, c'est comme ça qu'on flingue les budgets.

ACHIR Charaf — La Decision Intelligence pose un paradigme decision-centric plutôt que data-centric — on part de la décision à prendre. Sur les systèmes que tu connais, à quel point tu ferais confiance à un système prescriptif, voire à un agent, en prod, pour une décision à fort enjeu ?

Directeur programme IA (ProBTP) — Alors d'abord, sur le « decision-centric plutôt que data-centric » — je signe des deux mains. Ça, c'est pas du buzzword, c'est du bon sens qu'on a oublié. Pendant vingt ans on a collecté de la donnée pour la donnée. « Faisons un data lake, on verra après. » Et on s'est retrouvés avec des marécages de données que personne utilise. Repartir de « quelle décision je veux améliorer, et donc de quoi j'ai besoin pour ça », c'est remettre le truc à l'endroit. Ça, j'adhère complètement. Sur la confiance à un système prescriptif à fort enjeu, en prod... ma réponse elle est courte, hein : ça dépend de l'enjeu et de la réversibilité, et par défaut, faible.

ACHIR Charaf — Développe le « ça dépend ».

Directeur programme IA (ProBTP) — Ben regarde. Une décision à fort enjeu mais réversible, où si le système se trompe je peux revenir en arrière sans dégât majeur — là je laisse le système faire, je surveille, et c'est très bien. Genre optimiser une allocation, ajuster un paramètre, un truc que je peux corriger demain. Une décision à fort enjeu et irréversible — un truc qui engage juridiquement, financièrement, qui touche un assuré, un client — là, non, pas d'agent tout seul, jamais, en tout cas pas aujourd'hui. Il me faut un humain qui valide, qui met sa signature, qui porte la responsabilité. Le critère c'est pas « est-ce que le modèle est bon ». Le critère c'est « qu'est-ce qui se passe le jour où il se trompe, et qui paie ». Parce qu'il se trompera, hein. La question c'est jamais si, c'est quand. Et « c'est l'algorithme qui a décidé » ça tient pas deux minutes devant un régulateur.

ACHIR Charaf — Qu'est-ce qu'il te faudrait, techniquement, pour avoir cette confiance ? Backtesting, validation online/offline, intervalles de confiance, human-in-the-loop, monitoring de drift, une feedback loop instrumentée ?

Directeur programme IA (ProBTP) — Alors là tu parles ma langue, parce que c'est de l'ops, ça, au fond. Alors : le backtesting, oui, évidemment, montre-moi qu'il aurait bien décidé sur l'historique — mais je me méfie, parce que le passé prédit pas le futur, surtout le jour où le contexte change. Le monitoring de drift, pour moi c'est le truc numéro un, celui qu'on oublie et qui est vital. Un modèle il pourrait doucement, le monde bouge sous ses pieds, et si tu surveilles pas que les données d'entrée ressemblent toujours à ce sur

quoi il a appris, un jour il déraile sans prévenir et personne voit rien. Ça, c'est mon obsession, le drift, parce que c'est silencieux. Les intervalles de confiance, oui, mais alors surtout — et là je suis peut-être plus original — je veux que le système sache dire « je sais pas ». Un système qui répond toujours avec la même assurance, qu'il soit sûr ou paumé, c'est un danger public, hein. Je préfère un système qui, sur les vingt pour cent de cas chelous, lève la main et dit « celui-là, humain, occupe-t'en ». L'abstention, quoi. Human-in-the-loop, oui, sur les cas à enjeu — mais attention au piège, on va en parler juste après je crois, parce que le human-in-the-loop mal fait c'est pire que rien. Et la feedback loop instrumentée — indispensable, mais c'est le truc qu'on met jamais en place parce que ça coûte cher et que ça rapporte rien tout de suite. Tout le monde veut le modèle qui décide, personne veut payer la tuyauterie qui mesure si la décision était bonne après coup.

ACHIR Charaf — Et la frontière entre décision automatisable et décision sous contrôle humain, tu la mets où ?

Directeur programme IA (ProBTP) — Je te l'ai un peu donnée : réversibilité, et enjeu. Je te rajoute un troisième critère : le volume et la répétabilité. Une décision qui revient dix mille fois par jour, cadrée, avec un impact unitaire faible — automatise, l'humain peut pas suivre de toute façon. Une décision rare, singulière, à gros impact — humain, obligatoire. Le mauvais réflexe c'est de vouloir automatiser les décisions rares et importantes parce que ce sont les plus « intéressantes ». Non. Automatise le volume ennuyeux et répétitif, et garde tes humains pour les cas rares et lourds. C'est exactement l'inverse de ce que les gens ont envie de faire, hein.

ACHIR Charaf — Arbitrage classique : t'as un système black-box nettement plus performant, contre un modèle interprétable un peu moins bon, sur une décision qui engage l'organisation. Tu prends lequel, et sous quelles conditions tu changerais d'avis ?

Directeur programme IA (ProBTP) — Sur une décision qui engage l'organisation ? L'interprétable. Sans hésiter, presque à tous les coups. Et je vais te dire pourquoi, c'est pas de l'idéologie. Le jour où ça part en vrille — et ça partira en vrille — avec le black-box tu peux rien faire. Tu peux pas expliquer, tu peux pas corriger de façon ciblée, tu peux pas défendre ta décision devant un régulateur, un client mécontent, un tribunal. « Le modèle a dit non à votre crédit mais je peux pas vous dire pourquoi » — c'est intenable, et de plus en plus c'est illégal. Moi j'ai fait de la sécu, de l'ISO 27001, de la conformité — mon réflexe c'est « comment je prouve, comment j'audite, comment je défends ». Un truc que je peux pas expliquer, je peux pas le défendre, donc je le mets pas sur une décision qui engage.

ACHIR Charaf — Sous quelles conditions tu changerais d'avis ?

Directeur programme IA (ProBTP) — Deux conditions. Un : si l'écart de performance est énorme et que la mauvaise décision fait vraiment mal. Genre en médical, si le black-box détecte un cancer avec vingt points de mieux, là on discute, parce que refuser vingt points de performance ça tue des gens, l'éthique elle s'inverse. Deux : si autour du black-box je peux mettre assez de garde-fous pour compenser — de la validation, de l'abstention, une surveillance serrée, un humain sur les cas limites. Si j'arrive à encadrer la bête suffisamment, je peux vivre avec un cœur opaque. Mais opaque et lâché en autonomie sur une décision qui engage, non.

ACHIR Charaf — L'explicabilité post-hoc — SHAP, LIME, les importances de variables — ça te suffit pour justifier une décision, ou c'est de la rationalisation a posteriori ? Et est-ce qu'un modèle causal résout une partie du dilemme ?

Directeur programme IA (ProBTP) — Bon, SHAP, LIME, je connais les noms, je sais que c'est des techniques pour, après coup, essayer d'expliquer ce qu'un modèle a fait. Mais le détail des maths, je vais pas te bluffer, c'est pas moi qui vais te les coder. En revanche sur le fond j'ai une intuition très forte, et c'est un peu dans ta question : « post-hoc ». Pour moi, une explication qu'on fabrique après coup pour justifier une décision déjà prise, faut s'en méfier comme de la peste. Parce que c'est exactement ce que fait un humain de mauvaise foi : il décide au feeling, et après il t'invente une justification propre. Si mon système décide dans son coin de façon opaque et qu'ensuite un autre outil me fabrique une jolie histoire pour expliquer, comment je sais que l'histoire est vraie et pas juste... plausible ? On revient à mon mot de tout à l'heure. Plausible c'est pas vrai. Alors est-ce que le causal résout le dilemme ? En partie, oui, je pense. Un modèle causal, si tu arrives à le construire, il est explicable par construction — il te dit « c'est ça qui cause ça », c'est pas une histoire fabriquée après coup, c'est la structure même du modèle. Le problème c'est ce que je t'ai dit au début : le construire, ce modèle causal, on sait très mal le faire. Donc c'est la bonne réponse théorique à un problème qu'on sait pas résoudre en pratique. C'est un peu l'histoire de tout ce domaine, d'ailleurs.

ACHIR Charaf — T'as vu de l'automation bias concret ? Des sorties de système suivies sans être challengées ? Si oui, la cause racine, l'impact, et les garde-fous que tu mets ?

Directeur programme IA (ProBTP) — Oh oui. Oui, oui, oui. Et pas qu'un peu. L'automation bias, c'est le truc le plus sous-estimé de tout ton sujet, à mon avis. Le cas le plus bête : le GPS. Les gens qui foncent dans un lac parce que le GPS a dit tourne à gauche. C'est ça, l'automation bias, à l'état pur — la machine a dit,

donc j'exécute, mon cerveau s'éteint. Et en entreprise c'est pareil, en plus vicieux. J'ai vu des équipes ops qui suivaient les recommandations d'un outil de supervision sans plus jamais réfléchir, parce que « l'outil sait ». Le pire truc, c'est le human-in-the-loop de façade : tu mets un humain censé valider, mais tu lui donnes trois secondes et deux cents cas par heure, et un système qui a raison quatre-vingt-quinze pour cent du temps. Au bout d'une semaine, le mec il clique « valider » machinalement. Il tamponne, quoi. Et le jour où le système se plante sur le cas critique, le garde-fou humain il a démissionné dans sa tête depuis longtemps. Donc t'as l'illusion d'un contrôle humain, et t'as zéro contrôle réel. Ça, c'est le plus dangereux, parce que ça rassure à tort. La cause racine ? La confiance excessive plus la fatigue plus le volume. Les garde-fous, du coup : le premier, celui auquel personne pense, c'est de ne pas noyer l'humain. Si tu veux un vrai contrôle humain, tu lui donnes peu de cas, du temps, et les bons cas — l'abstention dont je parlais. Un humain qui traite dix cas difficiles par jour reste vigilant. Un humain qui en tamponne deux cents, non. Ensuite, l'affichage des contrefactuels, le « si telle variable avait été différente la décision aurait changé » — ça réveille le cerveau. L'alerting sur le drift, je te l'ai dit, c'est mon obsession. Et un truc bête : faire tourner de temps en temps des cas dont tu connais la réponse pour voir si l'humain challenge vraiment ou s'il valide en dormant. Contrôler le contrôleur, quoi.

ACHIR Charaf — Dernier point du bloc, sur la conformité : AI Act, ISO 42001, model cards, audit de modèles — c'est une contrainte réelle dans ton taf, ou de la paperasse ? Et si un système mène à une erreur grave, où doit être la responsabilité ?

Directeur programme IA (ProBTP) — Alors là, tu tapes dans le mille, parce que la conformité c'est un truc que je connais vraiment, j'ai renouvelé de l'ISO 27001 plusieurs fois. Donc je vais pas te dire que c'est de la paperasse, parce que ce serait me renier. Mais je vais te dire un truc plus nuancé. La conformité, c'est ce que t'en fais. L'ISO 42001, l'AI Act, si tu les vis comme une case à cocher, un mec qui remplit un document une fois par an pour l'auditeur et qu'on range dans un tiroir — alors oui, c'est de la paperasse inutile, et pire, ça donne une fausse sécurité. « On est conformes », et tout le monde dort tranquille sur un truc dangereux. Ça, c'est le mal. Mais si tu le vis comme une discipline — les model cards qui documentent vraiment sur quoi le modèle a été entraîné et où il est pas censé être utilisé, l'audit qui va vraiment regarder sous le capot, la traçabilité des décisions — alors c'est pas de la paperasse, c'est ce qui te sauve la mise le jour du problème. Et vu que je bosse dans la protection sociale, où on touche des données sensibles et des gens, moi je suis plutôt content qu'il y ait un cadre. C'est pas un frein, c'est un garde-fou, si on le prend au sérieux.

ACHIR Charaf — Et la responsabilité, en cas d'erreur grave ?

Directeur programme IA (ProBTP) — Alors ça, ma position est simple et elle bougera pas : la responsabilité est humaine. Point. Elle est chez l'organisation qui a déployé le système et chez les gens qui l'ont mis là et qui l'exploitent. « C'est l'IA qui a décidé » n'est pas une défense, ça doit jamais en être une, sinon on ouvre une porte terrifiante où plus personne est responsable de rien. L'IA c'est un outil, hein. Si ma voiture a un défaut de freins et qu'elle tue quelqu'un, c'est pas la voiture qu'on juge, c'est le constructeur. Pour l'IA c'est pareil. Celui qui décide de déployer un système à enjeu, il endosse la responsabilité de ce que le système fait. Et honnêtement, cette responsabilité claire, c'est le meilleur garde-fou de tous — parce que le jour où le décideur sait que c'est sa signature et sa tête qui sont en jeu, comme par magie il devient beaucoup plus rigoureux. La responsabilité floue, c'est ça qui rend les gens imprudents.

ACHIR Charaf — On finit sur une projection. Le système décisionnel AI-native idéal pour ton organisation, il ressemble à quoi ? Et qu'est-ce qui manque aujourd'hui pour y arriver ?

Directeur programme IA (ProBTP) — OK, je te fais la version « si j'avais une baguette magique et un budget infini », mais avec mon réalisme de vieux quand même. Au socle, tout en bas, je mets la donnée gouvernée. Pas glamour, mais tout part de là. De la donnée propre, avec des définitions partagées, une qualité mesurée. Sans ça, tout le reste c'est de la déco sur du sable. Quatre-vingts pour cent de l'effort il est là, et c'est le truc dont personne veut payer la facture. Au-dessus, la couche sémantique, l'ontologie — mais construite par morceaux, au fil des cas d'usage, jamais en big bang. Au-dessus encore, les modèles : du prédictif classique là où il marche, et idéalement du causal là où on veut agir sur des leviers — en sachant que le causal, aujourd'hui, on sait mal le faire. Les LLM et les agents, je les mets en couche d'interaction et d'orchestration, au-dessus. C'est l'interface. Mais — et c'est ma ligne rouge — l'agent il propose, il exécute pas les décisions à enjeu tout seul. Autonomie forte sur le volume répétitif et réversible, autonomie zéro sur le rare et l'irréversible, et partout, la capacité de dire « je sais pas, prends le relais ». Et transversal à tout ça, deux trucs qu'on oublie toujours : l'observabilité — je veux voir ce que le système fait, mesurer le drift, tracer les décisions — et la boucle de feedback. C'est mon côté ops : un système que tu peux pas observer et pas corriger, c'est pas un système, c'est une prière. (rires)

ACHIR Charaf — Et qu'est-ce qui manque, aujourd'hui, pour y arriver ?

Directeur programme IA (ProBTP) — Trois choses, et aucune des trois c'est de la techno, tu vas rire. Un : la donnée propre et gouvernée, je le redis parce que c'est vraiment le mur. Deux : les compétences et la volonté de tenir tout ça dans la durée — construire c'est facile, maintenir dix ans c'est ça qui tue, et personne budgète la maintenance. Trois : la confiance, qui se gagne petit à petit, en livrant des petits trucs

qui marchent et qui rendent service, pas en promettant le grand soir de l'IA qui décide tout. La techno, franchement, elle est là où elle arrive. Ce qui manque c'est la donnée, la rigueur organisationnelle, et la patience. Et ça, aucun vendeur te le mettra dans une licence. Si je devais résumer tout notre échange en une phrase : le problème est à quatre-vingts pour cent humain et organisationnel, et à vingt pour cent technique, et tout le monde passe quatre-vingts pour cent de son énergie sur les vingt pour cent techniques. Voilà. C'est peut-être ça, le vrai sujet de ta thèse. (rires)

ACHIR Charaf — (rires) C'est peut-être bien ça, oui. Dernière question rituelle : quelque chose d'important qu'on n'a pas creusé ? Et une ou deux personnes à qui tu me conseillerais de parler ?

Directeur programme IA (ProBTP) — Un truc qu'on a pas assez creusé... le coût. Le vrai coût complet de ces systèmes, run et maintenance compris, sur cinq ou dix ans, pas juste le projet initial. Tout le monde raisonne en « projet », personne raisonne en « produit qu'il faut entretenir à vie ». Et c'est là que les budgets explosent et que les trucs meurent. Regarde ça de près, le TCO réel, tu vas trouver des choses. Pour les gens à qui parler — va chercher des vrais data engineers, ceux qui se battent avec la donnée sale au quotidien, pas les data scientists stars qui font des jolis modèles sur des données déjà propres. La vérité de ton sujet elle est chez ceux qui nettoient. Et parle à des gens du métier, de la décision — les actuaux, les gens du risque, ceux qui décident vraiment et qui te diront ce qui les ferait, ou pas, faire confiance à une machine.

ACHIR Charaf — Exactement. Écoute, merci énormément, c'était super riche. Je te coupe l'enregistrement, et je t'envoie une synthèse anonymisée si tu veux.

Directeur programme IA (ProBTP) — Avec plaisir, envoie. Et bon courage pour la thèse — le sujet est bon, mais méfie-toi des mots qui brillent. (rires) Salut.

E.2 Entretien T2. Architecte logiciel et IA senior, solutions pour le voyage (Amadeus)

Entreprise : Amadeus

Poste du répondant : Senior Software Architect AI

Secteur : Technologies pour le voyage (GDS)

Langue : Français

Format : Entretien à distance (~38 min)

ACHIR Charaf — Je voulais juste vous dire que j'enregistre la retranscription, donc je voulais savoir si vous êtes d'accord pour ceci.

Architecte IA (Amadeus) — Aucun problème, pas de souci.

ACHIR Charaf — Super, merci. Alors, décrivez-moi votre rôle et la stack data / ML sur laquelle vous bossez, et à quel niveau de la chaîne vous intervenez : ingestion, modélisation, déploiement, décision support ?

Architecte IA (Amadeus) — OK, donc je suis Senior Software Architect AI chez Amadeus. Mon rôle est surtout de transformer les capacités génératives en système d'entreprise exploitable. Je pars de sources métier et des contraintes du SI ; je conçois la couche de connaissances, le retrieveur, l'orchestration et les garde-fous. Puis je m'assure que le tout s'intègre dans une plateforme Java entreprise, avec les exigences de sécurité, de scalabilité et de traçabilité d'Amadeus. Mon sujet n'est donc pas uniquement le modèle, c'est toute la chaîne qui rend la capacité utilisable dans un produit métier.

ACHIR Charaf — D'accord, donc c'est tout un tas de choses. Ça nous amène à une deuxième question : sur l'échelle descriptif, diagnostic, prédictif, prescriptif, où situez-vous honnêtement les systèmes que vous opérez, et qu'est-ce qui bloque le passage au niveau supérieur ?

Architecte IA (Amadeus) — Je dirais que nos systèmes à base d'IA générative sont aujourd'hui principalement entre le diagnostic et le prospectif assisté. Ils sont très bons pour retrouver de l'information, expliquer pourquoi une configuration se comporte d'une certaine manière, identifier des causes plausibles et recommander une action. En revanche, je serais prudent avant de les qualifier de prescriptifs au sens propre, parce qu'une recommandation générée par un LLM n'est pas encore une politique de décision validée. Pour passer au niveau supérieur, il faudrait fermer la boucle : instrumenter les décisions et leur outcome, disposer de métriques causales et au moins de contrefactuels crédibles, modéliser les contraintes métier, et valider les politiques en offline, en shadow, puis en mode progressif online. Le verrou principal, ce que j'essaie de vous dire, c'est que le problème n'est pas le LLM, c'est la capacité de relier une action à un résultat de manière fiable et gouvernée.

ACHIR Charaf — D'accord. Une autre question : quand un KPI décroche, qui fait le root cause ? Est-ce que c'est un humain, du drill-down, ou de l'automatique ?

Architecte IA (Amadeus) — Je dirais que les données d'outcome sont insuffisamment instrumentées : on sait souvent quelle action a été faite, mais moins bien pourquoi, et avec quel résultat final. Et il y a aussi un problème de validation : il faut une boucle de feedback, et des expérimentations ou quasi-expérimentations pour estimer les effets.

ACHIR Charaf — D'accord. Donc vous faites de l'inférence causale au sens propre ?

Architecte IA (Amadeus) — Non, on peut plus ou moins dire ça. Je dirais que, causalement, c'est impossible de déduire proprement à partir d'un simple historique ou de n'importe quel modèle de langage.

ACHIR Charaf — OK, ça nous amène à la prochaine question, par rapport au concept de world model au sens de LeCun : une représentation interne qui modélise la dynamique de l'environnement et les conséquences des actions, transposée à l'entreprise. Ça vous paraît réaliste ou fumeux, pour une organisation ?

Architecte IA (Amadeus) — Vous parlez du concept de world model de Yann LeCun, c'est ça ? Vous essayez de transcrire sa vision sur les entreprises. OK, je vois un peu ce que vous voulez dire. Je trouve l'idée — on fait quelques parallélismes un peu vulgaires, excusez-moi pour le terme — entre tout ce qui est physique, lié à des systèmes naturels, et des systèmes d'entreprise. Dans un futur, je trouve l'idée plus ou moins réaliste, si on la traite comme un objectif d'architecture composable. Une entreprise a déjà des fragments de modèles : on a des référentiels d'entités, des règles métier, des workflows, des historiques de paiements, des systèmes de pricing, des moteurs de règles, des modèles de risque. Ça, je parle de mon entreprise, mais de par mon expérience — j'ai été dans plusieurs entreprises — c'est différent, mais il y a toujours un socle. Donc l'enjeu est de relier tout ça dans une représentation temporelle et actionnable. Je parlais plutôt d'un ensemble de world models locaux, par domaine, reliés par une couche sémantique commune. Là où je suis maintenant, chez Amadeus, on pourrait par exemple modéliser explicitement les programmes, les partenariats, les règles, la configuration, et l'impact des règles. Ça pourrait devenir intéressant à condition qu'on borne clairement le périmètre et les hypothèses. Excusez-moi, je réfléchis en même temps que je parle, mais je trouve qu'un world model d'entreprise crédible n'est pas un cerveau central : je le perçois comme un graphe de modèles spécialisés, avec des contrats explicites entre eux. Le digital twin devient intéressant quand il sait répondre non seulement à « qu'est-ce qui est vrai ? », mais à « qu'est-ce qui se passe si on change X ? ».

ACHIR Charaf — D'accord. Donc une formalisation, ElixirData / Context OS, décompose ce modèle du monde organisationnel en 5 sous-modèles : entités, processus, autorité, règles (politiques) et terminologie. Est-ce que ça vous parle, et quels sont les plus durs à construire en vrai ?

Architecte IA (Amadeus) — Oh, je vais pas vous mentir, ça me parle, parce qu'on s'est déjà intéressés à ces sujets. Cette décomposition correspond à ce qu'on finit par reconstruire implicitement dans un système d'entreprise. Je ne suis pas très familier avec cette décomposition précise que vous citez, mais c'est plus ou moins la même dans tous les modèles, avec quelques petites adaptations. Le modèle d'identité et la terminologie sont généralement les plus visibles : on peut les tirer de schémas, de catalogues, d'API, de documentation. Pour moi, les trois difficiles sont plutôt les processus, l'autorité et les politiques. Les processus réels diffèrent souvent de ce qui est officiellement écrit dans une entreprise : ce qui se passe réellement sur le terrain, ce n'est pas ce qui est écrit dans les politiques, ou ce que les RH nous présentent quand on prend un poste. Il y a des exceptions, des raccourcis, des dépendances humaines. L'autorité est encore plus subtile : qui peut décider dépend du rôle, du contexte, du pays, du client, parfois même de délégations temporaires. Et les politiques sont souvent dispersées entre code, documentation, configuration et connaissances tacites. Le vrai challenge, ce serait de construire une ontologie initiale et de la maintenir synchronisée avec une organisation qui change en permanence. Si je dois vraiment classer la difficulté : pour moi, les politiques, les règles, seront les plus difficiles à mettre en pratique — c'est très hétérogène, parfois contradictoire, versionné, contextuel, réparti entre code, config, doc. Je vois très mal, avec les outils qu'on a aujourd'hui, comment on peut modéliser des choses comme ça, même avec du GraphQL. Ensuite je mettrais l'autorité — les droits formels, les délégations, la séparation des responsabilités —, c'est un peu plus modélisable. Ensuite, les entités, la terminologie et les processus sont des choses plus déterministes, donc on peut peut-être les modéliser plus facilement.

ACHIR Charaf — OK. Est-ce qu'on sait aujourd'hui construire un modèle qui simule les effets en cascade et les vulnérabilités structurelles à l'échelle d'une boîte, ou c'est encore de la recherche ? Et qu'est-ce qui manque vraiment : les données, la causalité, ou la modélisation ?

Architecte IA (Amadeus) — Aujourd'hui, à ce que je sache, il n'y a pas beaucoup d'entreprises qui travaillent avec ceci, à part quelques-unes. Si on parle des entreprises avec lesquelles on travaille tous les jours, très peu ont déployé de tels systèmes. On sait le faire sur des sous-systèmes bien définis, mais pas de manière générale à l'échelle d'une grande entreprise, avec le niveau de confiance qu'on aurait dans un simulateur physique. Parce que, du peu que je sais, ces systèmes sont des simulateurs physiques, pas organisationnels. Dans la supply chain, le risque, la fraude, la capacité de planning, certains réseaux opérationnels, on sait déjà simuler des cascades, parce que les états et les transitions sont relativement formalisés. À l'échelle d'une organisation entière, le principe qui manque n'est pas le compute : c'est surtout

les données de dépendance, la causalité, la temporalité, la modélisation des décisions humaines. Le compute devient un problème seulement après. Sans structure causale, une simulation très sophistiquée peut produire une fausse précision. Donc je vois la modélisation comme un verrou, pour être honnête, parce que je vois très mal comment définir les états, les actions, les dépendances et le niveau d'abstraction utile dans une très grande entreprise. Ensuite les données, pour instrumenter les événements — décision, changement, outcome — avec une temporalité correcte. Ensuite la causalité et les facteurs humains. Ensuite la validation. Et je mettrais le compute en dernier, parce que c'est rarement le premier obstacle.

ACHIR Charaf — OK. Ça nous amène à la distinction entre simuler avec un modèle explicite, versus un LLM qui raisonne sur le contexte. Vous la posez comment ?

Architecte IA (Amadeus) — Ah, là ce sont deux rôles carrément différents. Un modèle explicite représente des états, des transitions, des contraintes, éventuellement des relations causales. Il peut être testé, rejoué, calibré. Le LLM, de l'autre côté, est excellent pour interpréter le contexte, extraire des relations, proposer des hypothèses, traduire une intention en scénario, ou orchestrer des outils ; mais il ne garantit ni conservation d'état, ni cohérence dynamique. Donc si vous voulez mon avis, je ne laisserais pas le LLM être le simulateur de la vérité. Je l'utiliserais comme interface et couche de planification au-dessus d'un moteur explicite : il comprend le scénario, appelle le simulateur, interprète le résultat, explique les hypothèses. C'est l'architecture hybride qui me paraît robuste. En une phrase : le LLM pour la compréhension, la planification, la synthèse et l'interaction ; et le modèle explicite pour le moteur de règles, le graphe causal, les états, les contraintes, les transitions et le calcul des conséquences. On a aussi la policy de permission, parce qu'on doit vérifier ce qu'on a le droit de recommander ou d'exécuter — c'est un sujet en soi.

ACHIR Charaf — OK, ça couvre clairement ma question. Ça nous amène à parler d'ontologie et de couches sémantiques. Par rapport à l'ontologie d'entreprise façon Palantir : quatre dimensions — data, logique, action, sécurité — et une architecture en couches sémantique, cinétique, dynamique, présentée comme un digital twin de l'organisation partagé entre humains et agents. Sur le fond, qu'est-ce que vous en pensez techniquement ?

Architecte IA (Amadeus) — C'est un sujet très compliqué, pour être honnête. On en a échangé hier, vous et moi, durant la pause, et ça n'a pas changé depuis hier sur le fond. Je trouve l'idée techniquement saine. Une donnée brute n'est pas suffisante pour un agent : il faut savoir ce qu'est une entité, quelles relations sont valides, quelles opérations existent et sous quelle permission elles peuvent être exécutées. Séparer data, logique, action et sécurité, c'est justement ne pas confondre connaissance, calcul et capacité d'agir. Pour moi, le point de vigilance est de ne pas transformer l'ontologie en monolithe central, impossible à faire évoluer ; je préférerais une couche sémantique fédérée, versionnée, avec du lineage et des contrats par domaine. Le digital twin n'est crédible que s'il est sémantiquement correct par rapport au système opérationnel et à la temporalité réelle. Sinon, on a juste un beau catalogue. Ce que j'apprécie techniquement : un même objet métier peut être partagé entre humain, modèle et agent ; les actions deviennent des primitives explicites, au lieu de laisser un agent inventer comment il modifie le SI ; la sécurité peut être évaluée au niveau de l'objet et de l'action, pas seulement du document ; la logique métier est réutilisable et observable ; et le contexte devient versionné et gouverné, ce qui aide la traçabilité. Ensuite, mes réserves : il y a un coût de modélisation initiale et surtout de maintenance ; un risque de bottleneck sémantique central, si chaque équipe doit passer par une équipe unique pour évoluer ; des besoins de temporalité, parce qu'une relation vraie aujourd'hui ne l'était pas forcément hier ; et des besoins de gouvernance, parce qu'une relation déclarée par un humain, calculée par un LLM ou issue d'une API n'a pas le même niveau de confiance. Le graphe ne supprime pas les conflits de données, il les rend visibles, ce qui est déjà utile. Mais ce n'est pas la problématique qu'on cherche à résoudre aujourd'hui. Donc, cette ontologie façon Palantir, techniquement, c'est plus ou moins faisable, mais il faut être très rigoureux.

ACHIR Charaf — OK. Ça nous amène à la prochaine question. Dans votre expérience, la vraie difficulté d'une couche sémantique d'entreprise, elle est où ? Côté modélisation, résolution d'entités, gouvernance, maintenance, ou adoption ?

Architecte IA (Amadeus) — Je mettrais peut-être la maintenance et la gouvernance avant la modélisation initiale, parce que — excusez-moi, je parle beaucoup, mais ce sont des sujets très compliqués — faire un bon diagramme d'entités en atelier est relativement facile ; garantir six mois plus tard que les identifiants, les relations, les règles et les priorités sont toujours corrects, c'est beaucoup plus difficile. La résolution d'entités vient juste derrière, surtout dans un historique où la même mention existe en plusieurs représentations. Et l'adoption est critique : si le knowledge graph n'est pas branché dans les outils et les API utilisés au quotidien, les équipes continuent de maintenir la vérité ailleurs, et le graphe meurt. Donc la réponse courte, si on demande laquelle est la plus dure : je dirais la maintenance de la vérité dans le temps. Une ontologie statique est facile ; une ontologie vivante, avec les équipes et le vrai produit, c'est autre chose.

ACHIR Charaf — Super, je prends note. Par rapport au Graph-RAG et aux couches sémantiques pour brancher les LLM sur la donnée métier : est-ce que ça tient vraiment la route pour la décision, ou est-ce que ça déplace juste le problème de fiabilité ?

Architecte IA (Amadeus) — Je pense que c'est en bonne voie, mais ça déplace effectivement une partie du problème. Les graphes améliorent la navigation dans les relations métier, les questions multi-hop, la réduction du contexte, et surtout la traçabilité, par rapport à un RAG purement documentaire. En revanche, ça ne rend pas automatiquement la donnée vraie : si les entités sont mal résolues, si le graphe est obsolète, ou si la relation n'a pas de prévalence claire, le LLM donnera une réponse très structurée mais potentiellement fausse. Pour de la décision, il faut donc associer le graphe à la fraîcheur, à la prévalence, aux droits et aux règles, à une stratégie d'abstention et à une meilleure infrastructure de contexte — pas à un certificat de vérité.

ACHIR Charaf — OK. Une ontologie partagée comme substrat commun humain-agent, c'est une condition nécessaire pour des systèmes décisionnels fiables, ou pas ?

Architecte IA (Amadeus) — Je ne dirais pas que l'ontologie formelle complète est toujours nécessaire. Pour un use case local, des contrats JSON, un catalogue de données propres et quelques outils bien typés peuvent suffire. En revanche, dès qu'on veut plusieurs agents, plusieurs domaines, des actions, et un niveau de confiance élevé, un substrat sémantique commun devient presque inévitable. La question n'est donc pas « ontologie ou pas ontologie », c'est le niveau de formalisation, proportionné au risque et à la complexité.

ACHIR Charaf — Super. On passe à des questions plus orientées Decision Intelligence et confiance. La Decision Intelligence pose un paradigme décision-centrique plutôt que data-centrique, avec un cycle complet : donnée, paramètres de décision, modèle, output, boucle d'apprentissage. Sur les systèmes que vous connaissez, à quel point feriez-vous confiance à un système prescriptif, voire à un agent, pour une décision à fort enjeu ?

Architecte IA (Amadeus) — Pour une décision à fort enjeu, je ne raisonne pas en confiance binaire, mais en niveau d'autonomie. Je peux faire confiance à un agent pour collecter les signaux, calculer des options, simuler des scénarios, appliquer des règles déterministes et recommander une action. Je serais plus prudent sur l'exécution autonome si l'action est difficilement réversible, réglementée, financièrement importante, ou si l'état du monde est partiellement observable. Mon objectif est de monter l'autonomie progressivement, avec des preuves empiriques : le système doit gagner le droit d'agir. D'abord recommandation, puis action réversible sous seuil, et seulement ensuite davantage d'autonomie. Donc : faible enjeu, réversible, résultats mesurables — automatisation possible rapidement ; enjeu moyen avec bonne observabilité — autonomie sous un seuil, avec revue ; décisions importantes, irréversibles, à faible observabilité — pas d'autonomie, validation humaine, jamais de full autonomie uniquement parce que le benchmark est bon.

ACHIR Charaf — OK. Selon vous, qu'est-ce qu'il faudrait techniquement pour la confiance ? Backtesting, validation online/offline, intervalles de confiance, human-in-the-loop, monitoring de drift, feedback loop instrumentée ?

Architecte IA (Amadeus) — Il me faudrait plusieurs couches, parce qu'aucune métrique ne suffit — et c'est le cas dans toutes les problématiques qu'on a aujourd'hui. C'est vrai que ce genre de sujet n'est pas d'actualité en entreprise, parce que c'est un peu très optimiste, à mon goût. Mais d'abord, du backtesting offline sur des cas représentatifs, avec des scénarios adverses et des erreurs coûteuses sur-pondérées. Ensuite un shadow mode, pour comparer l'agent aux décisions réelles sans lui donner la main. Pour les modèles probabilistes, je veux des intervalles d'incertitude, ou plutôt des signaux de confiance opérationnels.

ACHIR Charaf — D'accord. Donc où placez-vous la frontière entre décision automatisable et décision sous contrôle humain, et sur quels critères ?

Architecte IA (Amadeus) — Je la placerais sur les critères suivants : l'impact, la réversibilité, l'observabilité, la maturité du modèle. Une décision est candidate à l'automatisation si son impact unitaire est limité, qu'elle est facilement réversible, que l'état nécessaire est observable, que la performance est stable sur des cas proches de la production, et qu'on sait attribuer et auditer l'action. Dès qu'on perd plusieurs de ces propriétés — par exemple une action irréversible sur un client, une décision avec un effet légal ou financier —, je garde une validation humaine. Et je préfère automatiser la préparation de la décision à 95 %, plutôt que les 5 % restants, surtout si ces 5 % concernent le risque.

ACHIR Charaf — OK, on passe à tout ce qui est explicabilité, automation bias et gouvernance. Par rapport à l'arbitrage classique : un système black-box nettement plus performant, versus un modèle interprétable un peu moins bon, sur une décision qui engage l'organisation. Vous prenez lequel, et sous quelles conditions vous changeriez d'avis ?

Architecte IA (Amadeus) — Je ne choiserais pas sur la performance brute du modèle, mais sur la performance décisionnelle ajustée au risque. Si l'écart de performance est faible et que la décision est à fort

enjeu, je prends généralement le modèle interprétable : la robustesse, l'auditabilité et la capacité à détecter une dérive peuvent valoir plus que quelques points de métrique. Si le black-box apporte un gain massif et démontrable, je peux l'utiliser, mais pas comme un arbitre opaque : je l'encadre avec des règles métier, des seuils, des tests de stabilité, de la calibration, une stratégie d'abstention, et une revue humaine sur les cas critiques. L'explicabilité est donc une priorité du système de décision, pas seulement du modèle.

ACHIR Charaf — Donc par rapport à l'explicabilité post-hoc, type SHAP : avez-vous vu des sorties suivies sans être challengées, et quels garde-fous vous mettez — seuil, abstention, revue humaine, contrefactuels affichés ?

Architecte IA (Amadeus) — Oui, oui, c'est ce que je fais, on travaille sur ça en ce moment, surtout sous une forme légère mais très observable, avec les assistants. Dès qu'une réponse est fluide, bien formulée, qu'elle a l'air de connaître le métier, l'utilisateur a tendance à réduire son niveau de vérification. Je n'ai pas besoin d'attendre un incident grave pour considérer ça comme un risque. La cause racine est souvent que le système présente une réponse synthétique, avec beaucoup plus de confiance visuelle que l'évidence sous-jacente. Les garde-fous que je privilégie, c'est donc de rendre la preuve aussi visible que la réponse : citation vers la source, date de fraîcheur, séparation claire. Et je monitore aussi le temps de revue humaine, et les cas où les utilisateurs acceptent systématiquement sans ouvrir les sources.

ACHIR Charaf — D'accord. Là on va parler architecture cible et clôture, c'est notre dernière partie. Le système décisionnel AI-native idéal pour votre organisation, il ressemble à quoi ? Archi, place de la couche sémantique / ontologie, du causal, des agents, degré d'autonomie ? Et qu'est-ce qui manque aujourd'hui pour y arriver ?

Architecte IA (Amadeus) — Chez nous, je verrais une architecture en couches. En bas, une data layer qui expose l'état réel : configuration, programmes, transactions, changements, incidents et outcomes. Au-dessus, une couche sémantique qui normalise les entités, les relations, la terminologie, la provenance et les droits. Ensuite, une couche de modèles : les LLM pour la connaissance non structurée, du prédictif pour les estimations quantitatives, et des modèles causaux, avec des simulateurs ciblés pour les décisions où l'action a un effet. Les agents se placent au-dessus, comme orchestrateurs : ils décomposent la tâche, interrogent les modèles, appellent des outils typés, et construisent une recommandation ; mais l'autorisation d'agir appartient à une policy action déterministe en arrière, qui vérifie les permissions, le risque et la réversibilité. Tout est instrumenté : évaluation, lineage, drift, feedback et audit. L'autonomie est graduée par type de décision, pas définie une fois pour toutes.

ACHIR Charaf — D'accord. Ça nous amène à notre dernier point : est-ce que vous voudriez me rappeler quelque chose d'important qu'on n'a pas creusé, et une ou deux personnes que vous me conseilleriez ?

Architecte IA (Amadeus) — Je vous dirais peut-être de vous rappeler — et ça m'a pris beaucoup de temps — qu'on n'appelait pas ça comme ça avant, on était plus sur du machine learning ; la terminologie change constamment, c'est l'un des problèmes qui rendent ce type de système un peu dur à mettre en prod. Mais je vous dirais, pour votre recherche et même pour votre carrière, de par mon expérience : le vrai enjeu n'est pas de mettre de l'IA n'importe où, c'est de rendre le contexte, les décisions, les actions et le feedback gouvernés et observables. L'autonomie est la dernière étape, pas la première. Et j'ajouterais un dernier sujet : la temporalité. On parle beaucoup d'ontologie et de connaissance, mais l'entreprise est un système dynamique — une règle, une configuration, une dépendance ont une période de validité. Pour faire de la vraie décision intelligente, il faut pouvoir reconstruire ce que le système savait au moment T, quelles options étaient disponibles, et quel outcome a suivi. C'est essentiel pour le backtesting, la causalité et l'audit. Et je creuserais aussi l'interface humain-agent : la qualité d'une décision dépend autant de la manière dont l'incertitude et les alternatives sont présentées que du modèle lui-même.

ACHIR Charaf — Merci beaucoup pour votre temps, je vous enverrai une synthèse.

Architecte IA (Amadeus) — Merci, au revoir.

E.3 Entretien T3. Fondateur et CEO, société deep-tech (TechnoLynx)

Entreprise : TechnoLynx

Poste du répondant : Founder & CEO

Secteur : Deep-tech R&D (GPU, computer vision, IA générative)

Langue : Anglais

Format : Entretien à distance (~30 min)

ACHIR Charaf — Before we dive in, let me just reconfirm on tape: you're OK with me recording, only for the transcript?

Founder & CEO (TechnoLynx) — Yeah, go ahead. Anonymous is good — means I can, you know, tell you what I actually think instead of the pitch-deck version. (laughs) Record away. Confirmed, I'm OK with the recording.

ACHIR Charaf — Perfect. So, describe your role and the data/ML stack you work on, and where in the chain you actually operate — ingestion, modelling, deployment, decision support?

Founder & CEO (TechnoLynx) — So, um, let me set expectations, because my answer is going to be skewed. I'm not a BI or enterprise-data person. Never have been. My whole career is, like, performance-critical systems — GPU compute, computer vision, codecs, generative pipelines. CUDA, OpenCL, SYCL, that world. I spent years making pixels move faster than physics should allow, basically. (laughs) Then codecs, real-time vision, and lately a lot of generative vision under, you know, nasty quality and explainability constraints. Where I sit in the chain now: I'm the founder, so day to day I'm at the top — architecture, technical risk trade-offs, IP strategy, mentoring. I'm the final call on technical direction. But — and this matters for your questions — my instinct is a builder's instinct. When you say « decision support », my brain immediately goes to the inference pipeline, the model, the latency budget, the failure modes on constrained hardware. Not to the boardroom dashboard. So on some of your blocks I'll be very at home, and on a couple I'll just tell you straight up, « that's a different tribe, not mine ». I'd rather flag it than bluff.

ACHIR Charaf — That's exactly the kind of honesty I need. Let's just go where it goes. On the classic ladder — descriptive, diagnostic, predictive, prescriptive — where do you honestly place the systems you deal with, and what blocks the jump to the next rung?

Founder & CEO (TechnoLynx) — In my world it's, um, a bit different from a typical enterprise, because we build bespoke systems for a specific hard problem. So when a client comes to us it's usually already predictive, sometimes prescriptive in a narrow slice — « detect this anomaly », « recognise this product in real time », « optimise this pipeline ». We kind of skip the dashboard stage, because that's not what they hire us for. But if you zoom out to the client's organisation as a whole? Descriptive, overwhelmingly. Same as everyone. We build one sharp predictive spike sticking out of a big descriptive swamp. And what blocks the jump isn't the model — I can almost always build a better model. What blocks it is everything around the model. The data is messy, the ground truth is sparse or drifting, and — this is the big one, in my experience — the gap between benchmark performance and production performance. Like, a model that's brilliant on the test set and falls apart the moment the camera angle changes, or the lighting changes, or the distribution shifts. That last mile from « works in the paper » to « works in the shop, on cheap hardware, at 3am » — that's where prescriptive dies.

ACHIR Charaf — When a KPI drops — some indicator falls off a cliff — who does the root-cause? A human, drill-down, or something automatic?

Founder & CEO (TechnoLynx) — A human, staring at plots, ninety-five percent of the time. And honestly, in my domain, that's often correct — because the interesting failures are, like, weird. A model degrades because someone swapped a camera, or a firmware update changed the sensor's colour response, or the deployment environment shifted. Automated root-cause is good at « which feature moved ». It's terrible at « somebody changed the hardware in store number forty ». That's a human with context, and I don't think that's changing soon.

ACHIR Charaf — Do you do causal inference in the proper sense — do-calculus, uplift, quasi-experiments, DAGs — or is it correlation and feature importance read causally? Where's the limit, for you?

Founder & CEO (TechnoLynx) — Okay, um, here I want to be precise, because I sit in a slightly odd spot. Correlation versus causation — I understand that at a, like, bone-deep level, it's the oldest trap in ML and it burns people constantly. Feature importance getting read as « this causes that » is probably the single most common intellectual crime in applied ML. So that part, I'm very clear on. But the formal machinery — Pearl, do-calculus, structural causal models, proper DAGs — I'll be honest, that's adjacent to my core, not my daily tool. My world is perception and generative modelling and signal, and there causal structure is often... let's say implicit. I know the concepts, I've read Pearl, I can reason about interventions versus observations. But I'm not sitting there drawing DAGs and running do-operators, you know. The causal-ML people are almost a separate community from the vision and generative people, and I'm firmly in the second camp.

ACHIR Charaf — So where's the boundary, practically?

Founder & CEO (TechnoLynx) — The boundary is the word « intervention ». As long as you're predicting within the same distribution — « given what I observe, what comes next » — my kind of models are fine, and correlation is enough. The moment someone wants to act on a lever and expects a specific effect, you've crossed into causal territory, and now a purely predictive model can, like, quietly lie to you, because it learned the correlation, not the mechanism. Uplift I know from the marketing framing — « did my action change behaviour, or was the person going to convert anyway » — the concept is clean, I just don't build those models myself. So: I can tell you exactly where correlation stops being safe, I can smell the trap from across the room. I'm just not the person who'll hand you a rigorous structural causal model. Different specialist for that.

ACHIR Charaf — That's a really useful line to have drawn. Now we climb in abstraction. The concept of a world model — LeCun's sense, an internal representation that models the dynamics of an environment and the consequences of actions — transposed to a company. Realistic, or hand-wavy?

Founder & CEO (TechnoLynx) — Ah, now you're in my kitchen. (laughs) Okay. Let me separate two things, because people, um, mash them together. LeCun's world models — the JEPA line, model-based agents, latent dynamics you can roll forward to predict consequences of actions — that's a real, serious research direction, and it works, genuinely works, in domains where the dynamics are learnable from lots of consistent observation. Robotics, physics, video prediction. I've done GPU physical simulation; I know what it means to have a model that rolls a system forward and predicts cascades. When the underlying dynamics are stationary and you can observe them a million times, you can learn a world model. That's not hand-wavy, that's the frontier and it's advancing fast.

ACHIR Charaf — But transposed to an organisation?

Founder & CEO (TechnoLynx) — That's where I get skeptical, and it's a technical skepticism, not a philosophical one. A physical system has stable dynamics — gravity doesn't, you know, change its mind on Tuesday. An organisation is non-stationary, adversarial, and reflexive. The « physics » of the company changes because people change their behaviour in response to the model itself. The moment you deploy a model that predicts what the org will do, people game it, and your dynamics shift underneath you. That's a fundamentally harder learning problem than anything in my simulation work, and honestly I'm not sure it's even well-posed. Realistic for a tightly-scoped, well-instrumented sub-process with lots of repetition — yeah, I'd believe that. Realistic for « a world model of the whole company » — today, no. The data doesn't exist and the target won't hold still.

ACHIR Charaf — One formalisation I'm looking at — ElixirData, or Context OS — decomposes that organisational world model into five sub-models: entities, processes, authority, rules/policies, and terminology. Does that land for you? Which are hardest to build?

Founder & CEO (TechnoLynx) — Honestly? This one I'll answer more as an engineer looking in from the outside, because entities-authority-policies-terminology is drifting toward enterprise-modelling territory, which — I'll say it again later — isn't really my home turf. But the decomposition is sensible, more concrete than the abstract « world model », so let me give you the modelling-feasibility read. From a pure « can a machine learn this » standpoint: entities and processes are the tractable ones — structured, observable, people have modelled those for decades. The two that scare me are authority and policies, and for the same reason: they're mostly unobserved. Real authority — who actually gets to decide — is rarely what the org chart says, and it's not written down anywhere a model can, you know, ingest. And policies contradict each other and mutate constantly. You can't learn a clean model of a thing that's inconsistent and undocumented. Terminology — the vocabulary one — that's a genuine machine-learning-meets-semantics problem, entity and sense disambiguation, and it's nastier than it looks because the same word means three different things in three departments. So: the hard ones are the ones with no clean training signal. Which, again, is a data problem before it's a modelling problem.

ACHIR Charaf — Can we, today, build a model that simulates cascade effects and structural vulnerabilities at company scale? Or is that still research? And what's missing most — data, causality, compute, modelling?

Founder & CEO (TechnoLynx) — Cascade effects — this is close to my simulation work, so I have a strong view. On systems with known coupling — a physical system, a dependency graph, a technical infrastructure — yes, absolutely, we simulate cascades, that's mature. I've done it on GPU: you know the couplings, you propagate the perturbation, you watch it ripple. At the scale of a whole organisation, with human, economic, second-order feedback effects — no. That's research, and frankly parts of it are still fantasy. And what's missing, in order? Data first, causality second, and compute is a distant, distant last — compute is the one thing we have in embarrassing abundance, I've spent my career squeezing compute and it's, like, never the actual wall anymore. The wall is that to learn cascades you need to have observed many cascades, cleanly instrumented. And organisational crises are rare, badly logged, every company lives through two or three a decade. You cannot train on that. And then causality, because a cascade is causal by definition — it's mechanism, not correlation. So it's a data-scarcity problem wearing a causality problem as a hat. Not a compute problem. Anyone who tells you « we just need a bigger cluster » for this is selling something. (laughs)

ACHIR Charaf — Last one on this block: the distinction between simulating with an explicit model versus an LLM « reasoning » over the context you give it — how do you frame that?

Founder & CEO (TechnoLynx) — This one I feel strongly about, because I build generative models and I know exactly what they are and aren't. An explicit model — symbolic, causal, physics-based, whatever — is rigorous and auditable. You know why it said what it said, you can trace it, you can trust it inside its validated envelope. The cost is it's brutal to build and it shatters the instant reality steps outside the box you designed for. An LLM is the opposite. Stunning flexibility — you pour in context and it produces a plausible-looking chain of reasoning about, like, literally anything. But « plausible » is the landmine word. It doesn't reason in the sense an explicit model computes; it produces text that has the shape of reasoning. I generate images for a living — I know intimately that a generative model will hand you something gorgeous and completely fabricated with total confidence. The failure mode of these things is confident fabrication,

and for a high-stakes decision the shape of a reasoning is worthless, I need the substance. Where I land — and this is a conviction, not a theorem — is a hybrid. The LLM as the interface and the hypothesis generator: it's a fantastic natural-language layer, great for exploring, for surfacing candidate options, for translating between human and system. And a hard, validated, explicit model underneath for anything that actually commits. LLM proposes, verified model disposes. Letting an LLM run a simulation of an organisation and believing its narrative — no. It hallucinates with a straight face, and it's very persuasive while doing it. That combination is dangerous.

ACHIR Charaf — Now a core of the thesis. The enterprise ontology, Palantir-style — four dimensions, Data, Logic, Action, Security, and a layered architecture, the whole thing sold as a « digital twin » of the organisation, shared between humans and agents. On the substance, technically, what do you make of it?

Founder & CEO (TechnoLynx) — Okay, honesty first: this is the block where I'm furthest from home. Enterprise ontologies, semantic layers, entity resolution at enterprise scale, data governance — that's a whole discipline, and it's not mine. There's a tribe of people who do enterprise knowledge modelling, and I'm not in it. So take what I say as a technologist reasoning from first principles, not as the expert on this one. That said — « digital twin of the organisation », the second I hear that phrase, my hand goes to my wallet. (laughs) That's marketing. Palantir are exceptional marketers. But under the slogan there's a real idea, and I don't want to throw it out. The real idea is: one coherent layer where the data, the business logic, the available actions and the security model all live together and agree with each other. As a systems person, that's the right dream — one place where « customer » means the same thing everywhere, where you don't re-translate between fifteen systems. And bolting the actions on — the « Action » dimension — is clever, because most data models describe the world but don't let you act on it. Linking the representation to what you can do is the interesting part. On the concept, I'm positive.

ACHIR Charaf — But?

Founder & CEO (TechnoLynx) — But it's a monstrous amount of work, and here I defer to the people who've actually lived it. Palantir sells you the finished, gleaming object. Filling that ontology with the real, filthy data of an actual company takes an army, years, and iron governance. And that maintenance-and-governance problem is exactly the part I'm not the expert in — I build the perception model that sits on top, I don't build the enterprise semantic layer underneath. What I can tell you from the outside is: the concept is a nine out of ten, and the ease-of-adoption they pitch is maybe a two. But the person who should really grade the middle of that is your enterprise-data interviewee, not me.

ACHIR Charaf — In your experience, where's the real difficulty of a semantic layer or enterprise knowledge graph — modelling, entity resolution, governance, maintenance, adoption?

Founder & CEO (TechnoLynx) — I'll answer the parts I can actually speak to and flag the parts I can't. Entity resolution — « is this Dupont the same as that Dupont J. » — that one I can speak to, it's a real technical problem, there's matching, there's embedding-based approaches, it's hard but it's a known hard. Modelling is intellectually hard but doable with good architects. Governance, maintenance, adoption — here I'm genuinely more of a spectator, but even as a spectator I've watched it kill projects from a distance, so I'll say the obvious thing: a knowledge graph is only alive if someone keeps it in sync with a company that changes every week, and nobody wants to fund that forever. It's the same disease as every stale internal registry I've seen a client drag around. But the mechanics of how you govern it well — that's your enterprise-data person's answer, not mine. I'd be bluffing to give you a strong one.

ACHIR Charaf — Graph-RAG, semantic layers to plug LLMs into business data — does that hold up for decision-making, or does it just move the reliability problem?

Founder & CEO (TechnoLynx) — This part I can speak to, because RAG is retrieval plus generation and the generation half is my world. And my answer is: it genuinely helps, and it moves the problem, both true. It helps because grounding an LLM in a structured graph instead of letting it free-associate from its internal soup does cut hallucination — you're forcing it onto retrieved facts. For finding information, for « surface the right documents and relationships », it's good, I'm a fan. But for decisions — you've relocated the reliability problem, you haven't removed it. Before, reliability lived in the LLM's guts. Now it lives in the quality of your graph. And if the graph is wrong or stale — which, per everything the governance people will tell you, it will be — the LLM gives you a confident, beautifully-sourced wrong answer. That's arguably worse, because now it looks rigorous, it's got citations. So: great for augmenting a human decision, for lighting the way. For deciding autonomously on something that matters — no, you've just moved the fragile point onto the graph, and the graph is your data, and your data is dirty. Same loop as always.

ACHIR Charaf — And a shared ontology as common substrate between humans and AI agents — necessary condition for reliable decision systems, or over-engineering?

Founder & CEO (TechnoLynx) — Necessary, at the limit — I'll go positive here. Because if the human and the agent don't share a vocabulary, you can't have them collaborate on a decision and, more importantly, you can't audit what the agent did. The shared substrate is what lets a human understand and challenge the machine's proposal. Without it the agent is a black box off in a corner talking to itself. But — and this is

where my builder's bias comes out — « necessary » does not mean « build it all up front ». That's the classic way to die. Do not spend three years building the perfect ontology of the entire company before you ship anything. You'll be dead before you deliver value. Build it in slivers, per use case, exactly where you need it. Shared ontology as a direction — yes. Shared ontology as a giant prerequisite — that's how budgets get incinerated. The incremental path is the only one I've seen survive.

ACHIR Charaf — Decision Intelligence frames things decision-centric rather than data-centric. On the systems you know, how far would you trust a prescriptive system — or an agent — in production, on a high-stakes decision?

Founder & CEO (TechnoLynx) — First, decision-centric over data-centric — I'll sign that immediately, and it's not a buzzword, it's common sense we forgot. For a decade everyone hoarded data for its own sake. « Build the data lake, we'll figure out the use later. » And we got swamps nobody drinks from. Starting from « which decision do I want to improve, therefore what do I actually need » is putting the thing back on its feet. Fully on board. On trusting a prescriptive system or an agent, high-stakes, in production — short version: it scales with reversibility and with how well I can bound the failure. And by default, low.

ACHIR Charaf — Unpack the « it depends ».

Founder & CEO (TechnoLynx) — Look, I live in a world where I know the model is wrong some of the time — anomaly detection with sparse, evolving ground truth, that's my bread and butter. So I never think « is the model good », I think « what happens on the day it's wrong, and can I contain that ». High-stakes but reversible, where a bad call can be rolled back cheaply — let it run, monitor it, fine. High-stakes and irreversible, something that commits legally or financially or touches a person — no autonomous agent, not today, full stop. I want a human who validates and owns it. And here's a builder's point most people miss: the trust question isn't really about accuracy, it's about calibration. I trust a model that knows when it doesn't know far more than a model that's slightly more accurate on average but confidently wrong on the tails. A well-calibrated model that says « I'm not sure about this one, escalate it » is worth ten percentage points of raw accuracy to me. Because the raw-accuracy model kills you exactly on the weird case, silently, while looking confident.

ACHIR Charaf — What would you need, technically, to have that trust? Backtesting, online/offline validation, confidence intervals, human-in-the-loop, drift monitoring, an instrumented feedback loop?

Founder & CEO (TechnoLynx) — All of them, but let me rank them the way a deployment person ranks them, because this is basically MLOps and I've shipped a lot of models onto hardware I don't control. Drift monitoring is number one and it's the one everyone underfunds. A model rots quietly — the world shifts under it, the sensor ages, the distribution moves — and if you're not watching whether today's inputs still look like the training distribution, one day it's silently garbage and nobody notices until it's a disaster. In my world drift is literal — a camera gets nudged, a store re-lights — so I'm, like, almost paranoid about it. Then calibration and proper uncertainty — I said it already — confidence intervals, but more than that, a model engineered to abstain. Abstention as a first-class output. On the twenty percent of weird cases, raise your hand and say « human, this one's yours ». A system that always answers with the same confidence whether it's sure or lost is a public hazard. Backtesting yes, but I distrust it a little, because the past doesn't cover the regime shift that's coming, and the regime shift is what actually hurts you. Human-in-the-loop yes, on the high-stakes tail — with a caveat I think you're about to poke at, because badly-done human-in-the-loop is worse than none. And the instrumented feedback loop — indispensable, and the thing nobody builds, because it costs real money and pays off nothing today. Everyone wants the model that decides; nobody wants to pay for the plumbing that measures whether the decision was any good afterwards.

ACHIR Charaf — And the line between an automatable decision and one under human control — where do you draw it?

Founder & CEO (TechnoLynx) — Reversibility and stakes, as I said — and I'll add a third: volume and repeatability. A decision that recurs ten thousand times a day, well-bounded, small per-unit impact — automate it, a human can't keep up anyway and won't do better. A rare, singular, heavy-impact decision — human, mandatory. And the classic mistake is wanting to automate the rare, important decisions precisely because they're the « interesting » ones. No. Automate the boring high-volume river, and save your humans for the rare, heavy cases. It's the exact opposite of what people's egos push them toward.

ACHIR Charaf — Classic trade-off: a black-box system that's clearly more accurate, versus an interpretable model that's a bit worse, on a decision that commits the organisation. Which do you take, and under what conditions do you change your mind?

Founder & CEO (TechnoLynx) — So this is a real one for me, because I've literally built generative vision under hard explainability constraints — think medical-adjacent imaging, where « it looks right » is not good enough, someone has to be able to justify the output. So I've lived both sides. On a decision that commits the organisation — I lean interpretable, and I lean there for engineering reasons, not ideology. The day it goes wrong — and it will — with a black box you can't do targeted surgery. You can't explain it, you can't fix

the specific failure, you can't defend the decision to a regulator or a customer. « The model said no and I can't tell you why » is untenable, and increasingly illegal. Lab accuracy on a black box is worth nothing if you can't stand behind the decision when it's challenged.

ACHIR Charaf — Under what conditions do you flip?

Founder & CEO (TechnoLynx) — Two. One: the accuracy gap is huge and the cost of the wrong decision is severe in a way that swamps the interpretability. Medical is the sharp example — if the black box catches disease twenty points better, refusing those twenty points to feel comfortable is itself unethical, it costs lives, the moral maths inverts. Two: if I can wrap the black box in enough scaffolding — uncertainty estimates, abstention, tight monitoring, a human on the boundary cases — that I've bounded the failure even though the core is opaque. I've done exactly this: ship an opaque high-performer but cage it in guardrails so a bad output can't escape unchecked. Opaque core I can live with. Opaque and autonomous on something that commits — no.

ACHIR Charaf — Post-hoc explainability — SHAP, LIME, feature importances — does it satisfy you as justification, or is it after-the-fact rationalisation? And does a causal model resolve part of the dilemma?

Founder & CEO (TechnoLynx) — Here I have opinions and I'll be careful about the ones I'm entitled to. SHAP, LIME — I know them, I've used them, they're tools to approximate, after the fact, what an opaque model leaned on. Useful for debugging, useful for sanity-checking a model, I'm not dismissing them. But as justification for a committing decision — the word « post-hoc » is doing a lot of damage, and I don't fully trust it. Because a story you construct after the decision to explain a decision already made is exactly what a dishonest human does: decide on gut, then invent a clean rationale. If my model decides opaquely and then a second tool manufactures a tidy explanation, how do I know the explanation is true rather than merely... plausible? Same landmine as before. Plausible is not true. And these attribution methods are approximations with their own instabilities — perturb the input a little and the explanation can swing. So as an engineering diagnostic, yes. As a courtroom-grade justification, I'm wary. Does a causal model resolve it? In principle, yes — and this is the one place I'll praise the causal camp even though I told you it's not my tribe. A genuine causal model is explainable by construction: it tells you « this causes that » as its actual structure, not as a story glued on afterward. So a real causal model does dodge the post-hoc-rationalisation trap. The catch is the one I flagged in block two: building that causal model is exactly the thing we're bad at. So it's the correct theoretical answer to a problem we can't yet solve in practice. Which is, honestly, the story of this whole field.

ACHIR Charaf — Have you seen concrete automation bias — outputs followed without being challenged? If so, root cause, and the guardrails you put in?

Founder & CEO (TechnoLynx) — Oh, constantly. And I'd argue automation bias is the most underrated risk in your entire topic. The dumb canonical case is the GPS — people driving into a lake because the machine said turn left. Brain off, execute. And it's worse in a subtle setting. I've watched operators follow a vision system's calls without a second thought because « the system knows ». The nastiest version is the fig-leaf human-in-the-loop: you put a human there to « validate », but you give them three seconds, two hundred cases an hour, and a system that's right ninety-five percent of the time. Within a week the human is clicking « approve » on reflex. They're not reviewing, they're rubber-stamping. And the day the system is wrong on the one critical case, your human guardrail resigned mentally a long time ago. So you have the illusion of human control and zero actual control — which is worse than no human, because it's falsely reassuring. Root cause: over-trust plus fatigue plus volume. You overload the human and ask them to contradict a machine that's usually right — psychologically that's unsustainable. Guardrails, from experience: the first one nobody thinks of is don't drown the human. If you want real oversight, give them few cases, time, and the right cases — which is the abstention idea again: the system escalates only the cases it's unsure about, not all of them. Ten hard cases a day keeps a human sharp; two hundred rubber-stamps doesn't. Then displayed counterfactuals — « if this feature had been different, the decision would have flipped » — that forces the person to actually think instead of stamp. Drift alerting, I've said, it's my obsession. And a cheap trick: periodically feed in cases where you know the answer, to check whether your human is genuinely challenging or validating in their sleep. Audit the auditor.

ACHIR Charaf — Last part, on compliance: AI Act, ISO 42001, model cards, model audits — a real constraint in your work, or paperwork? And if a system causes a serious error, where should responsibility sit?

Founder & CEO (TechnoLynx) — Alright, here I'm partly back outside my home turf — I'm a founder, not a compliance officer, I don't renew ISO certifications for a living. So this is the deep-tech-founder's-eye view, not the auditor's. From where I sit, the honest tension is this: as a small deep-tech company in Europe, regulation cuts both ways, and I feel both edges. The AI Act, ISO 42001 — done as a checkbox, a document someone fills once a year for the auditor and files in a drawer, it's worse than useless, because it manufactures false confidence. « We're compliant », everyone sleeps soundly on top of something dangerous. That's the failure mode. But done as a discipline — model cards that genuinely document what the model was trained on and, critically, where it must not be used, audits that actually look under the hood,

real traceability of decisions — that's not paperwork, that's the thing that saves you on the bad day. And I'll say the uncomfortable founder part too: heavy compliance load lands hardest on small innovators, and there's a real risk Europe regulates its startups into irrelevance while others just ship. I feel that pressure directly. But given some of what we build touches people — medical-adjacent imaging, behaviour analytics — I'm honestly glad there's a frame. On sensitive stuff I'd rather have guardrails than not. So: not a brake if you take it seriously, a genuine safety rail. Paperwork only if you treat it as paperwork.

ACHIR Charaf — And responsibility, when there's a serious error?

Founder & CEO (TechnoLynx) — Human. Full stop, and this one won't move. Responsibility sits with the organisation that deployed the system and the people who put it there and operate it. « The AI decided » is not a defence and must never become one, because the moment it is, you've opened a door where nobody is responsible for anything. AI is a tool. If my car has a brake defect and kills someone, we don't put the car on trial, we look at whoever shipped a defective thing onto the road. Same for a model. Whoever chooses to deploy a high-stakes system owns what it does. And frankly, clear responsibility is the best guardrail of the lot — the day the decision-maker knows it's their signature and their neck on the line, funny how much more rigorous they suddenly get about validation, abstention, and human oversight. Fuzzy responsibility is what makes people reckless.

ACHIR Charaf — Let's close on a projection. The ideal AI-native decision system for the kind of organisation you serve — what does it look like? And what's missing today to get there?

Founder & CEO (TechnoLynx) — Okay — the « magic wand, infinite budget » version, but with my usual realism baked in. At the very bottom, governed data. Not glamorous, but everything rests on it — clean data, shared definitions, measured quality. Skip that and everything above is decoration on sand. And I'll defer on how you govern it — that's the enterprise-data tribe — but I'm certain it's the foundation. Above that, the semantic layer, the ontology — but built in slivers, per use case, never big-bang. I've told you I'm not the expert on building it; I'm just certain it has to grow incrementally or it dies. Above that, the models — and here I'm home. A mix: strong perception and predictive models where they earn their keep, and ideally causal structure wherever you actually want to pull a lever — knowing causal is the part we build badly, so it's more a heading than a present reality. And crucially, every model uncertainty-aware and calibrated. In my ideal system no model outputs a number without also outputting how much to trust it. That's non-negotiable for me. LLMs and agents I put in the interaction and orchestration layer, on top. The natural-language interface, the hypothesis generator. But — my red line — the agent proposes, it does not autonomously execute the committing decisions. Autonomy scales with reversibility and volume: high autonomy on the repetitive, reversible river; zero autonomy on the rare and irreversible; and everywhere, the ability to say « I don't know, take over ». And cutting across all of it, two things everyone forgets, and they're the two I'd personally guard hardest because they're my instinct: observability — I want to see what the system does, measure drift, trace every decision — and the feedback loop, to learn after the fact whether decisions were actually good. A system you can't observe and can't correct isn't a system, it's a prayer.

ACHIR Charaf — And what's missing today to get there?

Founder & CEO (TechnoLynx) — Three things, and — you'll laugh — none of them is compute, and honestly none of them is even the model. One: clean, governed data, I'll say it again because it's genuinely the wall. Two: robustness — the gap between benchmark and production, the model that's brilliant in the paper and brittle in the shop. Closing that last mile is, technically, the thing I'd fund. Three: calibrated uncertainty and causality — models that know what they don't know and know what actually drives what. The compute, the frameworks, the raw model horsepower — that's here, or arriving, that's the least of our problems. What's missing is clean data, robustness, and honest uncertainty. And no vendor will sell you those in a licence. If I had to compress our whole conversation into one line: the field keeps solving the part that's already solved — bigger models, more compute — and keeps under-investing in the boring parts that actually block deployment — data, robustness, calibration, and the human system around it. That gap is basically the whole story. Might be the real subject of your thesis. (laughs)

ACHIR Charaf — (laughs) It might genuinely be. Ritual last question: anything important we didn't dig into? And one or two people you'd point me to?

Founder & CEO (TechnoLynx) — Something we under-covered — the last mile. The benchmark-to-production gap. Everyone in your thesis is going to talk about grand architectures and world models and ontologies, and the thing that actually kills these systems is a camera that got moved and a distribution that shifted. Robustness under real-world drift. Go look hard at that — it's unglamorous and it's where the bodies are buried. For people to talk to — go find the deployment engineers, the ones who babysit models in production on hardware they don't control, not just the researchers with clean benchmarks. And — deliberately — go find an actual enterprise-data and governance person for the ontology block, because I told you honestly that's not my tribe and you shouldn't take my outside-view as the expert answer. The interesting thing is precisely the seam between my kind of profile — the deep-tech builder — and theirs. That crossover is where it gets good. (laughs)

ACHIR Charaf — Exactly that. Thank you — this was genuinely rich. I'll stop the recording, and I'll send you an anonymised summary if you'd like.

Founder & CEO (TechnoLynx) — Please do, send it over. And good luck with the thesis — the topic's a good one, just be suspicious of the words that shine. (laughs) Take care.

E.4 Entretien BA1. Directeur Market Intelligence, équipements de la maison (Somfy)

Entreprise : Somfy (Sentri Group)

Poste du répondant : Directeur Market Intelligence

Secteur : Motorisation et automatismes de la maison

Langue : Français

Format : Entretien à distance (~39 min)

ACHIR Charaf — OK super, pouvez-vous juste me reconfirmer que vous m'autorisez à activer la retranscription sur ce meeting ?

Dir. Market Intelligence (Somfy) — Oui, bien sûr, allez-y.

ACHIR Charaf — Merci. Donc merci d'avoir accepté cet entretien. Deux mots pour le cadre : je fais une recherche de thèse sur la façon dont les entreprises prennent leurs décisions à partir de leurs données, et sur la place que l'IA pourrait y prendre. Ça dure environ 30 minutes, il n'y a pas de bonne ou mauvaise réponse, et surtout pas besoin d'être spécialiste, c'est vraiment votre expérience qui m'intéresse. Sans plus attendre, pouvez-vous d'abord me décrire votre poste et en quoi consiste votre travail au quotidien ?

Dir. Market Intelligence (Somfy) — Alors, mon poste, c'est Market Intelligence Director au sein de Sentri Group, comme vous le savez. Mon travail au quotidien consiste à la collecte des données. Nous, on est basés sur 59 business units à travers le monde, et moi je travaille directement avec les directeurs des business areas — on en a 9 — et je récolte les données des 9 à travers le monde pour n'en faire qu'une seule. C'est l'exercice fondamental de notre équipe Market Intelligence, qui est le Market tracking process. Avec ce fichier global qu'on réunit généralement vers mars-avril, on a les données de Somfy, les données des concurrents, les données des moteurs vendus, toutes les données possibles sur le marché, avec des granularités différentes. Et c'est ce fichier-là qui nous permet ensuite de créer des dashboards stratégiques, que ce soit pour les équipes transversales ou directement pour le COMEX, en travaillant par exemple des exercices de performance sur les trois dernières années. Avec cela, on réalise aussi des études — on a fait beaucoup avec BCG ou d'autres bureaux d'études. Nous, on réunit nos propres chiffres, et on aime bien les challenger, les mettre au défi face à d'autres bureaux d'études qui font des études sur le nombre de fenêtres, le nombre de motorisations, pour voir si nos chiffres sont pertinents ou s'ils ont besoin de modification. C'est ça notre métier, aussi faire de l'analyse compétitive. Ça, c'est le job d'un collègue à nous, Pierre Jacquot, qui s'occupe de tout ce qui est analyse des compétiteurs, des moteurs concurrents et de leur avancée dans le marché. Mais pour ma partie, c'est plus les données et les études qualitatives.

ACHIR Charaf — Super, vous êtes un peu le profil parfait pour mon étude. La question suivante : est-ce que vous prenez ou contribuez à des décisions importantes ? Si oui, lesquelles par exemple ?

Dir. Market Intelligence (Somfy) — Alors, le Market tracking process, c'est l'un des piliers de Somfy au niveau de la data. Il y a plein de fonctions et d'équipes chez Somfy, mais Market Intelligence, c'est l'équipe petite de taille mais à très grande valeur ajoutée, parce que c'est là qu'on réunit toutes les données majeures de Somfy. Et c'est avec cet exercice qu'on prend ensuite des décisions stratégiques. Par exemple, le projet Outdoor, mis en place l'année dernière en 2025, a été basé sur des données outdoor : le fait qu'on est déjà fort sur cette partie — c'est une business line, on en a 4, et l'outdoor est l'une des meilleures. Basé sur les chiffres du MCP, on a décidé de se positionner pour encore plus grandir et tirer le maximum de valeur ajoutée. Donc oui, notre équipe est vraiment au centre de la stratégie d'entreprise et de la stratégie digitale.

ACHIR Charaf — OK super. J'imagine que pour prendre des décisions, vous vous appuyez sur des chiffres, et sur des tableaux de bord. Vous utilisez quel outil pour ça ?

Dir. Market Intelligence (Somfy) — Alors, les tableaux de bord qu'on utilise, c'est soit Excel — mais c'est très basique —, soit Power BI. Les Excel qu'on réunit avec le MTP, et Power BI avec l'outil Power Query, j'imagine que vous connaissez. Généralement, le tableau de bord principal pour nous est affiché sur Power BI.

ACHIR Charaf — Super, merci beaucoup. On passe à la prochaine partie, plus par rapport à la façon de décider avec les données aujourd'hui. Pour nous mettre en contexte, est-ce que vous pouvez penser à une décision importante et récente que vous avez prise en vous appuyant sur des données ? Et me raconter

comment ça s'est passé, du début jusqu'à la fin, pour avoir une idée high level, tout en essayant d'être concis ?

Dir. Market Intelligence (Somfy) — Ouais, très bien. Alors, comme je l'ai déjà annoncé, on travaillait sur un sujet d'équipement rate. En gros, c'est quoi : combien il y a de fenêtres dans une maison qui sont déjà équipées d'un moteur, qu'il soit Somfy ou un autre ; et c'est sur cette fenêtre-là qu'on va attaquer pour motoriser. Dans ce sujet, on a plein de chiffres, plein de ratios, plein de pourcentages propres à nous, propres à l'équipe. On avait une quinzaine de pays sur lesquels on a des données précises — généralement l'Europe, notre fort du marché : France, Belgique, Allemagne, Espagne, Tchéquie. Et il y avait un directeur au COMEX, Bruno Barlay, qui nous a challengés sur ces chiffres — vu qu'il travaille sur la partie RSE, il s'y connaît bien. Ce qui nous a poussés à bosser avec BCG. Il faut savoir qu'il y a deux ans, on avait déjà bossé avec BCG sur plusieurs points stratégiques ; au vu de la demande de Bruno, on les a recontractés pour avoir plus de détails. Ils nous ont délivré tous les chiffres qu'ils avaient, on a confronté nos chiffres et les leurs, et on a conclu qu'on avait deux processus différents pour le calcul des pourcentages d'équipement : nous, on est partis vraiment des fenêtres qu'il y a en France, pour descendre d'un cran, jusqu'en bas, alors qu'eux sont partis par le haut. Est-ce que vous pouvez me rappeler la question, comme ça j'y vais directement ? Je me suis un peu perdu dans la réponse.

ACHIR Charaf — Vous avez un peu répondu à toute la question. Je vous demandais juste d'imaginer, de vous rappeler une situation où vous avez pris une décision importante en vous appuyant sur des données, et de me la raconter pour avoir une idée.

Dir. Market Intelligence (Somfy) — D'accord. Donc, comme je vous ai dit, on a suivi le processus MCP mais corrigé avec les données BCG : il y avait un écart de pourcentage qu'on a corrigé avec leurs chiffres. Sur les marchés où on est très sûrs, on a considéré que nos chiffres sont corrects ; et sur les marchés où on est moins sûrs, on a fait une moyenne entre nos chiffres et ceux de BCG. C'est avec ça qu'on a eu une présentation prête, qu'on a délivrée au COMEX, et sur laquelle les décisions d'équipement rate ont été prises au niveau de la direction.

ACHIR Charaf — OK super. J'imagine que les données et les chiffres vous ont suffi ? Ma question, c'est : à quel moment les chiffres vous ont suffi, à quel moment il a fallu creuser, réfléchir ou demander à quelqu'un ? Est-ce que votre analyse et celle de BCG ont suffi pour prendre la décision, ou il a fallu creuser davantage, faire d'autres études, demander à d'autres personnes ? Ou les choses étaient tellement convaincantes que la décision a sauté aux yeux ?

Dir. Market Intelligence (Somfy) — Alors, comme vous l'avez dit, nous on s'est appuyés sur nos chiffres, puis on a consolidé avec ceux de BCG, et comme ça on a eu le support qu'on a délivré au final. Je pense qu'on a eu quelque chose de solide : les chiffres étaient convaincants sur le périmètre qu'on avait considéré, une quinzaine de pays d'Europe. Après, si on voulait vraiment rentrer dans le détail des détails, ça aurait pu être une demande de Bruno, pour creuser d'autres ratios — par exemple la surface des fenêtres, parce qu'on a calculé le nombre de fenêtres, on pourrait aussi calculer la surface pour savoir quel type de moteur on pourrait installer. Mais pour la demande qui a été faite, les chiffres étaient bel et bien convaincants ; peut-être que pour une demande future, on aurait besoin de descendre d'un autre cran.

ACHIR Charaf — OK super. La prochaine question, par rapport aux indicateurs. Prenons un indicateur au hasard parmi ceux que vous avez cités, par exemple l'équipement rate. Lors de votre étude, vous avez eu un dashboard, un graphe, qui vous indique que l'équipement rate a augmenté ou diminué de tel pourcent dans tel pays. Vous avez l'information qu'il a bougé, mais ma question : est-ce que vous savez pourquoi il a bougé ?

Dir. Market Intelligence (Somfy) — Alors non, on ne sait pas pourquoi il a bougé. Il faut savoir que nos exercices avec le MTP, et tous les chiffres qu'on en conclut, c'est un exercice annuel : on n'a pas de variations journalières ou hebdomadaires, c'est plus annuel. On pourrait avoir des variations sur un an, sur trois ans, mais pas des variations récurrentes mensuelles ou hebdomadaires. Et non, pour répondre à votre question, on ne sait pas pourquoi ça bouge.

ACHIR Charaf — OK super, ça nous fait un très bon tremplin. Maintenant, imaginez un outil d'IA qui, au lieu d'afficher des chiffres, vous propose directement une recommandation : « voici ce que je vous conseille de décider, voici pourquoi. » Comment vous sentiriez-vous à l'idée de vous appuyer là-dessus pour une décision qui compte ?

Dir. Market Intelligence (Somfy) — Bah écoutez, moi je suis très ouvert à l'IA. Je n'ai pas un profil informatique, mais j'arrive quand même à faire du codage avec l'IA, et à faire du Power BI. C'est un outil indispensable pour notre service. Mais le seul bémol que j'aurais, c'est de savoir sur quelle base cet outil se base pour prendre les décisions et faire les recommandations.

ACHIR Charaf — OK. Donc qu'est-ce qui vous mettrait en confiance pour faire confiance à l'IA sur une décision qui compte, et de l'autre côté, qu'est-ce qui vous ferait douter ?

Dir. Market Intelligence (Somfy) — Alors, qu'est-ce qui me mettrait en confiance ? C'est que je connais maintenant la force de l'IA, la force d'un cerveau à taille énorme face à un cerveau humain qui ne peut pas

dépasser une analyse simple. Je suis certain que l'outil pourrait être très fort. Donc ce qui me mettrait à l'aise, c'est qu'il ait toutes les bases, toutes les analyses qu'on a, tous les chiffres, tous les ratios qu'on utilise. Avec ça, il pourrait donner des recommandations que moi, par exemple, j'aurais données, mais avec beaucoup plus de vitesse et beaucoup plus de chiffres à analyser. Et qu'est-ce qui me ferait douter ? Je reviens à la même chose : est-ce qu'il arrivera à lire toutes nos bases de données ? Est-ce qu'il n'y aura pas un angle mort, un chiffre ou une mesure auxquels il n'aura pas accès ?

ACHIR Charaf — OK super. On a un peu fini la première partie, on passe à la deuxième. Durant cette première partie, j'ai explicitement essayé de ne pas trop vous parler du cœur de la recherche, pour ne pas biaiser vos réponses. Maintenant, je vais prendre un peu de temps pour vous expliquer le cœur de la thèse et la problématique qu'on essaie de résoudre. Aujourd'hui, la plupart des outils décisionnels — la Business Intelligence et autres — servent surtout à décrire le passé : des tableaux de bord qui montrent ce qui s'est passé. Ma thèse s'intéresse à la génération suivante, capable non seulement de décrire, mais d'expliquer les causes, d'anticiper et de recommander des décisions. Trois idées reviennent au centre, ce sont trois couches d'un même système. La première, c'est un world model, un modèle du monde de l'entreprise. Cette idée découle directement des recherches de Yann LeCun sur les world models. Aujourd'hui, ce qu'on a d'accessible, c'est surtout les LLM, les agents, tout ce qu'on utilise au quotidien ; mais selon Yann LeCun, qui est un peu le père fondateur de l'IA qu'on connaît aujourd'hui, c'est une génération qui sert à faire des choses super, je dis pas le contraire, mais c'est très loin de la vraie intelligence. Pour lui, quelque chose d'intelligent, ce serait plutôt : si on veut apprendre à une voiture à rouler, on ne va pas créer un système qui connaît le code de la route, mais plutôt modéliser d'abord le monde physique, et déployer dans ce monde une entité dont la vocation serait de rouler ; et cette entité apprendrait en autonomie comment rouler en interagissant avec son monde. C'est un peu comme les mécanismes d'apprentissage humain : quand un bébé apprend à marcher, personne ne le lui apprend, c'est juste en interagissant avec son monde réel qu'il y arrive. Alors vous allez me dire que c'est très loin du contexte d'entreprise, et vous avez raison. L'idée, c'est de prendre ça et de faire le parallèle avec l'entreprise : un world model d'entreprise, c'est une sorte de maquette vivante, un peu comme un simulateur de vol, mais pour l'organisation. Elle représenterait comment l'entreprise fonctionne vraiment, ses clients, ses processus, ses règles, et permettrait de tester « si je fais ça, qu'est-ce qui se passe ? ». Comme dans un jeu : si tu augmentes les prix, les ventes vont baisser ; si une usine tombe en panne, certaines commandes seront retardées. Par exemple, le modèle pourrait savoir qu'un client possède un contrat, qu'un contrat dépend d'un produit, qu'un produit dépend d'un système informatique, qui dépend d'une infrastructure ; mais aussi comprendre les conséquences : si l'application tombe pendant 4 heures, quels services clients seront touchés, quels processus vont ralentir, quel impact financier. Donc un world model ne cherche pas seulement à décrire ce qui existe, il cherche à représenter comment le système évolue. Mais une vraie entreprise est extrêmement compliquée : relations humaines, exceptions, décisions politiques, comportements clients difficiles à modéliser ; c'est pour ça qu'un modèle complet de toute l'entreprise est aujourd'hui très ambitieux. Ce qui se rapproche le plus d'un world model aujourd'hui, c'est le concept d'ontologie. Depuis plus de 15 ans, des entreprises proposent des solutions très proches d'un world model d'entreprise, et ils appellent ça l'ontologie. On peut la voir comme une carte partagée : elle relie toutes les données de l'entreprise à ce qu'elles représentent réellement, pour que tout le monde — humain comme système — parle le même langage. Certains la décrivent comme un jumeau numérique de l'organisation. L'ontologie est plus simple à comprendre que le modèle, parce que c'est essentiellement un vocabulaire structurel de l'entreprise avec les relations entre les concepts. Prenons une entreprise dans le BTP : un adhérent possède un contrat, un contrat correspond à un produit, un produit contient des garanties, une demande client déclenche un processus, un processus utilise certaines applications. On définit les objets importants et les relations. L'intérêt principal, c'est d'éviter que chaque système parle son propre langage : une application appelle quelqu'un « client », une autre « adhérent », une autre « assuré » ; l'ontologie dit « attention, ces termes correspondent à tel concept, avec telle différence ». C'est particulièrement utile avec les agents IA : au lieu de donner au LLM 500 tables avec des noms incompréhensibles, on lui donne une couche plus proche du métier. Donc l'IA comprend mieux ce qu'elle manipule. Voyez l'ontologie comme le dictionnaire plus la carte conceptuelle de l'entreprise ; elle ne prédit pas ce qui va arriver, c'est ça la différence importante avec le modèle. Finalement, la troisième brique, c'est la Decision Intelligence : remettre la décision au centre plutôt que la donnée. Un système qui vous accompagne sur tout le cycle d'une décision, de la question de départ jusqu'à l'apprentissage tiré du résultat. Exemple : une entreprise doit décider « doit-on appeler ce client maintenant ? ». Une approche classique produit « ce client a 90 % de probabilité de partir » ; aussi bonne que soit cette prédiction, ça reste une prédiction, pas une décision. La Decision Intelligence ajoute d'autres éléments : si j'appelle, quelle est la probabilité qu'il reste ? Combien coûte l'appel ? Combien vaut ce client ? Dois-je l'appeler ou utiliser cette ressource pour un autre ? À la fin, le système peut recommander « oui, appeler ce client est probablement la meilleure décision ». Donc on passe de « donnée–information » à « donnée–compréhension–option–décision–action », puis mesure du résultat. Et surtout, après l'action, on regarde ce qui s'est réellement passé, pour faire de l'amélioration continue. Ces trois briques emboîtées donnent un système capable de modéliser l'entreprise, une sorte de SimCity de l'entreprise, par laquelle on peut simuler toute décision importante pour voir ses conséquences potentielles. Donc, ma question

maintenant : cette idée d'une maquette vivante de l'entreprise, un modèle qui simule les conséquences d'une décision avant de la prendre — qu'est-ce que ça vous évoque ?

Dir. Market Intelligence (Somfy) — Excusez-moi, vous pouvez répéter votre question ?

ACHIR Charaf — Par rapport à cette maquette vivante de l'entreprise, tout ce que je viens de vous expliquer, ce modèle qui simule les conséquences d'une décision avant de la prendre : qu'est-ce que ça vous évoque, c'est quoi votre ressenti à l'égard de cette idée ?

Dir. Market Intelligence (Somfy) — Alors, c'est quelque chose d'innovant, je l'admets, quelque chose qu'on n'a pas au sein de Somfy. De ma part, je l'accueillerais à bras ouverts. Je sais comment l'IA est très forte pour analyser, et encore plus pour anticiper. Je pense que ça pourrait être quelque chose de très fort au vu de notre service, de notre équipe qui est vraiment au centre de la donnée et de la stratégie digitale de l'entreprise. Vous m'avez parlé des trois couches liées entre elles ; j'ai bien compris le concept d'anticipation. De ma part, je pense que ça pourrait être utilisé au sein de Somfy dans les années à suivre. Il faut juste savoir où ça va être basé : est-ce que ce sera chez Somfy en interne, ou en externe. Mais ça reste un sujet très important et innovant.

ACHIR Charaf — OK super, merci. Maintenant, je vais vous poser des questions plus par rapport à la faisabilité technique de la solution, puis on reviendra à des questions plus fonctionnelles et éthiques. Un problème qu'on rencontre souvent en entreprise, que cette solution corrige, c'est celui des appellations. Est-ce que dans votre organisation tout le monde parle le même langage sur les données ? Quand un service parle d'un client ou d'un produit, désigne-t-il vraiment la même chose, ou vous avez des appellations différentes pour une même chose ?

Dir. Market Intelligence (Somfy) — Alors oui, vous avez parlé d'un sujet très important, parce que je considère que c'est courant dans les grandes entreprises. C'est vrai qu'on a des appellations différentes pour désigner plusieurs choses. Par exemple, en parlant des business lines, on a une business line qui s'appelle Windows Fashion, qui prend en considération les moteurs de tout ce qui est curtain, blind, tout ce qui est à l'intérieur de la maison. Nous, on l'appelle Windows Fashion ; il y a d'autres équipes qui l'appellent « intérieur », à titre d'exemple. Donc il y a eu cette différence d'appellation au sein de Somfy.

ACHIR Charaf — OK, donc ce petit décalage d'appellation, est-ce que ça vous coûte quelque chose concrètement, en temps, en erreurs, en désaccords ?

Dir. Market Intelligence (Somfy) — Alors non, pas pour l'instant, parce que nous, dans la récolte de données, il faut être intransigeant : sur les opérations, sur les erreurs, sur des petits espaces qui pourraient être fatals pour la continuité de l'exercice. Je fais en sorte que ces fautes ne soient pas faites, parce que maintenant le MCP, c'est un exercice qui a commencé en 2012 ; donc avec l'habitude des collègues, on sait les fautes qu'on peut accepter et celles qu'on ne peut pas. Et ce genre de fautes, on ne peut pas l'accepter. On a un modèle que j'envoie à chaque fois aux directeurs des business areas, et sur lequel il faut se baser pour nous rendre les Excel. Ce que je fais aujourd'hui, ça ne nous a jamais coûté plus que ça.

ACHIR Charaf — OK, merci beaucoup. Maintenant, si demain on propose une capacité de tester des scénarios « what if » — par exemple, si je baisse le prix d'un certain moteur, on lance la simulation et on voit ce qui va probablement se passer —, est-ce que l'existence d'un tel outil changerait quelque chose pour vous dans votre quotidien, et si oui, quoi ?

Dir. Market Intelligence (Somfy) — Bien sûr, maintenant j'ai compris la question, merci. Oui, ça changerait beaucoup de choses. On prendrait en compte des stratégies « what if » pour faire une certaine stratégie marketing de type A, type B, type C, et comparer plusieurs types et plusieurs stratégies pour voir la meilleure selon les résultats. Pour moi, ce serait quelque chose de très bien, qu'on pourrait même intégrer dans nos exercices annuels. Le fait de comparer plusieurs stratégies à la fois et de voir les résultats, je pense que ça pourrait nous servir.

ACHIR Charaf — OK super, merci beaucoup. Maintenant, imaginez un système qui ne vous donne pas juste des chiffres, mais qui vous accompagne sur toute la décision : du cadrage de la question, en passant par la simulation des options, puis la recommandation, et qui apprend du résultat. Est-ce que ça vous semble utile ou plutôt inquiétant ? Je pense que vous êtes assez ouvert à l'idée, donc ma question est plutôt : qu'est-ce qui vous inquiéterait le plus dans ce genre de système, quels seraient vos points de vigilance ?

Dir. Market Intelligence (Somfy) — Alors, juste pour vous dire, on a dépassé les 30 minutes, donc on va essayer d'être un peu concis. C'est un système très clair, et comme vous l'avez compris, je suis très ouvert à l'idée d'inclure une IA qui pourrait m'aider à la prise de décision, m'aider dans les recommandations que je pourrais faire à d'autres équipes. Mon seul point d'inquiétude, c'est que je sais que l'IA fait des erreurs. Je sais qu'elle est fiable à très haut niveau, mais jamais à 100 %. Donc cette erreur-là, je ne sais pas en quoi elle peut coûter, en temps, en argent, aux équipes qui vont recevoir ces décisions et recommandations basées sur l'IA. Si une équipe se base sur une décision qui ne sera pas totalement fiable, qui sera peut-être erronée — parce qu'on sait que ce n'est pas toujours fiable à 100 % —, c'est quoi le coût ? C'est ça mon point d'inquiétude.

ACHIR Charaf — OK super, on avance vers la dernière question, plutôt éthique. Si un tel système menait à une décision gravement erronée, qui pourrait être tenu responsable selon vous ? Et une décision doit-elle toujours être explicable pour être acceptable ? C'est deux questions.

Dir. Market Intelligence (Somfy) — C'est une très bonne question. Ouais, c'est le point que j'ai relevé à la question précédente. Je pense que déjà, la personne responsable, c'est moi directement, parce que c'est normalement mon job de faire la recommandation et les conseils basés sur la stratégie et les données. Donc en implémentant une IA grâce à votre système, je pense que je serais directement le responsable. Et vous avez dit : est-ce qu'une décision — erronée, ou une décision tout court — doit être explicable ? Pour moi, oui, toute décision. Une bonne décision aussi. Quelle que soit la décision, elle doit être explicable, surtout à un niveau international. On a passé plusieurs années à mettre en place un market tracking process, à réunir toutes les données clés de notre marché, pour prendre des décisions sur ces données. Donc pour moi, ces décisions doivent être explicables. L'erreur est humaine, elle peut venir aussi d'un humain, mais l'humain peut l'expliquer ; alors qu'une IA, si elle fait l'erreur, je pense qu'elle ne sera pas apte à l'expliquer. Donc on peut inclure cet outil, même s'il peut faire des erreurs, parce qu'on sait qu'il est très fiable, mais pas à 100 %. Mais il faut ajouter à chaque fois le fait que l'IA peut commettre des erreurs, que ce soit inclus dans les messages et les recommandations qu'elle envoie, et que ce n'est pas une stratégie à suivre de façon aveugle : c'est plus une recommandation que l'IA donne aux équipes, qu'elles peuvent prendre en considération ou pas, après une réflexion avec un cerveau humain.

ACHIR Charaf — OK super, merci beaucoup pour vos éléments de réponse, c'est extrêmement utile. Est-ce que vous avez quelque chose à rajouter, ou des éléments qu'on n'a pas abordés ?

Dir. Market Intelligence (Somfy) — Alors, je pense qu'on a parlé de tout. On pourrait aborder plein d'autres sujets, mais je pense que vous êtes plus pressé que moi, donc on peut en finir ici.

E.5 Entretien BA2. Business Analyst / Solutions Architect, e-commerce (Amazon)

Entreprise : Amazon

Poste du répondant : Business Analyst / Solutions Architect

Secteur : E-commerce / cloud

Langue : Anglais

Format : Entretien à distance (~30 min)

ACHIR Charaf — Before we properly start, let me just reconfirm on tape: you're OK with me recording, just for the transcript?

Business Analyst (Amazon) — Yeah, yeah, confirmed, all good. And — fair warning — I'm, like, pretty early in my career, so some of this might be more « from what I've seen so far » than, you know, twenty years of war stories. (laughs)

ACHIR Charaf — That's completely fine, that's exactly the perspective I want. So, to start — can you describe your role and what your work looks like day to day?

Business Analyst (Amazon) — Sure. So, um, I started at Amazon as a Business Analyst intern in Madrid, and I've recently moved into a Solutions Architect role. Day to day, honestly, a big chunk of it is data. Like, pulling numbers, building dashboards, cleaning up datasets so they actually make sense, and turning all that into something a stakeholder can look at and go « okay, I get it, here's what we do ». My background is a data science master's, so I'm, you know, comfortable in the data itself — SQL, a bit of Spark, that kind of thing — but my job isn't really to build fancy models, it's more to make the data tell a clear story to people who need to decide something.

ACHIR Charaf — Do you take, or contribute to, important decisions? What kind, for example?

Business Analyst (Amazon) — Contribute is the honest word, I'd say. I'm not the one who signs off — I'm, like, fairly junior, decisions of real weight are above me. But I feed them, right. So a manager needs to decide whether a process is worth changing, and my job is to put the numbers in front of them so the call is grounded and not just, you know, a gut feeling. At Amazon there's this whole culture of being data-driven, working backwards from the customer, so basically every decision is supposed to come with data attached. And often I'm the person assembling that data. So I'd say I, um, I shape decisions more than I make them, if that makes sense.

ACHIR Charaf — And what numbers, dashboards or tools do you lean on for that?

Business Analyst (Amazon) — A mix. A lot of internal dashboards, some QuickSight, SQL queries against our data, and — honestly, more than people admit — spreadsheets, still. (laughs) And there's this ritual, the weekly business review, where teams go through their key metrics every week, and if something moved, you're expected to explain why. So, like, a lot of my week is basically getting ready to answer « why did this number move », before someone even asks.

ACHIR Charaf — Think of an important, recent decision you supported using data. Walk me through how it went, start to finish.

Business Analyst (Amazon) — Okay, um, a concrete one. There was a metric — I won't get into specifics — but one of our operational numbers dipped for a couple of weeks, and the question was whether we needed to change something in the process, or whether it was just noise. So it landed on me to dig in. First thing, I pulled the data and just, like, looked at it — is this real, or is it a blip, is it seasonal. Then I sliced it a bunch of ways: by region, by segment, by time of week, trying to see if the dip was everywhere or concentrated somewhere. And it turned out it was concentrated — one specific slice was dragging the whole average down.

ACHIR Charaf — And then?

Business Analyst (Amazon) — And then the data kind of ran out, honestly. Like, the numbers told me where it was happening, but not why. So I had to go talk to people — the team closer to that slice — and it turned out there'd been an operational change on their side that the data had, you know, no way of showing me. So I put together the picture, the dashboard plus the explanation from the team, brought it to my manager, and the decision was made from that. But the point is, the data got me maybe seventy percent of the way, and then a human conversation got me the rest.

ACHIR Charaf — So where did the numbers suffice, and where did you have to dig, think, or ask someone?

Business Analyst (Amazon) — The numbers were great for the « what » and the « where ». They were, um, basically useless for the « why ». Every time it came to why — the actual cause — I had to leave the dashboard and go ask a human who had context the data didn't capture. That's been true pretty consistently, actually, in the short time I've been doing this.

ACHIR Charaf — When an important indicator moves, do your tools tell you why it moved, or only that it moved?

Business Analyst (Amazon) — Only that it moved. A hundred percent only that. Like, the tools are really good at flashing « hey, this went down ». They have basically zero to say about why. The why is always us — a person drilling in and, usually, a person picking up the phone. If a tool could actually tell me why, reliably, honestly, that would, like, change my whole job. That's the dream. But I've never seen it do it.

ACHIR Charaf — Now imagine an AI tool that, instead of showing you numbers, gave you a recommendation directly: « here's what I advise you to decide, and here's why. » How would you feel about leaning on that for a decision that matters?

Business Analyst (Amazon) — Hmm. Honestly? Mixed. Part of me is, like, excited, because I'm a data person and the idea of a tool that does the heavy lifting is appealing. But my gut reaction, for a decision that matters, is — I'd want to see the « here's why », and I'd want to be able to check it. If it just says « do X » and the why is, you know, one vague sentence, no chance, I'm not putting my name on that. I'd treat it as, like, a very smart colleague's suggestion — worth listening to, definitely not something I follow blindly.

ACHIR Charaf — What would build your confidence? What would make you doubt?

Business Analyst (Amazon) — What would build it... if I could see the reasoning and it matched things I could verify. Like, if it said « I recommend this because this metric, this segment, this trend », and I could go check those and they held up — okay, now I trust it more. And if it had a track record, if I'd, um, seen it be right over time. What would make me doubt — if it's a black box, if it sounds equally confident about everything, and, honestly, if it can't tell me when it's unsure. A tool that's always a hundred percent sure feels less trustworthy to me, not more. Oh, and if it recommended something that contradicted what the people on the ground were telling me, I'd trust the people first, at least for now. So — cautious. Interested, but cautious. I'd want it as a support, not as the decider.

ACHIR Charaf — Have you ever seen someone — you or a colleague — just follow what a tool or a number said, without really questioning it?

Business Analyst (Amazon) — Oh, yeah. All the time, honestly, and it's usually not dramatic, it's, like, small and quiet. The classic one is a number in a dashboard that everybody just... accepts. Nobody ever asks how it's calculated. People build decisions on top of « the number says forty-two percent », and nobody checks whether forty-two percent even means what they think it means. And I include myself in this, early on — I took dashboards at face value before I learned that, like, half of them have some weird definition baked in that somebody chose two years ago.

ACHIR Charaf — How did that play out, and with what result?

Business Analyst (Amazon) — The one that sticks with me — a metric that a couple of teams were both using, both trusting, and it turned out they were defining the underlying thing differently. So they were in a meeting basically, um, arguing past each other, both pointing at « the data », and the data was two different things wearing the same name. We lost a good chunk of time before someone — actually it might've been

me, because I'd been in the queries — realised the definitions didn't match. So the result was wasted time and a bit of a « wait, which number is right » mess, until we untangled it.

ACHIR Charaf — Has it ever happened that you were right against what a tool said?

Business Analyst (Amazon) — Yeah, a small one. A dashboard was showing this, like, alarming drop, and everyone's first reaction was « something's broken, panic ». But I'd been in the raw data and I had a feeling it was a data pipeline issue — like, records hadn't loaded, not that the real thing had dropped. And I was right, it was a loading gap, the actual number was fine. So that's a case where trusting the tool literally would've sent people chasing a problem that didn't exist. That one taught me a lot, actually — the tool isn't the truth, it's a view of the truth, and sometimes the view is broken.

ACHIR Charaf — Thanks, that's really helpful. Let me take two minutes to explain the heart of my research, and then I'd love your reactions. Today, most decision tools — « business intelligence » — mostly describe the past: dashboards that show what happened. My thesis is about the next generation, one that could not only describe, but explain causes, anticipate, and recommend decisions. Three ideas sit at the centre. The first is what people call a « world model » of the company: a kind of living mock-up, a bit like a flight simulator, but for the organisation. It would represent how the company really works — its customers, its processes, its rules — and let you test « if I do this, what happens? ». The second is the ontology, which you can think of as a shared map: it links all the company's data to what it really represents, so that everyone — humans and AI systems alike — speaks exactly the same language. Some people call it a « digital twin » of the organisation. And the third, « Decision Intelligence », is the idea of putting the decision at the centre, rather than the data: a system that walks with you through the whole life of a decision, from the starting question all the way to the learning you draw from the result. That's the picture. Now I'd love your reaction, completely freely. Is that clear so far?

Business Analyst (Amazon) — Yeah, that's clear — and actually a couple of those ring a bell from my master's, we, um, touched on knowledge graphs and ontologies a little, so I'm not totally cold on this. The flight simulator analogy is nice, that lands. Go for it, ask away.

ACHIR Charaf — This idea of a living mock-up of the company, a model that simulates the consequences of a decision before you take it — what does that bring to mind?

Business Analyst (Amazon) — Honestly, my first reaction is « I would love that ». Because it's, like, exactly the thing that's missing from my day, right — I told you the data tells me what and never why, and it definitely never tells me what would happen if. A simulator that could do the « what if » would be huge. That's the exciting side. The realistic side — and this is me having spent, you know, a year and a half wrestling with real data — building that mock-up so it's actually right sounds incredibly hard. A flight simulator works because the physics of a plane are known and stable. A company isn't like that. People change, the market changes, and, like, half the « rules » of how the company works aren't written down anywhere, they're just in people's heads. So the concept, ten out of ten, I want it. Whether we can actually build one that's trustworthy — I'm more skeptical, and I wasn't expecting to say that, but the more I picture the data behind it, the harder it looks.

ACHIR Charaf — In your organisation, does everyone speak the same language about data? When two teams talk about a « customer » or a « product », do they really mean the same thing?

Business Analyst (Amazon) — (laughs) No. And I say that having literally lived the example — I just told you the story of two teams arguing over a metric that meant two different things. So, no, they don't. Even at a company as data-mature as Amazon, you'd be surprised how often « active customer » or whatever means one thing to one team and something slightly different to another. It's rarely a huge gap, but the small gaps cause real confusion.

ACHIR Charaf — And when it's not the same, what does it cost, concretely — in time, errors, disagreements?

Business Analyst (Amazon) — Mostly time and trust, I'd say. Time, because you waste meetings figuring out that you're not even talking about the same number before you can talk about the actual problem. And trust, because once people get burned by « wait, whose number is right », they start second-guessing all the data, even the good data. That's the sneaky cost — one definition mismatch and suddenly people trust the dashboards a little less across the board. So this « shared map » idea, the ontology — now that you explain it, I actually get why it matters. It's not glamorous, but it's the thing that would've saved us those meetings.

ACHIR Charaf — And a capability to test « what if...? » scenarios before deciding — what would that change for you?

Business Analyst (Amazon) — It'd change the conversation from arguing about opinions to comparing options. Right now, when there's a decision, people kind of advocate for what they already believe and back it with whatever data supports them. If you could actually simulate « option A does this, option B does this », you'd argue about the assumptions instead of about egos, which is, like, a much healthier fight. For me

personally, junior as I am, it'd be amazing, because I could bring options to my manager instead of just a rear-view-mirror report. That'd make me way more useful, honestly.

ACHIR Charaf — Imagine a system that doesn't just give you numbers, but walks you through the whole decision: framing the question, simulating options, recommending, then learning from the result. Does that feel useful, or more worrying? Why?

Business Analyst (Amazon) — Both, and I think both is the right answer. Useful, clearly — it's basically automating the parts of my job that are slow, and adding the part that doesn't exist yet, the simulation and the learning loop. The « learning from the result » bit is the part I like most, actually, because that's the thing nobody does. We make a decision, and then we, like, almost never go back and rigorously check whether it was the right one. We just move on to the next fire. A system that closes that loop would make the whole organisation smarter over time. The worrying side is more subtle. It's — if the system frames the question and simulates and recommends, that's a lot of the thinking outsourced to one tool. And if that tool has a blind spot, everybody inherits the same blind spot, right. Right now, decisions are messy but there are lots of humans with different views poking at them. If one system drives the whole thing, you lose that diversity of « wait, that doesn't smell right ». So useful, yes, but I'd want humans still genuinely in the loop, not just, you know, rubber-stamping.

ACHIR Charaf — On which decisions in your work would it have the most value?

Business Analyst (Amazon) — The repetitive, data-heavy ones. Like, the stuff that comes up every week, where the shape of the decision is the same and only the numbers change — that's where a system would genuinely beat me, and free me up. The big, rare, weird strategic calls — I'd be much more cautious there, those need human judgment and context the system won't have. So: automate the routine analytical grind, keep humans firmly on the rare high-stakes stuff. That split feels right to me.

ACHIR Charaf — For a system like this to actually work in your organisation, what would need to be in place — on the data side, the culture side, the organisation side?

Business Analyst (Amazon) — Data side, number one, clean and consistent data with agreed definitions — the shared map you described. Without that, nothing else matters, it's built on sand. That's genuinely the biggest one, and it's the least exciting, which is probably why nobody funds it properly. Culture side — people would need to actually trust it, and trust has to be earned slowly. You can't just drop it on a team and say « the system decides now ». You'd have to run it alongside humans for a while, let people see it be right, let them catch it being wrong, build the trust gradually. And culturally, people need to feel allowed to challenge it — if challenging the system feels like insubordination, you've, um, killed the thing that keeps it honest. Organisation side — somebody has to own it. Own keeping the data current, own the definitions, own retraining it when the world changes. That's a real job, and organisations are bad at funding the boring maintenance job versus the shiny launch. So — data, gradual trust, and a clear owner. That's my honest list.

ACHIR Charaf — Earlier, before I explained all this, you told me you'd feel cautiously open — you'd want it as an assistant with visible reasoning, not as the decider. Now that you see the picture better, has your feeling changed?

Business Analyst (Amazon) — That's a good question, and — yeah, a bit, in two directions actually, which is interesting. On one hand, I'm more into the vision than I was. When you first asked, « AI gives you a recommendation », I pictured, like, a black box spitting out « do X », and I was wary. Now that I understand it's meant to be this whole transparent cycle, with a shared data map and a simulator and a learning loop — that's much more appealing, that's a system I could actually see trusting, because the « why » is built into it, not bolted on. So my trust in the concept went up. But on the other hand, understanding it better also made me more aware of how hard the preconditions are — the clean data, the shared definitions, the maintenance. So I got more optimistic about the idea and more realistic about how far we are from it, at the same time. If anything, my caution moved — before it was « I don't trust the AI », now it's « I trust the idea, but I don't trust that we've done the boring groundwork to make it real yet ». Which is, like, a more useful kind of caution, I think.

ACHIR Charaf — If such a system led to a seriously wrong decision, who should be held responsible? And must a decision always be explainable to be acceptable?

Business Analyst (Amazon) — On responsibility — a human, or the company. Not the system. That feels obvious to me, maybe because I'm junior and I'm very aware that « the tool told me to » has never once gotten anyone off the hook. (laughs) If I brought a bad recommendation to my manager and just said « the dashboard said so », that's on me for not checking, not on the dashboard. Scale that up: whoever deployed the system and chose to act on it owns the outcome. The moment « the AI decided » becomes a valid excuse, everyone stops being careful, and that's, um, a scary world. On explainability — for anything that matters, yes, I think it has to be explainable. And partly for a very practical reason: if you can't explain a decision, you can't defend it — to a customer, to your leadership, to yourself six months later. And you can't learn from it either. If you don't know why the system said do X, then when X turns out wrong, you've

learned nothing, you can't fix the reasoning. So explainability isn't just an ethics checkbox for me, it's what makes the whole learning loop actually work. For low-stakes, high-volume stuff, fine, I can live with less explanation. But for the decisions that count — if you can't explain it, you shouldn't act on it.

ACHIR Charaf — We're near the end. Is there anything important we didn't cover that you'd like to add?

Business Analyst (Amazon) — Maybe one thing — the human side of adoption. We talked a lot about data and systems, but a huge part of whether this works is whether people actually want to use it, and whether they feel it's helping them or replacing them. I've already seen good tools basically die because people didn't trust them or felt threatened by them. So however good the tech gets, the « will people actually adopt it » question is going to decide a lot, and I feel like that gets underestimated by technical people. That's my one add.

ACHIR Charaf — Would you point me to one or two people this might interest?

Business Analyst (Amazon) — Yeah — you should definitely talk to some of the more senior people who actually own decisions, not just support them like I do, because they'll have the « would I bet my name on this » perspective that I can't fully give you yet. And maybe someone on the data engineering side, the people who actually maintain the definitions and the pipelines — they'll tell you, probably with a tired laugh, exactly how hard the « shared map » really is. I can think of a couple of names and intro you if that helps.

ACHIR Charaf — That would be great. Thank you so much for your time — this was genuinely useful. I can send you an anonymous summary of the findings if you'd like.

Business Analyst (Amazon) — Please do, I'd love to read it — the topic's really interesting, and honestly it made me think about my own job differently. Thanks for having me.

E.6 Entretien M1. Directrice crédit et recouvrement, Green IT (Evernex)

Entreprise : Evernex

Poste du répondant : Directrice du crédit / recouvrement

Secteur : Green IT — maintenance et prolongation de vie des serveurs

Langue : Français

Format : Entretien à distance (~46 min)

ACHIR Charaf — Peux-tu juste me reconfirmer que tu m'autorises à activer la retranscription sur cette réunion ?

Directrice crédit (Evernex) — Oui, j'ai confirmé.

ACHIR Charaf — Merci. Donc sans plus attendre, je vais commencer notre entretien. Pour commencer, pouvez-vous me décrire votre poste et en quoi consiste votre travail au quotidien ?

Directrice crédit (Evernex) — D'accord. Alors je travaille en tant que directrice du crédit chez une multinationale française basée à Paris, qui opère dans la Green IT, c'est-à-dire tout ce qui est maintenance des serveurs. Pour faire simple, l'idée c'est de mettre la durée de vie des serveurs utilisés par les entreprises au maximum : si on a un serveur qui va vivre deux, trois ans, nous, à travers la maintenance et l'accompagnement, on rend ce serveur plus vivant, et il peut aller jusqu'à douze ans de survie.

ACHIR Charaf — Super, merci beaucoup. La question qui suit : est-ce que vous prenez ou contribuez à des décisions importantes, et si oui, lesquelles par exemple ?

Directrice crédit (Evernex) — Alors, mon rôle en gros dans l'entreprise, c'est le recouvrement. On a plusieurs clients avec qui on travaille, chaque client a son poids bien sûr, et ce poids se matérialise par le chiffre d'affaires qu'on fait avec lui. Par contre, des fois on se retrouve avec des factures impayées pendant très longtemps ; donc l'idée c'est de réclamer cet argent qu'on a dehors et de faire ces encaissements le plus tôt possible, pour garantir un niveau de trésorerie qui va me permettre de répondre à nos investissements, nos charges fixes, nos charges variables. Voilà les décisions auxquelles je contribue. Sans compter le côté relation avec nos clients et nos fournisseurs : à la signature d'un contrat avec un client, j'interviens pour déterminer le mode de paiement, la durée, les modalités et les échéances — si on va travailler avec du 60 jours, du 90 jours, ou du standard. Pour prendre ces décisions, on doit analyser ses états de synthèse, c'est-à-dire le bilan, etc. Donc c'est là surtout où je contribue à la prise de décision.

ACHIR Charaf — Super, merci beaucoup, c'est très clair. Pour ce genre de mission, est-ce que vous vous appuyez sur des chiffres ? Et si oui, quels chiffres, et est-ce que vous utilisez des tableaux de bord ou autres ?

Directrice crédit (Evernex) — Alors la réponse est oui. Pour vous rapprocher un peu du métier, la data qu'on utilise est surtout financière, ça tire des chiffres, et elle est orientée surtout analyse de la situation des clients. Pour ce faire, on a généralement Excel, et on a un outil — enfin, je dirais que c'est pas un logiciel, c'est une plateforme — qui s'appelle Crédit CF, dans laquelle on peut chercher chaque client, surtout ceux

basés en France ou en Europe. On tape juste le nom du client et on peut avoir ses états de synthèse, son bilan, son compte d'exploitation, et des fois même si ses clients ou ses fournisseurs recommandent de travailler avec lui. Donc c'est une plateforme qui nous aide à orienter nos décisions sur comment on va travailler avec lui. À côté de cette plateforme, on a des fichiers Excel dans lesquels on note notre suivi, les encaissements qu'on a reçus, la situation, et par exemple si on attend des encaissements futurs. C'est un outil de suivi fait sur Excel.

ACHIR Charaf — OK, merci beaucoup, c'est très clair.

Directrice crédit (Evernex) — Excusez-moi, j'ai juste oublié un autre outil très important, qui s'appelle Sidetrade. C'est aussi une plateforme, on vient de signer un contrat avec elle afin de minimiser l'emploi d'Excel. C'est le même rôle qu'Excel, mais en plus facile, plus intuitif ; c'est un outil partagé, plusieurs personnes peuvent y accéder en même temps.

ACHIR Charaf — Super, merci beaucoup. Ça nous permet d'avancer vers la deuxième partie, plus axée sur les données. Essayez de penser à une décision importante — ce sera mieux si elle est récente — que vous avez prise en vous appuyant sur des données. Si vous arrivez à me la raconter du début jusqu'à la fin, pour avoir une idée un peu bout-en-bout de comment le processus de décision fonctionne dans votre entreprise et votre poste.

Directrice crédit (Evernex) — La chose qui vient à mon esprit, c'est déjà la décision la plus récente qui a été prise. Elle est bien sûr accompagnée de l'avis de notre directeur administratif et financier, notre DAF. C'est par rapport à notre relation avec un client historique. C'est un client avec lequel on fait un chiffre d'affaires très important, avec qui on travaille depuis très longtemps. Par contre, en analysant notre relation avec lui — côté contrat, côté facturation, côté chiffre d'affaires —, on voit que tous ces éléments évoluent, mais les encaissements qu'on reçoit de son côté n'évoluent pas de la même allure. Donc on se retrouve avec un service qu'on fait et pour lequel on n'est pas payé à temps ; on a trouvé qu'il y a un non-respect des échéances, un non-respect de cette clause du contrat. On était obligé d'étudier sa situation financière, en se basant sur des données comptables et financières, et on a pu conclure qu'il n'est plus solvable. Donc continuer la relation avec lui allait compliquer la situation pour nous, on allait faire face à des impayés qui traînent longtemps. Si on voulait prendre une décision entre guillemets émotionnelle, sans recourir à cette étude financière, on aurait pu garder cette relation, vu que c'est un client historique ; mais il fallait se baser sur du chiffre pour prendre cette décision.

ACHIR Charaf — Super, et c'est une bonne transition. À quel moment les chiffres vous ont suffi, et à quel moment il a fallu creuser, réfléchir ou demander à quelqu'un pour prendre la décision ?

Directrice crédit (Evernex) — La vérité, pour ce cas particulier — et pour tous les cas qui passent par moi et que je gère —, toutes les décisions sont basées sur du chiffré, sur de la data, pour prendre une décision.

ACHIR Charaf — OK, merci. Quand un indicateur important bouge chez vous, est-ce que vos outils — Crédit safe, Excel, ou celui dont vous avez parlé — vous disent pourquoi, ou seulement que ça a bougé ?

Directrice crédit (Evernex) — Alors, laissez-moi réfléchir. Vous me demandez si ces outils interprètent le résultat, ou les données qu'ils produisent, c'est ça ?

ACHIR Charaf — Ce que j'essaie de dire, c'est : par exemple, vous avez un indicateur X que vous surveillez, et vos outils vous disent qu'il est passé de la valeur A à la valeur Y. Est-ce que vos outils vous informent seulement que l'indicateur a bougé, ou est-ce qu'ils vous expliquent pourquoi, où est la cause profonde ? C'est plus informatif ou explicatif ?

Directrice crédit (Evernex) — Oui, j'ai compris votre question, c'est plus clair. Alors honnêtement, c'est plutôt informatif. Que ce soit Excel, Crédit CF ou Sidetrade, ce sont des outils qui nous permettent de savoir qu'un indicateur a bougé. Par contre, côté interprétation, c'est à nous de le faire, c'est notre métier. Ces outils sont là pour nous faciliter la vie, nous permettre d'obtenir un suivi plus rigoureux et de recevoir des alertes quand un seuil n'est pas respecté — quand c'est nous qui paramétrons ces outils. En réalité, ce qu'on attend de ces outils, ce sont ces alertes et cette production rapide de l'information. Donc pour faire court, c'est plutôt informatif, plutôt côté alerte.

ACHIR Charaf — OK super. Maintenant, imaginez un outil qui, au lieu d'afficher des chiffres, vous proposerait directement des recommandations. Par exemple : « voici ce que je vous conseille de décider, et voici pourquoi. » Comment vous sentiriez-vous à l'idée de vous appuyer là-dessus pour vos décisions qui comptent ?

Directrice crédit (Evernex) — La vérité, je ne sais pas. Donc vous voulez dire qu'il faut que je repose une grande décision d'entreprise sur ce que l'IA va dire, c'est ça ? Qu'est-ce que cette IA va attendre de moi ? Qu'est-ce que je dois lui introduire pour qu'elle me donne cette recommandation ? Parce que là, ce que je comprends, c'est que je dois faire confiance à 100 % à l'IA et que c'est à elle d'orienter ma décision stratégique, c'est ça ?

ACHIR Charaf — C'est bien ça, et on y reviendra un peu plus tard. Maintenant, si vous pouvez me donner des éléments de réponse à chaud : est-ce que vous feriez peut-être confiance à une IA pour qu'elle vous

guide pour une décision qui compte au sein de votre organisation ? Et si oui, qu'est-ce qui vous mettrait en confiance ? Si non, qu'est-ce qui vous ferait douter ?

Directrice crédit (Evernex) — La vérité, je dirais non pour l'instant. Peut-être parce qu'elle a fait sa grande apparition récemment, c'est l'émergence qu'il y a en ce moment. Je pense qu'elle n'a pas vraiment atteint ce niveau de maturité sur lequel on peut reposer toute une décision d'entreprise. Donc non, je ne suis pas preneuse.

ACHIR Charaf — OK, merci, c'est très clair. Juste une dernière question avant que je vous parle un peu plus du sujet de la thèse — j'ai volontairement essayé de ne pas trop en parler, pour ne pas biaiser votre avis. Par rapport au suivi des outils aujourd'hui dans votre organisation : avez-vous déjà vu quelqu'un, un collègue, suivre ce qu'un outil ou un chiffre dit sans vraiment le remettre en question ?

Directrice crédit (Evernex) — Dans mon entourage, non. Mais j'ai entendu un collègue parler de ça — je pense que c'est sa femme qui lui en a parlé, dans son entreprise. Il y a quelqu'un qui fait vraiment confiance aux outils avec lesquels il travaille : il fait du copier-coller, le mec ne pense plus, il ne fait que prendre ce que ces outils lui donnent et il l'applique, c'est sa bible. Après, c'est un témoignage un peu lointain, donc il faut être un peu sceptique dans sa compréhension.

ACHIR Charaf — Super, c'est très clair. Pour la suite, je vais maintenant vous expliquer en deux minutes le cœur de ma recherche, puis j'aimerais recueillir votre réaction à chaud. Aujourd'hui, la plupart des outils décisionnels — ce qu'on appelle communément la Business Intelligence — servent surtout à décrire le passé : des tableaux de bord qui montrent ce qui s'est passé. Ma thèse s'intéresse à la génération suivante, capable non seulement de décrire, mais d'expliquer les causes, d'anticiper et de recommander des décisions. Trois idées reviennent au centre. La première, c'est ce qu'on appelle les world models. Pour être honnête, c'est un concept introduit par Yann LeCun — je sais pas si vous connaissez ce monsieur, mais si vous avez ChatGPT aujourd'hui, c'est en grande partie grâce à lui. C'est un peu le père de l'IA moderne. Selon ses recherches, les LLM qu'on a aujourd'hui — les modèles de langage comme ChatGPT — sont très loin de ce qu'on appelle l'AGI, un peu la prochaine génération de l'IA ; et pour lui, ce qui vient après, ce sont plutôt les world models. Les world models, selon Yann, ce sont plutôt des modèles physiques. Il imagine par exemple : si on veut apprendre à une voiture à rouler, on ne va pas lui apprendre le permis ou comment rouler, mais plutôt les règles physiques du monde. Le système qui conduit ma voiture serait conscient de son système physique — il sait que si un objet tombe, l'objet tombe. Un peu comme un bébé apprend, quand il est petit, par des essais-erreurs : le monde est déjà fait, et grâce à ces essais-erreurs, il apprend à interagir avec ce monde. C'est un peu l'idée de Yann LeCun derrière les world models. Ceci dit, dans un domaine d'entreprise, c'est pas du tout la même chose. Il y a eu des messieurs, certainement beaucoup plus doués que moi, qui ont pris ce que Yann a fait sur les world models physiques et l'ont retranscrit sur le monde de l'entreprise. Donc c'est une sorte de maquette vivante, un peu comme un simulateur de vol mais pour l'organisation : elle représenterait comment l'entreprise fonctionne vraiment, ses clients, ses processus, ses règles, et permettrait de tester « si je fais ça, qu'est-ce qui se passe ? ». Imaginons l'entreprise comme un jeu de simulation : le système sait que si tu augmentes les prix, les ventes vont baisser ; que si une usine tombe en panne, certaines commandes seront retardées. Par exemple, le modèle pourrait savoir qu'un client possède un contrat, qu'un contrat dépend d'un produit, qu'un produit dépend d'un système informatique, qui dépend d'une infrastructure. Mais il essaie aussi de comprendre les conséquences : si cette application tombe pendant 4 heures, quels services seront touchés, quels processus vont ralentir, quel impact potentiel. Donc un world model ne cherche pas seulement à décrire ce qui existe, il cherche idéalement à représenter comment le système évolue. Pour faire simple — avez-vous déjà joué aux Sims ?

Directrice crédit (Evernex) — Mes enfants, mais pas moi.

ACHIR Charaf — OK, donc c'est une sorte de SimCity de l'entreprise. La deuxième brique, c'est l'ontologie. C'est le concept, et le backbone, derrière des plateformes très puissantes. L'ontologie, on peut la voir comme une carte partagée : elle relie toutes les données de l'entreprise à ce qu'elles représentent réellement, pour que tout le monde — humain comme système — parle le même langage. Certains la décrivent comme un jeu de numération de l'organisation. Pour être plus parlant : prenons une entreprise de BTP. On pourrait définir qu'un adhérent possède un contrat, qu'un contrat correspond à un produit, qu'un produit contient des garanties, qu'une demande client déclenche un processus, qu'un processus utilise certaines applications. On définit donc les objets importants et leurs relations. L'intérêt principal, c'est d'éviter que chaque système parle son propre langage : une application appelle quelqu'un « client », une autre « adhérent », une autre « assuré » ; l'ontologie peut dire « attention, ces termes correspondent à tel concept métier, avec telle différence ». Et c'est particulièrement utile avec l'IA : on lui donne une couche beaucoup plus proche du métier, comme quoi l'adhérent a un contrat, le contrat un bénéficiaire, le bénéficiaire a besoin d'une garantie. Imaginez ça comme une cartographie de l'entreprise et de ses processus. La troisième partie, c'est la Decision Intelligence : l'idée de remettre la décision au centre plutôt que la donnée. Un système qui vous accompagne sur tout le cycle d'une décision, de la question de départ jusqu'à l'apprentissage tiré du résultat. Exemple simple : une entreprise doit décider « doit-on appeler ce

client maintenant ? ». L'approche classique data produit un résultat comme « ce client a 60 % de probabilité de partir » ; c'est une prédiction, mais une prédiction n'est pas encore une décision. La Decision Intelligence ajoute d'autres éléments : si j'appelle, quelle est la probabilité qu'il reste ? Combien coûte l'appel ? Combien vaut ce client ? Dois-je l'appeler lui ou utiliser cette ressource pour un autre ? À la fin, le système peut recommander « oui, appeler ce client est probablement la meilleure action ». Et surtout, après l'action, on regarde ce qui s'est réellement passé : on lui a proposé une offre, est-il resté ? Est-ce que notre recommandation était bonne ? Ça permet d'améliorer le système ensuite. Donc en emboîtant ces trois briques — l'ontologie, le world model et la Decision Intelligence —, on peut avoir un système d'IA très avancé pour décrire le « monde » (l'entreprise), comprendre son fonctionnement et décider comment agir dedans. J'espère ne pas avoir été trop long.

Directrice crédit (Evernex) — Non, non, c'est très important de savoir ça. C'est quelque chose sur lequel il faut s'ouvrir, j'imagine.

ACHIR Charaf — Du coup, on avance vers la deuxième partie. Cette idée d'une maquette vivante de l'entreprise, un modèle qui simule les conséquences d'une décision au moment de la prendre — qu'est-ce que ça vous évoque, d'après ce que je vous ai expliqué et par rapport à votre expérience ?

Directrice crédit (Evernex) — Là, après vos explications, j'imagine que c'est un outil — enfin, est-ce qu'on peut déjà appeler ça un outil ?

ACHIR Charaf — Oui, oui, c'est carrément un outil.

Directrice crédit (Evernex) — Je pense que c'est un outil qui peut contenir les trois outils dont je viens de vous parler et avec lesquels je travaille pour l'instant. Il peut englober tout ce qui est suivi, tout ce qui est alerte, tout ce qui est recommandation par rapport à notre relation avec nos clients et nos fournisseurs. Si on peut, comme vous avez dit, c'est un jumeau de l'entreprise, une entreprise physique mais plus intelligente, j'imagine, parce qu'il repose ses décisions sur les données. Donc c'est une bonne chose, et ça peut faire évoluer le business d'une manière générale.

ACHIR Charaf — Super, merci beaucoup, c'est très clair. J'ai quelques questions concernant la faisabilité de cette solution — peut-être qu'elles vont vous sembler un peu à côté de la plaque, mais c'est important, surtout côté ontologie. Est-ce que dans votre entreprise tout le monde parle le même langage sur les données ? Quand deux services parlent d'un client ou d'un produit, désignent-ils vraiment la même chose ?

Directrice crédit (Evernex) — Oui, je pense que oui. On a un jargon commun qu'on utilise dans l'entreprise. Donc si on dit quelque chose, l'autre personne comprend, on fait référence à la même chose, qu'on soit de l'équipe finance, ou marketing. On parle tous le même langage.

ACHIR Charaf — Super, merci beaucoup. Autre question : une capacité à tester des scénarios « et si » avant de décider, ça changerait quoi pour vous ?

Directrice crédit (Evernex) — Ça va nous ouvrir d'autres perspectives, comprendre ce qui pourrait se passer. Comme son nom l'indique, « what if » : qu'est-ce qui pourrait se passer si on prend cette décision ? Pour comprendre la décision A et pas la décision B. Je pense que ça pourrait nous orienter vers la prise de la bonne décision au bon moment, surtout, parce qu'une bonne décision prise des mois après, je pense que ça ne sert à rien. Il faut la prendre à chaud et qu'elle soit bonne. Donc c'est en termes de temps et de justesse.

ACHIR Charaf — Super. Maintenant, imaginez un système qui ne vous donne pas juste des chiffres, mais qui vous accompagne sur toute la décision : il vous aide à cadrer la question, à simuler toutes les options, puis à recommander et à apprendre du résultat. Ça vous semble utile ou plutôt inquiétant, et pourquoi ?

Directrice crédit (Evernex) — La vérité, j'ai des sentiments mitigés, parce que je ne sais pas à quel point on peut faire confiance à ceci. J'imagine qu'il peut nous induire en erreur comme il peut nous donner la bonne voie à suivre. Je sais que ça va arriver un jour, que c'est probable dans un futur proche. En réalité, je n'ai pas vraiment eu le temps de statuer sur ceci ; ça peut être bénéfique, mais pour statuer, il faut d'abord avoir une expérience avec cet outil.

ACHIR Charaf — OK super. Qu'est-ce qui vous emballle le plus dans cette idée, et surtout, qu'est-ce qui vous freine le plus ?

Directrice crédit (Evernex) — Quand je dis « je ne sais pas », ce qui me fait peur, c'est si jamais cet outil nous oriente vers une décision complètement erronée, ou s'il y a un bug, ou une fuite de données. Je vois des risques, parce que si ça vous facilite la vie à ce point, j'imagine que le risque est grand. Je n'ai pas de statistiques ou de data pour vous convaincre, c'est juste un ressenti, des choses que j'ai construites avec tout ce qu'on entend dans les news, sur les réseaux sociaux. Donc je saurais pas vraiment vous répondre, vu que je n'ai pas d'expérience réelle avec ces outils.

ACHIR Charaf — OK, ma prochaine question : partons du postulat que cet outil existe et qu'il est fiable, qu'on vous a montré d'une façon ou d'une autre qu'il marche à 100 %. Sur quelle décision de votre métier ça aurait le plus de valeur ?

Directrice crédit (Evernex) — Si c'est fiable et si c'est un outil sur lequel on peut compter, il va nous aider à gérer une relation avec nos clients et nos fournisseurs de manière très smart. On saurait qui est le bon client, qui est solvable, qui ne l'est pas, qui paye à temps, quelle est sa santé financière, comment les autres parties prenantes travaillent avec cette institution, que ce soit un client ou un fournisseur. Il va aussi nous alerter par rapport à notre propre santé financière, par exemple sur le BFR, le besoin en fonds de roulement : si on est bon là-dessus, si on a besoin de cash ou non. Donc dans ce sens-là, si c'est fiable, il va nous orienter vers la bonne décision.

ACHIR Charaf — Super, merci beaucoup. Pour notre dernière partie : pour que ce genre de système marche vraiment dans votre organisation, qu'est-ce qu'il faudrait réunir — côté données, côté culture, côté organisation — pour que vous, mais aussi toute votre organisation, fassiez confiance à un tel système ?

Directrice crédit (Evernex) — La vérité, je pense qu'il doit revenir au côté confidentialité, et aussi au volet rapidité, parce que des fois on se retrouve avec des problèmes dus au retard, surtout un retard de prise de décision. Donc si c'est un outil qui peut rassembler les deux — rapidité de prise de décision, sur une décision correcte et bonne, et confidentialité —, un système sécurisé... parce qu'on parle déjà d'une entreprise numérique jumelle de l'entreprise réelle, donc il faut qu'il soit sécurisé.

ACHIR Charaf — Super. Tout à l'heure, avant que je vous explique tout ça, vous étiez un peu sceptique à l'idée. Maintenant que vous voyez mieux de quoi il s'agit, est-ce que votre ressenti a changé ?

Directrice crédit (Evernex) — La vérité, oui et non. Je trouve que l'idée est — excusez-moi de vous le dire — trop belle pour être vraie. J'aimerais bien que ce soit vrai, qu'on puisse produire une chose aussi grandiose, qui va nous accompagner, booster notre business et notre santé financière. Donc si ça arrive, si on peut introduire une chose comme ça, bien sûr, c'est une bonne chose, on ne peut pas dire non à un changement positif. Par contre, j'imagine que c'est encore trop tôt. Je sais pas si nos systèmes vont suivre, parce que, pour parler d'une maquette de ce genre, il faut d'abord soigner notre data, introduire la bonne data, pour se retrouver avec des recommandations et des décisions fiables. Donc là, de notre côté, on n'est pas très prêts pour l'instant ; mais dans un futur proche, je pense qu'on peut suivre ceci.

ACHIR Charaf — OK, juste une dernière question, plutôt côté éthique. Si un tel système menait à une décision gravement erronée, qui devrait en être tenu responsable selon vous ?

Directrice crédit (Evernex) — Ça, c'est une très bonne question, et c'est parmi les raisons pour lesquelles je suis toujours sceptique par rapport à ce sujet. Je dirais que... je ne sais pas vraiment, c'est une grande question. Peut-être que tous les éléments sont responsables : le système en soi, la personne qui a introduit les données, la personne qui a fait confiance au système en premier lieu, aussi la personne qui a fabriqué le système. Là, je pense que toute partie a une part de responsabilité.

ACHIR Charaf — Et une dernière question : est-ce que vous pensez qu'une décision doit toujours pouvoir s'expliquer pour être acceptable ?

Directrice crédit (Evernex) — Ah oui, carrément. Oui, il le faut. Parce que sinon, comment convaincre les parties prenantes ? Si tu as une décision, il faut la défendre ; tu as une idée, il faut la défendre, parce qu'on peut se trouver face à des interlocuteurs têtus qui veulent des explications, des gens qui ont un avis contraire au vôtre. Donc il faut avancer les bons arguments, expliquer toute décision avant sa prise. Ça me semble naturel.

ACHIR Charaf — Et juste une dernière question : aujourd'hui, quand vous utilisez ChatGPT et qu'il vous répond à une question au hasard, est-ce que vous remettez vraiment en question sa réponse ?

Directrice crédit (Evernex) — La vérité, oui. Pour être honnête, mon utilisation de ChatGPT se limite à tout ce qui est formulation, correction d'orthographe, rédaction, du littéraire. Mais si je pose une question au hasard, bien sûr que je vais la remettre en question. Déjà, si ma mémoire est bonne, il y a un astérisque en bas qui dit « attention, cet outil peut vous induire en erreur, il faut toujours vérifier ». Moi — je sais pas si je suis méfiante, peut-être un trait de personnalité — pour GPT ou tous les autres modèles qui y ressemblent, je mets toujours en question, il faut toujours que je pousse un peu la recherche de manière traditionnelle, sur Google, sur des articles, des revues, etc.

ACHIR Charaf — Super, merci beaucoup, ça répond à ma question. On arrive à la fin. Y a-t-il quelque chose d'important qu'on n'a pas abordé et que vous aimeriez ajouter ?

Directrice crédit (Evernex) — Pas vraiment, je pense qu'on a fait le survol de tout.

ACHIR Charaf — Super, merci beaucoup. Merci, au revoir.

Directrice crédit (Evernex) — Au revoir.

E.7 Entretien M2. Contrôleuse de gestion senior, distribution automobile (RRG)

Entreprise : RRG (Renault Retail Group)

Poste du répondant : Contrôleur de gestion senior

Secteur : Automobile — production et distribution

Langue : Français

Format : Entretien à distance (~44 min)

ACHIR Charaf — OK super, pouvez-vous juste me reconfirmer que vous m'autorisez à activer la retranscription sur ce meeting ?

Contrôleur de gestion (RRG) — Bien sûr, allez-y.

ACHIR Charaf — Merci. Je vous ai un peu présenté ma thèse pro, donc je vais commencer avec les premières questions. Tout d'abord, pouvez-vous me décrire votre poste et en quoi consiste votre travail au quotidien ?

Contrôleur de gestion (RRG) — OK, alors pour vous mettre un peu dans le bain, je travaille en tant que contrôleur de gestion senior chez un grand groupe dans le secteur automobile, qui fait de la production et de la distribution. Mon poste, c'est un poste de contrôleur de gestion basique : c'est-à-dire un appétit pour les chiffres, tout ce qui est reporting, tout ce qui est analyse des KPI et leur interprétation bien évidemment. Et je reporte directement au management pour l'aide à la décision.

ACHIR Charaf — Du coup, j'imagine que dans votre travail vous vous appuyez beaucoup sur les données. Est-ce que vous prenez ou contribuez à des décisions importantes ? Vous avez dit que oui, pouvez-vous me citer quelques exemples ?

Contrôleur de gestion (RRG) — Bien sûr. Alors déjà, une décision importante — le mot « importante », je sais pas s'il est convenable de l'utiliser, parce que j'estime que toute décision est importante, surtout quand on opère dans un domaine dynamique et à forte extension. Donc bien évidemment on repose sur des chiffres, des chiffres et des chiffres. Le poste nécessite un profil qui a un grand appétit pour les chiffres. Qui dit ça dit analyse et suivi quotidien, et ce même suivi vous aide à dresser des reportings qui contribuent à l'aide à la décision. Là, en 2026, avec l'extension du marché automobile, il y a des décisions qui se prennent d'une manière vertigineuse, parce qu'il faut décider vite, surtout en cas d'urgence ou de changement de marché. Je vous donne juste un exemple : récemment, on veut s'ouvrir sur d'autres marchés, donc ça veut dire lancement de nouvelles succursales, de nouveaux points de vente. Il faut bien évidemment étudier leur rentabilité — si ça va marcher ou pas dans ce point de vente, si on a la bonne clientèle, si on est bien posé côté segmentation du marché, etc. Donc ce sont des décisions qui se posent principalement sur des chiffres.

ACHIR Charaf — Super, ça s'inscrit très bien dans le cadre de cet entretien. Du coup, j'imagine que vous avez des outils pour tracer ces chiffres, que ce soit des outils bureautiques, Excel, ou n'importe quel logiciel. Pouvez-vous me citer les outils que vous utilisez au quotidien ?

Contrôleur de gestion (RRG) — OK, bon, je sais pas si vous allez juger, si vous allez dire que c'est de l'école ancienne, mais je vais être très honnête avec vous. Pour l'instant, jusqu'à aujourd'hui, on travaille par Excel. Par contre, on est en train de chercher de nouvelles méthodes, parce que la data avec laquelle on travaille s'agrandit de jour en jour ; donc on cherche des méthodes qui vont optimiser la gestion de cette data, à savoir la data analytics, ou bien le Power BI pour tout ce qui est reporting. Je pense pas qu'on va appeler le Power BI un outil de gestion de données, parce que ça fait juste beau pour les reportings. Je sais pas si ça répond à votre question.

ACHIR Charaf — Oui, oui. Vous savez, Excel c'est l'outil le plus utilisé en France pour tout ce qui est data, donc y a pas de souci à l'utiliser.

Contrôleur de gestion (RRG) — D'accord, OK, merci de me rassurer.

ACHIR Charaf — OK, donc ça répond parfaitement. Juste pour boucler cette première partie : est-ce que vous arriveriez à penser à une décision importante — ça serait bien que ce soit récent — que vous avez prise en vous appuyant sur des données ? Et si vous pouvez me la raconter du début jusqu'à la fin, pour avoir une image un peu bout-en-bout de comment ça se passe, même avec une décision qui n'a pas un grand impact, juste pour voir le flot typique dans votre entreprise et votre rôle.

Contrôleur de gestion (RRG) — OK, alors je vais aller vers le contrôle de gestion sociale, comme ça je vous donne un exemple plus parlant et qui ne nécessite pas une grande expertise pour le comprendre. C'est en matière de recrutement, par exemple. Là, on se trouve avec un nombre d'employés bien précis, et on a des équipes qui demandent plus de recrutement. Qui dit recrutement dit budget, et qui dit budget dit suivi et optimisation. Chaque équipe a un budget qui lui est alloué en début d'année, puis révisé chaque trimestre ou chaque semestre selon le besoin. Là, on se trouve devant un épuisement du budget fait par l'équipe RH, surtout l'équipe des chasseurs de tête. Par contre, on se retrouve toujours avec des équipes qui demandent plus de recrutement. Donc il fallait analyser l'équipe et comprendre : est-ce qu'on a des départs, est-ce qu'on a des entrées, où est le besoin ? Faire le suivi de chaque employé, avoir une fiche, calculer la masse salariale, calculer son impact sur le budget global, sa relation avec le résultat de l'entreprise et son chiffre d'affaires. Est-ce que ça suit le développement de la société ou pas ? Donc en centralisant toutes ces

informations et en les analysant ensemble, on a pu arriver à une décision, qui est qu'il faut freiner le recrutement, le temps de faire quelques régulations côté budget. Et puis on décidera par la suite si on garde ce freeze pour longtemps, ou si on fait des ajustements pour répondre aux besoins des équipes qui demandent plus de ressources.

ACHIR Charaf — OK super. D'après ce que j'ai compris, vous vous êtes beaucoup appuyée sur les données pour sortir avec une décision, dans ce cas spécifique.

Contrôleur de gestion (RRG) — Tout à fait, oui. Et en plus — excusez-moi de vous interrompre — le fait d'avoir une information chiffrée, ça nous aide aussi à convaincre. Parce que quand on montre à la personne qui est devant nous un état qui affiche une évolution, un impact, quand c'est visuel, quand on arrive à faire parler ces chiffres, les gens comprennent plutôt la décision, même si elle va à l'encontre de ce qu'ils avaient en tête au début.

ACHIR Charaf — J'imagine donc que la donnée et les chiffres vous ont suffi pour sortir avec une décision dans ce cas précis ? Il a pas fallu creuser davantage, réfléchir, ou demander à quelqu'un et rajouter de l'humain dans la décision ? Enfin, les chiffres étaient tellement tranchants que c'est bon, on prend la décision grâce à ce qu'on voit ? Ou il y a eu de l'humain qui est venu rajouter son expertise ?

Contrôleur de gestion (RRG) — Oui, oui. Alors pour vous répondre, la donnée chiffrée était bien sûr tranchante, parlante. Par contre, là où on avait besoin de la vie, de l'humain, c'était pour comprendre pourquoi on a tant de turnover, c'est le climat social. Qu'est-ce qui se passe réellement ? Ce sont des choses qu'on ne peut pas vraiment calculer. Donc il faut faire des investigations qualitatives.

ACHIR Charaf — OK, donc j'extrapole de votre dernière réponse que vos outils d'aujourd'hui vous indiquent que ça a bougé — qu'un indicateur a bougé — mais est-ce qu'ils vous disent pourquoi, ou seulement que ça a bougé ? J'imagine que ça vous dit que l'indicateur X est passé de A à B, mais est-ce que ça vous dit réellement pourquoi ?

Contrôleur de gestion (RRG) — En fait non, pas vraiment, parce qu'on travaille par Excel. Si on fait une formule par-ci par-là, on arrive à savoir que voilà, cet indicateur a bougé. Mais qu'est-ce qui se passe réellement derrière ? Ça, c'est plutôt humain, c'est là où l'humain intervient, côté interprétation. On a la donnée devant nous, mais pour la comprendre, pour savoir la relation entre une donnée A et une donnée B, ou comment cette donnée a impacté une autre, il faut vraiment l'interprétation humaine, il faut creuser, il faut un effort supplémentaire.

ACHIR Charaf — Super, ça nous fait un excellent tremplin. Là j'ai envie de vous mettre dans une situation. Imaginez un outil d'IA qui, au lieu d'afficher des chiffres, vous propose directement une recommandation. Par exemple : « voici ce que je vous conseille de décider, et voici pourquoi. » Un outil qui aurait accès à toutes vos données et qui, grâce à des algorithmes derrière... — excusez-moi, je crois que ça a coupé.

Contrôleur de gestion (RRG) — Exact, je pense. J'ai un problème de connexion, je m'excuse.

ACHIR Charaf — Aucun souci, là ça marche. Du coup, on en était au point où je vous demandais, à propos de cet outil d'IA qui, au lieu d'afficher des chiffres, vous propose directement une recommandation, « voici ce que je vous conseille, voici pourquoi » : comment vous sentiriez-vous à l'idée de vous appuyer là-dessus pour une décision qui compte, par exemple celle des RH que vous venez d'expliquer ?

Contrôleur de gestion (RRG) — Alors, à vrai dire, peut-être que je serais plutôt confiante, parce que j'imagine que l'IA ne va que mouliner les données qui existent déjà et faire ressortir les choses dont on a besoin d'analyser, et sur lesquelles on va se baser pour prendre une décision. Donc je dirais que je serais plutôt favorable à cette idée, et en fait ça va me faciliter la vie, ça va optimiser le temps et l'énergie. Donc je suis plutôt preneuse.

ACHIR Charaf — OK, donc la question qui suit naturellement : vous êtes assez ouverte à l'idée, mais qu'est-ce qui vous mettrait en confiance ? Et de l'autre côté, qu'est-ce qui vous ferait douter d'un outil comme ça ?

Contrôleur de gestion (RRG) — La vérité, ce qui va me permettre de lui faire plutôt confiance, c'est que — je n'ai pas la certitude, c'est juste une idée que j'ai — ce sont des outils qui sont bêtes et disciplinés, donc ils ne vont faire que mouliner l'information qu'on injecte au premier lieu. Je ne sais pas si j'ai raison ou pas, mais c'est ce que j'estime. Donc c'est cette idée qui va me pousser à faire confiance à des outils de ce genre. Je sais qu'il va me mettre un peu mal à l'aise, ou me faire un peu douter entre guillemets — même si je doute pas — surtout en phase de lancement de l'outil, parce que j'imagine qu'il faut plusieurs entraînements, plusieurs allers-retours pour que ce soit opérationnel et un peu plus autonome. C'est dans cette phase que je serais un peu sceptique. Mais par la suite, s'il est bien entraîné et sait ce qu'il doit faire, je lui ferais plutôt confiance.

ACHIR Charaf — OK super. Dernière question dans cette partie, un peu relative à votre background : durant toute votre carrière, est-ce que vous, ou un collègue, avez déjà été dans une situation où quelqu'un fait confiance à un outil ou à un chiffre sans vraiment le remettre en question ? Par exemple, quelqu'un qui

voit une recommandation, une action à faire, et l'applique à la lettre sans la remettre en question. Est-ce que vous avez déjà vécu une expérience comme ça ?

Contrôleur de gestion (RRG) — La vérité, dans mon entourage, non, je n'ai pas un exemple palpable à vous dire, parce que je trouve déjà que l'émergence de ces outils est plutôt récente, surtout dans le domaine dans lequel j'opère. Je le vois pas vraiment, c'est pas monnaie courante de voir ces outils dans ce domaine. Peut-être qu'on est un peu ancienne école, j'espère que ça va s'arranger dans le futur. Donc ce genre de situation, je saurais pas vraiment répondre à cette question, parce que tout simplement je n'ai pas les exemples.

ACHIR Charaf — OK super. Jusqu'à maintenant, comme vous avez remarqué, je vous ai très peu parlé du cœur de ma thèse, pour ne pas biaiser votre vision. Je vais maintenant vous l'expliquer en deux minutes, puis j'aimerais recueillir vos réactions. Aujourd'hui, la plupart des outils décisionnels — de la Business Intelligence, et ce que vous faites peut rentrer dans ce cadre — servent surtout à décrire le passé. Vous avez des tableaux de bord qui montrent ce qui s'est passé. Ma thèse s'intéresse à la génération suivante, capable non seulement de décrire, mais d'expliquer les causes, d'anticiper et de recommander des décisions. Trois idées reviennent au centre. La première, c'est ce qu'on appelle un world model, un modèle du monde de l'entreprise. Ça découle directement des recherches de Yann LeCun, qui est un peu le père fondateur de l'IA que vous voyez aujourd'hui — enfin, si vous avez ChatGPT aujourd'hui, c'est en grande partie grâce à lui. Et ce monsieur imagine que, dans le futur, ce ne sera plus seulement une IA qui connaît des règles et opère grâce à des données, mais une IA consciente de son monde physique. Un exemple : pour qu'un robot, ou une Tesla, conduise en autonomie, on ne doit pas lui montrer comment un humain conduit, mais plutôt lui apprendre les règles physiques du monde, et il apprendra à conduire naturellement. Si on essaie de calquer cette vision sur l'entreprise — et des chercheurs bien avant moi, beaucoup plus doués, l'ont fait —, on sort avec ce qu'on appelle un world model de l'entreprise : une sorte de maquette vivante, un peu comme un simulateur de vol, mais pour l'organisation. Elle représenterait comment l'entreprise fonctionne vraiment, ses clients, ses processus, ses règles, et permettrait de tester « si je fais ça, qu'est-ce qui se passe ? ». En gros, cette IA n'a pas le passé de l'entreprise, mais elle a les règles de l'entreprise, les terminologies, elle connaît tout de l'entreprise, et en même temps elle a une compréhension du monde extérieur. Ce qui nous amène à la deuxième partie : l'ontologie, qu'on peut voir comme une carte partagée. Elle relie toutes les données de l'entreprise à ce qu'elles représentent réellement, pour que tout le monde — humain comme système — parle exactement le même langage. Certains la décrivent comme un jumeau numérique de l'organisation. Et ça nous amène à la troisième partie, la Decision Intelligence : l'intelligence de la décision, l'idée de remettre la décision au centre plutôt que la donnée. Aujourd'hui, sur Excel, vous avez la donnée et vous faites vos expertises dessus. Là, le centre ne sera pas la donnée mais la décision : un système qui vous accompagne sur tout le cycle de la décision, de la question de départ jusqu'à l'apprentissage du résultat. Et la nouvelle génération, ce ne sera même plus à vous de poser la question : grâce à sa compréhension du « monde » de l'entreprise, elle sera capable de comprendre ce qui se passe et de vous mettre au courant — elle peut même vous notifier « vu ces informations externes et internes, tel ou tel KPI doit être vérifié parce que telle chose a changé dans le monde réel ». Voilà, j'espère avoir été clair, c'est difficile d'expliquer des concepts compliqués en deux minutes, mais je pense que vous avez la big picture.

Contrôleur de gestion (RRG) — D'accord, OK. Non, non, vous étiez très concis et très clair. Pour moi, c'est vrai, c'est de la science-fiction, parce que c'est un truc que j'arrive à imaginer ; je vois que ça peut arriver et que ça va être très bénéfique pour l'entreprise. Après, je sais pas si l'IA va prendre nos jobs ou pas, mais pour l'instant, cet accompagnement pour des postes comme le mien, pour l'aide à la décision, cette certitude que nos données sont parlantes et correctes, que nos calculs reflètent vraiment la réalité et qu'on peut faire confiance à nos KPI — si ça arrive dans ce sens, ça va vraiment faire évoluer le monde du business d'une manière très palpable.

ACHIR Charaf — Super. Donc pour cette deuxième partie, je vais vous demander d'essayer de rentrer avec moi dans ce qui vous semble un épisode de Black Mirror, mais qui peut être réalité dans pas très longtemps. On rentre dans un monde parallèle et on imagine que cet outil existe. Cette idée d'une maquette vivante de l'entreprise, un modèle qui simule les conséquences d'une décision avant de la prendre — qu'est-ce que ça vous évoque ? Quels sont vos sentiments à l'égard d'un outil comme ça ?

Contrôleur de gestion (RRG) — Alors, comme je vous ai dit, je suis preneuse. Si on arrive à simuler ça, ou à le mettre dans la réalité, moi je suis favorable dans tous les cas. Je sais pas si j'ai répondu à votre question.

ACHIR Charaf — Oui, c'est super, c'était très clair. Maintenant, j'ai une question un peu plus technique. Tout à l'heure, j'ai mentionné que cet outil doit être vraiment ancré dans l'entreprise, il sait exactement ce qui s'y passe et les règles internes — comme un employé de l'entreprise. Le problème dans la visibilité d'un tel outil, c'est que parfois, même deux personnes dans la même entreprise ne parlent pas de la même terminologie. Donc la question qui se pose naturellement : est-ce que dans votre organisation tout le monde parle le même langage sur les données ? Quand deux services parlent d'un client ou d'un produit,

désignent-ils vraiment la même chose, ou une même terminologie peut-elle avoir deux interprétations différentes suivant la personne ?

Contrôleur de gestion (RRG) — Alors, je pense que ce problème ne se présente pas réellement dans le secteur automobile, parce qu'on a tous le même jargon, on parle le même langage. Par exemple, on ne dit pas « voiture », on dit « châssis », donc on sait de quoi on parle ; on a une terminologie précise pour chaque élément, qui est transversale, utilisée dans plusieurs services et bien sûr compréhensible. Par contre, là je parle de mon métier : si on veut partager une donnée chiffrée, on doit bien sûr la vulgariser, pour la mettre à disposition de notre interlocuteur. Parce qu'il se peut que, quand on parle avec quelqu'un du sales ou du marketing, on ne parle pas vraiment le même jargon. Et ça, c'est partout, chez toutes les entreprises. Donc il faut vulgariser l'information pour qu'elle soit plus fluide et plus compréhensible.

ACHIR Charaf — Super. Une dernière question par rapport à votre métier en particulier. On part du postulat que cet outil existe concrètement. Sur quelle décision de votre métier ça aurait le plus de valeur ? Si vous essayez de faire l'analogie entre ce que je viens de dire et votre métier, là où ça apporterait le plus de valeur.

Contrôleur de gestion (RRG) — Donc si je vous ai bien compris, vous voulez savoir là où cette maquette va nous aider le plus, en valeur, en termes de rentabilité, etc. Alors, je pense que si on arrive vraiment à maîtriser nos données et nos calculs, et à avoir plutôt une vision 360 sur ce qui se passe réellement dans le marché — par rapport à nos concurrents, par rapport à la vitesse à laquelle le marché évolue —, on aurait un peu plus de chances de prendre des décisions stratégiques pertinentes. On pourrait reposer ces décisions sur des données chiffrées produites par cet outil, donc orientées vers tout ce qui est rentabilité, évolution rapide, optimisation. Je pense que c'est dans ce sens-là que cet outil aurait le plus d'impact et de valeur.

ACHIR Charaf — OK super. Donc là j'ai la figure technique, organisationnelle et fonctionnelle de ce que ça pourrait apporter. Ma question : pour que ce genre de système marche vraiment dans votre organisation — pas techniquement, on assume qu'on a assez de données, qu'on a réussi à le mettre en prod et qu'il connaît votre organisation par cœur — côté culture, côté organisation, côté C-level, est-ce que vous pensez qu'un tel outil sera bien reçu, et comment réagiront-ils face à un système qui peut changer intégralement le fonctionnement d'une organisation ?

Contrôleur de gestion (RRG) — Alors, votre question repose sur deux volets : ce qu'ils vont penser, et comment ils vont réagir. On parle un peu de ressenti et un peu de réaction. Je vais commencer par la réaction. Bien sûr, tout changement fait face à une réticence, et la conduite du changement nécessite beaucoup d'efforts et prend plus de temps que d'habitude. Parce qu'on est des humains, le cerveau est conçu de cette manière, on aime rester dans notre zone de confort, on n'aime pas le changement. Donc si en entreprise on vous dit « on va introduire un outil numérique, artificiel, appelez-le comme vous voulez », bien sûr on va avoir de la réticence, des gens qui vont avoir peur de perdre leur métier. Ça a un aspect social, humain, émotionnel. Donc il faut bien évidemment une conduite du changement si on veut l'introduire. Par contre, là où je pense que le problème se pose, c'est peut-être la partie confidentialité : parce que oui, pour avoir cette vision 360, on doit avoir les données des concurrents aussi, et on ne veut pas vraiment faire exploser nos données. Donc c'est un peu paradoxal ; je sais pas si cet outil va protéger cet aspect confidentiel tout en ayant une vision sur ce qui se passe dans le marché. Ce sont des questions qui peuvent retarder le changement et impacter la réaction des gens. À part ça, pour le ressenti, les gens diffèrent. Comme j'opère dans le secteur automobile, c'est un secteur qui englobe plusieurs métiers — finance, marketing, vente, toute une force qui travaille derrière — et chacun a un ressenti, chacun adhère ou pas à l'idée. Donc en général, on va avoir des ressentis et des réactions mitigés.

ACHIR Charaf — OK, c'est très clair, merci beaucoup pour votre réponse. Tout à l'heure, avant que je vous explique tout ça, vous étiez plutôt très ouverte à l'idée de confier vos décisions à des outils. Maintenant que vous voyez mieux de quoi il s'agit, est-ce que votre ressenti change ?

Contrôleur de gestion (RRG) — Non, il est le même, toujours favorable.

ACHIR Charaf — Super. Ça m'amène à l'autre question : si un tel système menait à une décision gravement erronée, qui devrait en être tenu responsable selon vous ?

Contrôleur de gestion (RRG) — C'est une bonne question, une question éthique. Qui devrait être responsable... C'est peut-être la personne qui lui a introduit les données, pour qu'il nous produise des données erronées qui ont mené à cette décision fautive.

ACHIR Charaf — Je vous dirais que peut-être la personne qui a rentré les données a rentré juste les données qui existent, qui sont réelles. L'erreur ne vient pas des données, elle vient du fait que le système a mal calculé, a mal fait ses inférences, et vous a donné une mauvaise décision.

Contrôleur de gestion (RRG) — Mais ça, c'est suite à un bug système, ou bien ?

ACHIR Charaf — Si vous voulez, les systèmes d'IA sont des systèmes non déterministes. Même dans les systèmes qu'on a aujourd'hui pour le grand public, GPT par exemple, des fois il vous répond des réponses

qui ne sont pas très exactes. Et ça peut être la même chose dans les systèmes d'IA utilisables en entreprise.

Contrôleur de gestion (RRG) — Après, là je pense qu'au lieu de sanctionner, il faut plutôt étudier un ratio, le pourcentage d'erreur : si cet outil nous a fait une erreur sur 100, ou sur 1000, c'est non significatif. Le risque d'erreur ne tombe pas vers zéro, j'imagine. Donc il faut qu'on tolère un peu, surtout si l'impact de cette décision n'est pas vraiment gros. Parce que déjà, avec l'humain qui produit, interprète et décide, on a des décisions erronées, on a des pertes, et on fait une provision sur la base de ces pertes, parce qu'on sait qu'on va perdre à un moment donné. Donc j'imagine qu'il faut juste continuer à provisionner ces pertes et donner un peu de marge d'erreur à cet outil, parce que je pense pas qu'on peut en attendre la perfection ; il faut juste étudier le taux d'erreur.

ACHIR Charaf — Je suis d'accord avec vous. Et ça m'amène à ma dernière question sur le volet éthique. Est-ce que vous êtes plutôt d'accord pour dire qu'une décision doit toujours pouvoir s'expliquer pour être acceptable ? Pour vous mettre en contexte : dans un monde futur, si cet outil vous recommande une décision, avec un taux de réussite de 99 %, mais que ces recommandations ne sont pas explicables — vous savez par expérience qu'à 99 % elles sont vraies, mais pas explicables, c'est juste après coup que vous constatez qu'il avait raison. Est-ce qu'une décision doit vraiment être explicable pour être acceptable, selon vous ?

Contrôleur de gestion (RRG) — Alors là, comme vous le décrivez, si vous me dites qu'à 99 % la décision est bonne, peut-être que je ne chercherais pas d'explications. Mais attention, ça dépend de l'interlocuteur, de la personne devant laquelle on va présenter cette probabilité et qui attend de nous une explication. Là, en termes d'acceptance, je pense que ça va être un peu difficile. Je pense qu'il faut avoir des explications tout de même, ou bien juste montrer l'impact de cette décision, ou des simulations, ou des hypothèses, pour dire « voilà, si on fait A, on va voir B », juste des scénarios probables.

ACHIR Charaf — OK super, merci, c'était très clair. On arrive à la fin. Y a-t-il quelque chose d'important qu'on n'a pas abordé et que vous aimeriez ajouter ? Ça peut être votre point de vue personnel, quelque chose qui vous a marqué.

Contrôleur de gestion (RRG) — En vérité, moi j'ai trouvé cet échange très constructif, dans le sens où ça m'a permis d'imaginer, ça m'a fait penser — comme je vous ai dit au début — à des films de science-fiction. Là, j'essaie de personnifier la chose : je l'imagine comme un assistant, ou une assistante, à mes côtés au quotidien, sur lequel je peux m'appuyer pour la prise de décision, et qui est fiable surtout. C'est un assistant que je ne suis pas obligée de former, il est déjà formé ; il faut juste qu'il me procure l'information en temps réel, rapidement, parce que des fois il faut prendre la décision rapidement, alors qu'aujourd'hui il faut passer par un long chemin de production de la donnée, d'analyse, d'interprétation. Donc si on arrive à voir ça dans un seul outil accessible et intuitif, je trouve que ça va être vraiment un game changer.

ACHIR Charaf — Super, merci beaucoup pour votre temps. Je peux vous envoyer une synthèse anonyme du résultat si vous le souhaitez.

Contrôleur de gestion (RRG) — Oui, j'aimerais bien, merci beaucoup. Bon courage pour votre thèse.

E.8 Entretien M3. Digital Product Manager, transport aérien (Air France)

Entreprise : Air France

Poste du répondant : Digital Product Manager

Secteur : Transport aérien

Langue : Français

Format : Entretien à distance (~47 min)

ACHIR Charaf — Est-ce que vous pouvez juste me reconfirmer que vous m'autorisez à activer la retranscription sur notre échange ?

PM (Air France) — Oui, oui, je vous le confirme.

ACHIR Charaf — Parfait, merci. Donc sans plus attendre, je vais commencer par la première question : pouvez-vous me décrire votre poste et en quoi consiste votre travail au quotidien ?

PM (Air France) — Alors, comme je vous l'ai déjà dit, je suis digital product manager chez Air France, donc je suis beaucoup plus sur la partie logiciel et la partie IT. En gros, mon rôle, ça va être vraiment de faire le lien entre le besoin métier et nos équipes tech. Au quotidien, ça peut être très différent d'une journée à l'autre. Je peux avoir un atelier avec une équipe métier, ce qui va permettre de repérer le besoin, les nouvelles fonctionnalités dont on a besoin. Mon rôle, ça va être de comprendre ce besoin, le traduire s'il est vraiment technique, voir à qui ça va servir, quel est l'impact et comment on peut mettre tout ça en place. Donc je travaille beaucoup avec les équipes techniques, les développeurs, parfois aussi nos équipes data,

mais je suis aussi beaucoup sur le produit une fois qu'il est en production. Voilà, ça résume un peu mon rôle en tant que PM.

ACHIR Charaf — C'est super, c'est très clair. Prochaine question : est-ce que vous prenez ou contribuez à des décisions importantes ? Si oui, lesquelles par exemple ?

PM (Air France) — Alors, des décisions importantes, oui, surtout sur la priorisation. Par exemple, je peux avoir plusieurs demandes qui arrivent en même temps : une équipe métier qui va demander une nouvelle fonctionnalité pendant qu'une autre va remonter un problème sur une fonctionnalité qui existe déjà. Et donc mon rôle, ça va vraiment être de prendre la décision et de prioriser l'une des deux. Je me retrouve souvent à regarder l'impact de chaque sujet, à faire des analyses de mon côté, et à devoir trancher et prendre la décision. Donc oui, je suis clairement impliquée dans le processus de décision, et surtout dans la manière dont on arrive à cette décision.

ACHIR Charaf — Super, c'est très clair. Dans ce processus de prise de décision, est-ce que vous vous appuyez sur des chiffres, et si oui, est-ce que vous avez des outils pour ça, des tableaux de bord ou autre ?

PM (Air France) — Alors, ça dépend vraiment du sujet. Il m'arrive de regarder des indicateurs d'utilisation d'une fonctionnalité, donc le volume de demandes ou d'incidents, ou encore des données liées à la performance des fonctionnalités — donc là on parle beaucoup de chiffres. Donc oui, ça m'arrive de m'appuyer sur des chiffres. Mais je m'appuie aussi sur des dashboards, des tableaux de bord qui vont m'aider à comprendre le pourquoi derrière certaines données. Et je m'appuie aussi sur des retours utilisateurs, des retours des équipes métiers. Je sais pas si ça répond complètement à votre question, mais c'est vraiment un mélange de chiffres et d'outils de suivi qu'on va utiliser.

ACHIR Charaf — Juste, vous avez parlé de dashboards et de suivi : pouvez-vous me préciser quel outil en particulier vous utilisez ?

PM (Air France) — Alors, ça va peut-être vous paraître un peu à l'ancienne, mais on a beaucoup d'Excel dans mon équipe. En tout cas, nos backlogs produits sont très souvent faits en utilisant Excel. Voilà, c'est le principal outil aujourd'hui qu'on utilise en interne, en tout cas dans mon équipe.

ACHIR Charaf — OK, aucun souci, c'est pas juste à l'ancienne. Ça nous fait un bon tremplin pour la suite. Je vous demandais de penser à une décision importante et récente que vous avez prise en vous appuyant sur des données. Est-ce que vous pouvez me raconter comment ça s'est passé, du début jusqu'à la fin, juste pour avoir une idée un peu high level du processus de prise de décision dans votre poste ?

PM (Air France) — Alors, si je devais penser à un exemple bien particulier, assez représentatif de mon quotidien, je dirais que ce serait justement une décision de priorisation. Il nous arrive, pendant des périodes où on a vraiment un pic de demandes lié à un produit, d'avoir aussi une capacité limitée. Donc forcément, il faut faire des choix. Au départ, certaines demandes peuvent sembler très importantes parce qu'elles sont remontées par des équipes métiers qui ont le savoir nécessaire pour les remonter. Mais concrètement, dans des situations pareilles, plutôt que de nous baser uniquement sur le nombre de demandes et sur le fait que ce soit urgent pour les équipes métiers, on se base en plus sur les données disponibles, et notamment sur les utilisateurs concernés par les fonctionnalités : on compare la fréquence à laquelle elles sont utilisées et quels problèmes réels sont rencontrés sur le terrain. Et donc, on se rend compte qu'une demande qui semblait peut-être moins urgente pour les équipes métiers, finalement, concerne plusieurs utilisateurs, et là il faut revoir la priorisation. Ça m'arrive très souvent de faire ces comparaisons plus profondément, en termes d'impact et de complexité. C'est vraiment très important de pouvoir creuser et revoir l'ordre de priorité de notre backlog, de sortir d'une logique de « qui demande le plus fort » et d'avoir une discussion beaucoup plus objective, qui traduit réellement la réalité du terrain et l'impact réel des demandes.

ACHIR Charaf — OK, merci, c'est très clair. Durant ce processus, à quel moment les chiffres vous ont suffi et à quel moment il a fallu creuser, réfléchir, ou demander à quelqu'un d'autre ?

PM (Air France) — Alors, moi j'ai cette conviction que les chiffres, bien qu'ils soient très importants, même nécessaires à avoir entre les mains pour analyser, comparer... les chiffres vont suffire pour identifier qu'il y a un problème, qu'il y a des choses intéressantes à creuser. Par contre, ces mêmes chiffres ne vont pas suffire pour comprendre la cause derrière. Et ça, c'est mon rôle à moi, c'est mon métier, c'est ma responsabilité de creuser, de ne pas me contenter uniquement des chiffres. Pour être plus concrète : je vois que cette nouvelle fonctionnalité est utilisée par 10 000 personnes le mois dernier et seulement 6 000 ce mois-ci. Je sais qu'il y a une baisse, forcément les chiffres me le disent, mais c'est pas suffisant pour que je comprenne pourquoi, ce qui s'est passé derrière, et l'impact que ça va avoir sur nos activités. Donc j'ai des chiffres qui me permettent de remonter un problème, mais est-ce qu'il y a vraiment un problème technique ? Est-ce que les utilisateurs ont changé leur manière de travailler ? Ce sont des choses que je vais creuser de mon côté et que les chiffres ne vont pas forcément me communiquer.

ACHIR Charaf — Super, c'était très clair. Maintenant, imaginez un outil d'IA qui, au lieu d'afficher des chiffres, vous propose directement une recommandation. Par exemple, il peut vous dire quelque chose

comme : « voici ce que je vous conseille de décider, et voici pourquoi. » Comment vous sentiriez-vous à l'idée de vous appuyer là-dessus pour une décision qui compte ?

PM (Air France) — Ah, ce serait génial d'avoir des recommandations, ça ferait même une grosse partie de mon travail ! Honnêtement, je serais plutôt intéressée, parce que forcément, dans mon métier, on passe beaucoup de temps à analyser les informations avant de prendre une décision. Et quand je dis beaucoup de temps, c'est aussi beaucoup de réunions, beaucoup d'analyses internes, beaucoup d'échanges de mails — « est-ce qu'on peut faire ça ? est-ce qu'on devrait faire ça ? ». Donc s'il y a vraiment une IA qui me dit « j'ai identifié ton problème, voilà les données sur lesquelles je me suis basée, et voilà la recommandation », ça me ferait gagner beaucoup de temps.

ACHIR Charaf — OK, super. Juste pour rebondir : vous avez dit que vous seriez assez ouverte à l'idée d'une IA qui donne des recommandations. Mais est-ce que vous êtes assez confiante à l'égard de ce sujet ? Si oui, qu'est-ce qui vous mettrait en confiance ? Et sinon, qu'est-ce qui vous ferait douter ?

PM (Air France) — Bah, moi quand je dis que ce serait génial, ça veut pas forcément dire que je suivrais la recommandation les yeux fermés. Attention, je pense que sur ce point-là, avec l'IA, il faut être très vigilant. Si l'IA me recommande de déprioriser une fonctionnalité dans ma backlog juste comme ça, parce qu'elle trouve que c'est plus logique, même s'il y a des arguments derrière, moi je vais pas faire ça les yeux fermés. Ça peut sembler logique, mais de mon côté il y aura quand même une certaine réflexion, un certain effort. Donc si elle m'aide à ressortir une recommandation, c'est génial. Mais en tant que PM responsable, je vais forcément garder le rôle de validation et de décision. Donc un outil qui va m'aider, c'est sûr, mais pas un outil de décision, pour le coup.

ACHIR Charaf — OK, super. On a quasiment fini la première partie. Pour la deuxième, j'ai volontairement pas beaucoup parlé du contexte de la recherche, pour ne pas biaiser vos premières réponses. Maintenant, l'idée c'est de vous l'expliquer un peu plus en détail. Aujourd'hui, la plupart des outils décisionnels — ceux que vous utilisez peut-être avec Excel ou d'autres — servent surtout à décrire le passé : des tableaux de bord qui montrent ce qui s'est passé. Ma thèse s'intéresse à la génération suivante, capable non seulement de décrire, mais d'expliquer les causes, d'anticiper et de recommander des décisions. Trois idées reviennent au centre ; c'est trois couches différentes du même système. La première, c'est ce qu'on appelle un modèle du monde, un world model de l'entreprise. Cette idée découle directement des recherches de Yann LeCun, qui sont plutôt centrées sur la physique du monde. Pour lui, tout ce qui se fait aujourd'hui avec les LLM — les modèles de langage à la GPT — et les autres algorithmes de machine learning, c'est bien, ça a de la valeur, mais c'est pas la vraie intelligence. Selon lui, pour franchir un cap, c'est pas les règles qu'on doit définir, mais plutôt le monde physique dans lequel on vit. Par exemple, si on veut apprendre à une voiture à rouler sans chauffeur, aujourd'hui on lui apprend directement les règles de conduite ; alors que selon Yann, il faudrait plutôt modéliser le monde physique et lancer la voiture dedans, et elle apprendrait toute seule à rouler. Un peu comme un bébé apprend à marcher : personne ne lui apprend, c'est juste par l'interaction avec son monde, par essais-erreurs, qu'il y arrive. Ce sont des idées vraisemblablement faisables dans un contexte physique. La physique du monde est beaucoup plus compliquée qu'une simple entreprise, donc si on peut faire ça sur le monde, rien n'empêche de le faire sur une entreprise. Et c'est là que vient l'idée d'un world model d'entreprise : on représenterait comment l'entreprise fonctionne vraiment — ses clients, ses processus, ses règles — et ça permettrait de tester « si je fais ça, qu'est-ce qui se passe ? ». Pour vulgariser, un peu comme dans un jeu : le système sait que si tu augmentes les prix, les ventes peuvent baisser ; que si une usine tombe en panne, certaines commandes seront retardées. Par exemple, le modèle pourrait savoir qu'un client possède un contrat, qu'un contrat dépend d'un produit, que le produit dépend d'un système informatique, qui dépend d'une infrastructure. Mais il essaie aussi de comprendre les conséquences : si cette application tombe pendant 4 heures, quels services seront touchés, quels processus vont ralentir, quel impact financier. En gros, je sais pas si vous avez déjà joué aux Sims, mais un world model, c'est une sorte de SimCity de l'entreprise. Ça, c'est la première brique. La deuxième, c'est l'ontologie. C'est le concept clé derrière des plateformes très puissantes, et on peut voir ça comme une carte partagée : elle relie toutes les données de l'entreprise à ce qu'elles représentent réellement, pour que tout le monde — humain comme système — parle exactement le même langage. Certains la décrivent comme un jumeau numérique de l'entreprise. Prenons une entreprise qui opère, je dis n'importe quoi, dans le BTP : un adhérent possède un contrat, un contrat correspond à un produit, un produit contient des garanties, une demande client déclenche un processus, un processus utilise certaines applications. C'est tout lié, on peut voir ça comme un graphe. L'intérêt principal, c'est d'éviter que chaque système parle son propre langage : une application appelle quelqu'un « client », une autre « adhérent », une autre « assuré » ; l'ontologie dit « attention, ça correspond à tel concept métier, avec telle différence ». Et c'est particulièrement utile avec l'IA : au lieu de donner au LLM une table avec des noms incompréhensibles, on lui donne une couche beaucoup plus proche du métier. Donc l'IA comprend beaucoup mieux ce qu'elle manipule. Et l'ontologie ne définit pas forcément ce qui va arriver — c'est la différence importante avec le modèle. Finalement, la troisième brique, c'est la Decision Intelligence : remettre la décision au centre, plutôt que la donnée. C'est un système qui vous accompagne tout au long du cycle d'une décision, de la question de départ jusqu'à l'apprentissage du résultat. Exemple simple : «

doit-on appeler ce client maintenant ? ». L'approche classique produit un chiffre — « ce client a 72 % de probabilité de partir » —, mais ça reste une prédiction, pas une décision. La Decision Intelligence ajoute : si j'appelle, quelle est la probabilité qu'il reste ? Combien coûte l'appel ? Combien vaut ce client ? À la fin, le système peut recommander : « oui, appeler ce client est probablement la meilleure décision. » Et surtout, après l'action, on regarde ce qui s'est réellement passé, pour améliorer le système. Excusez-moi si j'ai été un peu long, j'essayais d'être bref pour passer à la deuxième partie.

PM (Air France) — Non, c'était intéressant, je comprends. Du coup, là on passe à la deuxième partie, ce sera plus sur le modèle que vous venez d'expliquer, c'est ça ?

ACHIR Charaf — C'est bien ça, oui. Du coup, la prochaine question : cette idée d'une maquette vivante de l'entreprise, un modèle qui simule les conséquences d'une décision avant de la prendre — qu'est-ce que cela vous évoque ?

PM (Air France) — Alors, ça m'évoque beaucoup de choses. Ça m'évoque le concept de digital twin — après, peut-être que je me trompe et que c'est pas vraiment l'idée que vous voulez.

ACHIR Charaf — C'est bien ça, c'est exactement ça, c'est une partie de la réponse.

PM (Air France) — Oui, cette conception virtuelle de l'entreprise, comme vous l'avez dit, un peu comme le jeu des Sims de l'entreprise si j'ai bien compris. Ce côté représentation virtuelle avec la décision, le combo, je trouve ça bien pensé. Après, c'est sûr que derrière c'est beaucoup plus complexe : dans l'entreprise et dans les équipes, je prends l'exemple de la variable humaine, c'est quelque chose de très complexe à maîtriser, à prendre en compte. Mais peut-être que finalement je me trompe, et que l'IA pourrait bien maîtriser ce genre de choses. Même en termes de capacité des équipes : est-ce qu'en termes de prédiction elle serait capable de donner des résultats fiables en prenant en compte toutes ces variables ? Mais à premier abord, je trouve ça intéressant. Dans mon cas de PM, ça voudrait dire que je passe d'une logique où je construis une fonctionnalité puis je mesure son impact — ce qu'on fait aujourd'hui — à une logique où je pourrais simuler en amont les conséquences de ma décision sur l'ensemble de l'entreprise, pas que sur mon équipe.

ACHIR Charaf — Exactement, vous avez tout compris. Sur l'ensemble de l'entreprise, et en tenant compte du monde extérieur aussi.

PM (Air France) — Oui, oui, clairement.

ACHIR Charaf — Super. Donc dans votre métier, imaginons que ce système existe : cette capacité à tester le scénario « et si » avant de décider, ça changerait quoi pour vous ?

PM (Air France) — Bah, ça changerait beaucoup de choses. Notamment, ça m'aiderait à mieux prioriser les initiatives — je sais que je parle beaucoup de priorisation, mais c'est vraiment un challenge très important dans mon métier, je fais quasiment que ça. Prioriser les initiatives, avoir une idée sur cette priorisation, la communiquer... ça m'aiderait aussi à anticiper les impacts. Et ça, c'est très important, parce qu'aujourd'hui on n'arrive pas forcément à mesurer les conséquences de la priorisation qu'on fait. Ça aura aussi un impact sur les équipes, sur tous les processus de mon métier de product manager.

ACHIR Charaf — OK. Maintenant, imaginez un système qui ne vous donne pas juste des chiffres, mais qui vous accompagne sur la décision : les questions, les options recommandées, et qui apprend du résultat. Ça vous semble utile ou plutôt inquiétant, et pourquoi ?

PM (Air France) — Bah c'est sûr que c'est utile. Si tu me donnes un système pareil et qu'il est vraiment un copilote de décision, c'est forcément quelque chose d'extrêmement intéressant, qui va me permettre de simuler différents scénarios, de m'expliquer pourquoi, et de prendre des décisions plus rapidement. Bien sûr que c'est utile. L'inquiétude, elle n'a de sens que si finalement je prenais à la lettre ce que ce système va me proposer. Pour moi, le système va m'éclairer, il va peut-être me challenger sur des hypothèses que j'ai déjà, mais je ne peux pas dire que cela m'inquiéterait si la décision finale reste mienne. Donc tant que c'est du copilote, pas d'inquiétude. Après, je peux comprendre en quoi ça peut être inquiétant : là tu me parles d'un concept très global, qui prendrait en considération tous les moindres détails de l'entreprise. Et ça peut être inquiétant, parce qu'il y a des choses très complexes, difficiles à intégrer dans l'IA. La capacité de mes équipes n'est pas stable, elle va changer, et ce n'est pas quelque chose que je peux prédire facilement. La décision de dernière minute d'un partenaire qui change d'avis, ça non plus je ne peux pas le prédire. Donc il y a cet aspect de fausse précision qui peut fausser les hypothèses, fausser les prédictions, et sur lequel il faut rester vigilant. Et aussi, si je peux me permettre, dans votre concept de world model, il y a un aspect de confidentialité important : un tel système aura potentiellement accès à énormément de données sensibles. Par exemple, chez nous, il y a des données clients qu'on ne peut pas communiquer, qu'on ne peut pas se permettre d'injecter dans le système. Et donc forcément ça va fausser les résultats, parce qu'un système qui n'a pas ces données clients importantes... les recommandations qu'il va me donner, je ne serai pas satisfaite, parce que ce sont des données que moi seule j'ai et que je n'ai pas communiquées, pour des raisons de confidentialité. Donc le concept est intéressant, mais il y a des points de vigilance ; après c'est normal, c'est de l'IA, et avec toute IA il faut savoir être vigilant et avoir une autorité derrière qui décide.

ACHIR Charaf — OK, merci. Ça nous permet de passer à la toute dernière partie, plutôt sur les conditions, la confiance et l'éthique. Pour que ce genre de système marche vraiment dans votre organisation, qu'est-ce qu'il faudrait réunir — côté données, culture, organisation — pour qu'il soit accepté par vos équipes ? Et à votre avis, vos collègues, voire vos supérieurs qui ont des décisions importantes à prendre, comment réagiraient-ils, en partant du postulat qu'il marche et qu'il est très performant ?

PM (Air France) — Alors, pour un système aussi puissant, aussi performant, je pense qu'il doit y avoir derrière — et c'est quelque chose qu'on valorise énormément chez Air France — une vraie gouvernance : qui peut lancer ce genre de simulation, qui peut manipuler ce système, quelles données. Il faut être très transparent, très précis sur quelles données vont être utilisées. Il faut aussi être très clair sur la frontière, et jusqu'à quel point les décisions peuvent être automatisées. Ça, c'est très important. Aujourd'hui, on aime beaucoup automatiser — on a beaucoup de process automatisés chez Air France parce que ça nous fait gagner du temps —, mais il y a quand même une frontière à ne pas dépasser. Et aussi la notion de responsabilité en cas d'erreur, en cas de mauvais fonctionnement : il faut vraiment être transparent là-dessus. Donc c'est vraiment quel type de gouvernance on veut pour ce genre de système, et je pense que c'est le rôle du comité intelligence artificielle de l'entreprise de s'en charger. Ce sont des questions importantes, en termes de manipulation des données et de culture d'entreprise.

ACHIR Charaf — Merci. Maintenant, dans le même monde où il est performant, tout va bien : dans quelle mesure pouvez-vous faire confiance aux recommandations ou aux simulations de ce système si je vous dis qu'elles ne sont pas explicables ? Le système sort des recommandations, des décisions à prendre ou à ne pas prendre, mais vous avez peu de visibilité sur comment l'IA a pris cette décision. Est-ce que c'est acceptable ou pas, sachant qu'il se trompe très peu, mais qu'on ne sait pas comment il marche — c'est une sorte de boîte noire ?

PM (Air France) — Donc tu es en train de me dire qu'avec ce système, il y a quand même une marge, que le système peut se tromper ?

ACHIR Charaf — Il peut se tromper, certes, mais ma question n'est pas par rapport à ça : on part dans un monde où il n'y a pas de système qui ne se trompe pas — même les humains se trompent. L'idée, c'est : le système se trompe très peu, disons qu'il a raison 90 % du temps, mais on ne peut jamais expliquer la décision qu'il recommande. On sait que ses décisions sont souvent vraies, mais on ne peut pas remonter à comment il l'a prise. C'est quoi votre ressenti, et est-ce que vous continueriez à lui faire confiance ?

PM (Air France) — Bah je pense que « confiance », c'est un grand mot, surtout que les décisions qu'on prend aujourd'hui ne sont pas à prendre à la légère : ce sont des décisions coûteuses, qui impactent notre budget, nos revenus, souvent difficiles à inverser, donc critiques pour l'entreprise. Donc je ne laisserai pas la performance seule de mon système justifier la confiance que je vais lui accorder. Je continuerais de me baser sur ses recommandations, de l'utiliser pour avoir une idée, et voir si elles sont similaires à celles que j'ai de mon côté ; mais je ne pense pas que mon niveau de confiance sera très élevé. Derrière, il y aura quand même de mon côté — et ça c'est certain — la possibilité de revoir la décision prise par le système, de contester la recommandation s'il le faut. C'est vrai que ça va peut-être, au lieu d'avoir 10 000 réunions autour d'une même décision, m'en faire beaucoup moins. Mais finalement, si le modèle reste une boîte noire, je peux garder une certaine confiance, mais pas complète ni totale, ça c'est sûr.

ACHIR Charaf — OK. Tout à l'heure, avant que je vous explique tout ça, vous étiez assez ouverte à l'idée, mais quand même avec des pincettes. Maintenant que vous voyez un peu plus — toute cette histoire de world model, d'ontologie et de Decision Intelligence — est-ce que votre ressenti a changé ?

PM (Air France) — Est-ce qu'il a réellement changé ? Pas vraiment, je dirais. Pour moi, l'IA, ça reste de l'IA — et peut-être que c'est une mentalité à revoir. C'est plus une question de potentiel : j'ai découvert un nouveau potentiel de l'IA, qui est intéressant. Et peut-être qu'en étant confrontée, en pouvant bénéficier de ce world model, mon ressenti pourra évoluer. Je pense vraiment que ce concept répond à une réelle difficulté de mon métier, à une grosse partie de la prise de décision, qui est une grosse partie de mon métier. Donc ça me permet de découvrir le potentiel que ça peut avoir et la puissance du système qu'on peut bâtir autour. Mais en termes de confiance, et de tout ce que je pense sur les limites et la responsabilité de l'humain derrière, je garde toujours la même idée.

ACHIR Charaf — Super. Juste une toute dernière question, plus éthique. Avant de répondre, sachez qu'il n'y a pas de bonne ou de mauvaise réponse. Si un tel système menait à une décision gravement erronée — par exemple de grosses pertes d'argent, et vu que vous travaillez chez Air France, on peut imaginer des scénarios beaucoup plus dramatiques —, à votre avis, qui devrait en être tenu responsable ?

PM (Air France) — Eh ben, l'humain.

ACHIR Charaf — Oui, mais quel humain ? Celui qui est intervenu dans quelle partie de la boucle de décision prise avec cet outil ?

PM (Air France) — Bah moi, personnellement, je distinguerais plusieurs niveaux de responsabilité. Déjà, la personne qui a validé la décision finale : parce que derrière tout le fonctionnement de l'IA et du système, c'est une personne qui a donné le dernier OK, qui a validé la décision finale, que ce soit moi en tant que PM

ou un autre décideur de l'entreprise. Là, il y a une part importante de responsabilité. Ensuite, je pense aussi à l'équipe qui a conçu le système : si on arrive à prouver que l'erreur ne vient pas de la décision finale du décideur, mais d'un modèle mal conçu — des tests qui ont foiré, des données inadéquates, ou des limites mal communiquées —, alors l'équipe qui a conçu et pensé le système a aussi sa part de responsabilité. Et plus globalement, il y a la part de l'entreprise, parce que c'est elle qui a la responsabilité de la gouvernance du système, donc du world model. Donc elle doit être tenue responsable aussi. Finalement, il y a beaucoup de responsables derrière.

ACHIR Charaf — Super, c'était la toute dernière question. Y a-t-il quelque chose d'important qu'on n'a pas abordé et que vous aimeriez ajouter ?

PM (Air France) — Pas de ma part. Je trouve que c'est intéressant, et ce serait génial d'avoir un outil pareil en entreprise. Moi je serais curieuse de tester.

ACHIR Charaf — Super, eh bien merci beaucoup pour votre temps et pour vos réponses.

E.9 Entretien M4. Ingénieur calcul et QSSE, sidérurgie (ArcelorMittal)

Entreprise : ArcelorMittal

Poste du répondant : Ingénieur calcul (simulation numérique)

Secteur : Industrie — sidérurgie / composants automobiles

Langue : Français

Format : Entretien à distance (~24 min) — conduit par ACHIR Charaf

ACHIR Charaf — Bonsoir, merci beaucoup d'avoir accepté cet entretien. Deux mots sur le cadre : je suis actuellement en train de faire une recherche de thèse sur la façon dont les entreprises prennent leurs décisions à partir de leurs données, et sur la place que l'IA pourrait y prendre. Ça va durer une vingtaine à une trentaine de minutes. Il n'y a aucune bonne ou mauvaise réponse, et surtout pas besoin d'être spécialiste, c'est vraiment votre expérience qui m'intéresse. Tout restera anonyme. Avec votre accord, j'aimerais enregistrer uniquement pour la retranscription, rien n'est partagé. Vous pouvez bien sûr m'interrompre, passer une question ou arrêter quand vous voulez. C'est bon pour vous, et vous me donnez votre accord pour que cet échange soit enregistré ?

Ingénieur calcul (ArcelorMittal) — Oui, tout à fait d'accord, pas de souci.

ACHIR Charaf — Parfait, alors on commence. Pour commencer, première question : pouvez-vous me décrire votre poste et en quoi consiste votre travail au quotidien ?

Ingénieur calcul (ArcelorMittal) — D'accord. Donc je vais faire une petite description de mon poste. Je suis ingénieur calcul, et en même temps il n'y a pas que le volet calcul, on va dire simulation numérique : il y a aussi un volet management de projet. On essaie de suivre la chaîne de notre produit, qui est de la simulation numérique. En fait, ce n'est pas qu'une question de calcul lourd numérique sur des PC, c'est aussi une question d'avoir les bonnes entrées, les bons datasets, de travailler sur de bons modèles géométriques. Donc ça allie un côté technique lourd, physique, et un côté managérial où on doit jalonner notre projet et gérer les choses pour assurer que nos clients sont satisfaits — on ne cherche pas à être seulement efficace, mais aussi efficient.

ACHIR Charaf — Parfait, merci, c'est intéressant. Et est-ce que vous prenez ou vous contribuez à des décisions importantes ? Lesquelles par exemple ?

Ingénieur calcul (ArcelorMittal) — Oui, effectivement. Je travaille sur le développement des véhicules, plus spécifiquement dans le développement des roues des véhicules. La décision importante, c'est le fait de valider le bon fonctionnement aérodynamique des roues. On s'assure, avant qu'elles soient lancées en production, en manufacture, d'avoir des roues qui sont bonnes et adaptées aux différentes conditions de conduite. Et pour faire cela, au lieu de construire le modèle et d'avoir la roue déjà prête, on va faire un modèle numérique, pour éviter de perdre du temps et de l'argent. Si nous ne prenons pas la bonne décision d'avoir des roues qui se comportent bien au contact de l'air, on va voir des véhicules qui consomment plus de carburant, qui n'ont pas la performance souhaitée par nos clients finaux, et cela va générer des pertes colossales. Donc mon équipe et moi, on travaille sur une étape très importante ; sans elle, on se retrouve avec une perte de temps, d'argent, et aussi de confiance client.

ACHIR Charaf — Je vois. Et du coup, est-ce que vous vous appuyez sur des chiffres, des tableaux de bord ou d'autres outils pour cette étape de décision ?

Ingénieur calcul (ArcelorMittal) — Oui, effectivement. On se base sur des datasets, sur des fichiers — ça peut être des fichiers Excel, des fichiers CSV. On a aussi des tableaux de bord, un suivi du développement des roues par exemple. Donc on a un panel d'outils, et on se base énormément sur les chiffres.

ACHIR Charaf — Et est-ce que vous pensez que ces chiffres vous suffisent ? À quel moment il faut creuser ? Est-ce qu'il y a une réflexion de votre part, est-ce que vous demandez à d'autres personnes ? Est-ce que ces chiffres sont suffisants pour bâtir votre décision ?

Ingénieur calcul (ArcelorMittal) — Non, en effet, ils ne sont pas suffisants, tout simplement parce qu'on a des limites, nos machines ont des limites, et la machine peut se tromper. On se retrouve dans des situations où il faut consulter d'autres personnes ; on a aussi des consultants, des ingénieurs spécialistes en full physique. On essaie parfois de se détacher de la machine et de voir si notre machine génère des résultats corrects. Effectivement, on a besoin de consulter un tas de personnes, parfois aussi des prestataires, lorsqu'on se retrouve bloqués. Donc non, on ne peut pas se fier à 1000 % aux chiffres.

ACHIR Charaf — Alors maintenant, j'aimerais que vous imaginiez un outil d'intelligence artificielle qui, au lieu d'afficher des chiffres, vous proposerait directement une recommandation. Cet outil vous dirait « voilà ce que je vous conseille de décider, et voilà pourquoi ». Comment vous sentiriez-vous à l'idée de vous appuyer là-dessus pour une décision qui compte ?

Ingénieur calcul (ArcelorMittal) — D'accord. En fait, je pourrais faire confiance à cet outil, tant que je sais de quoi il est alimenté. J'aimerais bien avoir une idée de : est-ce que je peux faire confiance à l'outil ? Je ne sais pas comment formuler ma réflexion, mais je ne veux pas me précipiter et prendre aveuglément ce que l'outil me produit. Je veux savoir comment il fonctionne et sur quoi il est basé. Parce que, dans mon métier, on sait que même avec tous les paramètres corrects, on peut se retrouver avec des résultats biaisés.

ACHIR Charaf — Exactement. Et vous, qu'est-ce qui vous mettrait en confiance en utilisant cet outil ?

Ingénieur calcul (ArcelorMittal) — Ce qui me mettrait en confiance, c'est d'abord avoir une idée du fonctionnement de l'outil en lui-même. Avoir une charte de transparence de la part du constructeur, du développeur, de la personne qui a conçu le logiciel. Avoir une idée sur comment ce logiciel se comporte, comment il traite les données, est-ce qu'il est hébergé localement, est-ce que nos données ne vont pas se retrouver quelque part en Inde, en Chine, ou dans un serveur aux États-Unis. On veut vraiment se retrouver dans une optique de transparence, et comprendre comment ce logiciel raisonne. Parce que, certes, nous, on manipule des logiciels de simulation, on ne fait pas confiance aveuglément, mais on sait comment ils fonctionnent. Donc j'aimerais bien faire confiance à cet outil en sachant comment il fonctionne et comment il raisonne.

ACHIR Charaf — Merci, c'est très clair. Je vais maintenant vous expliquer en deux minutes le cœur de ma recherche, puis j'aimerais recueillir vos réactions. Aujourd'hui, la plupart des outils décisionnels — ce qu'on appelle la Business Intelligence — servent surtout à décrire le passé : ce sont des tableaux de bord qui montrent ce qui s'est passé. Ma thèse s'intéresse beaucoup plus à la génération suivante de Business Intelligence, capable non seulement de décrire, mais d'expliquer les causes, d'anticiper et de recommander des décisions. Trois idées reviennent au centre. La première, c'est ce qu'on appelle un modèle du monde de l'entreprise : une sorte de maquette vivante, un peu comme un simulateur de vol, mais pour l'organisation. Cette simulation représenterait comment l'entreprise fonctionne vraiment, ses clients, ses processus, ses règles, et permettrait de tester « si je fais ça, qu'est-ce qui se passe ? ». Ensuite, la deuxième, c'est l'ontologie, qu'on peut voir comme une carte partagée : c'est ce qui relie toutes les données de l'entreprise à ce qu'elles représentent réellement, pour que tout le monde — humain comme système d'IA — parle exactement le même langage. C'est ce qu'on décrit aussi comme un jumeau numérique de l'organisation.

Ingénieur calcul (ArcelorMittal) — Ouais, ça, on travaille déjà dessus, en fait. Très intéressant.

ACHIR Charaf — Ah, d'accord, c'est intéressant. Et la troisième couche, c'est la Decision Intelligence : l'idée de remettre la décision au centre plutôt que la donnée. C'est un système qui vous accompagne sur tout le cycle d'une décision, de la question de départ jusqu'à l'apprentissage tiré du résultat. Donc l'idée, c'est de pouvoir avoir un world model, tout un concept qui va accompagner l'utilisateur du début jusqu'à la prise de décision, en prenant en compte tout un écosystème de données de l'entreprise, tout ce qui fonctionne dans l'entreprise, les processus, les règles. C'est ce qui permettrait d'avoir un système beaucoup plus poussé qu'une IA qui me recommande des choses ou qui m'assiste sur des tâches simples. Donc j'aimerais avoir vos réactions. Cette idée d'une maquette vivante de l'entreprise, un modèle qui simule les conséquences d'une décision avant de la prendre, qu'est-ce que cela vous évoque ?

Ingénieur calcul (ArcelorMittal) — Bah, en fait, comme j'ai dit pour la question du jumeau numérique, on travaille déjà sur ça, on en a quelques-uns chez nous, et franchement, personnellement, c'est la première fois que je me détache — parce que pour moi, le jumeau numérique était toujours lié à un élément physique, la roue d'une voiture par exemple, ou le moteur. Mais là, pour la première fois, je me suis dit « ah, en fait, l'idée peut être développée sur une échelle un peu plus grande ». J'ai entendu parler de jumeaux numériques sur des sections d'usine, surtout que je suis dans le domaine industriel. Mais là, pour la première fois, je vois les choses d'une façon un peu macro : on peut appliquer ça, par les mêmes équations, la même idée, d'une façon macro. Donc oui, en fait, ça connecte avec moi, et je suis très curieux d'en comprendre plus.

ACHIR Charaf — Et cette capacité à tester des scénarios avant de décider, ça changerait quoi pour vous dans votre métier ? Est-ce que vous pensez que ce concept changerait votre métier, dans un sens positif, avantageux ?

Ingénieur calcul (ArcelorMittal) — Bah oui, absolument, avec du recul. Je pense qu'on est confrontés à beaucoup de pressions côté planning : on a beaucoup de jalons à respecter, des cahiers des charges, des normes européennes, des clients partout dans le monde, des prestataires. On a une chaîne un peu impressionnante, et parfois on a même un effet cascade : si on ne satisfait pas une personne ici, on peut se retrouver avec 15 jalons bloqués. C'est vrai qu'avoir une idée de l'interconnexion entre nous, nos prestataires et même l'entreprise en interne, ça serait très pertinent. Au contraire, ça nous permettrait de faire un gain significatif, notamment dans la prise de décision, parce que parfois on se retrouve avec des questions, surtout avec le contexte géopolitique, avec certains blocages, et on se dit « comment on aurait pu juste avoir une idée, avoir du recul, avoir un peu de prémonition concernant ça ». C'est vrai que ça nous aiderait énormément.

ACHIR Charaf — Donc cela pourrait vous être utile. Est-ce que vous arrivez à voir des inquiétudes, des choses qui vous freineraient par rapport à ce système ? Là, on a parlé du côté positif, mais est-ce que vous voyez déjà des points à prendre avec des pincettes ?

Ingénieur calcul (ArcelorMittal) — Oui, dans le sens où ces logiciels, ces systèmes... à quel moment ça s'effondre, en fait ? À quel moment on sollicitera notre système et il sera hors service, et il va nous poser un lapin, et on va se retrouver dans une situation hyper gênante avec nos prestataires, nos clients, nos fournisseurs ? Donc la question qu'on se pose : ces systèmes, certes, ils sont performants, ils résolvent des problèmes que 50 personnes ne pourraient pas résoudre dans une seule salle de réunion, mais on se pose aussi la question du coût côté maintenance. On achète le logiciel, on achète la prestation, mais ça coûte combien ? Comment c'est maintenu ? Comment on garde la pertinence du système ? Moi, personnellement, en tant que personne en industrie, je vois les choses comme ça : on a le logiciel, c'est bon, c'est neuf, c'est beau, c'est séduisant, mais ça coûte quoi pour le maintenir, et pour garantir une pertinence ? Est-ce qu'avec le temps il sera moins pertinent, plutôt biaisé ? Donc je m'intéresse plutôt à cet aspect-là, parce que ça coûte de l'argent.

ACHIR Charaf — En effet. Alors, pour que ce genre de système marche vraiment dans votre entreprise, à votre avis, qu'est-ce qu'il faudrait réunir côté données, côté culture, côté organisation ? Est-ce qu'il y a des conditions précises pour que l'adoption soit faite de la bonne manière ?

Ingénieur calcul (ArcelorMittal) — Déjà, dans un premier lieu, je pense qu'il est important de souligner la résistance au changement, le facteur humain. Il y aurait plusieurs personnes dans l'organisation réticentes à l'implémentation d'un système tel que le vôtre : les gens ne vont pas faire confiance directement au système, une partie n'aura pas confiance, et une partie aura peur du système en lui-même. On se pose des questions, parce que ce système va mettre en péril une partie du personnel, côté carrière, côté évolution, ou même leur présence dans l'entreprise. Est-ce qu'il y aurait un plan social ? Donc une partie des gens aura des inquiétudes. Et il y aurait des gens qui vont profiter de la présence de ce système pour faire du présentéisme — il y a de l'absentéisme, il y a du présentéisme : on est là, mais on n'est pas là. C'est une question très compliquée à naviguer. Un autre élément, c'est le budget. C'est un logiciel sympa, magnifique, qui va résoudre tous les problèmes, mais est-ce que ça ne coûte pas beaucoup d'argent ? Là, on parle de tokens, on parle de chaque sollicitation, chaque petit message qu'on envoie à ChatGPT, à Claude, à toutes ces IA : ça coûte de l'argent. Parfois, on se pose la question : est-ce qu'avoir cinq ingénieurs qui vont simuler même 10 % du système ne serait pas plus économique que le système lui-même, notamment avec les coûts de maintenance et le coût énergétique. On a aussi des engagements environnementaux, on a un service QSSE qu'il faut consulter, parce qu'il y a une empreinte carbone. Il faut garder nos certifications, notre vision environnementale, surtout qu'on est une boîte qui met ça en avant, et ça va peser lourd sur notre empreinte carbone — surtout quand on vend des véhicules et qu'on vise la neutralité carbone : est-ce qu'on est sincère avec nos clients ?

ACHIR Charaf — En effet, merci, c'est très clair. J'ai une question qui relève de l'éthique. Si un tel système menait à une décision gravement erronée, qui devrait en être tenu responsable selon vous ?

Ingénieur calcul (ArcelorMittal) — Je pense que ce qui est compliqué dans cette question, c'est déjà : est-ce que le système a un statut juridique spécifique ? Le problème, je pense qu'il est plus grand que notre boîte. Est-ce que, de nos jours, les tribunaux, que ce soit en France ou aux États-Unis, considèrent que l'IA en elle-même a un statut juridique ? Est-ce qu'on est face à des systèmes qu'on peut tenir coupables s'ils sont responsables de faits qui peuvent littéralement tuer des milliers de personnes ? Donc c'est la première question à se poser ; je dois faire des recherches, me renseigner, je n'ai aucune idée. Aussi, à mon avis, les personnes responsables, ce sont toutes les personnes qui ont accepté, dans le top management, d'incorporer, d'implémenter ce système. Parce que sous réserve de quoi ? C'est vrai que c'est une question un peu sensible.

ACHIR Charaf — Et pour vous, une décision doit-elle toujours pouvoir s'expliquer pour être acceptable ? C'est-à-dire, si j'ai la recommandation mais pas les arguments derrière, pas d'explication, est-ce que cela peut faire de cette décision une décision acceptable ? Dans quelle mesure allez-vous l'accepter ?

Ingénieur calcul (ArcelorMittal) — En fait, ça dépend de l'exigence. Je vais donner un exemple avec le médecin : il y a des gens qui vont consulter un spécialiste ou leur médecin traitant, et qui seront intéressés de comprendre pourquoi on leur a prescrit tel médicament, quelle est la molécule, etc. ; et il y a des gens qui vont tout simplement prendre l'ordonnance et partir à la pharmacie, et ça s'arrête là. Donc je pense que ça dépend de la criticité de l'activité de l'entreprise. Il y a des entreprises où ça ne plaisante pas, où une simple erreur peut mener à la mort de milliers de personnes, littéralement.

ACHIR Charaf — Et j'imagine que c'est le cas pour votre métier ?

Ingénieur calcul (ArcelorMittal) — Oui, effectivement. Je peux donner un simple exemple. Je ne sais pas si vous avez une idée du scandale Takata : une entreprise qui a vendu des airbags défectueux, des milliers, même des millions d'airbags défectueux dans le monde entier, avec des rappels partout, même en France. Donc une entreprise développe des airbags, et les airbags peuvent causer la mort de milliers de personnes. Il faut vraiment être pointu et vérifier les choses. Moi, personnellement, je ne ferai jamais, jamais confiance à une décision générée par l'IA sans voir son raisonnement, comment il a fonctionné, comment il a pu générer ça. Donc c'est une question de criticité, et aussi de budget : quand on a beaucoup d'argent, on peut se permettre des erreurs, on peut pardonner ; mais quand les budgets sont serrés, notamment en industrie automobile, on n'a pas le droit à l'erreur.

ACHIR Charaf — Oui, je comprends. Alors, on arrive à la fin, c'était très intéressant comme échange, je vous remercie pour votre temps. Y a-t-il quelque chose d'important qu'on n'a pas abordé et que vous aimeriez ajouter ?

Ingénieur calcul (ArcelorMittal) — Non, je pense que la façon dont vous avez mené l'entretien était plutôt exhaustive. Non, c'est clair. Au contraire, je suis plutôt curieux de connaître encore plus de choses concernant cet outil, c'est très intéressant. Voilà, je pense que c'est clair, et ça s'arrête là.

ACHIR Charaf — Parfait, je vous remercie, et au revoir.

Ingénieur calcul (ArcelorMittal) — Je vous en prie, au revoir. Merci beaucoup.